



Defensie Ondersteuningscommando
Ministerie van Defensie

Statistiek: college 10

De chikwadraatverdeling

DOSCO

Dr. ir. Danny Blom

Nederlandse Defensie Academie

Faculteit Militaire Wetenschappen

juli 2025



Terugblik

- Punt- en intervalschatters
- Betrouwbaarheid- en voorspellingsintervallen
- De methode van hypothesetoetsen
- Hypothesetoetsen voor het gemiddelde van de normale verdeling



Leerdoelen


Aan het eind van dit college kunnen studenten:

- De eigenschappen van de chikwadraatverdeling benoemen en uitleggen
- De verschillende situaties kunnen benoemen waarin de chikwadraatverdeling een rol speelt.
- Met behulp van de chikwadraatverdeling een toets van onafhankelijkheid tussen twee nominale variabelen uitvoeren.
- De chikwadraatverdeling gebruiken om een aanpassingstoets voor discrete kansverdelingen (goodness-of-fit test) uit te voeren.



Recap: de standaardnormale verdeling $Z \sim N(0,1)$

- Gemiddelde $\mu = 0$ en standaardafwijking $\sigma = 1$
- Symmetrisch rond $x = 0$
- Belkromme
- Standaardisatie van normale verdeling

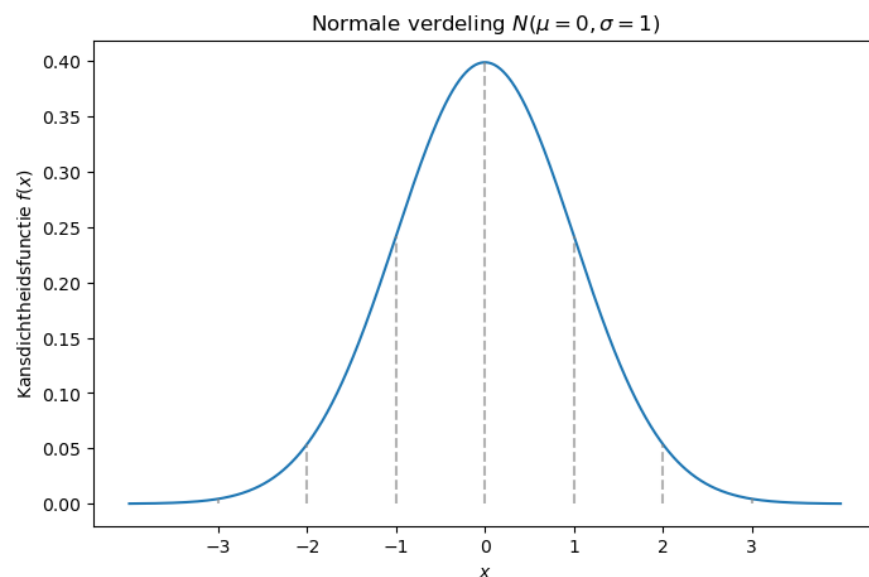




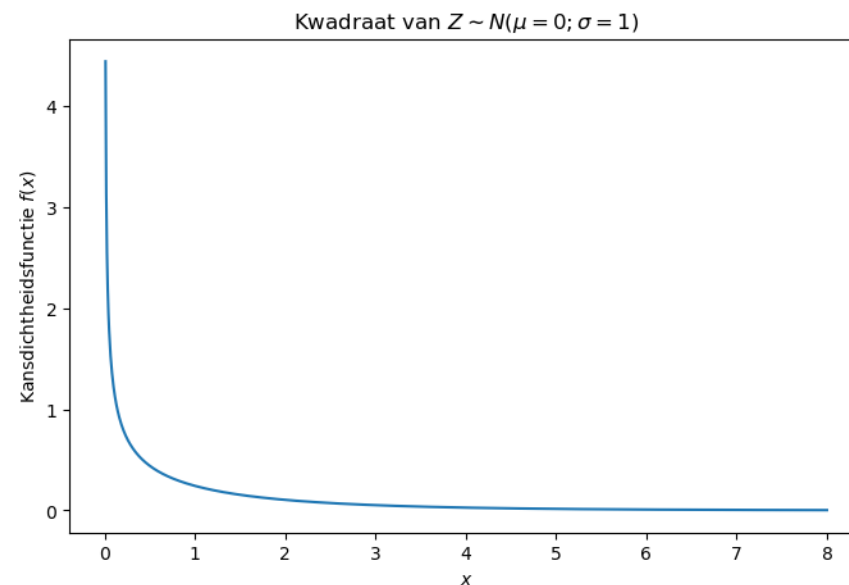
Wat kunnen we zeggen over het kwadraat Z^2 van $Z \sim N(0,1)$?

- $Z^2 \geq 0$: waarden zijn niet-negatief
- Niet meer symmetrisch
- Bouwsteen voor de chikwadraatverdeling

Kansdichtheidsfunctie van Z



Kansdichtheidsfunctie van Z^2





De chikwadraatverdeling

De **chikwadraatverdeling** is een continue kansverdeling die hoort bij de som van n kwadraten van standaardnormaal verdeelde kansvariabelen:

$$X = Z_1^2 + Z_2^2 + \cdots + Z_n^2 \sim \chi_n^2$$

Eigenschappen:

- We noemen het getal n ook wel het aantal **vrijheidsgraden** van de chikwadraatverdeling
- $E[X] = n$
- $\text{Var}(X) = 2n$

Merk op: de formule voor de (steekproef)variantie bevat ook een som van kwadraten!



De chikwadraatverdeling

interactive-chisq.streamlit.app



Toepassing 1: chikwadraattoets voor onafhankelijkheid

Stel dat we willen onderzoeken onder de gewonde soldaten tijdens een oorlogsmissie of het type verwonding samenhangt met hun taak tijdens de missie.

- Interactie tussen twee **categorische** variabelen, oftewel **nominaal** of **ordinaal**

Vraag: zijn deze twee variabelen (type verwonding / taakstelling) onafhankelijk van elkaar?



Stap 1: formuleer de nulhypothese H_0 en alternatieve hypothese H_1

Nulhypothese:

H_0 : de variabelen “type verwonding” en “taakstelling” zijn onafhankelijke variabelen.

Alternatieve hypothese:

H_1 : de variabelen “type verwonding” en “taakstelling” zijn afhankelijke variabelen.



Stap 2: bepaal de kans α op een type-I fout

We kunnen zelf een kans α op een type-I fout kiezen

- Hoeveel risico wil je nemen om H_0 (onafhankelijkheid van de twee variabelen) onterecht te verwerpen?

Kans α op een type-I fout: $\alpha = 0,05$

- Indien de twee variabelen onafhankelijk zijn (H_0 is waar), zal deze in 95% van alle steekproefresultaten ook daadwerkelijk worden aangenomen.



Stap 3: verzamelen van data

Stel dat gedurende een jaar tijdens verschillende missies deze aantal worden geregistreerd:

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	12	18	30	60
	Romp	8	22	20	50
	Ledematen	10	10	20	40
	Totaal	30	50	70	150



Stap 4: bepalen van de toetsingsgrootte χ^2

Om te toetsen of het type verwonding onafhankelijk is van de taak die wordt uitgevoerd, moeten we de verzamelde data vergelijken met de verwachte uitkomsten.

Wat voor uitkomsten verwachten we bij onafhankelijkheid?

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd				60
	Romp				50
	Ledematen				40
Totaal		30	50	70	150



Stap 4: bepalen van de toetsingsgrootte χ^2

Wat voor uitkomsten verwachten we bij onafhankelijkheid?

- Per type verwonding is het aantal gewonden ook evenredig verdeeld (verhouding 30 : 50 : 70)
- Algemeen: de **verwachte frequentie** is $E_{ij} = \frac{\text{rijtotaal}_i \cdot \text{kolomtotaal}_j}{\text{totaal}}$

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	$\frac{30 \cdot 60}{150} = 12$	$\frac{50 \cdot 60}{150} = 20$	$\frac{70 \cdot 60}{150} = 28$	60
	Romp	$\frac{30 \cdot 50}{150} = 10$	$\frac{50 \cdot 50}{150} = 16,66$	$\frac{70 \cdot 50}{150} = 23,33$	50
	Ledematen	$\frac{30 \cdot 40}{150} = 8$	$\frac{50 \cdot 40}{150} = 13,33$	$\frac{70 \cdot 40}{150} = 18,67$	40
Totaal		30	50	70	150



Stap 4: bepalen van de toetsingsgrootheid X^2

Geobserveerde frequenties uit data (“observed”)

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	12	18	30	60
	Romp	8	22	20	50
	Ledematen	10	10	20	40
	Totaal	30	50	70	150

Verwachte frequenties (“expected”)

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	12	20	28	60
	Romp	10	16,6666	23,3333	50
	Ledematen	8	13,3333	18,6666	40
	Totaal	30	50	70	150

Toetsingsgrootheid:
$$X^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2(df)$$

- O_{ij} (E_{ij}): geobserveerde (verwachte) aantallen voor rij i , kolom j
- $df = (\#rijen - 1) \cdot (\#kolommen - 1) = (3 - 1) \cdot (3 - 1) = 4$ vrijheidsgraden



Stap 4: bepalen van de toetsingsgrootte χ^2

Geobserveerde frequenties uit data (“observed”)

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	12	18	30	60
	Romp	8	22	20	50
	Ledematen	10	10	20	40
Totaal		30	50	70	150

Verwachte frequenties (“expected”)

		Taakstelling			
		Patrouille	Mijnruiming	Logistiek	Totaal
Type verwonding	Hoofd	12	20	28	60
	Romp	10	16,6666	23,3333	50
	Ledematen	8	13,3333	18,6666	40
Totaal		30	50	70	150

De **geobserveerde toetsingsgrootte** χ^2 is dan gelijk aan

$$\chi^2 = \frac{(12 - 12)^2}{12} + \frac{(18 - 20)^2}{20} + \dots + \frac{(20 - 18,6666)^2}{18,6666} \approx 4,3543$$




Stap 5: geef een conclusie en formuleer in de originele context

Methode 1 (kritiek gebied): het **kritieke gebied** wordt gegeven door $[g, \infty)$, waarbij de grens g de oplossing is van $\chi^2 \text{cdf}(a = X; b = 10^{99}; df = 4) = \alpha = 0,05$

Met de solver optie krijgen we $g = 9,4877$

→ $\chi^2 \approx 4,3543$ ligt niet in het kritieke gebied

→ H_0 wordt niet verworpen!




Er is onvoldoende reden om de onafhankelijkheid van de twee nominale variabelen “type verwonding” en “taakstelling” te verwerpen.



Stap 5: geef een conclusie en formuleer in de originele context

Methode 2 (p -waarde): de p -waarde (rechteroverschrijdingskans) wordt gegeven door

$$p = P(X^2 \geq \chi^2 \approx 4,3543) = \chi^2 \text{cdf}(a = 4,3543; b = 10^{99}; df = 4) \approx 0,3602$$



→ de p -waarde is groter dan het significantieniveau $\alpha = 0,05$, dus H_0 wordt niet verworpen.

Er is onvoldoende reden om de onafhankelijkheid van de twee nominale variabelen “type verwonding” en “taakstelling” te verwerpen.



Toepassing 2: aanpassingstoets (“goodness-of-fit test”)

De commandant van Paresto wil inzicht krijgen in de drukte tijdens piekuren in de bedrijfskantines. Hij wil graag weten of het aantal personen dat in een minuut binnenkomt tijdens de lunchpauze een Poissonverdeling met gemiddelde $\mu = 3,7$ personen.

Doel: bestuderen in hoeverre data overeenkomen met een **gegeven kansverdeling**



Stap 1: formuleer de nulhypothese H_0 en de alternatieve hypothese H_1

Nulhypothese H_0 :

Het aantal personen dat in een minuut de kantine binnenkomt volgt een Poissonverdeling met gemiddelde $\mu = 3,7$.

Alternatieve hypothese H_1 :

Het aantal personen dat in een minuut de kantine binnenkomt volgt **NIET** een Poissonverdeling met gemiddelde $\mu = 3,7$.



Stap 2: bepaal de kans α op een type-I fout

We kunnen zelf een kans α op een type-I fout kiezen

- Hoeveel risico wil je nemen om H_0 (de aanname van de Poisson($\mu = 3,7$) verdeling) onterecht te verwerpen?

Kans α op een type-I fout: $\alpha = 0,05$

- 5% kans op type-I fout, oftewel onterecht verwerpen dat het aantal binnenkomende mensen Poisson($\mu = 3,7$) verdeeld is
- Indien het aantal binnenkomende mensen inderdaad Poisson($\mu = 3,7$) verdeeld is (H_0 is waar), zal de nulhypothese in 95% van alle steekproefresultaten ook daadwerkelijk worden aangenomen.



Stap 3: verzamelen van data

We verzamelen een jaar lang elke dag een datapunt, waarmee we de volgende frequentietabel kunnen maken:

Aantal personen	Geobserveerde frequenties O_i
0	10
1	25
2	60
3	85
4	80
5	55
6	30
≥ 7	20
Totaal	365



Stap 3: verzamelen van data

We gaan opnieuw de geobserveerde frequenties vergelijken met de verwachte frequenties onder H_0 . Merk op H_0 uitgaat van een Poissonverdeling met gemiddelde $\mu = 3,7$.

Aantal personen	Geobserveerde frequenties O_i	Verwachte frequenties E_i
0	10	$365 * \text{poissonpdf}(\lambda = 3,7; k = 0) \approx 9,0241$
1	25	$365 * \text{poissonpdf}(\lambda = 3,7; k = 1) \approx 33,3891$
2	60	$365 * \text{poissonpdf}(\lambda = 3,7; k = 2) \approx 61,7699$
3	85	$365 * \text{poissonpdf}(\lambda = 3,7; k = 3) \approx 76,1828$
4	80	$365 * \text{poissonpdf}(\lambda = 3,7; k = 4) \approx 70,4691$
5	55	$365 * \text{poissonpdf}(\lambda = 3,7; k = 5) \approx 52,1472$
6	30	$365 * \text{poissonpdf}(\lambda = 3,7; k = 6) \approx 32,1574$
≥ 7	20	$365 - 9,0241 - 33,3891 - \dots \approx 29,8603$
Totaal	365	365



Stap 4: bepaal de toetsingsgrootheid χ^2

Toetsingsgrootheid: $X^2 = \sum_i \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(df)$

- $df = \text{\#categorieën} - 1 = 7$

Aantal personen	Geobserveerde frequenties O_i	Verwachte frequenties E_i
0	10	$365 * \text{poissonpdf}(\lambda = 3,7; k = 0) \approx 9,0241$
1	25	$365 * \text{poissonpdf}(\lambda = 3,7; k = 1) \approx 33,3891$
2	60	$365 * \text{poissonpdf}(\lambda = 3,7; k = 2) \approx 61,7699$
3	85	$365 * \text{poissonpdf}(\lambda = 3,7; k = 3) \approx 76,1828$
4	80	$365 * \text{poissonpdf}(\lambda = 3,7; k = 4) \approx 70,4691$
5	55	$365 * \text{poissonpdf}(\lambda = 3,7; k = 5) \approx 52,1472$
6	30	$365 * \text{poissonpdf}(\lambda = 3,7; k = 6) \approx 32,1574$
≥ 7	20	$365 - 9,0241 - 33,3891 - \dots \approx 29,8603$
Totaal	365	365

De geobserveerde toetsingsgrootheid χ^2 is dan

$$\chi^2 = \frac{(10 - 9,0241)^2}{9,0241} + \frac{(25 - 33,3891)^2}{33,3891} + \dots + \frac{(20 - 29,8603)^2}{29,8603} \approx 8,1304$$



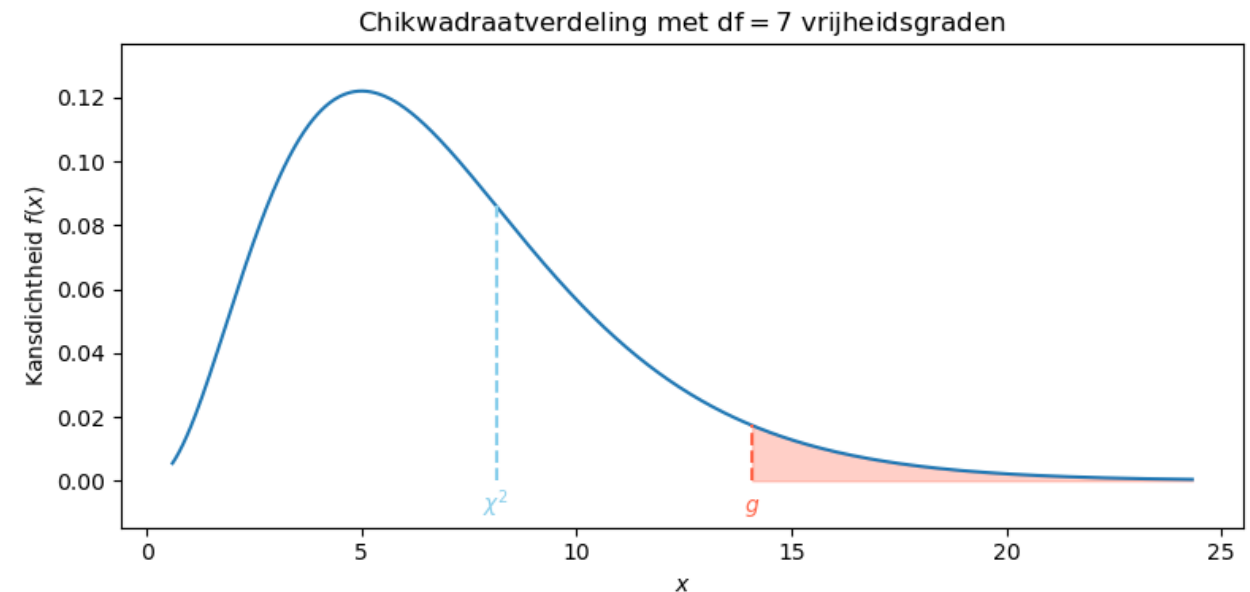
Stap 5: geef een conclusie en formuleer deze in de originele context

Methode 1 (kritiek gebied): het **kritieke gebied** wordt gegeven door $[g, \infty)$, waarbij de grens g de oplossing is van $\chi^2 \text{cdf}(a = X; b = 10^{99}; df = 7) = 0,05$

Met de solver optie krijgen we $g = 14,0671$

→ χ^2 ligt niet in het kritieke gebied

→ H_0 wordt niet verworpen!




Er is onvoldoende reden om aan te nemen dat het aantal klanten in de kantine tijdens de lunchpauze een andere kansverdeling volgt dan een Poissonverdeling met $\mu = 3,7$.



Stap 4: geef een conclusie en formuleer deze in de originele context

Methode 2 (p -waarde): de p -waarde (rechteroverschrijdingskans) wordt gegeven door

$$p = P(X^2 \geq \chi^2) = \chi^2 \text{cdf}(a = 8,1304; b = 10^{99}; df = 7) \approx 0,3212$$



→ de p -waarde is groter dan het significantieniveau $\alpha = 0,05$, dus H_0 wordt niet verworpen.

Er is onvoldoende reden om aan te nemen dat het aantal klanten in de kantine tijdens de lunchpauze een andere kansverdeling volgt dan een Poissonverdeling met $\mu = 3,7$.



Stap 5: formuleer een duidelijke conclusie in de originele context.

Volgens beide methoden (kritiek gebied / p -waarde) wordt er op basis van deze steekproef de nulhypothese H_0 niet verworpen.

Dat betekent dat op basis van deze steekproef onvoldoende reden is om de hypothese te verwerpen dat het aantal binnenkomende personen bij de bedrijfskantine $Poisson(\mu = 3,7)$ verdeeld is.



Enkele aandachtspunten

- Vuistregel:** de chikwadraatverdeling benadert de verdeling van de toetsingsgrootheid, en is goed genoeg als alle verwachte frequenties groter of gelijk aan 5 zijn ($E_i \geq 5$). Mocht dat niet zo zijn, dan moet je rijen samenvoegen (**merk op dat dit het aantal vrijheidsgraden verlaagt!**)

Aantal personen	Verwachte frequenties E_i	→	Aantal personen	Verwachte frequenties E_i
0	2		0-1	5
1	3		2	6
2	6		3	11
3	11		4	15
4	15		5	17
5	17		≥ 6	12
6	8		Totaal	66
≥ 7	4			
Totaal	66			

- Bij het schatten van parameters verlies je ook een vrijheidsgraad (voorbeeld: opgave 10.15)



Samenvatting

- De chikwadraatverdeling en toepassingen
 - Onafhankelijkheidstoets
 - Aanpassingstoets

Huiswerk:

- Lezen van A. Buijs: hoofdstuk 10.1 (blz. 315-318), 10.2 (blz. 318-323), 10.3 (blz. 325-330)
- Opdrachten:
 - Hoofdstuk 10: m1-m4, 10.1, 10.5a, 10.7, 10.11, 10.12, 10.13

Volgende les: verschiltoetsen