

Formuleblad Statistiek MBW deel 1

Gegeven een steekproef met n waarnemingen $x_1, x_2, \dots, x_n$:

Steekproefgemiddelde

$$\bar{x} = \frac{\sum_i x_i}{n} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Steekproefvariantie en steekproefstandaardafwijking:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}$$
$$s = \sqrt{s^2} = \sqrt{\frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}}$$

Rekenregels kansrekening ($\cup$ betekent “of”, $\cap$ betekent “en”, $\neg$ betekent “niet”, $|$ betekent “gegeven”):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (\text{optelregel})$$

$$P(B) = 1 - P(\neg B) \quad (\text{complementregel})$$

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad (\text{conditionele kansen})$$

Discrete en continue kansvariabelen:

	Discrete kansvariabelen	Continue kansvariabelen
Uitkomstenruimte:	Losse, afzonderlijke waarden, bv. 0, 1, 2, ...	Doorlopend spectrum van waarden, bv. alles tussen 0 en 1
Toepassingen:	Tellen / categoriseren	Metten
	Kansfunctie $p(k) = P(X = k)$	Kansdichtheidsfunctie $f(x)$
Kansbegrip:	$p(k) \geq 0$ voor alle k $\sum_k p(k) = 1$	$f(x) \geq 0$ voor alle x $\int_{-\infty}^{\infty} f(x) dx = 1$
CDF	$F(k) = P(X \leq k) = \sum_{\ell: \ell \leq k} p(\ell)$	$F(x) = P(X \leq x) = \int_{-\infty}^x f(y) dy$
Verwachtingswaarde:	$E[X] = \sum_k k \cdot P(X = k)$	$E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx$
Variantie:	$\text{Var}(X) = \sum_k (k - E[X])^2 \cdot P(X = k)$	$\text{Var}(X) = \int_{-\infty}^{\infty} (x - E[X])^2 \cdot f(x) dx$
Standaardafwijking:	$\sigma(X) = \sqrt{\text{Var}(X)}$	$\sigma(X) = \sqrt{\text{Var}(X)}$

Speciale kansverdelingen:

- Binomiale verdeling:** aantal successen tellen bij onafhankelijke (Bernoulli-)kansexperimenten met twee mogelijke uitkomsten: succes / mislukking.
 - *Parameters:* aantal Bernoulli-experimenten n , succeskans per experiment p
- Poissonverdeling:** aantal “gebeurtenissen” tellen in een “meetinterval” van tijd of ruimte.
 - *Parameters:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte), het aantal meeteenheden t (bijv. $t = 7$ als een week lang wordt gemeten, en de meeteenheid is “dag”).
- Exponentiële verdeling:** de tijd / afstand tot de volgende “gebeurtenis”.
 - *Parameter:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte).

Verwachtingswaarde en variantie van veelgebruikte kansverdelingen:

DISCRETE KANSVERDELINGEN				
Verdeling	Kansfunctie $p(k) = P(X = k)$	CDF $F(k) = P(X \leq k)$	$E(X)$	$\text{Var}(X)$
Uniform(a, b)	$p(k) = \frac{1}{b-a+1}$ ($k = a, a+1, \dots, b$)	$F(k) = \begin{cases} 0, & x < a, \\ \frac{k-a+1}{b-a+1}, & a \leq k < b, \\ 1, & k \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$
Bernoulli(p)	$p(k) = \begin{cases} 1-p, & k=0 \\ p, & k=1 \end{cases}$	$F(k) = \begin{cases} 0, & k < 0, \\ 1-p, & 0 \leq k < 1, \\ 1, & k \geq 1. \end{cases}$	p	$p \cdot (1-p)$
Binomiaal(n, p)	$p(k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$F(k) = \sum_{i=0}^k \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Poisson(λ)	$p(k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	$F(k) = \sum_{i=0}^k e^{-\lambda} \cdot \frac{\lambda^i}{i!}$	λ	λ
CONTINUE KANSVERDELINGEN				
Verdeling	Kansdichtheidsfunctie $f(x)$	CDF $F(x) = P(X \leq x)$	$E(X)$	$\text{Var}(X)$
Uniform(a, b)	$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{elders.} \end{cases}$	$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentieel(λ)	$f(x) = \lambda e^{-\lambda x}$ ($x \geq 0$)	$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

Veelgebruikte functies op de grafische rekenmachine:

Kansverdeling	Type vraag	TI-84 Plus CE-T	Casio fx-CG50
Continue verdeling met kansdichtheidsfunctie $f(x)$	$P(a \leq X \leq b)$	$\int_a^b f(x) \, dx$	$\int_a^b f(x) \, dx$
Binomiaal(n, p)	$P(X = k)$	binompdf(n, p, k)	BinomialPD(k, n, p)
	$P(X \leq k)$	binomcdf(n, p, k)	BinomialCD(k, n, p)
$N(\mu, \sigma)$	$P(a \leq X \leq b)$	normalcdf(a, b, μ, σ)	NormCD(a, b, σ, μ)
	Grenswaarde g zodat $P(X \leq g) = p$	InvNorm(p, μ, σ)	InvN(p, σ, μ)
Poisson($\mu = \lambda \cdot t$)	$P(X = k)$	poissonpdf(μ, k)	PoissonPD(k, μ)
	$P(X \leq k)$	poissoncdf(μ, k)	PoissonCD(k, μ)

z-score:

$$z = \frac{x - \mu}{\sigma}$$

Centrale limietstelling:

Gegeven zijn n kansvariabelen $X_1, X_2, \dots, X_n$, die onderling onafhankelijk zijn en dezelfde kansverdeling volgen met verwachtingswaarde μ en standaardafwijking σ . Er geldt (bij benadering) het volgende:

- de som $\sum_{i=1}^n X_i = X_1 + X_2 + \dots + X_n$ is normaal verdeeld met parameters $n \cdot \mu$ en $\sqrt{n} \cdot \sigma$.
- het gemiddelde $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$ is normaal verdeeld met parameters μ en $\frac{\sigma}{\sqrt{n}}$.

Formuleblad Statistiek MBW deel 2

100(1 - α)%-betrouwbaarheidsinterval (BI) voor het gemiddelde μ (als σ bekend is)

TI84-Plus

- $z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2, \mu = 0, \sigma = 1)$
- $[\bar{x} - z_{\alpha/2} \cdot \sigma / \sqrt{n}, \quad \bar{x} + z_{\alpha/2} \cdot \sigma / \sqrt{n}]$

Casio fx-CG50

- $z_{\alpha/2} = \text{InvN}(\text{area} = 1 - \alpha/2, \sigma = 1, \mu = 0)$
- $[\bar{x} - z_{\alpha/2} \cdot \sigma / \sqrt{n}, \quad \bar{x} + z_{\alpha/2} \cdot \sigma / \sqrt{n}]$

Minimale steekproefomvang n voor een 100(1 - α)%-BI met maximale afwijking $\pm a$:

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{a} \right)^2$$

100(1 - α)%-betrouwbaarheidsinterval (BI) voor het gemiddelde μ (als σ NIET bekend is)

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1)$
- $[\bar{x} - t_{\alpha/2} \cdot s / \sqrt{n}, \quad \bar{x} + t_{\alpha/2} \cdot s / \sqrt{n}]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 1)$
- $[\bar{x} - t_{\alpha/2} \cdot s / \sqrt{n}, \quad \bar{x} + t_{\alpha/2} \cdot s / \sqrt{n}]$

Minimale steekproefomvang n voor een 100(1 - α)%-BI met maximale afwijking $\pm a$:

Gebruik het functiescherm en maak een tabel:

TI84-Plus ($y =$)

- $y_1 = s / \sqrt{X} \cdot \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = X - 1)$
- Bepaal de laagste waarde voor X zodat $y_1 \leq a$

Casio fx-CG50 (MENU 5)

- $y_1 = s / \sqrt{X} \cdot \text{InvT}(\text{area} = \alpha/2, \text{df} = X - 1)$
- Bepaal de laagste waarde van X zodat $y_1 \leq a$

100(1 - α)%-BI voor de binomiale succeskans p (Clopper-Pearson methode)

Gegeven is een binomiale verdeelde kansvariabele met bekende n en uitkomst k , en onbekende $p = ?$.

1. Bereken ondergrens van het interval: de kleinste succeskans p_1 zodat geldt $P(X \geq k) \geq \alpha/2$.
2. Bereken bovengrens van het interval: de grootste succeskans p_2 zodat geldt $P(X \leq k) \geq \alpha/2$.

TI84-Plus

1. Gebruik numerieke solver met
$$E_1 = 1 - \text{binomcdf}(n, p = X, k - 1)$$
$$E_2 = \alpha/2$$
2. Gebruik numerieke solver met
$$E_1 = \text{binomcdf}(n, p = X, k)$$
$$E_2 = \alpha/2$$

Casio fx-CG50

1. Gebruik numerieke solver met
$$\text{SolveN}(1 - \text{BinomialCD}(k - 1, n, x) = \alpha/2, x)$$
2. Gebruik numerieke solver met
$$\text{SolveN}(\text{BinomialCD}(k, n, x) = \alpha/2, x)$$

Stappenplan voor iedere hypothesetoets

1. Definieer de nulhypothese H_0 en de alternatieve hypothese H_1 .
2. Bepaal het significantieniveau α (kans op onterecht verwerpen van $H_0 \rightarrow$ type-I fout).
3. Verzamel data voor de toetsingsgrootheid.
4. Bereken de toetsingsgrootheid.
5. Bepaal de toetsuitslag (wel of niet verwerpen van H_0).
6. Vertaal de toetsuitslag naar de originele probleemcontext.

Toetsuitslag bepalen

- De toetsingsgrootheid volgt, uitgaande van H_0 , een bepaalde kansverdeling.
- Op basis van deze kansverdeling kun je (i) een kritiek gebied bepalen, of (ii) een p -waarde berekenen.
 - **Kritiek gebied:** verwerp H_0 alleen als de geobserveerde toetsingsgrootheid in het kritieke gebied ligt.
 - **p -waarde:** verwerp H_0 alleen als $p \leq \alpha$ (links-/rechtszijdig) of $p \leq \alpha/2$ (tweezijdig).

Soorten hypothesetoetsen

Soort toets	H_0	Toetsingsgrootheid	Kansverdeling (onder H_0)
Toetsen voor het gemiddelde μ van een normale verdeling			
σ bekend	$\mu \leq / = / \geq \mu_0$	$\bar{X}$	$N(\mu_0, \sigma/\sqrt{n})$
σ onbekend	$\mu \leq / = / \geq \mu_0$	$T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$	$t(df = n - 1)$
Chikwadraattoetsen (χ^2)			
Onafhankelijkheid	Variabelen zijn onafhankelijk	$X^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$	$\chi^2 (df = (\#rijen-1) \cdot (\#kolommen-1))$
Goodness-of-fit	Variabele volgt bepaalde discrete kansverdeling	$X^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$	$\chi^2 (df = \#categorieën-1)$
Toetsen op basis van twee onafhankelijke populaties A en B (met steekproefgroottes n en m)			
F -toets	$\sigma_A^2 = \sigma_B^2$	$F = \frac{S_A^2}{S_B^2}$	$F (df_A = n - 1, df_B = m - 1)$
z -toets	$\mu_A \leq / = / \geq \mu_B$	$Z = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{\sigma_A^2}{n} + \frac{\sigma_B^2}{m}}}$	$N(\mu = 0, \sigma = 1)$
t -toets ($\sigma_A^2 = \sigma_B^2$)	$\mu_A \leq / = / \geq \mu_B$	$T = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_P^2}{n} + \frac{S_P^2}{m}}}$	$t (df = n + m - 2)$
t -toets ($\sigma_A^2 \neq \sigma_B^2$)	$\mu_A \leq / = / \geq \mu_B$	$T = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{n} + \frac{S_B^2}{m}}}$	$t (df = \min(n - 1, m - 1))$

Kritieke gebieden

Kansverdeling (onder H_0)	Linkszijdig $(-\infty, g)$	Tweezijdig $(-\infty, g_1)$ en (g_2, ∞)	Rechtszijdig (g, ∞)
$N(\mu, \sigma)$	$g = \text{InvNorm}(\alpha, \mu, \sigma)$	$g_1 = \text{InvNorm}(\alpha/2, \mu, \sigma)$ $g_2 = \text{InvNorm}(1 - \alpha/2, \mu, \sigma)$	$g = \text{InvNorm}(1 - \alpha, \mu, \sigma)$
$t(df)$	$g = \text{InvT}(\alpha, df)$	$g_1 = \text{InvT}(\alpha/2, df)$ $g_2 = \text{InvT}(1 - \alpha/2, df)$	$g = \text{InvT}(1 - \alpha, df)$
Grenzen die met de “numeric solver” moeten worden opgelost:			
$\chi^2(df)$	-	-	$\chi^2\text{cdf}(g, 10^{99}, df) = \alpha$
$F(df_A, df_B)$	-	$\text{Fcdf}(0, g_1, df_A, df_B) = \alpha/2$ $\text{Fcdf}(g_2, 10^{99}, df_A, df_B) = \alpha/2$	-

NB: bij de Casio kun je InvT , InvChiCD , InvFCD , etc. gebruiken in plaats van SolveN . Let op dat de Casio standaard kijkt naar oppervlaktes RECHTS van de grenswaarde (behalve bij invNormalCD), dus gebruik $\alpha/2$ in plaats van $1 - \alpha/2$, α in plaats van $1 - \alpha$, etc.!


p-waardes (gegeven theoretische en geobserveerde toetsingsgrootheid T en t)

Kansverdeling (onder H_0)	Linkszijdige toets: $P(T \leq t)$	Rechtszijdige toets: $P(T \geq t)$
$N(\mu, \sigma)$	$p = \text{normalcdf}(-10^{99}, t, \mu, \sigma)$	$p = \text{normalcdf}(t, 10^{99}, \mu, \sigma)$
$t(\text{df})$	$p = \text{tcdf}(-10^{99}, t, \text{df})$	$p = \text{tcdf}(t, 10^{99}, \text{df})$
$\chi^2(\text{df})$	-	$p = \chi^2\text{cdf}(t, 10^{99}, \text{df})$
$F(\text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(0, t, \text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(t, 10^{99}, \text{df}_A, \text{df}_B)$


NB: bij tweezijdige toetsen is de p -waarde gelijk aan het minimum van $P(T \leq t)$ en $P(T \geq t)$.

Linkszijdige, tweezijdige en rechtszijdige hypothesetoetsen


Linkszijdig
 $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$
 Acceptatiegebied: $[g, \infty)$
 Kritiek gebied: $(-\infty, g)$




Tweezijdig
 $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$
 Acceptatiegebied: $[g_1, g_2]$
 Kritiek gebied: $(-\infty, g_1)$ en (g_2, ∞)



Rechtszijdig
 $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$
 Acceptatiegebied: $(-\infty, g]$
 Kritiek gebied: (g, ∞)



Beslisboom hypothesetoetsen



Correlatie en regressie

Correlatiecoëfficiënt van Pearson:

$$r = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\sqrt{(\overline{x^2} - \bar{x}^2) \cdot (\overline{y^2} - \bar{y}^2)}}$$

Coëfficiënten van de lineaire regressielijn $Y = a + b \cdot X$:

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$
$$a = \bar{y} - b \cdot \bar{x}$$

Schatting van de variantie van de storingsterm ε :

$$s_\varepsilon^2 = \frac{\sum e_i^2}{n-2} = \frac{\sum (y_i - (a + b \cdot x_i))^2}{n-2} = \frac{n}{n-2} \cdot (\overline{y^2} - a \cdot \bar{y} - b \cdot \overline{xy})$$

$100 \cdot (1 - \alpha)\%$ -betrouwbaarheidsinterval voor de gemiddelde Y bij een gegeven $X = x_0$:

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 2)$
- $s_\mu = s_\varepsilon \cdot \sqrt{\frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_\mu, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_\mu]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 2)$
- $s_\mu = s_\varepsilon \cdot \sqrt{\frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_\mu, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_\mu]$

$100 \cdot (1 - \alpha)\%$ -betrouwbaarheidsinterval voor Y bij een gegeven $X = x_0$:

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 2)$
- $s_f = s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_f, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_f]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 2)$
- $s_f = s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_f, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_f]$