

Formuleblad Statistiek MBW deel 1

Gegeven een steekproef met n waarnemingen $x_1, x_2, \dots, x_n$:

Steekproefgemiddelde

$$\bar{x} = \frac{\sum_i x_i}{n} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Steekproefvariantie en steekproefstandaardafwijking:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}$$
$$s = \sqrt{s^2} = \sqrt{\frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}}$$

Rekenregels kansrekening ($\cup$ betekent “of”, $\cap$ betekent “en”, $\neg$ betekent “niet”, $|$ betekent “gegeven”):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (\text{optelregel})$$

$$P(B) = 1 - P(\neg B) \quad (\text{complementregel})$$

$$P(A | B) = \frac{P(A \cap B)}{P(B)} \quad (\text{conditionele kansen})$$

Discrete en continue kansvariabelen:

	Discrete kansvariabelen	Continue kansvariabelen
Uitkomstenruimte:	Losse, afzonderlijke waarden, bv. 0, 1, 2, ...	Doorlopend spectrum van waarden, bv. alles tussen 0 en 1
Toepassingen:	Tellen / categoriseren	Metten
	Kansfunctie $p(k) = P(X = k)$	Kansdichtheidsfunctie $f(x)$
Kansbegrip:	$p(k) \geq 0$ voor alle k $\sum_k p(k) = 1$	$f(x) \geq 0$ voor alle x $\int_{-\infty}^{\infty} f(x) dx = 1$
CDF	$F(k) = P(X \leq k) = \sum_{\ell: \ell \leq k} p(\ell)$	$F(x) = P(X \leq x) = \int_{-\infty}^x f(y) dy$
Verwachtingswaarde:	$E[X] = \sum_k k \cdot P(X = k)$	$E[X] = \int_{-\infty}^{\infty} x \cdot f(x) dx$
Variantie:	$\text{Var}(X) = \sum_k (k - E[X])^2 \cdot P(X = k)$	$\text{Var}(X) = \int_{-\infty}^{\infty} (x - E[X])^2 \cdot f(x) dx$
Standaardafwijking:	$\sigma(X) = \sqrt{\text{Var}(X)}$	$\sigma(X) = \sqrt{\text{Var}(X)}$

Speciale kansverdelingen:

- Binomiale verdeling:** aantal successen tellen bij onafhankelijke (Bernoulli-)kansexperimenten met twee mogelijke uitkomsten: succes / mislukking.
 - *Parameters:* aantal Bernoulli-experimenten n , succeskans per experiment p
- Poissonverdeling:** aantal “gebeurtenissen” tellen in een “meetinterval” van tijd of ruimte.
 - *Parameters:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte), het aantal meeteenheden t (bijv. $t = 7$ als een week lang wordt gemeten, en de meeteenheid is “dag”).
- Exponentiële verdeling:** de tijd / afstand tot de volgende “gebeurtenis”.
 - *Parameter:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte).

Verwachtingswaarde en variantie van veelgebruikte kansverdelingen:

DISCRETE KANSVERDELINGEN				
Verdeling	Kansfunctie $p(k) = P(X = k)$	CDF $F(k) = P(X \leq k)$	$E(X)$	$\text{Var}(X)$
Uniform(a, b)	$p(k) = \frac{1}{b-a+1}$ ($k = a, a+1, \dots, b$)	$F(k) = \begin{cases} 0, & x < a, \\ \frac{k-a+1}{b-a+1}, & a \leq k < b, \\ 1, & k \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$
Bernoulli(p)	$p(k) = \begin{cases} 1-p, & k=0 \\ p, & k=1 \end{cases}$	$F(k) = \begin{cases} 0, & k < 0, \\ 1-p, & 0 \leq k < 1, \\ 1, & k \geq 1. \end{cases}$	p	$p \cdot (1-p)$
Binomiaal(n, p)	$p(k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$F(k) = \sum_{i=0}^k \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Poisson(λ)	$p(k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	$F(k) = \sum_{i=0}^k e^{-\lambda} \cdot \frac{\lambda^i}{i!}$	λ	λ
CONTINUE KANSVERDELINGEN				
Verdeling	Kansdichtheidsfunctie $f(x)$	CDF $F(x) = P(X \leq x)$	$E(X)$	$\text{Var}(X)$
Uniform(a, b)	$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{elders.} \end{cases}$	$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentieel(λ)	$f(x) = \lambda e^{-\lambda x}$ ($x \geq 0$)	$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

Veelgebruikte functies op de grafische rekenmachine:

Kansverdeling	Type vraag	TI-84 Plus CE-T	Casio fx-CG50
Continue verdeling met kansdichtheidsfunctie $f(x)$	$P(a \leq X \leq b)$	$\int_a^b f(x) \, dx$	$\int_a^b f(x) \, dx$
Binomiaal(n, p)	$P(X = k)$	binompdf(n, p, k)	BinomialPD(k, n, p)
	$P(X \leq k)$	binomcdf(n, p, k)	BinomialCD(k, n, p)
$N(\mu, \sigma)$	$P(a \leq X \leq b)$	normalcdf(a, b, μ, σ)	NormCD(a, b, σ, μ)
	Grenswaarde g zodat $P(X \leq g) = p$	InvNorm(p, μ, σ)	InvN(p, σ, μ)
Poisson($\mu = \lambda \cdot t$)	$P(X = k)$	poissonpdf(μ, k)	PoissonPD(k, μ)
	$P(X \leq k)$	poissoncdf(μ, k)	PoissonCD(k, μ)

z-score:

$$z = \frac{x - \mu}{\sigma}$$

Centrale limietstelling:

Gegeven zijn n kansvariabelen $X_1, X_2, \dots, X_n$, die onderling onafhankelijk zijn en dezelfde kansverdeling volgen met verwachtingswaarde μ en standaardafwijking σ . Er geldt (bij benadering) het volgende:

- de som $\sum_{i=1}^n X_i = X_1 + X_2 + \dots + X_n$ is normaal verdeeld met parameters $n \cdot \mu$ en $\sqrt{n} \cdot \sigma$.
- het gemiddelde $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$ is normaal verdeeld met parameters μ en $\frac{\sigma}{\sqrt{n}}$.

Formuleblad Statistiek MBW deel 2

100(1 - α)%-betrouwbaarheidsinterval (BI) voor het gemiddelde μ (als σ bekend is)

TI84-Plus

- $z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2, \mu = 0, \sigma = 1)$
- $[\bar{x} - z_{\alpha/2} \cdot \sigma / \sqrt{n}, \quad \bar{x} + z_{\alpha/2} \cdot \sigma / \sqrt{n}]$

Casio fx-CG50

- $z_{\alpha/2} = \text{InvN}(\text{area} = 1 - \alpha/2, \sigma = 1, \mu = 0)$
- $[\bar{x} - z_{\alpha/2} \cdot \sigma / \sqrt{n}, \quad \bar{x} + z_{\alpha/2} \cdot \sigma / \sqrt{n}]$

Minimale steekproefomvang n voor een 100(1 - α)%-BI met maximale afwijking $\pm a$:

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{a} \right)^2$$

100(1 - α)%-betrouwbaarheidsinterval (BI) voor het gemiddelde μ (als σ NIET bekend is)

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1)$
- $[\bar{x} - t_{\alpha/2} \cdot s / \sqrt{n}, \quad \bar{x} + t_{\alpha/2} \cdot s / \sqrt{n}]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 1)$
- $[\bar{x} - t_{\alpha/2} \cdot s / \sqrt{n}, \quad \bar{x} + t_{\alpha/2} \cdot s / \sqrt{n}]$

Minimale steekproefomvang n voor een 100(1 - α)%-BI met maximale afwijking $\pm a$:

Gebruik het functiescherm en maak een tabel:

TI84-Plus ($y =$)

- $y_1 = s / \sqrt{X} \cdot \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = X - 1)$
- Bepaal de laagste waarde voor X zodat $y_1 \leq a$

Casio fx-CG50 (MENU 5)

- $y_1 = s / \sqrt{X} \cdot \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = X - 1)$
- Bepaal de laagste waarde van X zodat $y_1 \leq a$

100(1 - α)%-BI voor de binomiale succeskans p (Clopper-Pearson methode)

Gegeven is een binomiale verdeelde kansvariabele met bekende n en uitkomst k , en onbekende $p = ?$.

1. Bereken ondergrens van het interval: de kleinste succeskans p_1 zodat geldt $P(X \geq k) \geq \alpha/2$.
2. Bereken bovengrens van het interval: de grootste succeskans p_2 zodat geldt $P(X \leq k) \geq \alpha/2$.

TI84-Plus

1. Gebruik numerieke solver met
$$E_1 = 1 - \text{binomcdf}(n, p = X, k - 1)$$
$$E_2 = \alpha/2$$
2. Gebruik numerieke solver met
$$E_1 = \text{binomcdf}(n, p = X, k)$$
$$E_2 = \alpha/2$$

Casio fx-CG50

1. Gebruik numerieke solver met
$$\text{SolveN}(1 - \text{BinomialCD}(k - 1, n, x) = \alpha/2, x)$$
2. Gebruik numerieke solver met
$$\text{SolveN}(\text{BinomialCD}(k, n, x) = \alpha/2, x)$$

Stappenplan voor iedere hypothesetoets

1. Definieer de nulhypothese H_0 en de alternatieve hypothese H_1 .
2. Bepaal het significantieniveau α (kans op onterecht verwerpen van $H_0 \rightarrow$ type-I fout).
3. Verzamel data voor de toetsingsgrootheid.
4. Bereken de toetsingsgrootheid.
5. Bepaal de toetsuitslag (wel of niet verwerpen van H_0).
6. Vertaal de toetsuitslag naar de originele probleemcontext.

Toetsuitslag bepalen

- De toetsingsgrootheid volgt, uitgaande van H_0 , een bepaalde kansverdeling.
- Op basis van deze kansverdeling kun je (i) een kritiek gebied bepalen, of (ii) een p -waarde berekenen.
 - **Kritiek gebied:** verwerp H_0 alleen als de geobserveerde toetsingsgrootheid in het kritieke gebied ligt.
 - **p -waarde:** verwerp H_0 alleen als $p \leq \alpha$ (links-/rechtszijdig) of $p \leq \frac{\alpha}{2}$ (tweezijdig).

Soorten hypothesetoetsen

Soort toets	H_0	Toetsingsgrootheid	Kansverdeling (onder H_0)
Toetsen voor het gemiddelde μ van een normale verdeling			
σ bekend	$\mu \leq / = / \geq \mu_0$	$\bar{X}$	$N(\mu_0, \sigma/\sqrt{n})$
σ onbekend	$\mu \leq / = / \geq \mu_0$	$T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$	$t(df = n - 1)$
Chikwadraattoetsen (χ^2)			
Onafhankelijkheid	Variabelen zijn onafhankelijk	$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$	$\chi^2 (df = (\#rijen-1) \cdot (\#kolommen-1))$
Goodness-of-fit	Variabele volgt bepaalde discrete kansverdeling	$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$	$\chi^2 (df = \#categorieën-1)$
Toetsen op basis van twee onafhankelijke populaties A en B			
F -toets	$\sigma_A^2 = \sigma_B^2$	$F = \frac{S_A^2}{S_B^2}$	$F(df_A, df_B)$
z -toets	$\mu_A \leq / = / \geq \mu_B$	$Z = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{\sigma_A^2}{n} + \frac{\sigma_B^2}{m}}}$	$N(0, 1)$
t -toets ($\sigma_A^2 = \sigma_B^2$)	$\mu_A \leq / = / \geq \mu_B$	$T = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_P^2}{n} + \frac{S_P^2}{m}}}$	$t(df = n + m - 2)$
t -toets ($\sigma_A^2 \neq \sigma_B^2$)	$\mu_A \leq / = / \geq \mu_B$	$T = \frac{(\bar{X}_A - \bar{X}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{S_A^2}{n} + \frac{S_B^2}{m}}}$	$t(df = \min(n - 1, m - 1))$

Kritieke gebieden

Kansverdeling (onder H_0)	Linkszijdig $(-\infty, g]$	Tweezijdig $(-\infty, g_1]$ en $[g_2, \infty)$	Rechtszijdig $[g, \infty)$
$N(\mu, \sigma)$	$g = \text{InvNorm}(\alpha, \mu, \sigma)$	$g_1 = \text{InvNorm}(\text{opp} = \frac{\alpha}{2}, \mu, \sigma)$ $g_2 = \text{InvNorm}(\text{opp} = 1 - \frac{\alpha}{2}, \mu, \sigma)$	$g = \text{InvNorm}(1 - \alpha, \mu, \sigma)$
$t(df)$	$g = \text{InvT}(\alpha, df)$	$g_1 = \text{InvT}(\text{opp} = \frac{\alpha}{2}, df)$ $g_2 = \text{InvT}(\text{opp} = 1 - \frac{\alpha}{2}, df)$	$g = \text{InvT}(1 - \alpha, df)$
Grenzen die met de “numeric solver” moeten worden opgelost:			
$\chi^2(df)$	-	-	$\chi^2\text{cdf}(g, 10^{99}, df) = \alpha$
$F(df_A, df_B)$	-	$\text{Fcdf}(0, g_1, df_A, df_B) = \frac{\alpha}{2}$ $\text{Fcdf}(g_2, 10^{99}, df_A, df_B) = \frac{\alpha}{2}$	-

NB: bij de Casio kun je Invt, InvChiCD, InvFCD, etc. gebruiken in plaats van SolveN. Let op dat de Casio standaard kijkt naar oppervlaktes RECHTS van de grenswaarde (behalve bij invNormalCD), dus gebruik $\alpha/2$ in plaats van $1 - \alpha/2$, α in plaats van $1 - \alpha$, etc.!


p -waardes (gegeven theoretische en geobserveerde toetsingsgrootheid T en t)

Kansverdeling (onder H_0)	Linkszijdig ($P(T \leq t)$)	Rechtszijdig ($P(T \geq t)$)
$N(\mu, \sigma)$	$p = \text{normalcdf}(-10^{99}, t, \mu, \sigma)$	$p = \text{normalcdf}(t, 10^{99}, \mu, \sigma)$
$t(\text{df})$	$p = \text{tcdf}(-10^{99}, t, \text{df})$	$p = \text{tcdf}(t, 10^{99}, \text{df})$
$\chi^2(\text{df})$	-	$p = \chi^2\text{cdf}(t, 10^{99}, \text{df})$
$F(\text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(0, t, \text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(t, 10^{99}, \text{df}_A, \text{df}_B)$


NB: bij tweezijdige toetsen is de p -waarde gelijk aan het minimum van de linkszijdige en rechtszijdige p -waarde.

Linkszijdige, tweezijdige en rechtszijdige hypothesetoetsen


Linkszijdig
 $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$
 Acceptatiegebied: $[g, \infty)$
 Kritiek gebied: $(-\infty, g)$




Tweezijdig
 $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$
 Acceptatiegebied: $[g_1, g_2]$
 Kritiek gebied: $(-\infty, g_1)$ en (g_2, ∞)



Rechtszijdig
 $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$
 Acceptatiegebied: $(-\infty, g]$
 Kritiek gebied: (g, ∞)



Beslisboom hypothesetoetsen



Correlatie en regressie

Correlatiecoëfficiënt van Pearson:

$$r = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\sqrt{(\overline{x^2} - \bar{x}^2) \cdot (\overline{y^2} - \bar{y}^2)}}$$

Correlatiecoëfficiënt van Spearman:

$$r_s = 1 - \frac{6 \cdot \sum_i d_i^2}{n^3 - n}$$

Coëfficiënten van de lineaire regressielijn $Y = a + b \cdot X$:

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$
$$a = \bar{y} - b \cdot \bar{x}$$

Schatting van de variantie van de storingsterm ε :

$$s_\varepsilon^2 = \frac{\sum e_i^2}{n-2} = \frac{\sum (y_i - (a + b \cdot x_i))^2}{n-2} = \frac{n}{n-2} \cdot (\overline{y^2} - a \cdot \bar{y} - b \cdot \overline{xy})$$

$100 \cdot (1 - \alpha)\%$ -betrouwbaarheidsinterval voor de gemiddelde Y bij een gegeven $X = x_0$:

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 2)$
- $s_\mu = s_\varepsilon \cdot \sqrt{\frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_\mu, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_\mu]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 2)$
- $s_\mu = s_\varepsilon \cdot \sqrt{\frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_\mu, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_\mu]$

$100 \cdot (1 - \alpha)\%$ -betrouwbaarheidsinterval voor Y bij een gegeven $X = x_0$:

TI84-Plus

- $t_{\alpha/2} = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 2)$
- $s_f = s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_f, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_f]$

Casio fx-CG50

- $t_{\alpha/2} = \text{InvT}(\text{area} = \alpha/2, \text{df} = n - 2)$
- $s_f = s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)}$
- $[a + b \cdot x_0 - t_{\alpha/2} \cdot s_f, \quad a + b \cdot x_0 + t_{\alpha/2} \cdot s_f]$