Formuleblad Statistiek KW/MBW

Gegeven een steekproef met n observaties $x_1, x_2, \ldots, x_n$:

Steekproefgemiddelde

$$\overline{x} = \frac{\sum_i x_i}{n} = \frac{x_1 + x_2 + \ldots + x_n}{n}$$

Steekproefvariantie en steekproefstandaardafwijking:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \overline{x})^2}{n-1} = \frac{(x_1 - \overline{x})^2 + (x_2 - \overline{x})^2 + \ldots + (x_n - \overline{x})^2}{n-1}$$

$$s = \sqrt{s^2} = \sqrt{\frac{(x_1 - \overline{x})^2 + (x_2 - \overline{x})^2 + \ldots + (x_n - \overline{x})^2}{n-1}}$$

Rekenregels kansrekening ($\cup$ betekent "of", $\cap$ betekent "en", $\neg$ betekent "niet", $|$ betekent "gegeven"):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \qquad \text{(optelregel)}$$

$$P(B) = 1 - P(\neg B) \qquad \text{(complementregel)}$$

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \qquad \text{(conditionele kansen)}$$

Discrete en continue kansvariabelen:

	Discrete kansvariabelen	**Continue kansvariabelen**
Uitkomstenruimte:	Eindig / aftelbaar oneindig	Overaftelbaar oneindig
Toepassingen:	Tellen / categoriseren	Meten
Kansbegrip:	Kansfunctie $p(k) = P(X = k)$	Kansdichtheidsfunctie $f(x)$
CDF	$F(k) = P(X \leq k) = \sum_{\ell : \ell \leq k} p(\ell)$	$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(y)\,\mathrm{d}y$
Verwachtingswaarde:	$E[X] = \sum_k k \cdot P(X = k)$	$E[X] = \int_{-\infty}^{\infty} x \cdot f(x)\,\mathrm{d}x$
Variantie:	$\mathrm{Var}(X) = \sum_k (k - E[X])^2 \cdot P(X = k)$	$\mathrm{Var}(X) = \int_{-\infty}^{\infty} (x - E[X])^2 \cdot f(x)\,\mathrm{d}x$
Standaardafwijking:	$\sigma(X) = \sqrt{\mathrm{Var}(X)}$	$\sigma(X) = \sqrt{\mathrm{Var}(X)}$

Speciale kansverdelingen:

- **Binomiale verdeling**: aantal successen tellen bij onafhankelijke (Bernoulli-)kansexperimenten met twee mogelijke uitkomsten: succes / mislukking.
  - *Parameters:* aantal Bernoulli-experimenten n, succeskans per experiment p
- **Poissonverdeling:** aantal "gebeurtenissen" tellen in een "meetinterval" van tijd of ruimte.
  - *Parameters:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte), het aantal meeteenheden t (bijv. $t = 7$ als een week lang wordt gemeten, en de meeteenheid is "dag").
- **Exponentiële verdeling:** de tijd / afstand tot de volgende "gebeurtenis".
  - *Parameter:* gemiddelde aantal gebeurtenissen λ per meeteenheid (tijd / ruimte).

Verwachtingswaarde en variantie van veelgebruikte kansverdelingen:

DISCRETE KANSVERDELINGEN				
Verdeling	**Kansfunctie** $p(k) = P(X = k)$	**CDF** $F(k) = P(X \leq k)$	$E(X)$	Var(X)
Uniform(a, b)	$p(k) = \frac{1}{b-a+1}$ $(k = a, a+1, \ldots, b)$	$F(k) = \begin{cases} 0, & x < a, \\ \frac{k-a+1}{b-a+1}, & a \leq k < b, \\ 1, & k \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$
Bernoulli(p)	$p(k) = \begin{cases} 1-p, & k = 0 \\ p, & k = 1 \end{cases}$	$F(k) = \begin{cases} 0, & k < 0, \\ 1-p, & 0 \leq k < 1, \\ 1, & k \geq 1. \end{cases}$	p	$p \cdot (1-p)$
Binomiaal(n, p)	$p(k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$	$F(k) = \sum_{i=0}^{k} \binom{n}{i} \cdot p^i \cdot (1-p)^{n-i}$	$n \cdot p$	$n \cdot p \cdot (1-p)$
Poisson(λ)	$p(k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$	$F(k) = \sum_{i=0}^{k} e^{-\lambda} \cdot \frac{\lambda^i}{i!}$	λ	λ
CONTINUE KANSVERDELINGEN				
Verdeling	**Kansdichtheidsfunctie** $f(x)$	**CDF** $F(x) = P(X \leq x)$	$E(X)$	Var(X)
Uniform(a, b)	$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{elders.} \end{cases}$	$F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentieel(λ)	$f(x) = \lambda e^{-\lambda x}$ $(x \geq 0)$	$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

Veelgebruikte functies op de grafische rekenmachine:

Kansverdeling	**Type vraag**	**TI-84 Plus CE-T**	**Casio fx-CG50**
Continue verdeling met kansdichtheidsfunctie $f(x)$	$P(a \leq X \leq b)$	$\int_a^b f(x)\,\mathrm{d}x$	$\int_a^b f(x)\,\mathrm{d}x$
Binomiaal(n, p)	$P(X = k)$	$\mathrm{binompdf}(n, p, k)$	BinomialPD(k, n, p)
	$P(X \leq k)$	$\mathrm{binomcdf}(n, p, k)$	BinomialCD(k, n, p)
$N(\mu, \sigma)$	$P(a \leq X \leq b)$	$\mathrm{normalcdf}(a, b, \mu, \sigma)$	NormCD(a, b, σ, μ)
	Grenswaarde g zodat $P(X \leq g) = p$	$\mathrm{InvNorm}(p, \mu, \sigma)$	InvN(p, σ, μ)
Poisson$(\mu = \lambda \cdot t)$	$P(X = k)$	$\mathrm{poissonpdf}(\mu, k)$	PoissonPD(k, μ)
	$P(X \leq k)$	$\mathrm{poissoncdf}(\mu, k)$	PoissonCD(k, μ)

z-score:

$$z = \frac{x - \mu}{\sigma}$$

Centrale limietstelling:

Gegeven zijn n kansvariabelen $X_1, X_2, \ldots, X_n$, die onderling onafhankelijk zijn en dezelfde kansverdeling volgen met verwachtingswaarde μ en standaardafwijking σ. Er geldt (bij benadering) het volgende:

- de som $\sum_{i=1}^{n} X_i = X_1 + X_2 + \ldots + X_n$ is normaal verdeeld met parameters $n \cdot \mu$ en $\sqrt{n} \cdot \sigma$.
- het gemiddelde $\overline{X} = \frac{X_1 + X_2 + \ldots + X_n}{n}$ is normaal verdeeld met parameters μ en $\frac{\sigma}{\sqrt{n}}$.

Statistiek deel 2:

Betrouwbaarheidsintervallen voor het gemiddelde μ (σ bekend)

- **$100 \cdot (1-\alpha)\%$-betrouwbaarheidsinterval (BI) voor μ:**

$$z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2, \mu = 0, \sigma = 1)$$

$$[\overline{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \quad \overline{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}]$$

- **Minimale steekproefomvang voor $100 \cdot (1-\alpha)\%$-BI als μ maximaal $\pm\, a$ mag afwijken:**

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{a}\right)^2$$

Betrouwbaarheidsintervallen voor het gemiddelde μ (σ onbekend)

- **$100 \cdot (1-\alpha)\%$-betrouwbaarheidsinterval (BI) voor μ:**

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1)$$

$$[\overline{x} - t \cdot \frac{s}{\sqrt{n}}, \quad \overline{x} + t \cdot \frac{s}{\sqrt{n}}]$$

- **Minimale steekproefomvang voor $100 \cdot (1-\alpha)\%$-BI als μ maximaal $\pm\, a$ mag afwijken:**

$$\text{GR tabel (voor verschillende } n\text{):} \quad \frac{s}{\sqrt{n}} \cdot \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1) \leq a$$

NB: zodra $n \geq 30$, vallen de normale en de t-verdeling nagenoeg samen. Je mag dan rekenen met de schatting s (steekproefstandaardafwijking) in plaats van de daadwerkelijke (onbekende) σ.

Betrouwbaarheidsintervallen voor de binomiale succeskans p

Betrouwbaarheidsinterval voor p (Clopper-Pearson): Gegeven een binomiale verdeling met n Bernoulli-experimenten en onbekende p, en uitkomst k.

1. Bereken (met "numeric solver") de succeskans p_1 zodat geldt $P(X \leq k) = \text{binomcdf}(n, p_1, k) = \alpha/2$.
2. Bereken (met "numeric solver") de succeskans p_2 zodat geldt $P(X \geq k) = 1 - \text{binomcdf}(n, p_2, k-1) = \alpha/2$.
3. De berekende waarden voor p_1 en p_2 zijn de grenzen van het Clopper-Pearson interval.

Stappenplan hypothesetoetsen

1. Definieer de nulhypothese H_0 en de alternatieve hypothese H_1.
2. Bepaal het significantieniveau α (kans op onterecht verwerpen van $H_0 \rightarrow$ type-I fout).
3. Verzamel data voor de toetsingsgrootheid.
4. Bereken de toetsingsgrootheid.
5. Bepaal de toetsuitslag (wel of niet verwerpen van H_0).
   - De toetsingsgrootheid volgt, uitgaande van H_0, een bepaalde kansverdeling.
   - Op basis van deze kansverdeling kun je (i) een kritiek gebied bepalen, of (ii) een p-waarde berekenen.
     - Kritiek gebied: verwerp H_0 als de toetsingsgrootheid een waarde aanneemt in het kritiek gebied, anders accepteer H_0.
     - p-waarde: verwerp H_0 als $p \leq \alpha$ (links-/rechtszijdig) of $p \leq \frac{\alpha}{2}$ (tweezijdig), anders accepteer H_0.
6. Vertaal de toetsuitslag naar de originele probleemcontext.

Drie typen hypothesetoetsen: linkszijdig, tweezijdig, rechtszijdig

Linkszijdige toets
Kritiek gebied: $(-\infty, g]$

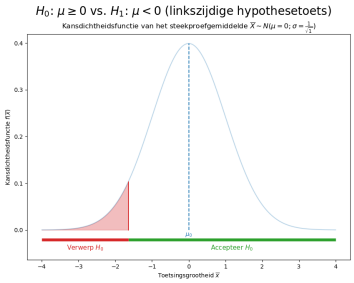

Tweezijdige toets
Kritiek gebied: $(-\infty, g_1]$ en $[g_2, \infty)$

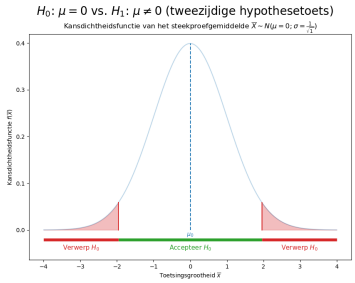

Rechtszijdige toets
Kritiek gebied: $[g, \infty)$

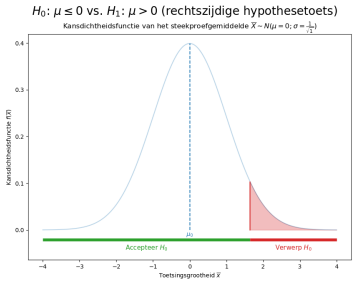

Kritieke gebieden uitrekenen

Kansverdeling (onder H_0)	**Linkszijdig** $(-\infty, g]$	**Tweezijdig** $(-\infty, g_1]$ en $[g_2, \infty)$	**Rechtszijdig** $[g, \infty)$
$N(\mu, \sigma)$	$g = \text{InvNorm}(\alpha, \mu, \sigma)$	$g_1 = \text{InvNorm}(\text{opp} = \frac{\alpha}{2}, \mu, \sigma)$ $g_2 = \text{InvNorm}(\text{opp} = 1 - \frac{\alpha}{2}, \mu, \sigma)$	$g = \text{InvNorm}(1 - \alpha, \mu, \sigma)$
$t(\text{df})$	$g = \text{InvT}(\alpha, \text{df})$	$g_1 = \text{InvT}(\text{opp} = \frac{\alpha}{2}, \text{df})$ $g_2 = \text{InvT}(\text{opp} = 1 - \frac{\alpha}{2}, \text{df})$	$g = \text{InvT}(1 - \alpha, \text{df})$
Grenzen die met de "numeric solver" moeten worden opgelost:			
$\chi^2(\text{df})$	$\chi^2\text{cdf}(0, g, \text{df}) = \alpha$	$\chi^2\text{cdf}(0, g_1, \text{df}) = \frac{\alpha}{2}$ $\chi^2\text{cdf}(g_2, 10^{99}, \text{df}) = \frac{\alpha}{2}$	$\chi^2\text{cdf}(g, 10^{99}, \text{df}) = \alpha$
$F(\text{df}_A, \text{df}_B)$	$\text{Fcdf}(0, g, \text{df}_A, \text{df}_B) = \alpha$	$\text{Fcdf}(0, g_1, \text{df}_A, \text{df}_B) = \frac{\alpha}{2}$ $\text{Fcdf}(g_2, 10^{99}, \text{df}_A, \text{df}_B) = \frac{\alpha}{2}$	$\text{Fcdf}(g, 10^{99}, \text{df}_A, \text{df}_B) = \alpha$

p-waardes uitrekenen (gegeven een theoretische en geobserveerde toetsingsgrootheid T en t)

Kansverdeling (onder H_0)	**Linkszijdig** $(P(T \leq t))$	**Rechtszijdig** $(P(T \geq t))$
$N(\mu, \sigma)$	$p = \text{normalcdf}(-10^{99}, t, \mu, \sigma)$	$p = \text{normalcdf}(t, 10^{99}, \mu, \sigma)$
$t(\text{df})$	$p = \text{tcdf}(-10^{99}, t, \text{df})$	$p = \text{tcdf}(t, 10^{99}, \text{df})$
$\chi^2(\text{df})$	$p = \chi^2\text{cdf}(0, t, \text{df})$	$p = \chi^2\text{cdf}(t, 10^{99}, \text{df})$
$F(\text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(0, t, \text{df}_A, \text{df}_B)$	$p = \text{Fcdf}(t, 10^{99}, \text{df}_A, \text{df}_B)$

NB: bij tweezijdige toetsen is de p-waarde gelijk aan het minimum van de linkszijdige en rechtszijdige p-waarde.

Onderscheidend vermogen $1 - \beta$ van een z-toets voor het gemiddelde μ (gegeven dat $\mu = \mu_1 \neq \mu_0$):

$$1 - \beta = \begin{cases} P(\overline{X} \leq g \mid \mu = \mu_1) = \text{normalcdf}(-10^{99}, g, \mu_1, \frac{\sigma}{\sqrt{n}}) & \text{(linkszijdige toets)} \\ P(\overline{X} \leq g_1 \text{ of } \overline{X} \geq g_2 \mid \mu = \mu_1) = 1 - \text{normalcdf}(g_1, g_2, \mu_1, \frac{\sigma}{\sqrt{n}}) & \text{(tweezijdige toets)} \\ P(\overline{X} \geq g \mid \mu = \mu_1) = \text{normalcdf}(g, 10^{99}, \mu_1, \frac{\sigma}{\sqrt{n}}) & \text{(rechtszijdige toets)} \end{cases}$$

Soorten hypothesetoetsen

Soort toets	Toetsingsgrootheid	Kansverdeling (onder H_0)
Toetsen voor het gemiddelde $\mu \leq \mu_0$ of $\mu = \mu_0$ of $\mu \geq \mu_0$		
z-toets (σ bekend)	$\overline{X}$	$N(\mu_0, \frac{\sigma}{\sqrt{n}})$
t-toets (σ onbekend)	$T = \frac{\overline{X}-\mu_0}{\frac{s}{\sqrt{n}}}$	$t(\text{df} = n-1)$
Chikwadraattoetsen (χ^2)		
Onafhankelijkheid	$X^2 = \sum_{i,j} \frac{(O_{ij}-E_{ij})^2}{E_{ij}}$	$\chi^2(\text{df} = (\#\text{rijen-1}) \cdot (\#\text{kolommen-1}))$
Aanpassing (goodness-of-fit)	$X^2 = \sum_i \frac{(O_i-E_i)^2}{E_i}$	$\chi^2(\text{df} = (\#\text{categorieën-1}))$
Verschiltoetsen (op basis van twee populaties A en B)		
F-toets: $\sigma_A^2 = \sigma_B^2$	$F = \frac{S_A^2}{S_B^2}$	$F(\text{df}_A, \text{df}_B)$
z-toets	$V = \overline{X_A} - \overline{X_B}$	$N\left(\mu_A - \mu_B, \sqrt{\frac{\sigma_A^2}{n} + \frac{\sigma_B^2}{m}}\right)$
t-toets (geval $\sigma_A^2 = \sigma_B^2$)	$T = \frac{(\overline{X_A}-\overline{X_B})-(\mu_A-\mu_B)}{\sqrt{\frac{S_P^2}{n}+\frac{S_P^2}{m}}}$	$t(\text{df} = n+m-2)$
t-toets (geval $\sigma_A^2 \neq \sigma_B^2$)	$T = \frac{(\overline{X_A}-\overline{X_B})-(\mu_A-\mu_B)}{\sqrt{\frac{S_A^2}{n}+\frac{S_B^2}{m}}}$	$t(\text{df} = \min(n-1, m-1))$

Beslisboom hypothesetoetsen

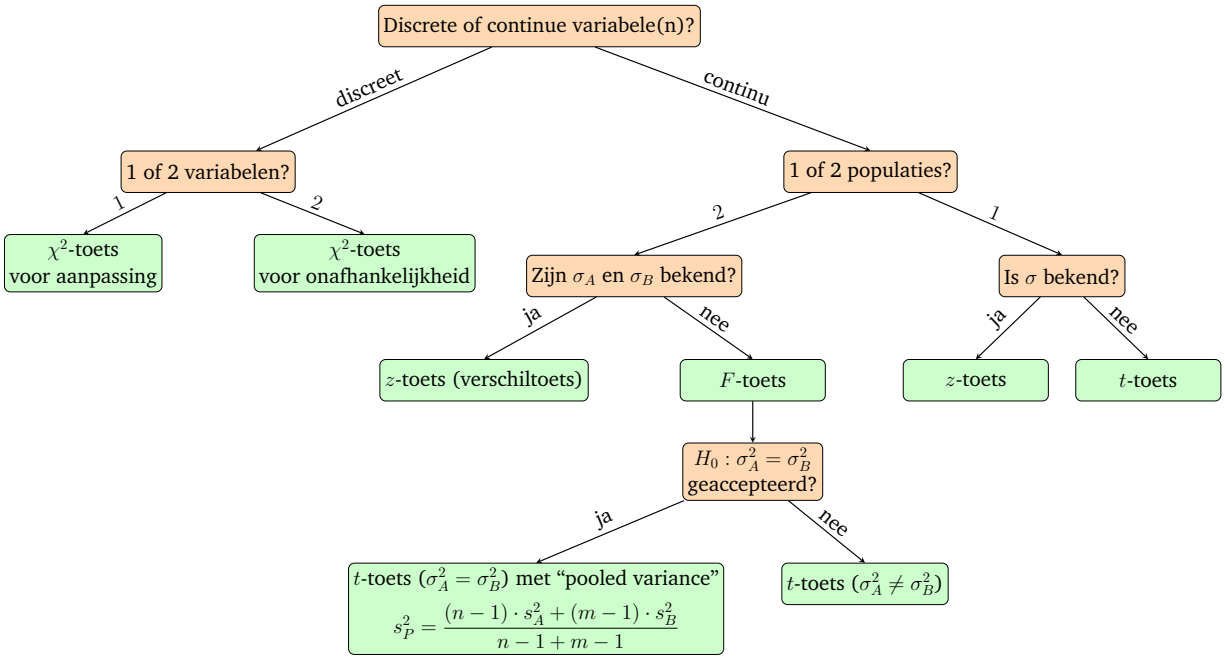

Correlatie en regressie

Correlatiecoëfficiënt van Pearson:

$$r = \frac{\overline{xy} - \overline{x} \cdot \overline{y}}{\sqrt{(\overline{x^2} - \overline{x}^2) \cdot (\overline{y^2} - \overline{y}^2)}}$$

Correlatiecoëfficiënt van Spearman:

$$r_s = 1 - \frac{6 \cdot \sum_i d_i^2}{n^3 - n}$$

Coëfficiënten van de lineaire regressielijn $Y = a + b \cdot X$:

$$b = \frac{\overline{xy} - \overline{x} \cdot \overline{y}}{\overline{x^2} - (\overline{x})^2}$$
$$a = \overline{y} - b \cdot \overline{x}$$

Schatting van de variantie van de storingsterm ε:

$$s_\varepsilon^2 = \frac{\sum e_i^2}{n-2} = \frac{\sum \left(y_i - (a + b \cdot x_i)\right)^2}{n-2} = \frac{n}{n-2} \cdot \left(\overline{y^2} - a \cdot \overline{y} - b \cdot \overline{xy}\right)$$

$100 \cdot (1 - \alpha)$%-betrouwbaarheidsinterval voor de gemiddelde Y bij een gegeven $X = x_0$:

$$t = \mathrm{InvT}(\text{opp} = 1 - \alpha/2, \text{df} = n - 2)$$

$$s_\mu = s_\varepsilon \cdot \sqrt{\frac{1}{n} \cdot \left(1 + \frac{(x_0 - \overline{x})^2}{\overline{x^2} - \overline{x}^2}\right)}$$

$$[a + b \cdot x_0 - t \cdot s_\mu, \quad a + b \cdot x_0 + t \cdot s_\mu]$$

$100 \cdot (1 - \alpha)$%-betrouwbaarheidsinterval voor Y bij een gegeven $X = x_0$:

$$t = \mathrm{InvT}(\text{opp} = 1 - \alpha/2, \text{df} = n - 2)$$

$$s_f = s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \overline{x})^2}{\overline{x^2} - \overline{x}^2}\right)}$$

$$[a + b \cdot x_0 - t \cdot s_f, \quad a + b \cdot x_0 + t \cdot s_f]$$