

Statistiek

Uitwerkingen van huiswerkopgaven

Dr. ir. D.A.M.P. Blom

Nederlandse Defensie Academie

2025 – 2026

Inhoudsopgave

Inhoudsopgave	i
1 Grondslagen statistiek en datavisualisatie	1
2 Discrete kansvariabelen	19
3 Continue kansvariabelen	39
4 De binomiale verdeling	53
5 De normale verdeling en de centrale limietstelling	63
6 De Poissonverdeling	75
7 Schatten en betrouwbaarheid (1/2)	87
8 Schatten en betrouwbaarheid (2/2)	97
9 Hypothesetoetsen	115
10 De chikwadraatverdeling	129
11 Verschiltoetsen	149
12 Correlatie en regressie	167

Week **1**

Grondslagen statistiek en datavisualisatie

Hoofdstuk 1

Opdracht 1.m1: Bij een verkeersonderzoek is een van de grootheden die wordt genoteerd het merk van de passerende auto's. Dit merk is ...

- (a) een ratiovariabele
- (b) een kwantitatieve variabele
- (c) een nominale variabele.
- (d) geen variabele

Uitwerking

Het merk van een passerende auto is een categorische variabele. Je kunt merken niet ten opzichte van elkaar ordenen, dus kan het niet het ordinale meetniveau hebben. Het juiste antwoord is dus (c).

Gegevens voor de vragen m2 en m3

Bij een straatenquête werden 250 voorbijgangers gevraagd naar hun mening over een aantal door de gemeente voorgestelde verkeersmaatregelen. De resultaten staan in de volgende tabel:

	Mee eens	Geen mening	Oneens	Totaal
Man	25	35	50	110
Vrouw	35	55	50	140
Totaal	60	90	100	250

Opdracht 1.m2: Zie tabel. Bij de mannen is het percentage dat het eens is met de voorgestelde maatregelen gelijk aan ...

- (a) 41.7 %
- (b) 10 %
- (c) 25 %
- (d) 22.7 %

Uitwerking

Uit de tabel is op te maken dat 25 van de 110 mannen het met de verkeersmaatregelen eens is, oftewel $\frac{25}{110} \cdot 100 \% \approx 22.7 \%$. Het juiste antwoord is dus (d).

Opdracht 1.m3: Zie tabel. De groep mensen die het oneens is met de maatregelen bestaat voor ... uit vrouwen.

- (a) 20 %
- (b) 56 %
- (c) 50 %
- (d) 40 %

Uitwerking

Uit de tabel is op te maken dat onder de 100 mensen die het met de verkeersmaatregelen oneens zijn zich 50 vrouwen bevinden. Dit komt neer op een percentage van $\frac{50}{100} \cdot 100 \% = 50 \%$. Het juiste antwoord is dus (c).

Opdracht 1.3: Geef voor elk van de volgende gevallen aan of de genoemde verzameling als een steekproef of als een populatie mag worden beschouwd:

- (a) de commissarissen van de koning van de 12 Nederlandse provincies
- (b) de 200 personen die zijn geïnterviewd bij een stratenquête
- (c) de 150 automobilisten die moesten stoppen voor een alcoholcontrole
- (d) de 740 leden van een studentenvereniging
- (e) de 38 klanten die tussen 11.00 en 12.00 uur een postkantoor binnenkomen
- (f) de 12000 verzekerden bij een verzekeringsmaatschappij
- (g) de 20 nummers die worden gedraaid in een muziekprogramma op de radio

Uitwerking

- (a) Populatie
- (b) Steekproef
- (c) Steekproef
- (d) Populatie
- (e) Steekproef
- (f) Populatie
- (g) Steekproef

Opdracht 1.4: Geef voor de volgende variabelen aan of deze een nominale, ordinale, interval- of ratioschaal heeft:

- (a) de speelduur van een dvd
- (b) de kleur van tulpen
- (c) de industrietak waarin werknemers een baan hebben
- (d) de jaaromzet (in euro) van bedrijven
- (e) het aantal sterren dat de moeilijkheidsgraad van puzzelboekjes aangeeft
- (f) de hoogte boven de zeespiegel van wintersportdorpen

Uitwerking

- (a) Speelduur DVD: ratiovariabele
- (b) Kleur tulpen: nominale variabele
- (c) Industrietak: nominale variabele
- (d) Jaaromzet: ratiovariabele
- (e) Aantal sterren moeilijkheidsgraad: ordinale variabele
- (f) Hoogte boven zeespiegel: intervalvariabele (merk op dat de zeespiegel een arbitrair gekozen nulpunt is, waardoor er eigenlijk geen absoluut nulpunt is.)

Opdracht 1.7: Een groep van dertig eerstejaarsstudenten is een aantal vragen voorgelegd. Dit betrof:

- Leeftijd
- Woonsituatie (z=zelfstandig, o=bij ouders)

- Geslacht (m=man, v=vrouw)
- De maandelijkse bestedingen aan voedsel en drank
- De score voor het tentamen statistiek

In het boek staan de resultaten in een tabel beschreven.

(a) Geef aan op welk type schaal de vijf variabelen worden gemeten.

Uitwerking

De vijf variabelen kunnen we als volgt classificeren op meetniveau:

Leeftijd: ratio

Woonsituatie: nominaal

Geslacht: nominaal

Besteding: ratio

Score: ratio


(b) Maak een frequentieverdeling van de leeftijden.

Uitwerking

Leeftijd	Frequentie
18	2
19	5
20	6
21	6
22	5
23	3
24	1
25	1
26	1
Totaal	30

(c) Teken een histogram van de bestedingen. Begin met ondergrens €250.

Uitwerking



- (d) Maak een klassenindeling van de scores voor mannen en vrouwen afzonderlijk. Kies voor de klassen 10 eenheden en verwerk de resultaten in een kruistabel. Bereken ook de procentuele frequenties van de scoreklassen voor de mannen en vrouwen afzonderlijk.

Uitwerking

De absolute frequentieverdeling van de scoreklassen naar geslacht is gelijk aan

Scoreklasse	Man	Vrouw
[30, 40)	1	0
[40, 50)	1	5
[50, 60)	3	0
[60, 70)	4	2
[70, 80)	2	4
[80, 90)	4	1
[90, 100)	3	0
Totaal	18	12

We bekijken de frequenties afzonderlijk voor mannen en vrouwen, en berekenen de relatieve frequenties binnen de twee populaties afzonderlijk. De relatieve frequentieverdeling van de scoreklassen naar geslacht is dan gelijk aan

Scoreklasse	Man	Vrouw
[30, 40)	5.6 %	0.0 %
[40, 50)	5.6 %	41.7 %
[50, 60)	16.7 %	0.0 %
[60, 70)	22.2 %	16.7 %
[70, 80)	11.1 %	33.3 %
[80, 90)	22.2 %	8.3 %
[90, 100)	16.7 %	0.0 %
Totaal	100 %	100 %

- (e) Maak een kruistabel waarin de waarnemingen worden verdeeld naar geslacht en woonsituatie.

Uitwerking


De kruistabel voor geslacht en woonsituatie is gelijk aan

Geslacht	Zelfstandig	Bij ouders	Totaal
Man	6	12	18
Vrouw	9	3	12
Totaal	15	15	30

- (f) Teken een spreidingsdiagram met “leeftijd” langs de horizontale as en “score” langs de verticale as.

Uitwerking

Het spreidingsdiagram van leeftijd (X) versus score (Y) ziet er als volgt uit:



Merk op dat de assen in het diagram niet op dezelfde schaal zijn en niet bij nul beginnen. Deze keuze is gemaakt om de punten beter zichtbaar te maken, aangezien de leeftijden en scores zich in verschillende bereiken bevinden.

Opdracht 1.15: Bij een verkeerscontrole zijn de banden van 200 auto's gecontroleerd. Hierbij werd het profiel gemeten in mm. Een en ander leidde tot de volgende frequentieverdeling (zie de tabel).

Gemeten profiel (in mm)	Aantal auto's
0.00– < 2.00	4
2.00– < 4.00	34
4.00– < 6.00	82
6.00– < 8.00	66
8.00– < 10.00	14


(a) Geef de waargenomen verdeling weer door middel van een cumulatieve frequentiecurve.

Uitwerking

De cumulatieve frequentieverdeling is als volgt:

Gemeten profiel (in mm)	Cumulatief aantal auto's
0.00 – < 2.00	4
2.00 – < 4.00	38
4.00 – < 6.00	120
6.00 – < 8.00	186
8.00 – < 10.00	200
Totaal	200


De cumulatieve frequentiecurve ziet er als volgt uit:



- (b) Probeer met de grafiek te schatten hoe groot het aantal auto's is met een profiel van minder dan 5.00 mm. (N.B.: in deze opgave mag men veronderstellen dat de klassengrenzen exact zijn, dus er hoeven geen correcties met "halfjes" uitgevoerd te worden.)

Uitwerking

De schatting voor het aantal auto's met hoogstens een profiel van 5.00 mm vinden we door te interpoleren op de cumulatieve frequentiecurve van opgave (a). Dit ziet er als volgt uit:



Naar schatting zullen er dus 79 auto's zijn met een profiel van hoogstens 5.00 mm dikte.

Hoofdstuk 2

Opdracht 2.m1: De mediaan van een even aantal waarnemingen is gelijk aan ...

- (a) de gemiddelde uitkomst.
- (b) de hoogste minus de laagste waarneming gedeeld door twee.
- (c) het gemiddelde van de middelste twee waarnemingen na ordening.
- (d) het getal dat het meeste blijkt te zijn waargenomen.

Uitwerking

Bij een even aantal waarnemingen is de mediaan het gemiddelde van de middelste twee waarnemingen na ordening. Het juiste antwoord is (c).

Opdracht 2.m2: Het gemiddelde maandinkomen van een groep van 15 net afgestudeerde hbo'ers is 1.850 euro per maand. Er blijkt nog een zestiende persoon tot die groep te behoren. Zijn maandinkomen bedraagt 2170 euro. Van de totale groep van zestien personen is het gemiddelde inkomen dus

- (a) 2010 euro
- (b) 1870 euro
- (c) 2150 euro

(d) niet te berekenen

Uitwerking

Merk op dat het gemiddelde van de eerste 15 personen 1.850 euro is, en het totale inkomen van deze 15 personen dus $15 \times 1.850 = 27.750$ euro bedraagt. Tel hierbij het inkomen van de zestiende persoon op: $27.750 + 2.170 = 29.920$ euro. Het gemiddelde inkomen van de totale groep van deze 16 personen is dus $\frac{29.920}{16} = 1.870$ euro. Het juiste antwoord is dus (b).

Opdracht 2.m4: De variantie is ...

- (a) slecht hanteerbaar als maatstaf voor spreiding.
- (b) de wortel uit de standaarddeviatie.
- (c) een grootheid die wordt opgebouwd uit gekwadrateerde afwijkingen van een waarneming ten opzichte van het gemiddelde.
- (d) het kwadraat van de gemiddelde afwijking.

Uitwerking

De variantie is een grootheid die wordt opgebouwd uit gekwadrateerde afwijkingen van elke waarneming ten opzichte van het gemiddelde. Het juiste antwoord is (c).

Opdracht 2.m5: Voor een steekproef van 500 werknemers van een groot concern is in 2001 de verdeling van de jaarinkomens onderzocht. Hierbij bleek dat de standaarddeviatie van de inkomens 7.500 guldens bedroeg. Ter wille van een internationale publicatie moeten de gegevens worden uitgedrukt in euro's (1 euro = afgerond 2.20 gulden). De standaarddeviatie gemeten in euro's bedraagt dus ...

- (a) 16.500
- (b) 36.300
- (c) 3.409
- (d) 1.100

Uitwerking

De standaarddeviatie in euro's wordt berekend door de standaarddeviatie in guldens te delen door de wisselkoers:

$$s_{\text{euro}} = \frac{s_{\text{gulden}}}{2,20} = \frac{7.500}{2.20} \approx 3.409.$$

Het juiste antwoord is dus (c).

Opdracht 2.m6: In een boxplot kan men diverse kenmerken van een frequentieverdeling aflezen. Wat kan men hierin echter *niet* aflezen?

- (a) de mediaan
- (b) het rekenkundig gemiddelde
- (c) het eerste kwartiel
- (d) de hoogste waarneming

Uitwerking

Een boxplot heeft informatie over vijf beschrijvende statistieken: de laagste waarneming, het eerste kwartiel, de mediaan, het derde kwartiel en de hoogste waarneming. Het rekenkundig gemiddelde is echter niet af te lezen uit een boxplot. Het juiste antwoord is (b).

Opdracht 2.1: Aan 20 personen die allemaal 40 jaar oud zijn, is gevraagd hoeveel jaar zij volledig dagonderwijs hebben genoten sinds hun eerste levensjaar. De resultaten waren als volgt:

Aantal jaren dagonderwijs van 20 personen

10	16	18	16	13	21	18	20	12	15
12	9	14	10	15	12	19	12	13	10

- (a) Bereken voor deze groep van 20 personen het rekenkundig gemiddelde van het aantal jaren op school.

Uitwerking

Voor de berekening van het rekenkundig gemiddelde van 20 waarden geldt de volgende formule:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{x_1 + x_2 + \dots + x_{20}}{20}$$

De 20 uitkomsten leveren gesommeerd:

$$\sum_i x_i = x_1 + x_2 + \dots + x_{20} = 10 + 16 + \dots + 10 = 285$$

Voor het rekenkundig gemiddelde vinden we dan:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_{20}}{20} = \frac{285}{20} = 14.25.$$

- (b) Bereken de mediaan.

Uitwerking

Om de mediaan te kunnen bepalen, zetten we de getallen op volgorde. Dit levert:

<i>Aantal jaren dagonderwijs van 20 personen</i>									
9	10	10	10	12	12	12	12	13	13
14	15	15	16	16	18	18	19	20	21

Omdat we hier een even aantal uitkomsten hebben, geldt als mediaan het gemiddelde van de twee middelste uitkomsten, oftewel:

$$\text{mediaan} = \frac{13 + 14}{2} = 13.5.$$

(c) Bepaal de modus.

Uitwerking

In het geval van afzonderlijke waarnemingen zoals hier, is de modus gedefinieerd als de uitkomst met de hoogste frequentie. Inspectie van de uitkomsten levert ons dat de uitkomst 12 het meeste voorkomt. De modus is dus 12, deze komt namelijk vier keer voor, meer dan welke andere uitkomst.

Opdracht 2.9: Een groep van 10 studenten behaalde de volgende scores bij een examen:

45, 60, 82, 32, 25, 75, 65, 66, 70, 80

(a) Bereken het rekenkundig gemiddelde, de mediaan en de standaarddeviatie voor deze gegevens.

Uitwerking

Het rekenkundig gemiddelde wordt berekend met:

$$\bar{x} = \frac{\sum x_i}{n} = \frac{45 + 60 + \dots + 80}{10} = \frac{600}{10} = 60$$

De mediaan wordt gevonden door eerst de scores te sorteren:

25, 32, 45, 60, 65, 66, 70, 75, 80, 82

Omdat er een even aantal scores is, bekijken we het gemiddelde van de middelste twee waarden:

$$\text{med}(x) = \frac{x_5 + x_6}{2} = \frac{65 + 66}{2} = 65.5$$

Omdat we te maken hebben met een steekproef, wordt de variantie berekend met:

$$\begin{aligned}
 s^2 &= \frac{1}{n-1} \cdot \sum (x_i - \bar{x})^2 \\
 &= \frac{1}{10-1} \cdot ((45-60)^2 + (60-60)^2 + \dots + (80-60)^2) \\
 &= \frac{1}{9} \cdot 3504 \\
 &= \frac{3504}{9}
 \end{aligned}$$

De standaarddeviatie vinden we door de wortel uit de variantie te nemen:

$$s = \sqrt{s^2} = \sqrt{\frac{3504}{9}} \approx 19.7315$$

- (b) Er wordt besloten alle studenten 10 punten extra te geven. Wat is het gevolg van deze maatregel voor de bij vraag (a) berekende maatstaven.

Uitwerking

Rekenkundig gemiddelde: als alle scores met 10 worden verhoogd, dan wordt het rekenkundig gemiddelde ook met 10 verhoogd.

Mediaan: als alle scores met 10 worden verhoogd, dan geldt dit specifiek ook voor de middelste twee scores (merk op dat de volgorde gelijk blijft!). De mediaan is het gemiddelde van de twee middelste scores, dus de mediaan wordt ook verhoogd met 10.

Standaarddeviatie: als alle scores met 10 worden verhoogd, dan blijft de spreiding van de scores gelijk, alleen met 10 naar rechts verschoven. De standaarddeviatie blijft in dat geval dus hetzelfde.

- (c) In plaats van 10 punten voor iedereen erbij (vraag b) wordt besloten de kandidaten allemaal een 10 % hogere score te geven dan zij oorspronkelijk gehaald hebben. Wat is de invloed van deze maatregel op de onder (a) berekende grootheden?

Uitwerking

Rekenkundig gemiddelde: als alle scores met 10 % worden verhoogd, dan wordt het rekenkundig gemiddelde ook met 10% verhoogd.

Mediaan: als alle scores met 10 % worden verhoogd, dan geldt dit specifiek ook voor de middelste twee scores (merk op dat de volgorde gelijk blijft!). De mediaan is het gemiddelde van de twee middelste scores, dus de mediaan wordt ook verhoogd met 10 %.

Standaarddeviatie: als alle scores met 10 % worden verhoogd, dan wordt de spreiding van de scores groter. Merk op dat voor elke term $(x_i - \bar{x})^2$ in de formule van

de variantie in deze nieuwe situatie moet worden vervangen door

$$(1.1 \cdot x_i - 1.1 \cdot \bar{x})^2 = (1.1 \cdot (x_i - \bar{x}))^2 = 1.1^2 \cdot (x_i - \bar{x})^2 = 1.21 \cdot (x_i - \bar{x})^2$$

De variantie stijgt dus met een factor 1.21, en de standaarddeviatie met een factor $\sqrt{1.21} = 1.1$ (stijging van 10 %).

Opdracht 2.10: In een gemeente is bijgehouden hoe de prijsontwikkeling is van woningen. Hierbij wordt een onderscheid gemaakt naar het type woning. De volgende resultaten zijn verzameld over het afgelopen jaar. Prijsverandering geeft het verschil aan tussen huidige verkoopprijzen en de prijzen van een jaar geleden.

Type woning	Aantal verkocht	Aantal aanwezig	Prijsverandering
Villa	14	280	+5 %
Rijthuis	130	1.600	+2.4 %
Appartement	48	450	+1.6 %
Twee onder een kap	26	500	+7.2 %
Serviceflat	28	140	-2.5 %

- (a) Bereken voor deze gemeente de gemiddelde prijsverandering van de verkochte huizen.

Uitwerking

De gemiddelde prijsverandering van de verkochte huizen wordt berekend als een gewogen gemiddelde:

$$\bar{x} = \frac{14 \cdot 5 + 130 \cdot 2.4 + 48 \cdot 1.6 + 26 \cdot 7.2 + 28 \cdot (-2.5)}{14 + 130 + 48 + 26 + 28} = \frac{576}{246} \approx 2.3415.$$

Gemiddeld is de prijs van de verkochte huizen dus met ongeveer 2.34 % gestegen.

- (b) Bereken op basis van de gegevens de gemiddelde waardeverandering van het totale woningbestand op basis van weging met het aantal aanwezige huizen.

Uitwerking

De gemiddelde waardeverandering van het totale woningbestand wordt berekend als een gewogen gemiddelde:

$$\begin{aligned} \bar{x} &= \frac{280 \cdot 5 + 1600 \cdot 2.4 + 450 \cdot 1.6 + 500 \cdot 7.2 + 140 \cdot (-2.5)}{280 + 1600 + 450 + 500 + 140} \\ &= \frac{9210}{2970} \\ &\approx 3.1010. \end{aligned}$$

Gemiddeld is de waarde van het totale woningbestand dus met ongeveer 3.10 % gestegen.

Opdracht 2.20: Bij een onderzoek in opdracht van Horeca Nederland werd onderzocht hoeveel geld mensen uitgeven aan eten buiten de deur. Twee groepen werden onderscheiden, namelijk studenten die zelfstandig wonen en afgestudeerden met minstens twee jaar werkervaring. De resultaten waren als volgt:

Uitgaven voor 30 studenten (euro per maand)
72, 51, 146, 30, 28, 88, 92, 47, 52, 68, 80, 34, 28, 105, 76, 93, 55, 40, 62, 37, 88, 30, 122, 46, 35, 29, 77, 40, 71, 57
Uitgaven voor 40 afgestudeerden (euro per maand)
88, 130, 255, 56, 0, 38, 167, 188, 132, 147, 78, 80, 40, 170, 280, 46, 174, 182, 75, 89, 103, 230, 380, 57, 55, 90, 96, 102, 78, 69, 53, 160, 195, 245, 60, 94, 145, 115, 225, 71

(a) Bereken voor beide groepen het gemiddelde en de mediaan.

Uitwerking

Het gemiddelde wordt berekend als:

$$\bar{x} = \frac{\sum x_i}{n}$$

Voor de groep studenten is het gemiddelde gelijk aan:

$$\bar{x}_{\text{stud}} = \frac{72 + 51 + \dots + 57}{30} \approx 62.6333.$$

Voor de groep afgestudeerden is het gemiddelde gelijk aan:

$$\bar{x}_{\text{afg}} = \frac{88 + 130 + \dots + 71}{40} \approx 125.9500.$$

Aangezien voor beide groepen geldt dat het aantal waarnemingen even is, bekijken we het gemiddelde van de twee middelste waarden. Voor de groep studenten is de gesorteerde lijst van waarnemingen gelijk aan:

28, 28, 29, 30, 30, 34, 35, 37, 40, 40, 46, 47, 51, 52, 55, 57, 62, 68, 71, 72, 76, 77, 80
88, 88, 92, 93, 105, 122, 146

De mediaan is gelijk aan het gemiddelde van de twee middelste waarden, oftewel:

$$\text{med}(\text{stud}) = \frac{55 + 57}{2} = 56.$$

Voor de groep afgestudeerden is de gesorteerde lijst van waarnemingen gelijk aan:

0, 38, 40, 46, 53, 55, 56, 57, 60, 69, 71, 75, 78, 78, 80, 88, 89, 90, 94, 96, 102,
103, 115, 130, 132, 145, 147, 160, 167, 170, 174, 182, 188, 195, 225, 230, 245,
255, 280, 380

De mediaan is gelijk aan het gemiddelde van de twee middelste waarden, oftewel:

$$\text{med}(\text{afg}) = \frac{96 + 102}{2} = 99.$$

(b) Bereken voor beide groepen de standaarddeviatie.

Uitwerking

De variantie wordt berekend als

$$s^2 = \frac{1}{n-1} \cdot \sum_i (x_i - \bar{x})^2$$

Voor de groep studenten is de variantie gelijk aan

$$\begin{aligned} s_{\text{stud}}^2 &= \frac{1}{30-1} \cdot ((72 - 62.6333)^2 + \dots + (57 - 62.6333)^2) \\ &\approx 896.5161. \end{aligned}$$

De standaarddeviatie is de wortel uit de variantie, oftewel

$$s_{\text{stud}} = \sqrt{s_{\text{stud}}^2} = \sqrt{896.5161} \approx 29.9419.$$

Voor de groep afgestudeerden is de variantie gelijk aan

$$\begin{aligned} s_{\text{afg}}^2 &= \frac{1}{40-1} \cdot ((88 - 125.9500)^2 + (130 - 125.9500)^2 + \dots \\ &\quad + (71 - 125.9500)^2) \\ &\approx 6255.9974. \end{aligned}$$

De standaarddeviatie is de wortel uit de variantie, oftewel

$$s_{\text{afg}} = \sqrt{s_{\text{afg}}^2} = \sqrt{6255.9974} \approx 79.0949.$$

(c) Bepaal voor beide groepen een boxplot. Zijn er uitbijters?

Uitwerking

De interkwartielafstand (interquartile range) IQR wordt berekend als:

$$\text{IQR} = Q_3 - Q_1$$

Voor studenten:

$$Q_1 = 37, \quad Q_3 = 80 \Rightarrow \text{IQR}_{\text{stud}} = 43$$

Voor afgestudeerden:

$$Q_1 = 70, \quad Q_3 = 172 \Rightarrow \text{IQR}_{\text{afg}} = 102$$

Uitbijters worden gedefinieerd als waarden buiten:

$$[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$$


Voor studenten:

$$[37 - 1.5 \times 43, 80 + 1.5 \times 43] = [-27.5, 144.5] \quad \text{Outliers: 146}$$

Voor afgestudeerden:

$$[70 - 1.5 \times 102, 172 + 1.5 \times 102] = [-83, 325] \quad \text{Outliers: 380}$$

De boxplots voor studenten en afgestudeerden zien er als volgt uit:



(d) Schrijf een korte notitie waarin het verschil wordt toegelicht tussen beide groepen.

Uitwerking

Afgestudeerden geven gemiddeld significant meer geld uit aan eten buiten de deur dan studenten. Dit verschil kan worden verklaard door hun hogere inkomen, stabiliteit en veranderde eetgewoonten. Daarnaast is de spreiding bij afgestudeerden aanzienlijk groter, wat betekent dat sommige individuen zeer hoge uitgaven hebben. De boxplot-analyse bevestigt dat er een uitbijter in de groep van afgestudeerden aanwezig is (380 euro), wat mogelijk iemand is met uitzonderlijke uitgavenpatronen.

Week 2

Discrete kansvariabelen

Hoofdstuk 3

Opdracht 3.11: Bij een exameninstituut voor rijexamens zijn drie examinatoren in dienst: Dirk, Judith en Ilse. Van alle kandidaten doet 40 % examen bij Dirk, 40 % doet examen bij Judith en 20 % bij Ilse. Bekend is dat het slagingspercentage voor de drie examinatoren verschilt. Dat is 40 % bij Dirk, 60 % bij Judith en 70 % bij Ilse.

- (a) Kandidaat Peter van der Meer gaat rijexamen doen bij een van de drie examinatoren. Hoe groot is de kans dat hij slaagt?

Uitwerking

We bekijken de gezamenlijke kansverdeling van de variabelen “examinator” en “resultaat van het examen”. Hiertoe moeten we een kruistabel opstellen om de discrete kansen te berekenen. De rijtotalen zijn gegeven in de vraag (namelijk de verdeling van kandidaten over de drie examinatoren):

Examinator	wel geslaagd	niet geslaagd	Totaal
Dirk			40 %
Judith			40 %
Ilse			20 %
Totaal			100 %

Vervolgens verdelen we per rij het rijtotaal over de cellen in de rij, gebaseerd op de slagingskansen bij iedere examiner:

Examinator	wel geslaagd	niet geslaagd	Totaal
Dirk	40 % van 40 % = 16 %	60 % van 40 % = 24 %	40 %
Judith	60 % van 40 % = 24 %	40 % van 40 % = 16 %	40 %
Ilse	70 % van 20 % = 14 %	30 % van 20 % = 6 %	20 %
Totaal			100 %

Op basis van deze tabel kunnen we ook de kolomtotalen bepalen (oftewel de kansen dat een kandidaat slaagt of niet slaagt, ongeacht de examinator):

Examinator	wel geslaagd	niet geslaagd	Totaal
Dirk	16 %	24 %	40 %
Judith	24 %	16 %	40 %
Ilse	14 %	6 %	20 %
Totaal	54 %	46 %	100 %

Uit deze tabel kunnen we ook aflezen dat 54 % van de kandidaten slaagt, dus de kans dat Peter slaagt gelijk is aan 0.54.

- (b) Kandidaat Peter blijkt geslaagd te zijn. Hoe groot is de kans dat hij examen heeft afgelegd bij Ilse?

Uitwerking

We kunnen opnieuw de kruistabel voor de gezamenlijke kansverdeling gebruiken om deze kans te bepalen. Uit de tabel kunnen we aflezen dat 54 % van alle kandidaten slaagt, en dat 14 % van alle kandidaten slaagt en Ilse als examinator heeft. De kans dat Peter examen heeft afgelegd bij Ilse, gegeven dat hij is geslaagd, is dus gelijk aan $\frac{14}{54} \approx 0.2593$.

Sommige gezakte kandidaten dienen een klacht in over het examen. Op basis van ervaring weten we dat 10 % van de gezakten van examinator Dirk een klacht indient. Bij Judith is dat 6 % en bij Ilse is dat 3 %.

- (d) Er komt een klacht binnen over het examen zonder vermelding van de naam van de examinator. Hoe groot is de kans dat de klacht over Dirk gaat?

Uitwerking

De relatieve frequenties van combinaties van uitkomsten voor de variabelen “examinator” en “resultaat van het examen” zijn als volgt:

Examinator	wel geslaagd	niet geslaagd	Totaal
Dirk	16 %	24 %	40 %
Judith	24 %	16 %	40 %
Ilse	14 %	6 %	20 %
Totaal	54 %	46 %	100 %

Het percentage deelnemers dat zakt en een klacht over Dirk instuurt is dus 10 % van 24 % = 2.4 %. Daarnaast is het percentage deelnemers dat zakt en een klacht instuurt (over alle examinatoren) gelijk aan

$$\begin{aligned}
 &10 \% \text{ van } 24 \% + 6 \% \text{ van } 16 \% + 3 \% \text{ van } 6 \% \\
 &= 2.4 \% + 0.96 \% + 0.18 \% \\
 &= 3.54 \%.
 \end{aligned}$$

De kans dat een klacht over Dirk gaat is dus gelijk aan $\frac{2.4\%}{3.54\%} \approx 0.6779$.

Opdracht 3.24: In een fabriek wordt de kwaliteit gecontroleerd van de uitgaande producten. De employé die de controle verrichtte, blijkt 1 % van alle goede producten af te keuren en verder keurt hij 5 % van alle slechte producten goed. De totale productie bestaat voor 90 % uit goede producten.

- (a) Bereken de kans dat een willekeurig product goed is en wordt goedgekeurd.

Uitwerking

We beschrijven de relatieve frequenties in een tabel:

	Goedgekeurd	Afgekeurd	Totaal
Goed product	99 % van 90 % = 89.1 %	1 % van 90 % = 0.9 %	90 %
Slecht product	5 % van 10 % = 0.5 %	95 % van 10 % = 9.5 %	10 %
Totaal	89.6 %	10.4 %	100 %

Uit de cel voor “goed product” en “goedgekeurd” is af te lezen dat 89.1 % van de producten goed zijn en worden goedgekeurd, oftewel de kans is 0.891.

- (b) Hoe groot is de kans dat de controleur voor een willekeurig product de verkeerde beslissing neemt?

Uitwerking

Deze kans kunnen we opnieuw aflezen uit de tabel, namelijk de som van kansen voor de combinaties (“goed product”, “afgekeurd”) en (“slecht product”, “goedgekeurd”). Uit de tabel is af te lezen dat $0.9\% + 0.5\% = 1.4\%$ van de producten een verkeerde beslissing oplevert, oftewel de kans is 0.014.

(c) Hoe groot is het percentage goedgekeurde producten dat de fabriek verlaat?

Uitwerking

Deze kans kunnen we opnieuw aflezen uit de tabel, namelijk het kolomtotaal voor de kolom “goedgekeurd”. Hieruit volgt dat 89.6% van de producten wordt goedgekeurd.

Hoofdstuk 4

Opdracht 4.m1: We besluiten driemaal een muntstuk op te gooien en we tellen het aantal malen dat de uitkomst “kop” verschijnt. Dit aantal malen “kop” ...

- (a) is geen kansvariabele, omdat de uitkomsten “kop” en “munt” geen getallen zijn.
- (b) is een continue kansvariabele, omdat dit spelletje eindeloos vaak kan worden herhaald.
- (c) laat altijd een waarde tussen 1 en 3 zien.
- (d) is een discrete variabele, omdat slechts eindig veel uitkomsten hiervoor mogelijk zijn.

Uitwerking

Aangezien we hier een aantal keer “kop” tellen, hebben we te maken met een discrete variabele. Omdat we driemaal een muntstuk gooien, zijn er slechts eindig veel uitkomsten mogelijk (namelijk 0, 1, 2 of 3 keer “kop”). Het juiste antwoord is dus (d).

Opdracht 4.m2: Voor de populatie Nederlandse hbo-studenten is vastgesteld dat het aantal verschillende statistiekboeken waaruit zij wel eens hebben gestudeerd, kan worden beschreven door een kansvariabele X die in de volgende tabel is weergegeven

Aantal boeken (k)	0	1	2	3	4
$P(X = k)$	0.15	0.40	0.30	0.10	0.05

De kans dat een willekeurige student heeft gestudeerd uit minstens twee statistiekboeken is daardoor gelijk aan ...

- (a) 0.30
- (b) 0.85

(c) 0.45

(d) 0.15

Uitwerking

De kans dat een willekeurige student heeft gestudeerd uit minstens twee statistiekboeken is gelijk aan:

$$P(X \geq 2) = P(X = 2) + P(X = 3) + P(X = 4) = 0.30 + 0.10 + 0.05 = 0.45.$$

Het juiste antwoord is dus (c).

Opdracht 4.m3: Een kansvariabele X kan n verschillende waarden aannemen, namelijk $k_1, k_2, \dots, k_n$. Voor de kansfunctie van de variabele X moet dan gelden:

$$\sum f(k) = \sum P(X = k) = \dots$$

(a) 0

(b) 1

(c) $\frac{1}{n}$

(d) n

Uitwerking

Een kansfunctie moet voldoen aan de volgende eigenschappen:

- $f(k) \geq 0$ voor alle mogelijke waarden k van de variabele X .
- $\sum_k f(k) = 1$, oftewel de som van de kansen over alle mogelijke waarden van X moet gelijk zijn aan 1.

Daarom geldt dat $\sum_k P(X = k) = 1$. Het juiste antwoord is dus (b).

Opdracht 4.m4: Van de kansvariabele X is de verdelingsfunctie als volgt:

Uitkomst k	10	11	12	13	14	15	16
$F(k)$	0.16	0.28	0.46	0.66	0.84	0.94	1.00

Bereken $P(X = 14)$. Wat is de uitkomst?

(a) 0.18

(b) 0.84

(c) 0.10

(d) 0.16

Uitwerking

In dit geval is niet de kansfunctie $f(k)$ gegeven, maar de (cumulatieve) verdelingsfunctie $F(k) = P(X \leq k)$, oftewel de CDF. De kans dat X de waarde 14 aanneemt, oftewel $P(X = 14)$, kunnen we berekenen door het verschil te nemen tussen de verdelingsfunctie bij 14 en de verdelingsfunctie bij de vorige uitkomst, namelijk 13:

$$P(X = 14) = P(X \leq 14) - P(X \leq 13) = F(14) - F(13) = 0.84 - 0.66 = 0.18.$$

Het juiste antwoord is (a).

Opdracht 4.m5: Het aantal koelkasten dat wekelijks wordt verkocht op de afdeling “witgoed” van een supermarkt, kan worden weergegeven door de kansvariabele X waarvan de kansfunctie is weergegeven in de volgende tabel:

Aantal uitkomsten k	0	1	2	3	4
$P(X = k)$	0.25	0.40	0.20	0.10	0.05

De standaarddeviatie van de variabele X bedraagt dus ...

- (a) 1.3 koelkasten
- (b) 1.1 koelkasten
- (c) 0.93 koelkasten
- (d) 1.21 koelkasten

Uitwerking

Om de standaarddeviatie (standaardafwijking) van een discrete kansvariabele X te berekenen, hebben we eerst de verwachtingswaarde nodig. Deze kan worden berekend met de volgende formule:

$$\begin{aligned} E(X) &= \sum_k k \cdot P(X = k) \\ &= 0 \cdot 0.25 + 1 \cdot 0.40 + 2 \cdot 0.20 + 3 \cdot 0.10 + 4 \cdot 0.05 \\ &= 1.3. \end{aligned}$$

Vervolgens kunnen we de variantie berekenen met de volgende formule:

$$\begin{aligned} \text{Var}(X) &= \sum_k (k - E(X))^2 \cdot P(X = k) \\ &= (0 - 1.3)^2 \cdot 0.25 + (1 - 1.3)^2 \cdot 0.40 + \dots + (4 - 1.3)^2 \cdot 0.05 \\ &= 1.21. \end{aligned}$$

De standaarddeviatie krijgen we door de wortel van de variantie te nemen, oftewel:

$$\sigma(X) = \sqrt{\text{Var}(X)} = \sqrt{1.21} = 1.1.$$

Het juiste antwoord is dus (b).

Opdracht 4.1: Een kioskhoudster verkoopt elke zaterdag een aantal exemplaren van het *Weekendmagazine*. Het aantal exemplaren dat op een willekeurige zaterdag wordt gevraagd, kan worden beschouwd als een kansvariabele X waarvoor de volgende uitkomsten en bijbehorende kansen gegeven zijn (zie de tabel).

Aantal gevraagde <i>Weekendmagazines</i> k	$P(X = k)$
30	0.10
35	0.35
40	0.30
45	0.20
50	0.05

- (a) De kioskhoudster koopt elke zaterdag 40 exemplaren van het *Weekendmagazine*. Hoe groot is de kans dat hij niet aan de vraag kan voldoen?

Uitwerking

De kioskhoudster kan niet aan de vraag voldoen als er meer dan 40 exemplaren worden gevraagd. Dit is het geval (zie tabel) als er 45 of meer kranten worden gevraagd. De gevraagde kans is gelijk aan:

$$P(X = 45) + P(X = 50) = 0.20 + 0.05 = 0.25.$$

- (b) Hoe groot is de verwachtingswaarde van de vraag op een willekeurige zaterdag?

Uitwerking

Volgens de definitie van verwachtingswaarde geldt de volgende formule:

$$\begin{aligned}
 E(X) &= \sum_k k \cdot P(X = k) \\
 &= 30 \cdot P(X = 30) + 35 \cdot P(X = 35) + \dots + 50 \cdot P(X = 50) \\
 &= 30 \cdot 0.10 + 35 \cdot 0.35 + 40 \cdot 0.30 + 45 \cdot 0.20 + 50 \cdot 0.05 \\
 &= 38.75.
 \end{aligned}$$

- (c) Hoe groot is de variantie van de vraag?

Uitwerking

De formule voor de variantie luidt:

$$\text{Var}(X) = \sum_k (k - E(X))^2 \cdot P(X = k).$$

Hiertoe berekenen we eerst de termen $(k - E(X))^2$:

Aantal gevraagde Weekendmagazines k	$(k - E(X))^2$
30	$(30 - 38.75)^2 = 76.5625$
35	$(35 - 38.75)^2 = 14.0625$
40	$(40 - 38.75)^2 = 1.5625$
45	$(45 - 38.75)^2 = 39.0625$
50	$(50 - 38.75)^2 = 126.5625$

Term voor term invullen levert:

$$\begin{aligned}
 \text{Var}(X) &= \sum_k (k - E(X))^2 \cdot P(X = k) \\
 &= 76.5625 \cdot 0.10 + 14.0625 \cdot 0.35 + \dots + 126.5625 \cdot 0.05 \\
 &= 21.1875.
 \end{aligned}$$

- (d) De inkoopprijs van de kranten is voor de kioskhouders €1.40, terwijl de verkoopprijs €2.25 bedraagt. De kranten die niet worden verkocht, moeten worden weggegooid (en leveren dus een verlies op van €1.40 per stuk). Bereken de verwachte winst van de kioskhouders bij een inkoop van 40 exemplaren per zaterdag.

Uitwerking

We berekenen de opbrengst van de verschillende aantallen die gevraagd kunnen worden. De opbrengst per zaterdag definiëren we als de kansvariabele Y .

- Bij een vraag van 30 stuks worden 10 kranten niet verkocht, en bedraagt de opbrengst $30 \cdot 0.85 + 10 \cdot (-1.40) = \text{€}11.50$.
- Bij een vraag van 35 stuks worden 5 kranten niet verkocht, en bedraagt de opbrengst $35 \cdot 0.85 + 5 \cdot (-1.40) = \text{€}22.75$.
- Bij een vraag van (minstens) 40 stuks worden alle kranten verkocht, en bedraagt de opbrengst $40 \cdot 0.85 = \text{€}34$.

De kansvariabele Y kan dus als volgt worden beschreven:

Winst y	11.50	22.75	34
$P(Y = y)$	0.10	0.35	0.55

De verwachte winst is te berekenen met de formule voor de verwachtingswaarde:

$$\begin{aligned} E(Y) &= \sum_y y \cdot P(Y = y) \\ &= 11.50 \cdot 0.10 + 22.75 \cdot 0.35 + 34 \cdot 0.55 \\ &\approx \text{€}27.81. \end{aligned}$$

Opdracht 4.3: Gegeven is dat een kansvariabele X alleen de waarden 10, 20, 30 en 40 kan aannemen.

(a) Verifieer voor de volgende vier gevallen of de geformuleerde waarden van $f(k)$ zodanig zijn dat f als een kansfunctie kan worden beschouwd.

(A) $f(10) = 0.30$; $f(20) = 0.40$; $f(30) = 0.10$ en $f(40) = 0.10$.

(B) $f(10) = 0.50$; $f(20) = 0.30$; $f(30) = 0.30$ en $f(40) = 0.10$.

(C) $f(10) = 0.05$; $f(20) = 0.05$; $f(30) = 0.10$ en $f(40) = 0.80$.

(D) $f(10) = 0$; $f(20) = 0$; $f(30) = 1$ en $f(40) = 0$.

Uitwerking

Een kansfunctie f moet voldoen aan de volgende twee voorwaarden:

- Alle waarden van $f(k)$ moeten tussen 0 en 1 liggen.
- De som van alle waarden van $f(k)$ moet gelijk zijn aan 1 zijn.

Voor alle vier gevallen geldt dat alle waarden van $f(k)$ tussen 0 en 1 liggen. Echter, de som van alle waarden van $f(k)$ is alleen gelijk aan 1 voor de gevallen C en D.

Alleen in gevallen C en D kan f dus als kansfunctie worden beschouwd.

(b) Kansen kunnen ook worden weergegeven door de cumulatieve verdelingsfunctie (CDF) $F(k)$. Geef voor de kansfunctie zoals beschreven bij punt C de verstrekte informatie weer door middel van $F(k)$.

Uitwerking

We beschrijven F , de cumulatieve verdelingsfunctie (CDF), aan de hand van een tabel:


Uitkomst k	10	20	30	40
$F(k) = P(X \leq k)$	0.05	0.10	0.20	1.00

Opdracht 4.4: Het aantal augurken dat in een halveliterpot zit, blijkt enigszins te variëren. Uitvoerig onderzoek heeft aangetoond dat dit aantal tussen 15 en 20 ligt, waarbij de volgende kansen van toepassing zijn:

Aantal augurken k	15	16	17	18	19	20
$P(X = k)$	0.10	0.30	0.30	0.15	0.10	0.05

(a) Teken de kansfunctie.

Uitwerking




(b) Bereken en teken de cumulatieve kansfunctie.

Uitwerking

We beschreven F , de cumulatieve verdelingsfunctie (CDF), door middel van een tabel:

Aantal augurken k	15	16	17	18	19	20
$F(k) = P(X \leq k)$	0.10	0.40	0.70	0.85	0.95	1.00

In een grafiekvorm ziet dit er als volgt uit:



- (c) Hoe groot is de kans om in een willekeurige pot meer dan 16 maar minder dan 20 augurken aan te treffen?

Uitwerking

We willen de kans $P(16 < X < 20)$ bepalen. Omdat we met een discrete kansverdeling werken, kunnen we die als volgt berekenen:

$$P(16 < X < 20) = P(17 \leq X \leq 19) = F(19) - F(16) = 0.95 - 0.40 = 0.55.$$

- (d) Er worden twee willekeurige potten augurken geselecteerd. Hoe groot is de kans dat beide potten meer dan 18 augurken bevatten?

Uitwerking

Stel er worden twee willekeurige potten geselecteerd. De kans dat een pot meer dan 18 augurken bevat is gelijk aan

$$P(X > 18) = 1 - P(X \leq 18) = 1 - F(18) = 1 - 0.85 = 0.15.$$

Omdat de potten onafhankelijk van elkaar gevuld zijn, is de totale kans gelijk aan $0.15 \cdot 0.15 = 0.0225$.

- (e) Hoe groot is de kans dat twee willekeurige potten augurken in totaal 38 augurken bevatten?

Uitwerking

Laat nu X_1 het aantal augurken zijn in pot 1, en X_2 het aantal augurken in pot 2. We willen de kans $P(X_1 + X_2 = 38)$ bepalen. Dit doen we als volgt:

$$\begin{aligned} P(X_1 + X_2 = 38) &= P(X_1 = 18, X_2 = 20) + P(X_1 = 19, X_2 = 19) \\ &\quad + P(X_1 = 20, X_2 = 18) \\ &= 0.15 \cdot 0.05 + 0.10 \cdot 0.10 + 0.05 \cdot 0.15 \\ &= 0.025. \end{aligned}$$

Opdracht 4.6: Bij een schoolreisje worden vier bussen gebruikt met elk een eigen chauffeur. Van de in totaal 130 leerlingen hebben deze bussen respectievelijk 45, 35, 30 en 20 leerlingen vervoerd.

- (a) Op basis van toeval kiest men één van de vier chauffeurs. Men vraagt aan de chauffeur hoe groot X is, het aantal leerlingen in zijn bus. Bereken $E(X)$.

Uitwerking

De kansvariabele X telt het aantal leerlingen in de bus van een willekeurige chauffeur. De onderliggende kansverdeling van X wordt gegeven door

Aantal leerlingen k	20	30	35	45
$P(X = k)$	0.25	0.25	0.25	0.25

Het is immers zo dat ieder van de vier chauffeurs gekozen wordt met kans $\frac{1}{4}$. De verwachtingswaarde $E(X)$ is dan

$$E(X) = \sum_k k \cdot P(X = k) = 20 \cdot 0.25 + 30 \cdot 0.25 + 35 \cdot 0.25 + 45 \cdot 0.25 = 32.5.$$

- (b) Op basis van toeval kiest men één van de 130 leerlingen en vraagt aan hem of haar hoeveel leerlingen Y er in de bus zaten waarmee deze leerling werd vervoerd. Bereken $E(Y)$.

Uitwerking

De kansvariabele Y telt het aantal leerlingen in de bus van een willekeurige leerling. De uitkomstenruimte van Y is dezelfde als die van X , namelijk $\{20, 30, 35, 45\}$. De kansverdeling van Y is echter anders dan die van X . Dit komt omdat de kansen nu evenredig zijn met de uitkomst zelf. De kans dat een leerling in een bus zit met k leerlingen is namelijk evenredig met k . Het totaal aantal leerlingen is $20 + 30 + 35 + 45 = 130$. De onderliggende kansverdeling is dan

Aantal leerlingen k	20	30	35	45
$P(Y = k)$	$\frac{20}{130}$	$\frac{30}{130}$	$\frac{35}{130}$	$\frac{45}{130}$

De verwachtingswaarde $E(Y)$ is dus gelijk aan

$$\begin{aligned} E(Y) &= \sum_k k \cdot P(Y = k) \\ &= 20 \cdot \frac{20}{130} + 30 \cdot \frac{30}{130} + 35 \cdot \frac{35}{130} + 45 \cdot \frac{45}{130} \\ &= 35. \end{aligned}$$

Opdracht 4.7: Het aantal personen dat in een willekeurig uur opbelt naar de klantenservice van een groot bedrijf, wordt beschreven door de kansvariabele X , waarvan de gegevens zijn geplaatst in de volgende tabel:

Aantal k	0	1	2	3	4	5
$f(k) = P(X = k)$	0.20	0.30	0.20	0.15	0.10	0.05

(a) Hoe groot is $P(X \geq 3)$ en $P(X \leq 3)$?

Uitwerking

We berekenen deze kansen als volgt:

$$\begin{aligned} P(X \geq 3) &= P(X = 3) + P(X = 4) + P(X = 5) \\ &= 0.15 + 0.10 + 0.05 = 0.30, \\ P(X \leq 3) &= 1 - P(X \geq 4) \\ &= 1 - (P(X = 4) + P(X = 5)) \\ &= 1 - (0.10 + 0.05) \\ &= 1 - 0.15 = 0.85. \end{aligned}$$

(b) Bereken de verwachtingswaarde van X .

Uitwerking

We berekenen de verwachtingswaarde van X als volgt:

$$\begin{aligned} E(X) &= \sum_k k \cdot P(X = k) \\ &= 0 \cdot P(X = 0) + 1 \cdot P(X = 1) + \dots + 5 \cdot P(X = 5) \\ &= 0 \cdot 0.20 + 1 \cdot 0.30 + \dots + 5 \cdot 0.05 \\ &= 1.8. \end{aligned}$$

(c) Bereken de standaarddeviatie van X .

Uitwerking

We berekenen de standaarddeviatie van X door eerst de variantie te berekenen:

$$\begin{aligned} \text{Var}(X) &= \sum_k (k - E[X])^2 \cdot P(X = k) \\ &= (0 - 1.8)^2 \cdot P(X = 0) + (1 - 1.8)^2 \cdot P(X = 1) + \dots \\ &\quad + (5 - 1.8)^2 \cdot P(X = 5) \\ &= (0 - 1.8)^2 \cdot 0.20 + (1 - 1.8)^2 \cdot 0.30 + \dots + (5 - 1.8)^2 \cdot 0.05 \\ &= 2.06. \end{aligned}$$

De standaarddeviatie vinden we dan door de wortel uit de variantie te nemen:

$$\sigma(X) = \sqrt{\text{Var}(X)} = \sqrt{2.06} \approx 1.4353.$$

Opdracht 4.8: Een verzekeringsmaatschappij heeft een analyse gemaakt van de schadeclaims die in een gegeven jaar werden ingediend door mensen met een WA-verzekering. Op basis van deze gegevens is de kansverdeling geformuleerd in de tabel. Hierin staat per individuele

verzekerde aangegeven hoe groot in een gegeven jaar de kansen zijn op uitbetaling van een bepaald schadebedrag.

Schadebedrag k (euro)	Kans $P(X = k)$
0	0.85
100	0.05
200	0.04
400	0.03
1000	0.02
3000	0.01

- (a) Bereken het verwachte schadebedrag per klant.

Uitwerking

Het verwachte schadebedrag per klant is de verwachtingswaarde van de kansvariabele X en wordt als volgt berekend:

$$\begin{aligned}
 E(X) &= \sum_k k \cdot P(X = k) \\
 &= 0 \cdot P(X = 0) + 100 \cdot P(X = 100) + \dots + 3000 \cdot P(X = 3000) \\
 &= 0 \cdot 0.85 + 100 \cdot 0.05 + \dots + 3000 \cdot 0.01 \\
 &= 75.
 \end{aligned}$$

Het verwachte schadebedrag per klant is dus €75.

- (b) Veronderstel dat de schadeclaims per klant voor opeenvolgende jaren mogen worden beschouwd als onderling onafhankelijke kansvariabelen. Hoe groot is de kans dat een willekeurige klant in drie opeenvolgende jaren telkens een bedrag van minstens 1000 euro claimt? Hoe groot is de kans dat men in drie opeenvolgende jaren geen enkele keer een schadebedrag claimt (dus $X = 0$ in alle jaren)?

Uitwerking

De kans dat een willekeurige klant in drie opeenvolgende jaren telkens een bedrag van minstens €1000 claimt, is de kans dat X in elk van de drie jaren gelijk is aan 1000 of 3000. We berekenen deze kans (voor een enkel jaar) als volgt:

$$\begin{aligned}
 P(X \geq 1000) &= P(X = 1000) + P(X = 3000) \\
 &= 0.02 + 0.01 \\
 &= 0.03.
 \end{aligned}$$

De kans dat een klant in drie opeenvolgende jaren telkens een bedrag van minstens €1000 claimt, is dan (aangezien de claims per jaar onafhankelijk zijn):

$$P(X \geq 1000)^3 = (0.03)^3 = 0.000027.$$

Op eenzelfde manier is de kans dat een klant in een enkel jaar geen schadebedrag claimt $P(X = 0) = 0.85$. Aangezien de claims per jaar onafhankelijk zijn, is de kans dat een klant in drie opeenvolgende jaren geen enkel schadebedrag claimt:

$$P(X = 0)^3 = (0.85)^3 \approx 0.6141.$$

De kans dat men in drie opeenvolgende jaren geen enkele keer een schadebedrag claimt is dus ongeveer 61.41%.

- (c) De WA-verzekering kost €98 per verzekerde per jaar. De maatschappij heeft 25000 klanten. Hoe is de verwachte winstbijdrage per jaar?

Uitwerking

We kunnen de verwachtewinstbijdrage per klant berekenen als het verschil tussen de premie en het verwachte schadebedrag per klant (berekend in deel (a)):

$$\text{Winstbijdrage per klant} = \text{Premie} - E(X) = 98 - 75 = 23.$$

Aangezien de maatschappij 25000 klanten heeft, is de verwachte winstbijdrage per jaar:

$$\text{Totale winstbijdrage} = \text{Aantal klanten} \cdot \text{Winstbijdrage per klant} = 25000 \cdot 23 = 575000.$$

Opdracht 4.9: Een huiseigenaar in Amsterdam besluit drie kamers te huur aan te bieden via Airbnb. Het dagelijks aantal verhuurde kamers op een willekeurige dag kan worden weergegeven door de kansvariabele X , zoals weergegeven in de tabel:

Aantal boekingen	$P(X = k)$
0	0.50
1	0.25
2	0.15
3	0.10
Totaal	1.00

- (a) Hoe groot is de kans dat op een willekeurige dag minstens twee kamers zijn verhuurd.

Uitwerking

We berekenen deze kans als volgt:

$$\begin{aligned} P(X \geq 2) &= P(X = 2) + P(X = 3) \\ &= 0.15 + 0.10 \\ &= 0.25. \end{aligned}$$

- (b) De aantallen boekingen op twee opeenvolgende dagen kan men beschouwen als onderling onafhankelijke kansvariabelen. Maak een kanstabel voor de variabele X_{som} waarmee het aantal boekingen per twee dagen wordt aangegeven. Hoe groot is de kans dat in twee dagen meer dan 3 boekingen plaatsvinden?

Uitwerking

De kansvariabele X_{som} telt het aantal boekingen in twee dagen. De mogelijke uitkomsten van X_{som} zijn 0, 1, 2, 3, 4, 5 of 6. We kunnen de kansen van X_{som} berekenen door alle combinaties van het aantal boekingen X_1 en X_2 op de eerste en tweede dag te combineren, aangezien X_{som} de som is van twee onafhankelijke variabelen die dezelfde verdeling hebben als X .

De kanstabel voor de somvariabele X_{som} ziet er als volgt uit:

Aantal boekingen	$P(X_{\text{som}} = k)$
0	0.25
1	0.25
2	0.2125
3	0.175
4	0.0725
5	0.03
6	0.01
Totaal	1.00

De kans dat er in twee dagen meer dan 3 boekingen plaatsvinden is dus gelijk aan

$$\begin{aligned}
 P(X_{\text{som}} > 3) &= P(X_{\text{som}} = 4) + P(X_{\text{som}} = 5) + P(X_{\text{som}} = 6) \\
 &= 0.0725 + 0.03 + 0.01 \\
 &= 0.1125.
 \end{aligned}$$

Opdracht 4.12: Een doe-het-zelfzaak verhuurt apparaten waarmee oud behang van een muur kan worden afgestoomd. De vraag per dag naar dergelijke apparaten kan worden weergegeven door een kansvariabele X die de volgende waarden aanneemt:

Aantal gevraagde machines (k)	0	1	2	3
$P(X = k)$	0.20	0.35	0.25	0.20

- (a) Bereken de verwachtingswaarde van het aantal gevraagde machines.

Uitwerking

We berekenen deze verwachtingswaarde van het aantal gevraagde machines X als volgt:

$$\begin{aligned}
 E(X) &= \sum_k k \cdot P(X = k) \\
 &= 0 \cdot P(X = 0) + \dots + 3 \cdot P(X = 3) \\
 &= 0 \cdot 0.20 + 1 \cdot 0.35 + 2 \cdot 0.25 + 3 \cdot 0.20 \\
 &= 1.45.
 \end{aligned}$$

- (b) De bedrijfsleiding vraagt zich af hoeveel machines in voorraad moeten worden gehouden om aan de (onzekere) vraag te kunnen voldoen. Het beschikbaar hebben van zo'n apparaat kost 4 euro per dag, terwijl de huurprijs 6 euro per dag bedraagt. Bereken de opbrengst per dag Y indien twee apparaten beschikbaar zijn bij de verschillende waarden van X . Doe dit ook bij drie beschikbare apparaten. Bereken voor beide gevallen de verwachtingswaarde van Y . Welke beslissing levert de hoogste verwachtingswaarde?

Uitwerking

Indien er twee apparaten beschikbaar zijn, beschrijft de volgende tabel de opbrengsten per dag. De opbrengsten zijn berekend op basis van opbrengst is huurinkomsten minus beschikbaarheidskosten.

- Bij 0 gevraagde machines is de opbrengst $0 \cdot 6 = 0$ en zijn de kosten gelijk aan $2 \cdot 4 = 8$ euro. De totale opbrengst is dus $0 - 8 = -8$ euro.
- Bij 1 gevraagde machine is de opbrengst $1 \cdot 6 = 6$ en zijn de kosten gelijk aan $2 \cdot 4 = 8$ euro. De totale opbrengst is dus $6 - 8 = -2$ euro.
- Bij 2 gevraagde machines is de opbrengst $2 \cdot 6 = 12$ en zijn de kosten gelijk aan $2 \cdot 4 = 8$ euro. De totale opbrengst is dus $12 - 8 = 4$ euro.
- Bij 3 gevraagde machines is de opbrengst $2 \cdot 6 = 12$ (omdat er maar 2 machines beschikbaar zijn) en zijn de kosten gelijk aan $2 \cdot 4 = 8$ euro. De totale opbrengst is dus $12 - 8 = 4$ euro.

Aantal gevraagde machines (k)	0	1	2	3
Opbrengst ℓ	-8	-2	4	4
$P(X = k)$	0.20	0.35	0.25	0.20

De verwachte opbrengst bij twee beschikbare apparaten is dus

$$\begin{aligned}
 E(Y) &= \sum_{\ell} \ell \cdot P(X = k) \\
 &= -8 \cdot P(X = 0) + \dots + 4 \cdot P(X = 3) \\
 &= -8 \cdot 0.20 + -2 \cdot 0.35 + 4 \cdot 0.25 + 4 \cdot 0.20 \\
 &= -0.5.
 \end{aligned}$$

Indien er drie apparaten beschikbaar zijn, beschrijft de volgende tabel de opbrengsten per dag.

- Bij 0 gevraagde machines is de opbrengst $0 \cdot 6 = 0$ en zijn de kosten gelijk aan $3 \cdot 4 = 12$ euro. De totale opbrengst is dus $0 - 12 = -12$ euro.
- Bij 1 gevraagde machine is de opbrengst $1 \cdot 6 = 6$ en zijn de kosten gelijk aan $3 \cdot 4 = 12$ euro. De totale opbrengst is dus $6 - 12 = -6$ euro.
- Bij 2 gevraagde machines is de opbrengst $2 \cdot 6 = 12$ en zijn de kosten gelijk aan $3 \cdot 4 = 12$ euro. De totale opbrengst is dus $12 - 12 = 0$ euro.
- Bij 3 gevraagde machines is de opbrengst $3 \cdot 6 = 18$ (omdat er nu wel 3 machines beschikbaar zijn) en zijn de kosten gelijk aan $3 \cdot 4 = 12$ euro. De totale opbrengst is dus $18 - 12 = 6$ euro.

Aantal gevraagde machines (k)	0	1	2	3
Opbrengst ℓ	-12	-6	0	6
$P(X = k)$	0.20	0.35	0.25	0.20

De verwachte opbrengst bij drie beschikbare apparaten is dus

$$\begin{aligned}
 E(Y) &= \sum_{\ell} \ell \cdot P(X = k) \\
 &= -12 \cdot P(X = 0) + \dots + 6 \cdot P(X = 3) \\
 &= -12 \cdot 0.20 + -6 \cdot 0.35 + 0 \cdot 0.25 + 6 \cdot 0.20 \\
 &= -3.3.
 \end{aligned}$$

De beslissing om twee apparaten beschikbaar te hebben levert dus naar verwachting de hoogste opbrengst (kleinste verlies) op.

Opdracht 4.13: In een bedrijf staat een aantal machines opgesteld die soms vanwege een storing moeten worden stilgelegd. Op grond van ervaring is vastgesteld dat het aantal storingen X per week in de kanstabel wordt beschreven.

Aantal storingen (k)	$P(X = k)$
0	0.50
1	0.26
2	0.12
3	0.08
4	0.04
Totaal	1.00

- (a) Bereken het verwachte aantal storingen per week.

Uitwerking

Het verwachte aantal storingen per week berekenen we als volgt:

$$\begin{aligned}
 E(X) &= \sum_k k \cdot P(X = k) \\
 &= 0 \cdot P(X = 0) + \dots + 4 \cdot P(X = 4) \\
 &= 0 \cdot 0.50 + 1 \cdot 0.26 + 2 \cdot 0.12 + 3 \cdot 0.08 + 4 \cdot 0.04 \\
 &= 0.9.
 \end{aligned}$$

- (b) Bereken de variantie van het aantal storingen per week.

Uitwerking

Het variantie van het aantal storingen per week berekenen we als volgt:

$$\begin{aligned}
 \text{Var}(X) &= \sum_k (k - E(X))^2 \cdot P(X = k) \\
 &= (0 - 0.9)^2 \cdot P(X = 0) + \dots + (4 - 0.9)^2 \cdot P(X = 4) \\
 &= (0 - 0.9)^2 \cdot 0.50 + \dots + (4 - 0.9)^2 \cdot 0.04 \\
 &= 0.81 \cdot 0.50 + \dots + 9.61 \cdot 0.04 \\
 &\approx 1.29.
 \end{aligned}$$

- (c) Bereken het verwachte aantal storingen per jaar (= 50 weken).

Uitwerking

Het verwachte aantal storingen per week is gelijk aan 0.9, oftewel het verwachte aantal storing per 50 weken is gelijk aan $50 \cdot 0.9 = 45$.

We mogen dit zeggen omdat de verwachtingswaarde van een som van kansvariabelen $X_{\text{som}} = X_1 + X_2 + \dots + X_{50}$ gelijk is aan de som van verwachtingswaarden,

oftewel:

$$\begin{aligned} E(X_{\text{som}}) &= E(X_1 + X_2 + \dots + X_{50}) = E(X_1) + E(X_2) + \dots + E(X_{50}) \\ &= 0.9 + 0.9 + \dots + 0.9 \\ &= 50 \cdot 0.9 = 45. \end{aligned}$$

- (d) Een storing kost het bedrijf aan reparatie en gemiste productie €500 per geval. Bereken de verwachte storingskosten per jaar.

Uitwerking

De verwachte storingskosten per jaar berekenen we simpelweg door het verwachte aantal storingen per jaar te vermenigvuldigen met de kosten per storing, oftewel $45 \cdot €500 = €22500$.

- (e) Bereken de standaarddeviatie van het aantal storingen per jaar.

Uitwerking

Aangezien de wekelijkse aantallen storingen onderling onafhankelijke kansvariabelen zijn, geldt

$$\begin{aligned} \text{Var}(X_{\text{som}}) &= \text{Var}(X_1 + X_2 + \dots + X_{50}) \\ &= \text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_{50}) \\ &= 1.29 + 1.29 + \dots + 1.29 \\ &= 50 \cdot 1.29 \\ &= 64.5. \end{aligned}$$

De standaarddeviatie van het aantal storingen per jaar vinden we door de wortel hiervan te nemen:

$$\sigma(X_{\text{som}}) = \sqrt{\text{Var}(X_{\text{som}})} = \sqrt{64.5} \approx 8.03.$$

Week 3


Continue kansvariabelen

Hoofdstuk 4

Opdracht 4.14: Bij een loterij wordt een ronddraaiend rad gebruikt om een winnend nummer te loten. Op het rad is een indeling gemaakt in centimeters lopend van 0.00 tot 100.00 (wat weer gelijk valt met 0.00, want de cirkel is dan rond). De uitkomst van één draai met het rad kan men beschouwen als een willekeurige trekking uit de uniforme verdeling tussen 0.00 en 100.00.

- (a) Hoe groot is de kans dat een willekeurige draai een uitkomst oplevert tussen 40.00 en 75.00?

Uitwerking



Laat X de kansvariabele zijn die de resultaat beschrijft van een draai aan het rad.


De uitkomstenruimte van X is het interval tussen 0 en 100. Deze kansdichtheidsfunctie van X is gelijk aan

$$f(x) = \begin{cases} \frac{1}{b-a} = \frac{1}{100-0} = 0.01, & \text{als } a \leq x \leq b \\ 0, & \text{anders.} \end{cases}$$

De cumulatieve verdelingsfunctie (CDF) van de uniforme verdeling tussen 0 en 100 laat zich beschrijven door

$$F(x) = P(X \leq x) = \begin{cases} 0, & \text{als } x < 0 \\ \frac{x-a}{b-a} = \frac{x}{100}, & \text{als } 0 \leq x < 100 \\ 1, & \text{als } x \geq 100 \end{cases}$$

Cumulatieve verdelingsfunctie (CDF) van de continue uniforme verdeling tussen 0 en 100



De kans op een uitkomst tussen 40 en 75 is dus

$$\begin{aligned} P(40 \leq X \leq 75) &= F(75) - F(40) \\ &= \frac{75}{100} - \frac{40}{100} \\ &= 0.35. \end{aligned}$$

- (b) Hoe groot is de kans dat drie draaien achter elkaar alle drie een uitkomst opleveren tussen 80.00 en 100.00?

Uitwerking

De kans dat een draai een uitkomst oplevert tussen 80 en 100 is gelijk aan

$$\begin{aligned} P(80 \leq X \leq 100) &= F(100) - F(80) \\ &= 1 - \frac{80}{100} \\ &= 0.20. \end{aligned}$$

Aangezien afzonderlijke draaien onafhankelijk zijn van elkaar (oftewel de uitkomst van een draai verandert niet de kansverdeling van andere draaien) is de kans op drie keer een uitkomst tussen 80 en 100 gelijk aan $0.20 \cdot 0.20 \cdot 0.20 = 0.008$.

- (c) We doen twee draaien met het rad. Hoe groot is de kans dat de eerste draai een uitkomst kleiner dan 20.00 oplevert en de tweede draai een uitkomst groter dan 20.00?

Uitwerking

Opnieuw hebben we te maken met het feit dat de twee draaien onafhankelijk van elkaar plaatsvinden. Deze kans is gelijk aan

$$P(X < 20) \cdot P(X > 20) = 0.2 \cdot 0.8 = 0.16.$$

- (d) Gegeven is dat de eerste draai 60 oplevert, hoe groot is dan de kans dat de tweede draai een groter getal oplevert?

Uitwerking

De kans dat de tweede draai een uitkomst groter dan 60 oplevert is gelijk aan

$$P(X > 60) = 1 - P(X \leq 60) = 1 - F(60) = 1 - \frac{60}{100} = 0.4.$$

- (e) Gegeven is dat de eerste draai A oplevert, hoe groot is dan de kans dat de tweede draai meer dan A oplevert?

Uitwerking

Als de eerste draai de waarde A oplevert, dan is de kans dat de tweede draai meer oplevert gelijk aan

$$\begin{aligned} P(X > A) &= 1 - P(X \leq A) \\ &= 1 - F(A) \\ &= 1 - \frac{A}{100} \quad \left(= \frac{100}{100} - \frac{A}{100} = \frac{100 - A}{100} \right). \end{aligned}$$

Opdracht 4.15: Gegeven is een continue kansvariabele X die alleen waarden kan aannemen op een bepaald gedeelte van de x -as.

(a) Verifieer voor de volgende twee gevallen of de geformuleerde functie f als kansdichtheid kan dienen.

$$\text{a) } f(x) = \begin{cases} 0.20, & \text{voor } 5 \leq x \leq 10 \\ 0, & \text{elders.} \end{cases}$$

$$\text{b) } f(x) = \begin{cases} \frac{2}{5}x - 2, & \text{voor } 5 \leq x \leq 10 \\ 0, & \text{elders.} \end{cases}$$

Uitwerking

Een functie f kan dienen als kansdichtheidsfunctie als aan twee voorwaarden is voldaan:


- $f(x) \geq 0$ voor alle mogelijke waarden van x .
- De oppervlakte ingesloten door de grafiek van f en de x -as is gelijk aan 1:

$$\int_{-\infty}^{\infty} f(x) \, dx = 1.$$

Voor het eerste geval zien we direct aan de definitie van de functie dat aan de eerste voorwaarde is voldaan, aangezien voor iedere waarde van x geldt dat ofwel $f(x) = 0$ ofwel $f(x) = 0.20$. Met de grafische rekenmachine checken we dat verder geldt:

$$\int_{-\infty}^{\infty} f(x) \, dx = \int_5^{10} 0.20 \, dx = 1.$$

Omdat de eerste functie aan beide voorwaarden voldoet, zou deze als kansdichtheidsfunctie kunnen dienen.



Merk op: in dit geval is de oppervlakte onder de grafiek van f ook te berekenen als de oppervlakte van een rechthoek met lengte $10 - 5 = 5$ en hoogte 0.2. Dit geeft een


oppervlakte van

$$\text{lengte} \cdot \text{hoogte} = 5 \cdot 0.2 = 1.$$

Voor het tweede geval geldt dat het een stijgende lineaire functie is (de richtingscoëfficiënt $\frac{2}{5} > 0$), dus de minimale waarde van f op het interval $5 \leq x \leq 10$ wordt aangenomen in de kleinste x , namelijk $x = 5$. Hier is de functiewaarde $f(5) = \frac{2}{5} \cdot 5 - 2 = 0$. Er volgt dus dat aan de eerste voorwaarde is voldaan, aangezien $f(x) = 0$ (voor $x < 5$ en $x > 10$) of $f(x) \geq 0$ (voor $5 \leq x \leq 10$). Met de grafische rekenmachine checken we dat verder geldt:

$$\int_{-\infty}^{\infty} f(x) \, dx = \int_5^{10} \left(\frac{2}{5}x - 2 \right) \, dx = 5.$$

Omdat niet aan de tweede voorwaarde is voldaan, zou dit tweede geval niet als kansdichtheidsfunctie kunnen dienen.



Merk op: in dit geval is de oppervlakte onder de grafiek van f ook te berekenen als de oppervlakte van een driehoek met lengte $10 - 5 = 5$ en hoogte 2. Dit geeft een oppervlakte van

$$\frac{1}{2} \cdot \text{lengte} \cdot \text{hoogte} = \frac{1}{2} \cdot 5 \cdot 2 = 5.$$

- (b) Bereken voor de gegevens bij vraag (a) de verdelingsfunctie $F(x)$ van de betreffende variabele.

Uitwerking

De cumulatieve verdelingsfunctie $F(x)$ behorend bij functie 1 uit (a) is

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(y) \, dy,$$

oftewel voor iedere x is $F(x)$ gelijk aan de oppervlakte onder de grafiek van f van

$-\infty$ tot en met x (links van x). We gebruiken hier y als variabele, omdat x al is gedefinieerd als bovengrens van de integraal.

Voor $x \leq 5$ geldt dat

$$F(x) = \int_{-\infty}^x f(y) \, dy = \int_{-\infty}^x 0 \, dy = 0,$$

aangezien $f(y) = 0$ voor alle $y < 5$. Voor waarden tussen 5 en 10 is de kansdichtheid gelijk aan 0.20, oftewel voor x tussen 5 en 10 geldt:

$$F(x) = \int_{-\infty}^x f(y) \, dy = \int_{-\infty}^5 0 \, dy + \int_5^x 0.2 \, dy = 0.2 \cdot (x - 5)$$


Deze laatste stap komt van het feit dat de oppervlakte onder de grafiek een rechthoek is met breedte $x - 5$ en hoogte 0.2.

Tenslotte geldt voor $x > 10$ dat de oppervlakte onder de grafiek gelijk is aan de oppervlakte van de rechthoek van 5 tot 10 met hoogte 0.2, oftewel

$$F(x) = 0.2 \cdot (10 - 5) = 1.$$

Samengevat kunnen we de verdelingsfunctie F als volgt beschrijven:

$$F(x) = \int_{-\infty}^x f(y) \, dy = \begin{cases} 0, & \text{als } x < 5, \\ 0.2(x - 5), & \text{als } 5 \leq x \leq 10, \\ 1, & \text{als } x > 10. \end{cases}$$



Opdracht 4.16: Gegeven is de volgende kansdichtheid:

$$f(x) = \begin{cases} 0.2, & \text{voor } 0 \leq x \leq 5, \\ 0, & \text{elders.} \end{cases}$$

(a) Bereken $E(X)$ en $\text{Var}(X)$.

Uitwerking

De verwachtingswaarde berekenen met de algemene formule voor continue kansverdelingen, namelijk:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) \, dx = \int_0^5 x \cdot 0.2 \, dx = 2.5.$$

Ook voor de variantie gebruiken we de algemene formule voor continue kansverdelingen, namelijk:

$$\begin{aligned} \text{Var}(X) &= \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f(x) \, dx \\ &= \int_0^5 (x - 2.5)^2 \cdot 0.2 \, dx \\ &\approx 2.0833. \end{aligned}$$

- (b) We doen twee trekkingen uit deze verdeling. Hoe groot is de kans dat beide uitkomsten groter dan 4 zijn?

Uitwerking

De kans op één keer een trekking groter dan 4 is gelijk aan

$$P(X \geq 4) = \int_4^{\infty} f(x) \, dx = \int_4^5 0.2 \, dx = 0.2.$$


Als we nu twee trekkingen uit deze kansverdeling nemen, zijn deze onafhankelijk van elkaar. In dat geval mogen we kansen vermenigvuldigen. De kans op tweemaal een trekking groter dan 4 is dan gelijk aan $0.2 \cdot 0.2 = 0.04$.

Opdracht 4.17: Een conservatoriumstudent oefent per dag tussen 180 en 300 minuten. Het aantal oefenuren op een willekeurige dag kan worden weergegeven door een continue kansvariabele X (in uren) met de volgende kansdichtheid:

$$f(x) = \begin{cases} 0.40, & \text{voor } 3.00 \leq x < 4.00, \\ 0.60, & \text{voor } 4.00 \leq x < 5.00, \\ 0, & \text{elders.} \end{cases}$$

- (a) Geef de kansdichtheid grafisch weer.

Uitwerking



- (b) Hoe groot is de kans dat de student op een willekeurige dag minder dan 210 minuten oefent? Hoe groot is de kans dat hij tussen 200 en 260 minuten oefent?


Uitwerking

De kans dat een student op een willekeurige dag minder dan 210 minuten, oftewel 3.5 uur oefent, is gelijk aan

$$P(X \leq 3.5) = \int_{-\infty}^{3.5} f(x) \, dx = \int_{3.00}^{3.5} 0.40 \, dx = 0.2.$$

De kans dat een student op een willekeurige dag tussen 200 en 260 minuten oefent, oftewel tussen $\frac{10}{3}$ en $\frac{13}{3}$ uur oefent, is gelijk aan

$$\begin{aligned} P\left(\frac{10}{3} \leq X \leq \frac{13}{3}\right) &= \int_{\frac{10}{3}}^{\frac{13}{3}} f(x) \, dx \\ &= \int_{\frac{10}{3}}^{4.00} 0.40 \, dx + \int_{4.00}^{\frac{13}{3}} 0.6 \, dx \\ &\approx 0.4667. \end{aligned}$$



(c) Wat is de verwachtingswaarde van de dagelijkse studietijd?

Uitwerking

De verwachtingswaarde van de dagelijkse studietijd berekenen we met de algemene formule voor continue kansverdelingen:

$$\begin{aligned}
 E(X) &= \int_{-\infty}^{\infty} x \cdot f(x) \, dx \\
 &= \int_{3.00}^{4.00} x \cdot 0.40 \, dx + \int_{4.00}^{5.00} x \cdot 0.60 \, dx \\
 &= 4.1.
 \end{aligned}$$

De verwachte dagelijkse studietijd is 4.1 uur, oftewel 246 minuten.

Opdracht 4.18: Antiekhandelaar Lauwen overweegt op een veiling een fraaie Friese staartklok te kopen. Bekend is dat deze klok een bedrag zal moeten opleveren tussen €20000 en €30000. Een concurrent van Lauwen wil eveneens een (onbekend) bod X doen, waarvan de hoogte mag worden beschouwd als een trekking uit een rechthoekige kansverdeling tussen 20000 en 30000. Gelet op het veronderstelde continue karakter van de kansvariabele, mogen we ervan uitgaan dat beide partijen nooit exact hetzelfde bod zullen doen.

(a) Veronderstel dat Lauwen €23000 biedt. Hoe groot is de kans dat hij daarmee in het bezit komt van de klok?

Uitwerking

Gegeven is dat het bod van zijn concurrent X wordt gemodelleerd als een uniforme kansvariabele op het interval tussen €20 000 en €30 000, met andere woorden $X \sim \text{Uniform}(20000, 30000)$. Lauwen komt enkel en alleen in bezit van de klok als

geldt dat $X \leq 23000$. De kans hierop is gelijk aan

$$P(X \leq 23000) = \frac{23000 - 20000}{30000 - 20000} = \frac{3000}{10000} = 0.3.$$

- (b) Veronderstel Lauwen biedt €28000 respectievelijk €30000. Hoe groot is dan de kans op aankoop van de klok?

Uitwerking

Als Lauwen een bod van €28000 doet, is de kans op aankoop gelijk aan

$$P(X \leq 28000) = \frac{28000 - 20000}{30000 - 20000} = \frac{8000}{10000} = 0.8.$$

Als Lauwen een bod van €30000 doet, is de kans op aankoop gelijk aan 1, want dit is de bovengrens van het bod X wat de concurrent gaat uitbrengen.

- (c) Er is een klant aan wie Lauwen de klok voor een bedrag van €31 000 onmiddellijk kan verkopen. Hoeveel bedraagt de verwachte winst voor Lauwen bij de biedingen die bij de vragen a en b worden overwogen?

Uitwerking

Als Lauwen een bod van €23000 doet, is de kans op aankoop gelijk aan 0.3. In het geval dat hij de concurrent overtreft ($X \leq 23000$), is de winst gelijk aan $31000 - 23000 = 8000$ euro. In het geval dat hij de concurrent niet overtreft ($X > 23000$), is de winst gelijk aan 0. Hij kan dan immers de klok niet doorverkopen. Dit gebeurt met kans $1 - 0.3 = 0.7$. Je kunt dus de winst W zien als een discrete kansvariabele met twee mogelijke uitkomsten:

winst k (in euro)	0	8000
$f(k) = P(W = k)$	0.7	0.3

De verwachte winst is in dat geval gelijk aan

$$\begin{aligned} E(W) &= 0 \cdot P(W = 0) + 8000 \cdot P(W = 8000) \\ &= 0 \cdot 0.7 + 8000 \cdot 0.3 \\ &= €2400. \end{aligned}$$

Op eenzelfde manier kun je de verwachte winst bepalen in het geval dat Lauwen respectievelijk €28000 en €30000 biedt:

- Wanneer Lauwen een bod van €28000 uitbrengt, is de kans op aankoop gelijk aan $P(X < 28000) = 0.8$. In dat geval is de winst gelijk aan $31000 - 28000 =$

3000 euro, en anders 0 euro (met kans $1 - 0.8 = 0.2$). Je kunt dus de winst W zien als een discrete kansvariabele met twee mogelijke uitkomsten:

winst k (in euro)	0	3000
$f(k) = P(W = k)$	0.2	0.8

De verwachte winst (in euro) is in dat geval gelijk aan

$$\begin{aligned} E(W) &= 0 \cdot P(W = 0) + 3000 \cdot P(W = 3000) \\ &= 0 \cdot 0.2 + 3000 \cdot 0.8 \\ &= \text{€}2400. \end{aligned}$$

- Wanneer Lauwen een bod van €30000 uitbrengt, is Lauwen verzekerd van aankoop en maakt hij altijd een winst gelijk aan $31000 - 30000 = 1000$ euro.

- (d) Noem het bedrag dat Lauwen gaat bieden B . Bij welke bieding B is de verwachte verkoopwinst zo hoog mogelijk?

Uitwerking

Stel dat Lauwen een bedrag van B euro gaat bieden. We mogen aannemen dat $20000 \leq B \leq 30000$.

- Als $B < 20000$ euro, dan wordt Lauwen altijd overboden door zijn concurrent en is zijn winst gegarandeerd 0 euro.
- Als $B > 30000$ euro, dan is hij verzekerd van aankoop. Echter, dat zou hij al zijn geweest bij een bod van €30000, in welk geval zijn winst strikt hoger zal zijn.

De kans op aankoop wordt voor iedere B gegeven door

$$P(X < B) = \frac{B - 20000}{30000 - 20000} = \frac{B - 20000}{10000},$$

oftewel de kans dat hij een hoger bod (B) uitbrengt dan zijn concurrent (X). Bij aankoop maakt Lauwen een winst van $31000 - B$ euro (opbrengsten minus kosten). Als Lauwen wordt overboden, dan is zijn winst 0 euro. Dit gebeurt met kans $P(X \geq B) = 1 - P(X < B) = 1 - \frac{B - 20000}{10000} = \frac{30000 - B}{10000}$. De winst W kun je opnieuw beschrijven als een discrete kansvariabele met twee mogelijke uitkomsten:

winst k (in euro)	0	$31000 - B$
$f(k) = P(W = k)$	$\frac{30000 - B}{10000}$	$\frac{B - 20000}{10000}$

De verwachte winst (in euro) is in dat geval gelijk aan

$$\begin{aligned}
 E(W) &= 0 \cdot P(W = 0) + (31000 - B) \cdot P(W = 31000 - B) \\
 &= 0 \cdot \left(\frac{30000 - B}{10000} \right) + (31000 - B) \cdot \left(\frac{B - 20000}{10000} \right) \\
 &= \frac{(31000 - B) \cdot (B - 20000)}{10000} \\
 &= \frac{-620000000 + 51000 \cdot B - B^2}{10000} \\
 &= -62000 + 5.1 \cdot B - \frac{1}{10000} \cdot B^2.
 \end{aligned}$$

De verwachte winst is dus een functie van het bod B van Lauwen, oftewel $f(B)$. We vinden de optimale waarde voor B door de afgeleide $f'(B)$ te nemen (exponent naar voren halen en exponent met 1 verminderen) en gelijk te stellen aan 0:

$$\begin{aligned}
 f'(B) &= 5.1 - \frac{2}{10000} \cdot B = 0 \\
 \rightarrow B &= 5.1 \cdot \frac{10000}{2} = 25500.
 \end{aligned}$$

Invullen van $B = 25500$ geeft een maximale verwachte winst (in euro) van

$$E(W) = -62000 + 5.1 \cdot 25500 - \frac{1}{10000} \cdot (25500)^2 = \text{€}3025.$$

Noot: deze opgave is erg lastig, aangezien we hier symbolisch rekenen als we de interactie tussen twee uniforme verdelingen willen bekijken. Dit is geen tentamenstof.

- (e) Veronderstel dat de klant niet €31000 maar € Y wenst te betalen. Geef aan hoe het optimale bod B afhangt van de gekozen Y .

Uitwerking

In dat geval is bij aankoop de winst niet gelijk aan $31000 - B$, maar gelijk aan $Y - B$. Je kunt dus de winst W zien als een discrete kansvariabele met twee mogelijke uitkomsten:

winst k (in euro)	0	$Y - B$
$f(k) = P(W = k)$	$\frac{30000 - B}{10000}$	$\frac{B - 20000}{10000}$

De verwachte winst (in euro) is in dat geval gelijk aan

$$\begin{aligned}
 E(W) &= 0 \cdot P(W = 0) + (Y - B) \cdot P(W = Y - B) \\
 &= 0 \cdot \frac{30000 - B}{10000} + (Y - B) \cdot \frac{B - 20000}{10000} \\
 &= \frac{(Y - B) \cdot (B - 20000)}{10000} \\
 &= \frac{20000Y + (Y + 20000)B - B^2}{10000} \\
 &= 2Y + \frac{Y + 20000}{10000}B - \frac{1}{10000}B^2.
 \end{aligned}$$

Dit is opnieuw een functie, nu van zowel B als Y . We vinden de optimale waarde voor B door de afgeleide naar B te nemen (zie in dit geval Y als een vaststaand getal, niet een variabele) en gelijk te stellen aan 0:

$$\begin{aligned}
 \frac{Y + 20000}{10000} - \frac{2}{10000}B &= 0 \\
 \rightarrow B &= \frac{Y + 20000}{10000} \cdot \frac{10000}{2} = \frac{Y + 20000}{2}.
 \end{aligned}$$

Merk op dat deze optimale waarde voor B precies in het midden tussen 20000 en Y ligt. Invullen van $B = \frac{Y+20000}{2}$ geeft een verwachte winst (in euro) van

$$\begin{aligned}
 E(W) &= \frac{(Y - B) \cdot (B - 20000)}{10000} \\
 &= \frac{\frac{Y-20000}{2} \cdot \frac{Y-20000}{2}}{10000} \\
 &= \frac{(Y - 20000)^2}{40000}.
 \end{aligned}$$

Als $Y > 40000$, dan kun je in plaats van $B = \frac{Y+20000}{2} > 30000$ beter kiezen voor een bod van $B = 30000$, omdat je dan toch al verzekerd bent van de aankoop.

Noot: ook deze opgave is erg lastig: dit is geen tentamenstof.

Week 4

De binomiale verdeling

Hoofdstuk 6

Opdracht 6.4: Een multiplechoice-examen bestaat uit tien vragen die elk drie antwoordmogelijkheden kennen, waarvan er precies één correct is. Een kandidaat die volstrekt niet weet wat hij moet antwoorden, kruist naar willekeur bij elk van de tien vragen een antwoord aan.

- (a) Bereken de kans op respectievelijk nul, één of twee antwoorden goed.

Uitwerking

Laat X de kansvariabele zijn die het aantal juiste antwoorden telt. Dan geldt dat X binomiaal verdeeld is met parameters $n = 10$ (aantal “kansexperimenten”, oftewel aantal examenvragen) en $p = \frac{1}{3}$ (succeskans / kans op het juiste antwoord). De kansen op respectievelijk nul, één of twee antwoorden goed zijn gelijk aan

$$P(X = 0) = \text{binompdf}(n = 10, p = \frac{1}{3}, k = 0) \approx 0.0174,$$

$$P(X = 1) = \text{binompdf}(n = 10, p = \frac{1}{3}, k = 1) \approx 0.0870,$$

$$P(X = 2) = \text{binompdf}(n = 10, p = \frac{1}{3}, k = 2) \approx 0.1955.$$

- (b) Bereken de kans dat hij minstens zes antwoorden goed heeft.

Uitwerking

De kans dat hij minstens zes antwoorden goed heeft is gelijk aan

$$P(X \geq 6) = 1 - P(X \leq 5) = 1 - \text{binomcdf}(n = 10, p = \frac{1}{3}, k = 5) \approx 0.0762.$$

- (c) Bereken de verwachtingswaarde van het aantal goede antwoorden.

Uitwerking

De verwachtingswaarde van een binomiale kansvariabele $X \sim \text{Binomiaal}(n, p)$ is gelijk aan $E(X) = n \cdot p$. Aangezien in dit geval geldt dat $n = 10$ en $p = \frac{1}{3}$, is de verwachtingswaarde van het aantal correcte antwoorden gelijk aan $E(X) = 10 \cdot \frac{1}{3} = \frac{10}{3}$.

Opdracht 6.5: Bekend is dat van de volwassen Nederlanders thans 70 % over een of meer creditcards beschikt. We kiezen een steekproef van vijftien personen. Bepaal met behulp van de tabel van de binomiale verdeling de kans dat de volgende aantallen mensen in deze steekproef over een of meer creditcards beschikken:

(a) precies 10

Uitwerking

Het aantal mensen in een steekproef van 15 personen met een of meer creditcards is een binomiaal verdeelde kansvariabele X met parameters $n = 15$ (aantal personen) en $p = 0.7$ (succeskans / kans dat we iemand hebben gekozen die een of meer creditcards heeft). De kans dat precies 10 van de 15 mensen een of meer creditcards heeft is gelijk aan

$$P(X = 10) = \text{binompdf}(n = 15, p = 0.7, k = 10) \approx 0.2061.$$

(b) precies 15

Uitwerking

De kans dat alle 15 mensen in de steekproef een of meer creditcards heeft is gelijk aan

$$P(X = 15) = \text{binompdf}(n = 15, p = 0.7, k = 15) \approx 0.0047.$$

(c) meer dan 9

Uitwerking

De kans dat meer dan 9 (dus minstens 10) van de 15 mensen in de steekproef een of meer creditcards heeft is gelijk aan

$$\begin{aligned} P(X > 9) &= P(X \geq 10) = 1 - P(X \leq 9) \\ &= 1 - \text{binomcdf}(n = 15, p = 0.7, k = 9) \\ &\approx 0.7216. \end{aligned}$$

(d) minder dan 12

Uitwerking

De kans dat minder dan 12 (dus hoogstens 11) van de 15 mensen in de steekproef een of meer creditcards heeft is gelijk aan

$$P(X < 12) = P(X \leq 11) = \text{binomcdf}(n = 15, p = 0.7, k = 11) \approx 0.7031.$$

Opdracht 6.6: Bij een aangeboren afwijking blijkt bij 25 % van de baby's een bepaalde complicatie op te treden. In een jaar worden twintig baby's geboren met de afwijking. Bepaal met de tabel van de binomiale verdeling de volgende kansen:

- (a) de kans dat twee of minder baby's de complicatie vertonen.

Uitwerking

Het aantal baby's waarbij bij een aangeboren afwijking een bepaalde complicatie optreedt is een binomiaal verdeelde kansvariabele X met parameters $n = 20$ (aantal baby's met een aangeboren afwijking) en $p = 0.25$ (kans op complicatie). Merk op dat het in deze context vreemd is om te spreken van een "succeskans" p . De kans dat twee of minder baby's de complicatie vertonen is gelijk aan

$$P(X \leq 2) = \text{binomcdf}(n = 20, p = 0.25, k = 2) \approx 0.0913.$$

- (b) de kans dat precies twee baby's de complicatie vertonen.

Uitwerking

De kans dat precies twee baby's de complicatie vertonen is gelijk aan

$$P(X = 2) = \text{binompdf}(n = 20, p = 0.25, k = 2) \approx 0.0670.$$

- (c) de kans dat meer dan twee baby's de complicatie vertonen.

Uitwerking

De kans dat meer dan twee baby's de complicatie vertonen is gelijk aan

$$\begin{aligned} P(X > 2) &= P(X \geq 3) = 1 - P(X \leq 2) \\ &= 1 - \text{binomcdf}(n = 20, p = 0.25, k = 2) \\ &\approx 0.9087. \end{aligned}$$

- (d) de kans dat het aantal baby's met de complicatie minstens 4 maar hoogstens 7 is.

Uitwerking

De kans dat minstens 4 maar hoogstens 7 baby's de complicatie vertonen is gelijk

aan

$$\begin{aligned}
 P(4 \leq X \leq 7) &= P(X \leq 7) - P(X \leq 3) \\
 &= \text{binomcdf}(n = 20, p = 0.25, k = 7) \\
 &\quad - \text{binomcdf}(n = 20, p = 0.25, k = 3) \\
 &\approx 0.8982 - 0.2252 \approx 0.6730.
 \end{aligned}$$

Opdracht 6.7: De Bloedbank is een organisatie waar burgers bloed kunnen laten aftappen. Dit donorbloed kan worden gebruikt bij patiënten die dit nodig hebben. In Nederland heeft 44 % van de bevolking bloedgroep A. Deze groep is onderverdeeld in 36 % met bloedgroep A+ en 8 % met bloedgroep A-. Er komen op een bepaalde dag 30 donoren om bloed te geven.

- (a) Hoe groot is de kans dat hiervan precies 8 donoren bloedgroep A hebben?

Uitwerking

Het aantal bloeddonoren met bloedgroep A uit een groep van 30 donoren is een binomiaal verdeelde kansvariabele X met parameters $n = 30$ (aantal donoren) en $p = 0.44$ (succeskans / kans op bloedgroep A). De kans dat precies 8 van de 30 donoren bloedgroep A hebben is gelijk aan

$$P(X = 8) = \text{binompdf}(n = 30, p = 0.44, k = 8) \approx 0.0237.$$

- (b) Hoe groot is de kans dat *binnen* de groep van 8 mensen met bloedgroep A er twee zijn met bloedgroep A-?

Uitwerking

Het aantal donoren met bloedgroep A- binnen een groep van 8 willekeurige donoren met bloedgroep A is een binomiaal verdeelde kansvariabele Y met parameters $n = 8$ en $p = P(A- \mid A) = \frac{P(A-)}{P(A)} = \frac{8}{44}$. De kans dat binnen deze groep precies twee donoren bloedgroep A- hebben is gelijk aan

$$P(Y = 2) = \text{binompdf}(n = 8, p = \frac{8}{44}, k = 2) \approx 0.2777.$$

Opdracht 6.8: De kans dat een willekeurig gekozen student slaagt bij een bepaald tentamen is 0.6. Hoe groot is de kans dat van 150 willekeurig gekozen studenten er meer dan 100 voor het tentamen slagen?

Uitwerking

Het aantal studenten dat slaagt bij een bepaald tentamen is een binomiaal verdeelde kansvariabele X met parameters $n = 150$ (aantal willekeurig gekozen studenten) en $p = 0.6$ (de succeskans, kans op slagen). De kans dat meer dan 100 studenten voor het

tentamen slagen is gelijk aan

$$\begin{aligned} P(X > 100) &= P(X \geq 101) = 1 - P(X \leq 100) \\ &= 1 - \text{binomcdf}(n = 150, p = 0.6, k = 100) \\ &\approx 0.0389. \end{aligned}$$

Opdracht 6.10: Een viermotorig vliegtuig kan nog blijven doorvliegen als tijdens de vlucht twee van de vier motoren uitvallen. Voor een willekeurige motor is de kans 0.005 dat deze tijdens de vlucht defect raakt.

- (a) Hoe groot is de kans dat na een vlucht alle vier de motoren nog functioneren? En drie van de vier?

Uitwerking

Het aantal motoren dat tijdens een vlucht uitvalt is een binomiaal verdeelde kansvariabele met parameters $n = 4$ (aantal motoren) en $p = 0.005$ (in dit geval is het opnieuw vreemd om van een “succeskans” te spreken, aangezien het de kans op uitval van een motor beschrijft). De kans dat alle vier de motoren nog functioneren (oftewel geen enkele motor is uitgevallen) is gelijk aan

$$P(X = 0) = \text{binompdf}(n = 4, p = 0.005, k = 0) \approx 0.9801.$$

De kans dat drie van de vier motoren nog functioneren (oftewel precies één motor is uitgevallen) is gelijk aan

$$P(X = 1) = \text{binompdf}(n = 4, p = 0.005, k = 1) \approx 0.0197.$$

- (b) Bereken de kans dat het vliegtuig neerstort?

Uitwerking

Een vliegtuig stort neer als strikt meer dan twee van de vier motoren uitvallen, oftewel minimaal drie. De kans dat minimaal drie motoren uitvallen tijdens een vlucht is gelijk aan

$$\begin{aligned} P(X \geq 3) &= 1 - P(X \leq 2) \\ &= 1 - \text{binomcdf}(n = 4, p = 0.005, k = 2) \\ &\approx 4.9813 \cdot 10^{-7}. \end{aligned}$$

- (c) Van de motoren zijn er twee bevestigd aan de linkervleugel en twee aan de rechtervleugel. Als drie of vier motoren uitvallen, stort het vliegtuig neer. Als echter twee motoren uitvallen die zich aan dezelfde kant van het vliegtuig bevinden, dan stort het vliegtuig ook neer. Bereken opnieuw de kans dat vliegtuig neerstort. Geef commentaar op het

verschil met het antwoord op vraag (b).

Uitwerking

We kunnen in dit geval de situatie het best opsplitsen in twee (onafhankelijke) binomiaal verdeelde kansvariabelen X_L en X_R die het aantal uitgevallen motoren telt aan respectievelijk de linker- en rechtervleugel. Deze binomiaal verdeelde kansvariabelen hebben beiden de parameters $n = 2$ (aantal motoren per vleugel) en $p = 0.005$ (kans op uitval van een motor). Een vliegtuig stort neer als geldt dat ofwel $X_L = 2$ ofwel $X_R = 2$ ofwel beiden. Dit gebeurt met kans

$$\begin{aligned} P(X_L = 2 \text{ of } X_R = 2) &= 1 - P(X_L \leq 1, X_R \leq 1) \\ &= 1 - P(X_L \leq 1) \cdot P(X_R \leq 1) \\ &= 1 - \text{binomcdf}(n = 2, p = 0.005, k = 1)^2 \\ &\approx 4.9999 \cdot 10^{-5}. \end{aligned}$$

We mogen deze kansen in de tweede stap vermenigvuldigen, omdat X_L en X_R onafhankelijke kansvariabelen zijn.

Zoals je ziet is de berekende kans groter dan de kans die we bij (b) hebben berekend. De reden hiervoor is dat bij vraag (b) de gevallen (i) $X_L = 2, X_R = 0$ en (ii) $X_L = 0, X_R = 2$ niet zijn meegenomen als scenario waarbij het vliegtuig zal neerstorten.

Opdracht 6.12: In de binnenstad van Utrecht worden door de politie op een gegeven dag 800 parkeerbonnen uitgeschreven, elk met een boetebedrag van 40 euro per parkeerbon. Het is een bekend gegeven dat 75 % van de ontvangers van zo'n bekeuring het bedrag overmaakt. 25 % doet dat niet.

- (a) Bereken voor de dag met 800 parkeerbonnen de verwachtingswaarde en de standaarddeviatie (standaardafwijking) van het aantal directe betalers. Stel dat voor deze specifieke dag op de uiterste betaaldatum 520 bekeurden hun boete hebben voldaan, is dat dan uitzonderlijk gegeven de betaalkans van 75 %?

Uitwerking

Het aantal directe betalers kan worden geïnterpreteerd als een binomiaal verdeelde kansvariabele met parameters $n = 800$ (aantal parkeerbonnen) en $p = 0.75$ (kans op directe betaling). De verwachtingswaarde $E(X)$ en standaardafwijking $\sigma(X)$ van deze kansvariabele zijn gelijk aan

$$\begin{aligned} E(X) &= n \cdot p = 800 \cdot 0.75 = 600 \\ \sigma(X) &= \sqrt{n \cdot p \cdot (1 - p)} = \sqrt{800 \cdot 0.75 \cdot (1 - 0.75)} \approx 12.2474. \end{aligned}$$

Om te bepalen of 520 directe betalers een uitzonderlijk aantal is, bepalen we de

kans op hoogstens 520 directe betalers.

$$P(X \leq 520) = \text{binomcdf}(n = 800, p = 0.75, k = 520) = 1.9170 \cdot 10^{-10}.$$

Aangezien deze kans extreem klein is, is een aantal van 520 directe betalers uitzonderlijk laag. Merk op dat 520 inderdaad een aantal standaardafwijkingen onder de verwachtingswaarde ligt.

- (b) Wat is het verwachte bedrag dat binnenkomt van een dag met 800 bekeurden en wat is de standaarddeviatie?

Uitwerking

Het bedrag dat binnenkomt op een dag met 800 bekeurden is een kansvariabele $B = 40 \cdot X$. Het verwachte bedrag dat binnenkomt is dus gelijk aan

$$E(B) = E(40 \cdot X) = 40 \cdot E(X) = 40 \cdot 600 = \text{€}24000,$$

en de standaardafwijking is dus gelijk aan

$$\sigma(B) = \sigma(40 \cdot X) = 40 \cdot \sigma(X) = 40 \cdot 12.2474 \approx \text{€}489.90.$$

- (c) De gemeente besluit extra invorderingsmaatregelen te nemen voor de niet-betalers van de boete. Zo'n actie kost 5 euro per niet-betaalde parkeerbon. De boete is nu verhoogd naar 52 euro. Bekend is dat van deze groep 60 % daarna betaalt. Maak een kosten-batenanalyse van de extra maatregel.

Uitwerking

Stel dat deze extra maatregel ingevoerd zou worden. Naar verwachting zijn er 600 directe betalers en dus 200 niet-directe betalers die deze maatregel gaan ervaren. Het aantal betalers in tweede instantie, na intreding van de maatregel, is een binomiaal verdeelde kansvariabele Y met parameters $n = 200$ en $p = 0.60$. De verwachte opbrengst van deze groep is dus $200 \cdot 0.6 \cdot \text{€}52 = \text{€}6240$. De verwachte kosten van deze maatregel zijn gelijk aan $200 \cdot \text{€}5 = \text{€}1000$. Naar verwachting is het dus financieel zeer aantrekkelijk om de maatregel door te voeren.

Opdracht 6.14: Bij een keukenbedrijf weet men dat van alle klanten die een catalogus aanvragen, 15 % daadwerkelijk een bestelling zal plaatsen in de maand volgend op de toezending van de catalogus. Daarna, dus méér dan een maand later, blijken er nooit bestellingen te worden gedaan.

- (a) In een bepaalde maand worden 120 catalogi verzonden. Bereken de kans dat meer dan twintig klanten een bestelling gaan plaatsen.

Uitwerking

Laat X de kansvariabele zijn die het aantal klanten telt dat daadwerkelijk een bestelling zal plaatsen. Er geldt dat $X \sim \text{Binomiaal}(n, p)$, met parameters $n = 120$ (aantal klanten dat een catalogus heeft aangevraagd) en $p = 0.15$ (kans dat een klant die een catalogus aanvraagt daadwerkelijk een bestelling plaatst). We willen de kans $P(X > 20)$ bepalen (“meer dan” betekent “>”):

$$\begin{aligned} P(X > 20) &= P(X \geq 21) = 1 - P(X \leq 20) \\ &= 1 - \text{binomcdf}(n = 120, p = 0.15, k = 20) \\ &\approx 0.2557. \end{aligned}$$

Met 25.57 % kans zullen meer dan twintig klanten een bestelling gaan plaatsen.

- (b) In een bepaald jaar worden 1200 catalogi aangevraagd. Hoe groot is het verwachte aantal bestellingen? Bereken een voorspellingsinterval (symmetrisch) waarvoor geldt dat hierin met 95 % kans het aantal waar te nemen bestellingen ligt.

Uitwerking

De kansvariabele $X \sim \text{Binomiaal}(n, p)$ telt het aantal klanten dat daadwerkelijk een bestelling zal plaatsen, met nu $n = 1200$ (aantal klanten die een catalogus aangevraagd hebben) en $p = 0.15$ (kans dat een klant die een catalogus aanvraagt daadwerkelijk een bestelling plaatst). We vinden nu dat

$$E(X) = n \cdot p = 1200 \cdot 0.15 = 180,$$

en

$$\sigma(X) = \sqrt{n \cdot p \cdot (1 - p)} \approx 12.3693.$$

Het 95 %-voorspellingsinterval worden dan gegeven door

$$E(X) - 2 \cdot \sigma(X) = 180 - 2 \cdot 12.3693 \approx 155.2614,$$

$$E(X) + 2 \cdot \sigma(X) = 180 + 2 \cdot 12.3693 \approx 204.7386.$$

Met 95 % kans zal het aantal waar te nemen bestellingen tussen 155 en 205 liggen (merk op: naar buiten afronden om 95 % zekerheid te behouden).

- (c) In een bepaalde periode werden 800 catalogi verzonden. Hoe groot is de kans dat de fractie bestellers minder is dan 10 % voor deze groep aanvragers?

Uitwerking

De kansvariabele $X \sim \text{Binomiaal}(n, p)$ telt het aantal klanten dat daadwerkelijk een bestelling zal plaatsen, met nu $n = 800$ (aantal klanten die een catalogus aangevraagd hebben) en $p = 0.15$ (kans dat een klant die een catalogus aanvraagt daadwerkelijk een bestelling plaatst). Laat F de fractie van het totaal aantal klanten zijn dat daadwerkelijk een bestelling zal plaatsen. We willen de kans $P(F < 0.1)$ bepalen (“minder dan” betekent “<”):

$$\begin{aligned} P(F < 0.1) &= P(X < 0.1 \cdot n) \\ &= P(X < 80) \\ &= P(X \leq 79) \\ &= \text{binomcdf}(n = 800, p = 0.15, k = 79) \\ &\approx 1.2317 \cdot 10^{-5}. \end{aligned}$$

Het is zeer onwaarschijnlijk dat minder dan 10% van de groep aanvragers een bestelling plaatst.

Week 5

De normale verdeling en de centrale limietstelling

Hoofdstuk 5

Opdracht 5.m1: Voor een willekeurige normale verdeling geldt dat de volgende drie grootheden aan elkaar gelijk moeten zijn:

- (a) gemiddelde, standaarddeviatie en mediaan.
- (b) modus, de totale kans en de variantie.
- (c) mediaan, gemiddelde en modus.
- (d) standaarddeviatie, variantie en spreidingsbreedte.

Uitwerking

De normale verdeling is een symmetrische, continue kansverdeling. Hierdoor zijn de mediaan, het gemiddelde en de modus allemaal gelijk aan elkaar. Het juiste antwoord is dus (c).

Opdracht 5.m3: Voor de populatie van mannelijke economiestudenten is bekend dat het lichaamsgewicht kan worden beschreven door middel van een normaal verdeelde kansvariabele X met $\mu = 75$ kilogram en een standaarddeviatie van 6 kilogram. Hieruit volgt dat het percentage studenten van deze populatie dat een gewicht van meer dan 85 kilogram heeft ongeveer bedraagt:

- (a) 95.2.
- (b) 66.

(c) 34.

(d) 4.8.

Uitwerking

De kansvariabele X meet het lichaamsgewicht van een willekeurige mannelijke economiestudent en is normaal verdeeld met $\mu = 75$ en $\sigma = 6$. Om de kans te berekenen dat iemand meer dan 85 kilogram weegt, maken we gebruik van de functie “normalcdf” op de grafische rekenmachine:

$$P(X > 85) = \text{normalcdf}(\text{lower} = 85, \text{upper} = 10^{99}, \mu = 75, \sigma = 6) \\ \approx 0.0478.$$

Ongeveer 4.78 % van de mannelijke economiestudenten heeft een gewicht van meer dan 85 kilogram. Het juiste antwoord is dus (d).

Opdracht 5.m4: Het aantal jaarlijkse reiskilometers aan woon-werkverkeer per auto is voor de werknemers van een groot concern nauwkeurig geregistreerd. Het bleek hierbij dat dit aantal goed kon worden beschreven door een normale verdeling met $\mu = 8000$ kilometer en $\sigma = 2500$. Op basis van deze verdeling kan worden vastgesteld dat de 10 % werknemers die het grootste aantal woon-werkkilometers maken, per jaar per persoon meer reizen dan ongeveer ...

(a) 8000 km.

(b) 10500 km.

(c) 11200 km.

(d) 12100 km.

Uitwerking

De kansvariabele X meet het aantal woon-werkkilometers van een willekeurige werknemer en is normaal verdeeld met $\mu = 8000$ en $\sigma = 2500$.

We willen in dit geval, gegeven een kans van 0.10, de grenswaarde g berekenen waarvoor geldt $P(X \geq g) = 0.10$, oftewel $P(X \leq g) = 1 - 0.10 = 0.90$. Hiervoor moeten we dus gebruik maken van de functie “invNorm” op de grafische rekenmachine.

$$g = \text{InvNorm}(\text{area} = 1 - 0.10 = 0.90, \mu = 8000, \sigma = 2500) \\ \approx 11204 \text{ km.}$$

Het juiste antwoord is dus (c).

Noot: bij het gebruik van de functie “InvNorm” wordt in de rest van de uitwerkingen altijd uitgegaan van de oppervlakte links van de grenswaarde g (oftewel we gebruiken

Tail=LEFT), tenzij expliciet anders aangegeven.

Opdracht 5.m5: Van een normaal verdeelde kansvariabele X is gegeven dat deze een standaarddeviatie heeft die gelijk is aan 9. Verder is gegeven dat $P(X < 15.5) = 0.3085$. De waarde van μ van deze variabele is dan ...

(a) 16.

(b) 17.

(c) 20.

(d) 11.

Uitwerking

In dit geval willen we bepalen wat de waarde van μ is zodanig dat geldt:

$$\text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 15.5, \mu = ?, \sigma = 9) = 0.3085.$$

Gebruik hiervoor de functie “Numeric Solver”, via MATH-C en vul het volgende in:

$$E_1 = \text{normalcdf}(-10^{99}, 15.5, X, 9)$$

$$E_2 = 0.3085$$

Zodra je dit hebt ingevoerd en op OK hebt gedrukt (via de knop “graph”), krijg je een scherm te zien met “ $X =$ ” en “bound =”.

- “ $X =$ ” geeft een eerste gok aan voor de waarde van X . Voor nu maakt het niet uit wat je hier invult, dus stel $X = 0$.
- “bound =” geeft aan in welk gebied de rekenmachine de oplossing moet gaan zoeken. De standaardinstellingen $\{-1E99, 1E99\}$ kun je laten staan.

Als je met de cursor op de regel staat met “ $X =$ ”, dan komt er SOLVE in beeld te staan. Druk nu op SOLVE (nogmaals de knop “graph”). Als je dat niet doet, lost de rekenmachine niet de vergelijking op! De rekenmachine gaat nu de vergelijking $E_1 = E_2$ oplossen, waaruit een oplossing X komt.

Dit geeft in ons geval de oplossing $X = 20.0010$. Dit betekent dat μ een waarde van ongeveer 20 heeft. Het juiste antwoord is dus (c).



Noot: bij de Casio fx-CG50 is de syntax gelijk aan

$$\text{SolveN}(\text{NormCD}(-10^{99}, 15.5, 9, x) = 0.3085, x) = 20.0010$$

Let opnieuw op dat de volgorde van μ en σ omgedraaid zijn. Het zou kunnen dat je nu een waarschuwing in beeld krijgt dat de vergelijking die je oplost meerdere oplossingen zou kunnen hebben. Deze kun je negeren, aangezien er maar één unieke x -waarde is die voldoet aan deze vergelijking.

Opdracht 5.m6: Voor een speerwerper geldt dat het resultaat van een worp X kan worden beschreven door een normale verdeling met $\mu = 61$ meter en $\sigma = 3$ meter. De speerwerper doet drie pogingen, waarvoor mag worden verondersteld dat de worpresultaten kunnen worden beschouwd als onderling onafhankelijke kansvariabelen. De kans dat het gemiddelde resultaat van de drie worpen minder is dan 59 meter, is ongeveer gelijk aan ...

- (a) 0.35.
- (b) 0.255.
- (c) 0.125.
- (d) 0.745.

Uitwerking

Aangezien de originele verdeling de normale verdeling is, volgt uit de centrale limietstelling dat de kansverdeling van het gemiddelde $\bar{X}$ van deze drie worpen van de speerwerper gelijk is aan de normale verdeling met verwachtingswaarde $\mu = 61$ meter en standaarddeviatie $\frac{\sigma}{\sqrt{n}} = \frac{3}{\sqrt{3}} = \sqrt{3}$ meter. De kans dat het gemiddelde resultaat van de drie worpen minder is dan 59 meter is gelijk aan:

$$P(\bar{X} \leq 59) = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 59, \mu = 61, \sigma = \sqrt{3}) \approx 0.1241.$$

Het juiste antwoord is dus (c).

Opdracht 5.2: Een vulmachine vult pakken rijst waarop staat dat daarin 1000 gram rijst zit. Omdat er altijd wat variatie zit in de afgeleverde hoeveelheden, staat de machine ingesteld op een gemiddeld vulgewicht van 1010 gram. We mogen ervan uitgaan dat de afgeleverde hoeveelheden beschreven worden door een normale verdeling met $\mu = 1010$ gram. De standaarddeviatie is echter onbekend.

- (a) Bij nauwkeurig nawegen van een groot aantal pakken bleek dat in 20 % van de gevallen een pak minder dan 1000 gram rijst bevat. Bereken op basis van deze informatie de standaarddeviatie van de vulgewichten.

Uitwerking

We noteren met X het vulgewicht van een willekeurig pak rijst. Er geldt dat X normaal verdeeld is met verwachtingswaarde $\mu = 1010$ en onbekende standaardafwijking σ . Verder is gegeven dat de kans op een gewicht van minder dan 1000 gram is 20 %, oftewel $P(X \leq 1000) = 0.2$.

We kunnen de standaardafwijking σ vinden als we de vergelijking $P(X \leq 1000) = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 1000, \mu = 1010, \sigma = ?) = 0.2$ kunnen oplossen. Dit doen we met behulp van de “numeric solver”:

$$E_1 = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 1000, \mu = 1010, \sigma = X)$$

$$E_2 = 0.2$$

Uit de functie “Numeric Solver” volgt dan een standaardafwijking $\sigma = X \approx 11.8818$.

- (b) Hoe groot is de kans dat een willekeurig pak rijst meer weegt dan 1020 gram?

Uitwerking

Zodra we de verwachtingswaarde μ en de standaarddeviatie σ van een normale verdeling weten, kunnen we de kans berekenen dat een willekeurig pak rijst meer dan 1020 gram weegt:

$$P(X > 1020) = \text{normalcdf}(\text{lower} = 1020, \text{upper} = 10^{99}, \mu = 1010, \sigma = 11.8818) \approx 0.2000.$$

Merk op dat we dit ook zonder berekening hadden kunnen inzien. We hebben immers te maken met een normale verdeling met gemiddelde $\mu = 1010$, oftewel een symmetrische verdeling rond 1010. Uit deze symmetrie volgt dat $P(X > 1020 = 1010 + 10) = P(X < 1000 = 1010 - 10) = 0.20$.

- (c) Stel we kiezen willekeurig 16 pakken rijst. Hoe groot is de kans dat deze gemiddeld minder dan 1000 gram rijst bevatten?

Uitwerking

Laat $X_1, X_2, \dots, X_{16}$ de gewichten zijn van 16 willekeurig gekozen pakken rijst. Volgens de centrale limietstelling geldt dat het gemiddelde gewicht van deze 16 pakken rijst

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_{16}}{16}$$

normaal verdeeld is met $\mu = 1010$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{11.8818}{\sqrt{16}} \approx 2.9705$. De kans dat de 16 willekeurig gekozen pakken rijst gemiddeld minder dan 1000 gram rijst bevatten is dan gelijk aan

$$P(\bar{X} < 1000) = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 1000, \mu = 1010, \sigma = 2.9705) \\ \approx 3.8072 \cdot 10^{-4}.$$

Opdracht 5.4: Bepaal voor de standaardnormaal verdeelde variabele Z :

- $P(Z < -0.35)$
- $P(-0.16 < Z < 0.16)$
- $P(Z > -1.15)$

Uitwerking


We kunnen deze kansen bepalen aan de hand van de functie “normalcdf” op de grafische rekenmachine.

$$P(Z < -0.35) = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = -0.35, \mu = 0, \sigma = 1) \\ \approx 0.3632.$$

$$P(-0.16 < Z < 0.16) = \text{normalcdf}(\text{lower} = -0.16, \text{upper} = 0.16, \mu = 0, \sigma = 1) \\ \approx 0.1271.$$

$$P(Z > -1.15) = \text{normalcdf}(\text{lower} = -1.15, \text{upper} = 10^{99}, \mu = 0, \sigma = 1) \\ \approx 0.8749.$$

Deze kansen kunnen ook visueel geïllustreerd worden als de oppervlaktes van de blauw gearceerde gebieden in de onderstaande figuur:



Opdracht 5.5: Een garagebedrijf bestudeert de tijdsduur waarin de jaarlijkse servicebeurt van een auto kan worden uitgevoerd. Deze kan worden beschouwd als een normaal verdeelde variabele X met $\mu = 120$ minuten en $\sigma = 20$ minuten.

- (a) Hoe groot is de kans dat een servicebeurt meer dan 150 minuten vergt?

Uitwerking

De kansvariabele X die de tijdsduur meet van de jaarlijkse servicebeurt van een willekeurige auto is normaal verdeeld met $\mu = 120$ en $\sigma = 20$ minuten. De kans dat een servicebeurt meer dan 150 minuten vergt is dan gelijk aan

$$P(X > 150) = \text{normalcdf}(\text{lower} = 150, \text{upper} = 10^{99}, \mu = 120, \sigma = 20) \\ \approx 0.0668.$$

- (b) Een klant komt zijn auto brengen voor service. De werkzaamheden gaan onmiddellijk beginnen. De garagehouder zegt tegen de klant: “Komt u over x minuten maar terug”. Hoe groot moet x worden gekozen als we eisen dat de klant minder dan 5 % kans wil hebben dat hij nog moet wachten als hij zich na X minuten weer meldt bij de garage? En hoe zit dat bij 1 % kans?

Uitwerking

De klant heeft minder dan 5% kans om nog te moeten wachten als hij terugkomt bij de garage na x minuten als geldt:

$$P(X > x) < 0.05 \rightarrow P(X \leq x) > 1 - 0.05 = 0.95.$$

We willen dus een grenswaarde bepalen, en dat kunnen we doen met de functie “InvNorm”:

$$x = \text{InvNorm}(\text{area} = 0.95, \mu = 120, \sigma = 20) \approx 152.8971 \text{ min.}$$

In het geval van minder dan 1 % is de berekening op een soortgelijke manier te maken, namelijk:

$$P(X > x) < 0.01 \rightarrow P(X \leq x) > 1 - 0.01 = 0.99.$$

We willen dus een grenswaarde bepalen, en dat kunnen we opnieuw doen met de functie “InvNorm”:

$$x = \text{InvNorm}(\text{area} = 0.99, \mu = 120, \sigma = 20) \approx 166.5270 \text{ min.}$$

Opdracht 5.6: De gewichten van appels uit een grote partij blijken normaal verdeeld te zijn met $\mu = 100$ gram en $\sigma = 20$ gram. We willen deze appels in vijf gewichtsklassen verdelen die allemaal evenveel appels bevatten.

- (a) Wat is de klassengrens van de 20 % appels met het geringste gewicht?

Uitwerking

De kansvariabele X meet het gewicht van een willekeurige appel en is normaal verdeeld met $\mu = 100$ en $\sigma = 20$ gram. Je wilt de appels opdelen in vijf gewichtsklassen die elk evenveel appels bevatten, dat wil zeggen dat de kans dat een appel in een bepaalde gewichtsklasse zit moet gelijk zijn voor elke gewichtsklasse. Er zijn vijf klassen dus die kans is telkens $\frac{1}{5} = 0.2$. De klasse met de 20 % lichtste appels loopt van $-\infty$ tot g_1 voor een bepaald gewicht g_1 en er geldt $P(X < g_1) = 0.2$. Dat betekent dus dat

$$g_1 = \text{InvNorm}(\text{area} = 0.2, \mu = 100, \sigma = 20) \approx 83.1676 \text{ g.}$$

Noot: het gewicht van een appel kan natuurlijk niet negatief zijn. De normale verdeling heeft echter een uitkomstenruimte bestaande uit alle mogelijke waarden van $-\infty$ tot ∞ . Dit is een beperking van de normale verdeling als kansmodel, maar de kans dat je uit deze normale verdeling een negatieve uitkomst kan waarnemen is verwaarloosbaar klein.

$$\begin{aligned} P(X < 0) &= \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 0, \mu = 100, \sigma = 20) \\ &\approx 0.0000003. \end{aligned}$$

- (b) Bepaal ook de andere klassengrenzen?

Uitwerking

Om de overige klassengrenzen te bepalen, gebruiken we soortgelijke berekeningen. Voor de tweede klassegrens g_2 geldt

$$P(g_1 < X < g_2) = 0.2.$$

Omdat voor g_1 geldt dat $P(X < g_1) = 0.2$, geldt nu dat:

$$P(X < g_2) = P(X < g_1) + P(g_1 < X < g_2) = 0.2 + 0.2 = 0.4.$$

We kunnen de tweede klassegrens dus bepalen als volgt:

$$g_2 = \text{InvNorm}(\text{area} = 0.4, \mu = 100, \sigma = 20) \approx 94.9331 \text{ gram.}$$

Op een soortgelijke manier vinden we g_3 en g_4 :

$$g_3 = \text{InvNorm}(\text{area} = 0.6, \mu = 100, \sigma = 20) \approx 105.0669 \text{ gram.}$$

$$g_4 = \text{InvNorm}(\text{area} = 0.8, \mu = 100, \sigma = 20) \approx 116.8324 \text{ gram.}$$

Opdracht 5.10: In een kliniek wordt van een groep 50-plussers bloed afgenomen voor de bepaling van het cholesterolgehalte. Het is een bekend gegeven dat de hoeveelheid cholesterol per buisje bloed kan worden weergegeven door een normaal verdeelde variabele X met $\mu = 5.20$ mg en $\sigma = 0.9$ mg. Het 98-ste percentiel van een verdeling is het punt op de x -as waarboven zich 2 % van de waarnemingen bevindt, dus waaronder 98 % van de waarnemingen ligt.

- (a) Welke x -waarde geeft hier het 98-ste percentiel aan?

Uitwerking

De kansvariabele X meet de hoeveelheid cholesterol (in mg) van een willekeurig buisje bloed en is normaal verdeeld met $\mu = 5.20$ en $\sigma = 0.9$. Het 98-ste percentiel berekenen is hetzelfde als een waarde x vinden waarvoor geldt dat $P(X \leq x) = 0.98$. Met andere woorden, we willen een grenswaarde berekenen en dat kunnen we doen met behulp van de functie “InvNorm”:

$$x = \text{InvNorm}(\text{area} = 0.98, \mu = 5.20, \sigma = 0.9) \approx 7.0484 \text{ mg.}$$

- (b) Hoeveel standaarddeviaties ligt dat punt verwijderd van het gemiddelde van 5.20 mg.

Uitwerking

Het aantal standaarddeviaties waarmee x verwijderd ligt van het gemiddelde 5.20 mg is gelijk aan de z -score:

$$z = \frac{x - \mu}{\sigma} = \frac{7.0484 - 5.20}{0.9} \approx 2.0537.$$

De waarde $x \approx 7.0484$ mg ligt dus net iets meer dan 2 standaarddeviaties boven het gemiddelde $\mu = 5.20$ mg.

- (c) In een gemeente wordt een bevolkingsonderzoek gehouden naar het cholesterolgehalte. Hierbij waren 8500 personen betrokken. Mensen met een cholesterolwaarde boven het 98-ste percentiel worden voor nader onderzoek opgeroepen. Hoeveel personen krijgt naar verwachting een oproep?

Uitwerking

Per definitie van percentielen, geldt dat 2 % van de bevolking een cholesterolwaarde heeft boven het 98-ste percentiel. In een groep van 8500 personen zullen naar verwachting dus $0.02 \cdot 8500 = 170$ mensen een oproep krijgen voor nader onderzoek.

- (d) Voor een willekeurig persoon uit de groep 50-plussers bepalen we het cholesterolgehalte. Noem deze uitkomst y . Wat is het twee-sigma gebied voor y ? en het drie-sigma gebied?

Uitwerking

Het twee-sigma gebied voor y is het interval van uitkomsten binnen 2 standaarddeviaties van het gemiddelde μ , oftewel het interval van $\mu - 2 \cdot \sigma$ tot $\mu + 2 \cdot \sigma$. Er geldt dat:

$$\mu - 2 \cdot \sigma = 5.20 - 2 \cdot 0.9 = 3.40,$$

$$\mu + 2 \cdot \sigma = 5.20 + 2 \cdot 0.9 = 7.00.$$

Het twee-sigma gebied loopt dus van 3.40 tot 7.00. Op een soortgelijke manier vinden we het drie-sigma gebied:

$$\mu - 3 \cdot \sigma = 5.20 - 3 \cdot 0.9 = 2.50,$$

$$\mu + 3 \cdot \sigma = 5.20 + 3 \cdot 0.9 = 7.90.$$

Het drie-sigma gebied loopt dus van 2.50 tot 7.90.

Opdracht 5.12: De tijd die een vertegenwoordiger nodig heeft voor het bezoeken van een klant wordt weergegeven door de kansvariabele X . Op grond van ervaring is bekend dat X normaal verdeeld is met $\mu = 45$ minuten en $\sigma = 10$ minuten (in de tijdsduur X is ook de reistijd opgenomen). De tijdsduren van bezoeken zijn onderling onafhankelijk.

- (a) Hoe groot is de kans dat een willekeurig bezoek meer dan 60 minuten vergt?

Uitwerking

De kansvariabele X meet de tijdsduur van een willekeurig klantbezoek en is normaal verdeeld met $\mu = 45$ en $\sigma = 10$. De kans dat een willekeurig bezoek meer dan 60 minuten vergt is dus gelijk aan

$$\begin{aligned} P(X > 60) &= \text{normalcdf}(\text{lower} = 60, \text{upper} = 10^{99}, \mu = 45, \sigma = 10) \\ &\approx 0.0668. \end{aligned}$$

Met 6.68 % kans vergt een willekeurig bezoek meer dan 60 minuten.

- (b) Hoe groot is de kans dat acht bezoeken meer dan $6\frac{1}{2}$ uur vergen?

Uitwerking

De kansvariabelen $X_1, X_2, \dots, X_8$ meten de tijdsduur van acht verschillende klantbezoeken, onafhankelijk van elkaar. Volgens de centrale limietstelling geldt dat de totale tijdsduur, oftewel de som $X_1 + X_2 + \dots + X_8$, normaal verdeeld is met gemiddelde $n \cdot \mu = 8 \cdot 45 = 360$ minuten en standaardafwijking $\sigma \cdot \sqrt{n} = 10\sqrt{8}$. De

kans dat acht bezoeken meer dan $6\frac{1}{2}$ uur, oftewel 390 minuten, vergen is gelijk aan

$$\begin{aligned} &P(X_1 + X_2 + \dots + X_8 > 390) \\ &= \text{normalcdf}(\text{lower} = 390, \text{upper} = 10^{99}, \mu = 360, \sigma = 10\sqrt{8}) \\ &\approx 0.1444. \end{aligned}$$

Met 14.44 % kans zullen de acht bezoeken in totaal meer dan $6\frac{1}{2}$ uur vergen.

- (c) De vertegenwoordiger moet op een zekere dag tien klanten bezoeken. Hoeveel tijd T moet hij reserveren om met 95 % kans de tien bezoeken binnen de tijdsduur T te kunnen afhandelen?

Uitwerking

De kansvariabelen $X_1, X_2, \dots, X_{10}$ meten de tijdsduur van tien verschillende klantbezoeken, onafhankelijk van elkaar. Volgens de centrale limietstelling geldt dat de totale tijdsduur, oftewel de som $X_1 + X_2 + \dots + X_{10}$, normaal verdeeld is met gemiddelde $n \cdot \mu = 10 \cdot 45 = 450$ minuten en standaardafwijking $\sigma \cdot \sqrt{n} = 10 \cdot \sqrt{10}$.

We willen nu de grens T berekenen waarvoor geldt dat $P(X_1 + X_2 + \dots + X_{10} \leq T) = 0.95$.

Hiervoor kunnen we weer de “Numeric Solver” functie gebruiken. Vul in:

$$\begin{aligned} E_1 &= \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = X, \mu = 450, \sigma = 10\sqrt{10}) \\ E_2 &= 0.95 \end{aligned}$$

Dit geeft een oplossing $X \approx 502.0148$. De vertegenwoordiger moet dus net iets meer dan 8 uur en 22 minuten reserveren om de tien bezoeken met 95 % kans binnen de tijd af te kunnen handelen.

Week 6

De Poissonverdeling

Hoofdstuk 7

Opdracht 7.m1: Welke van de volgende uitspraken over een kansvariabele X met een Poissonverdeling is waar?

- (a) Het waargenomen aantal successen kan niet gelijk aan nul zijn.
- (b) De verwachtingswaarde en de standaarddeviatie zijn aan elkaar gelijk.
- (c) Er geldt $\mu = n \cdot \pi$.
- (d) De variabele kan gehele waarden groter of gelijk aan nul aannemen.

Uitwerking

De uitkomstenruimte van een Poisson verdeelde kansvariabele bestaat uit $0, 1, 2, 3, \dots$, oftewel alle niet-negatieve gehele getallen. Het juiste antwoord is dus (d).

Opdracht 7.m2: Het aantal noodlandingen op een bepaalde luchthaven mag worden beschouwd als een kansvariabele met een Poissonverdeling waarbij $\lambda = 0.5$ per maand. De kans dat in een willekeurige periode van zes maanden precies drie noodlandingen plaatsvinden, bedraagt dus ...

- (a) 1.000.
- (b) 0.224.
- (c) 0.013.
- (d) ongeveer 0.455.

Uitwerking

We bekijken een interval van zes maanden met een tijdseenheid van een maand, dus $t = 6$. De parameter μ van de Poissonverdeling voor dit interval is gelijk aan $\lambda \cdot t = 0.5 \cdot 6 = 3$. Het aantal noodlandingen in zes maanden kan dus worden beschouwd als een Poisson verdeelde kansvariabele $X \sim \text{Poisson}(\mu = 3)$. De kans op precies drie noodlandingen in zes maanden is gelijk aan

$$P(X = 3) = \text{poissonpdf}(\mu = 3, k = 3) \approx 0.2240.$$

Het juiste antwoord is dus (b).

Opdracht 7.m3: Het aantal ongevallen per maand op een kruispunt kan worden beschreven door een Poissonverdeling met $\lambda = 0.5$. De standaarddeviatie van het aantal ongelukken per jaar bedraagt daarom ...

- (a) 6.
- (b) $\sqrt{6}$.
- (c) $\frac{0.5}{\sqrt{6}}$.
- (d) $0.5 \times \sqrt{12}$.

Uitwerking

Een jaar heeft 12 maanden, dus we bekijken een interval van twaalf maanden met een tijdseenheid van een maand, oftewel $t = 12$. Het aantal ongevallen per jaar kan in dat geval worden beschreven door een Poissonverdeling met $\mu = \lambda \cdot t = 0.5 \cdot 12 = 6$. De standaarddeviatie van een $\text{Poisson}(\mu)$ -verdeling is gelijk aan $\sqrt{\mu}$, oftewel $\sqrt{\mu} = \sqrt{6}$. Het juiste antwoord is dus (b).

Opdracht 7.m5: Bij een landelijk bingospelletje is de kans op het winnen van een prijs 0.001. In een zaal vanwaaruit een directe televisie-uitzending plaatsvindt, bevinden zich 1500 mensen. De kans dat zich in die zaal meer dan één prijswinnaar bevindt, is gelijk aan ...

- (a) 0.592.
- (b) ongeveer 0.50.
- (c) 0.409.
- (d) 0.442.

Uitwerking

Het aantal winnaars in de zaal kan worden beschreven door een binomiaal verdeelde kansvariabele X met parameters $n = 1500$ en $p = 0.001$. Deze verdeling kan worden

benaderd met de Poissonverdeling met $\mu = n \cdot p = 1500 \cdot 0.001 = 1.5$. De kans dat zich in de zaal meer dan één prijswinnaar bevindt is gelijk aan

$$P(X > 1) = 1 - P(X \leq 1) = 1 - \text{poissoncdf}(\mu = 1.5, k = 1) \approx 0.4422.$$

Het juiste antwoord is dus (d).

Opdracht 7.m6: De tijd (in minuten) die verstrijkt tussen de binnenkomst van twee opeenvolgende klanten bij een postkantoor, kan worden beschouwd als een kansvariabele T die een negatief exponentiële verdeling heeft met parameters $\lambda = 4$. De standaarddeviatie van de variabele T is dan gelijk aan ...

- (a) 4 minuten.
- (b) 0.25 minuten.
- (c) 2 minuten.
- (d) 0.50 minuten.

Uitwerking

De standaarddeviatie σ van een (negatief) exponentieel verdeelde kansvariabele T met parameter λ is gelijk aan $\sigma = \sqrt{\text{Var}(T)} = \sqrt{\frac{1}{\lambda^2}} = \frac{1}{\lambda}$. Als $\lambda = 4$, is de standaarddeviatie dus gelijk aan $\frac{1}{\lambda} = \frac{1}{4} = 0.25$. Het juiste antwoord is dus (b).

Opdracht 7.3: Het aantal lekke banden dat bij een garage dagelijks ter reparatie wordt aangeboden, mag worden beschouwd als een kansvariabele K met een Poissonverdeling met $\lambda = 4$ per dag. Bepaal met de tabel van de Poissonverdeling voor een willekeurige dag de kans op het ter reparatie aanbieden van:

- (a) precies één lekke band.

Uitwerking

Als we het aantal lekke banden tellen op een willekeurige dag, dan bekijken we een interval van één dag met een tijdseenheid van een dag, oftewel $t = 1$. De parameter μ van de Poissonverdeling voor dit interval is gelijk aan $\mu = \lambda \cdot t = 4 \cdot 1 = 4$. De kans op precies één lekke band is gelijk aan

$$P(K = 1) = \text{poissonpdf}(\mu = 4, k = 1) \approx 0.0733.$$

- (b) precies zes lekke banden.

Uitwerking

De kans op precies zes lekke banden is gelijk aan

$$P(K = 6) = \text{poissonpdf}(\mu = 4, k = 6) \approx 0.1042.$$

(c) meer dan drie lekke banden.

Uitwerking

De kans op meer dan drie lekke banden is gelijk aan

$$P(K > 3) = P(K \geq 4) = 1 - P(K \leq 3) = 1 - \text{poissoncdf}(\mu = 4, k = 3) \approx 0.5665.$$

(d) minder dan drie lekke banden.

Uitwerking

De kans op minder dan drie lekke banden is gelijk aan

$$P(K < 3) = P(K \leq 2) = \text{poissoncdf}(\mu = 4, k = 2) \approx 0.2381.$$

(e) meer dan vier, maar minder dan tien lekke banden.

Uitwerking

De kans op meer dan vier, maar minder dan tien lekke banden is gelijk aan

$$\begin{aligned} P(4 < K < 10) &= P(5 \leq K \leq 9) \\ &= P(K \leq 9) - P(K \leq 4) \\ &= \text{poissoncdf}(\mu = 4, k = 9) - \text{poissoncdf}(\mu = 4, k = 4) \\ &\approx 0.3630. \end{aligned}$$

Opdracht 7.4: Voor een eerstehulpafdeling van een ziekenhuis geldt dat het aantal patiënten met brandwonden dat per dag binnenkomt, kan worden beschreven door een Poissonverdeling met $\lambda = 0.35$. Bereken met de formule van de Poissonverdeling de kans dat het aantal van dergelijke patiënten per dag ...

(a) precies nul bedraagt.

Uitwerking

Laat X de kansvariabele zijn die het aantal patiënten telt dat op een willekeurige dag met brandwonden binnenkomt op de eerstehulpafdeling van het ziekenhuis. We bekijken een interval van één dag met een tijdseenheid van een dag, oftewel $t = 1$. De parameter μ van de Poissonverdeling voor dit interval is gelijk aan $\mu = \lambda \cdot t = 0.35 \cdot 1 = 0.35$. Gegeven is dat $X \sim \text{Poisson}(\mu = 0.35)$. De Poissonformule

geeft voor elke mogelijke uitkomst $k = 0, 1, 2, \dots$ de kans op die uitkomst aan als

$$P(X = k) = e^{-\mu} \cdot \frac{\mu^k}{k!}.$$

De kans dat het aantal van dergelijke patiënten per dag precies nul bedraagt is dus gelijk aan

$$P(X = 0) = e^{-0.35} \cdot \frac{(0.35)^0}{0!} \approx 0.7047.$$

(b) precies één is.

Uitwerking

De kans dat het aantal van dergelijke patiënten per dag precies één bedraagt is dus gelijk aan

$$P(X = 1) = e^{-0.35} \cdot \frac{(0.35)^1}{1!} \approx 0.2466.$$

(c) meer dan één bedraagt.

Uitwerking

De kans dat het aantal van dergelijke patiënten per dag meer dan één bedraagt kan met de complementregel berekend worden:

$$\begin{aligned} P(X > 1) &= P(X \geq 2) = 1 - P(X \leq 1) \\ &= 1 - P(X = 0) - P(X = 1) \\ &\approx 1 - 0.7047 - 0.2466 \\ &\approx 0.0487. \end{aligned}$$

Opdracht 7.6: In een containerhaven kunnen per dag drie schepen worden afgehandeld met laden en lossen. Bekend is dat het aantal binnenlopende schepen een variabele is met een Poissonverdeling met $\lambda = 2$ per dag. Schepen die zich melden wanneer op een dag reeds drie schepen in behandeling zijn, worden doorverwezen naar een andere haven.

(a) Hoe groot is de kans dat op een willekeurige dag een of meer schepen moeten worden doorverwezen?

Uitwerking

Laat X de kansvariabele zijn die het aantal binnenlopende schepen telt op een willekeurige dag. We bekijken een interval van één dag met een tijdseenheid van een dag, oftewel $t = 1$. Dan geldt dat X een Poissonverdeling volgt met parameter $\mu = \lambda \cdot t = 2 \cdot 1 = 2$.

De situatie waarin een of meer schepen moeten worden doorverwezen vindt plaats

als er meer dan drie schepen binnenlopen. Dit gebeurt met een kans van

$$P(X > 3) = P(X \geq 4) = 1 - P(X \leq 3) = 1 - \text{poissoncdf}(\mu = 2, k = 3) \approx 0.1429.$$

(b) Hoe groot is het verwachte aantal schepen dat zich per dag aanmeldt?

Uitwerking

De verwachtingswaarde van een Poisson verdeelde kansvariabele met parameter μ is gelijk aan μ . In dit geval is het verwachte aantal schepen per dag dus simpelweg gelijk aan $\mu = 2$.

(c) Hoe groot is het verwachte aantal dat per dag kan worden afgehandeld?

Uitwerking

Merk op dat het aantal schepen dat per dag kan worden afgehandeld begrensd is van boven door 3, omdat in het geval van meer dan 3 schepen de resterende schepen naar andere havens moeten uitwijken. Laat Y het aantal schepen zijn dat op een willekeurige dag wordt afgehandeld, de kansverdeling hiervan wordt gegeven door

Aantal schepen k	$P(Y = k)$
0	$P(X = 0) = \text{poissonpdf}(\mu = 2, k = 0) \approx 0.1353$
1	$P(X = 1) = \text{poissonpdf}(\mu = 2, k = 1) \approx 0.2707$
2	$P(X = 2) = \text{poissonpdf}(\mu = 2, k = 2) \approx 0.2707$
3	$P(X \geq 3) = 1 - \text{poissoncdf}(\mu = 2, k = 2) \approx 0.3233$

Het verwachte aantal schepen dat wordt afgehandeld is gelijk aan de verwachtingswaarde van deze kansvariabele Y , oftewel:

$$\begin{aligned} E[Y] &= 0 \cdot P(Y = 0) + 1 \cdot P(Y = 1) + 2 \cdot P(Y = 2) + 3 \cdot P(Y = 3) \\ &= 0 \cdot 0.1353 + 1 \cdot 0.2707 + 2 \cdot 0.2707 + 3 \cdot 0.3233 \\ &\approx 1.7820. \end{aligned}$$

(d) Wat is het verwachte aantal dat per dag wordt doorverwezen naar een andere haven?

Uitwerking

Het verwachte aantal dat per dag wordt doorverwezen naar een andere haven is gelijk aan het verwachte aantal schepen dat op een dag binnenkomt minus het verwachte aantal schepen dat kan worden afgehandeld. In andere woorden, dit aantal is gelijk aan $2 - 1.7820 = 0.2180$.

Opdracht 7.8: Op de luchthaven van Port Elizabeth is slechts één security-doorgang. Het

aantal passagiers dat zich per minuut meldt bij de security kan worden beschreven door een Poissonverdeling met $\lambda = 3$.

- (a) Hoe groot is de kans dat in een bepaalde minuut geen passagiers arriveren bij het security-punt?

Uitwerking

Laat X de kansvariabele zijn die het aantal passagiers telt dat zich per minuut bij de security meldt. We bekijken een interval van één minuut met een tijdseenheid van een minuut, oftewel $t = 1$. De parameter μ van de Poissonverdeling voor dit interval is gelijk aan $\mu = \lambda \cdot t = 3 \cdot 1 = 3$. Gegeven is dat $X \sim \text{Poisson}(\mu = 3)$. De kans dat in een bepaalde minuut geen passagiers arriveren bij het security-punt is gelijk aan

$$P(X = 0) = e^{-\mu} \cdot \frac{\mu^0}{0!} = e^{-3} \cdot \frac{3^0}{0!} = e^{-3} \approx 0.0498.$$

- (b) Hoe groot is de kans dat er meer dan 5 passagiers komen in een willekeurige minuut?

Uitwerking

De kans dat er meer dan 5 passagiers komen in een willekeurige minuut is gelijk aan

$$P(X > 5) = 1 - P(X \leq 5) = 1 - \text{poissoncdf}(\mu = 3, k = 5) \approx 0.0839.$$

- (c) Hoe groot is de kans dat er meer dan 200 passagiers komen in een willekeurig uur?

Uitwerking

Laat nu X de kansvariabele zijn die het aantal passagiers telt dat in een willekeurig uur aankomt bij de security-doorgang. We bekijken nu een interval van één uur met een tijdseenheid van een minuut, oftewel $t = 60$ minuten. De parameter μ van de Poissonverdeling voor dit interval is gelijk aan $\mu = \lambda \cdot t = 3 \cdot 60 = 180$. De kans op meer dan 200 passagiers in een willekeurig uur is dan gelijk aan

$$\begin{aligned} P(X > 200) &= P(X \geq 201) = 1 - P(X \leq 200) \\ &= 1 - \text{poissoncdf}(\mu = 180, k = 200) \\ &\approx 0.0749. \end{aligned}$$

Opdracht 7.10: Bij een bepaald soort chirurgische ingreep is de kans op het optreden van een bepaalde, zeer zeldzame complicatie gelijk aan 0.002. In een ziekenhuis worden per jaar 400 van dergelijke ingrepen uitgevoerd.

- (a) Hoe groot is de kans dat in een willekeurig jaar meer dan éénmaal een dergelijke complicatie wordt geconstateerd?

Uitwerking

Laat X de kansvariabele zijn die het aantal ingrepen telt waarbij de zeer zeldzame complicatie wordt geconstateerd. Deze kansvariabele is binomiaal verdeeld met parameters $n = 400$ en $p = 0.002$. Aangezien de kans op complicaties zeer klein is, kan deze kansvariabele X benaderd worden met een Poissonverdeling met $\mu = n \cdot p = 400 \cdot 0.002 = 0.8$. De kans dat meer dan éénmaal in een willekeurig jaar de complicatie wordt geconstateerd is gelijk aan

$$P(X > 1) = P(X \geq 2) = 1 - P(X \leq 1) = 1 - \text{poissoncdf}(\mu = 0.8, k = 1) \approx 0.1912.$$

- (b) Landelijk worden per jaar 18000 van dergelijke ingrepen uitgevoerd. Hoe groot is de kans dat in een willekeurig jaar minder dan 30 keer de bedoelde complicatie optreedt?

Uitwerking

In dit geval kunnen we de kansvariabele X benaderen met een Poissonverdeling met parameter $\mu = 18000 \cdot 0.002 = 36$. De kans dat in een willekeurig jaar minder dan 30 keer de bedoelde complicatie optreedt is dus gelijk aan

$$P(X < 30) = P(X \leq 29) = \text{poissoncdf}(\mu = 36, k = 29) \approx 0.1379.$$

Opdracht 7.12: Het aantal schepen K dat per dag in een bepaalde haven aankomt, is te beschouwen als een variabele met een Poissonverdeling waarvoor geldt $\lambda = 2\frac{1}{2}$. Per dag kunnen vier schepen worden afgehandeld in de haven. Als zich meer dan vier schepen melden, dan worden de overige schepen doorgestuurd naar een andere haven.

- (a) Hoe groot is de kans dat op een zekere dag één of meer schepen worden doorgestuurd?

Uitwerking

De kansvariabele K telt het aantal binnenlopende schepen op een willekeurige dag. We bekijken een interval van één dag met een tijdseenheid van een dag, oftewel $t = 1$. De parameter μ van de Poissonverdeling voor X is dus gelijk aan $\mu = \lambda \cdot t = 2\frac{1}{2} \cdot 1 = 2\frac{1}{2}$. Er wordt minstens één schip doorverwezen naar een andere haven als er meer dan vier schepen zich melden in de haven. Dit gebeurt met een kans van

$$P(K > 4) = 1 - P(K \leq 4) = 1 - \text{poissoncdf}(\mu = 2\frac{1}{2}, k = 4) \approx 0.1088.$$

- (b) Wat is het verwachte aantal schepen dat per dag worden doorgestuurd?

Uitwerking

Merk op dat het aantal schepen dat per dag moet worden doorgestuurd gelijk is aan het verwachte aantal binnenkomende schepen ($\mu = 2\frac{1}{2}$) minus het verwachte aantal dat kan worden afgehandeld.

We berekenen eerst het verwachte aantal schepen dat wordt afgehandeld. Het aantal schepen dat wordt afgehandeld is een kansvariabele op zich, zeg kansvariabele Y , omdat deze afhangt van het aantal schepen dat zich meldt. Deze kansvariabele Y heeft als uitkomstenruimte de waarden 0, 1, 2, 3, 4, omdat er maximaal vier schepen per dag kunnen worden afgehandeld. De kansverdeling van Y wordt gegeven door

Aantal schepen k	$P(Y = k)$
0	$P(K = 0) = \text{poissonpdf}(\mu = 2\frac{1}{2}, k = 0) \approx 0.0821$
1	$P(K = 1) = \text{poissonpdf}(\mu = 2\frac{1}{2}, k = 1) \approx 0.2052$
2	$P(K = 2) = \text{poissonpdf}(\mu = 2\frac{1}{2}, k = 2) \approx 0.2565$
3	$P(K = 3) = \text{poissonpdf}(\mu = 2\frac{1}{2}, k = 3) \approx 0.2138$
4	$P(K \geq 4) = 1 - \text{poissoncdf}(\mu = 2\frac{1}{2}, k = 3) \approx 0.2424$

Het verwachte aantal schepen dat wordt afgehandeld is gelijk aan verwachtingswaarde van deze kansvariabele Y , oftewel:

$$\begin{aligned}
 E[Y] &= 0 \cdot P(Y = 0) + 1 \cdot P(Y = 1) + 2 \cdot P(Y = 2) + 3 \cdot P(Y = 3) + 4 \cdot P(Y = 4) \\
 &\approx 0 \cdot 0.0821 + 1 \cdot 0.2052 + 2 \cdot 0.2565 + 3 \cdot 0.2138 + 4 \cdot 0.2424 \\
 &\approx 2.3292.
 \end{aligned}$$

Het verwachte aantal schepen dat moet worden doorgestuurd is dus gelijk aan $2.5 - 2.3292 = 0.1708$.

- (c) Hoe groot moet de capaciteit van de haven worden om een kans kleiner dan 0.01 te hebben dat op een willekeurige dag een of meer schepen worden doorgestuurd?

Uitwerking

Laat C de capaciteit van de haven zijn, oftewel het aantal schepen dat per dag kan worden afgehandeld. We willen de capaciteit C dusdanig vinden zodat de kans dat er meer dan C schepen aankomen op een dag kleiner is dan 0.01, omdat in dat geval er minstens één schip moet worden doorgestuurd. Om deze capaciteit C te bepalen, moeten we dus de volgende ongelijkheid oplossen:

$$P(X > C) = 1 - P(X \leq C) = 1 - \text{poissoncdf}(\mu = 2.5, k = C) < 0.01.$$

Merk op dat zodra C groter wordt, de kans $P(X > C)$ steeds kleiner wordt. We kunnen de juiste waarde van C vinden door met de grafische rekenmachine een

tabel te maken. Dit doen we door eerst in het functiescherm van de grafische rekenmachine de functie

$$y_1 = 1 - \text{poissoncdf}(\mu = 2.5, k = X)$$

in te voeren (via de knop “y=”), en vervolgens een tabel te genereren (via de knop “2nd” + “GRAPH”). We zoeken in de tabel naar de kleinste waarde van X waarvoor geldt dat $y_1 < 0.01$. We vinden dan de volgende waarden:

$$k = 6 : \quad 1 - \text{poissoncdf}(\mu = 2.5, k = 6) \approx 0.0142,$$

$$k = 7 : \quad 1 - \text{poissoncdf}(\mu = 2.5, k = 7) \approx 0.0042.$$

De haven moet dus een capaciteit hebben om op een dag minstens 7 schepen te kunnen afhandelen als de kans kleiner dan 0.01 moet zijn dat er een schip naar een andere haven moeten worden doorgestuurd.

Opdracht 7.14: Op een werkdag van de dierenambulance komen oproepen binnen volgens een Poissonproces met $\lambda = 0.50$ oproepen per uur. Men is 10 uur per dag bereikbaar.

- (a) Bereken de kans dat op een dag minder dan 4 oproepen binnenkomen.

Uitwerking

Laat X de kansvariabele zijn die het aantal binnenkomende oproepen telt op een werkdag (10 werkuren met gemiddelde 0.50 oproepen per uur) bij de dierenambulance. We bekijken een interval van 10 uur met tijdseenheden van een uur, dus $t = 10$. De parameter μ van de Poissonverdeling is dus gelijk aan $\mu = \lambda \cdot t = 0.50 \cdot 10 = 5$. Gegeven is dat $X \sim \text{Poisson}(\mu = 5)$.

De kans dat op een dag minder dan 4 oproepen binnenkomen is dan gelijk aan

$$P(X < 4) = P(X \leq 3) = \text{poissoncdf}(\mu = 5, k = 3) \approx 0.2650.$$

- (b) Hoe groot is de kans dat er meer dan 3 uur voorbijgaan zonder dat een enkele oproep is geweest?

Uitwerking

Stel nu dat X de kansvariabele is van het aantal binnenkomende oproepen in drie uur tijd. We bekijken een interval van 3 uur met tijdseenheden van een uur, dus $t = 3$. De parameter μ van de Poissonverdeling is dus gelijk aan $\mu = \lambda \cdot t = 0.50 \cdot 3 = 1.5$. De kans dat er meer dan 3 uur voorbijgaan zonder dat een enkele oproep is geweest is gelijk aan de kans op geen oproepen in drie uur tijd, oftewel:

$$P(X = 0) = \text{poissonpdf}(\mu = 1.5, k = 0) \approx 0.2231.$$

- (c) De chauffeur van de dierenambulance wil met lunchpauze. Hij wil de tijdsduur van de pauze zodanig kiezen dat de kans hoogstens 0.25 is dat binnen die periode een oproep binnenkomt. Hoelang mag hij pauzeren?

Uitwerking

Het aantal inkomende oproepen tijdens een lunchpauze van t uur is Poisson verdeeld met parameter $\mu = \lambda \cdot t = 0.5 \cdot t$. De chauffeur wil de tijdsduur t van zijn pauze zodanig kiezen dat geldt dat $P(X \geq 1) = 1 - P(X \leq 0) \leq 0.25$ is.

Om deze ongelijkheid op te lossen, kunnen we opnieuw de “numeric solver” gebruiken:

$$E_1 = 1 - \text{poissoncdf}(\mu = 0.5 \cdot X, k = 0)$$

$$E_2 = 0.25.$$

Dit geeft ons een waarde $x \approx 0.5754$ uur, oftewel ongeveer 34.5 minuten. De chauffeur zal dus ongeveer na 34.5 minuten terug moeten zijn van zijn pauze om hoogstens 25 % kans te hebben een oproep te hebben gemist.

Opdracht 7.19: Een satelliet heeft vijf zonnepanelen. Ieder zonnepaneel heeft een levensduur die kan worden beschreven door een negatief-exponentiële verdeling met $\lambda = 0.5$. Dus de gemiddelde levensduur van een paneel is $\frac{1}{0.50} = 2$ jaar. Zodra drie zonnepanelen zijn uitgevallen, houdt de satelliet op te functioneren.

- (a) Hoe groot is de kans dat een willekeurig zonnepaneel na vier jaar nog functioneert?

Uitwerking

Laat X de continue kansvariabele zijn die de levensduur van een zonnepaneel op een satelliet meet. Gegeven is dat $X \sim \text{Exponentieel}(\lambda = 0.5)$. We willen de kans bepalen dat de satelliet na vier jaar nog functioneert, oftewel

$$\begin{aligned} P(X > 4) &= 1 - P(X \leq 4) \\ &= 1 - (1 - e^{-0.5 \cdot 4}) \\ &= e^{-2} \\ &\approx 0.1353. \end{aligned}$$

Met ongeveer 13.53 % kans functioneert een willekeurig zonnepaneel van de satelliet nog na vier jaar.

- (b) Hoe groot is de kans dat de satelliet na vier jaar nog functioneert? We gaan ervan uit dat de levensduren van de panelen onderling onafhankelijk zijn.

Uitwerking

Laat Y nu de kansvariabele zijn die telt hoeveel zonnepanelen van de satelliet na vier jaar nog functioneren. Gegeven de aanname dat de levensduren van de panelen onderling onafhankelijk zijn, kunnen we het al dan niet functioneren van de zonnepanelen na vier jaar zien als onafhankelijke Bernoulli-experimenten. In andere woorden, Y is een binomiaal verdeelde kansvariabele met parameters $n = 5$ (aantal zonnepanelen op de satelliet) en $p = 0.1353$ (kans dat een willekeurig zonnepaneel na vier jaar nog functioneert). De satelliet functioneert na vier jaar nog zolang dat er drie zonnepanelen nog functioneren, dit gebeurt met kans

$$\begin{aligned} P(Y \geq 3) &= 1 - P(Y \leq 2) \\ &= 1 - \text{binomcdf}(n = 5, p = 0.1353, k = 2) \\ &\approx 0.0200. \end{aligned}$$

Week 7

Schatten en betrouwbaarheid (1/2)

Hoofdstuk 8

Opdracht 8.m2: Bij een grote financiële instelling worden jaarlijks vele honderden net afgestudeerden aangenomen als trainee. Bedoeling is dat deze trainees na een zekere tijd (T) een eerste aanbod ontvangen voor een officiële baan bij deze instelling. Bij een onderzoek onder 36 trainees is gebleken dat men gemiddeld na zestien maanden het eerste aanbod kreeg. Voor T is gegeven dat de standaarddeviatie drie maanden is. Het 95 %-betrouwbaarheidsinterval voor de gemiddelde tijd tot het eerste aanbod is dan gelijk aan ...

- (a) $9.01 < \mu < 22.99$
- (b) $15.16 < \mu < 16.85$
- (c) $15.02 < \mu < 16.98$
- (d) $14.84 < \mu < 17.17$

Uitwerking

De tijd T (in maanden) tot een willekeurige trainee een eerste aanbod ontvangt is een kansvariabele met een onbekende verwachtingswaarde μ en standaardafwijking $\sigma = 3$. Uit de centrale limietstelling volgt dat de gemiddelde tijd $\bar{T}$ tot eerste aanbod van 36 willekeurige trainees bij benadering normaal verdeeld is met verwachtingswaarde $\mu = ?$ en $\sigma = \frac{3}{\sqrt{36}} = \frac{1}{2}$. Omdat we een 95 %-betrouwbaarheidsinterval willen berekenen, is het onbetrouwbaarheidsniveau $\alpha = 0.05$.

Het betrouwbaarheidsinterval op basis van deze geobserveerde steekproef kunnen berekenen met de formule

$$\left[\bar{t} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \quad \bar{t} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right].$$

Gegeven is dat het steekproefgemiddelde $\bar{t} = 16$, en verder geldt dat

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - \frac{\alpha}{2}, \mu = 0, \sigma = 1) \approx 1.9600.$$

Het 95 %-betrouwbaarheidsinterval voor het gemiddelde μ is dus gelijk aan

$$\begin{aligned} & [\bar{t} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \quad \bar{t} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}] \\ & \approx [16 - 1.9600 \cdot \frac{3}{\sqrt{36}}, \quad 16 + 1.9600 \cdot \frac{3}{\sqrt{36}}] \\ & \approx [15.0200, \quad 16.9800] \end{aligned}$$

Het juiste antwoord is dus (c).

Opdracht 8.1: Een machine vult zakken met meel. Het gewicht van het meel in een willekeurige zak is te beschouwen als een trekking uit een normale verdeling met onbekende μ en een standaarddeviatie van 100 gram. Om het schattingsinterval te berekenen voor μ weegt men de inhoud van 25 zakken meel. Het gemiddelde gewicht van het meel per zak bedroeg 20.142 kg.

- (a) Bereken een schattingsinterval voor μ (de verwachtingswaarde van het gewicht van het meel) dat een betrouwbaarheid heeft van 95 %.

Uitwerking

De kansvariabele X meet het gewicht (in gram) van een willekeurige zak meel. Er is gegeven dat X normaal verdeeld is met onbekende $\mu = ?$ en standaardafwijking $\sigma = 100$. Als we 25 willekeurige zakken meel gaan wegen, hebben we te maken met 25 kansvariabelen $X_1, X_2, \dots, X_{25}$. Volgens de centrale limietstelling geldt dat het theoretische steekproefgemiddelde $\bar{X}$ van 25 zakken meel normaal verdeeld is met verwachtingswaarde $\mu = ?$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{100}{\sqrt{25}} = 20$.

Gegeven is een geobserveerde steekproef $x_1, x_2, \dots, x_{25}$ met steekproefgemiddelde $\bar{x} = 20142$ gram. Aangezien we een betrouwbaarheid van 95 % willen, is $\alpha = 0.05$ en

$$z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2, \mu = 0, \sigma = 1) \approx 1.9600.$$

Het 95 %-betrouwbaarheidsinterval voor μ op basis van deze geobserveerde steekproef is dan gelijk aan

$$\begin{aligned} & [\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}] \\ & = [20142 - 1.9600 \cdot \frac{100}{\sqrt{25}}, 20142 + 1.9600 \cdot \frac{100}{\sqrt{25}}] \\ & = [20102.8, 20181.2] \end{aligned}$$

Met 95 % betrouwbaarheid ligt het gemiddelde gewicht van een zak meel tussen de 20102.8 en 20181.2 gram.

- (b) Bereken een schattingsinterval voor μ dat een betrouwbaarheid heeft van 99 %.

Uitwerking

Aangezien we in dit geval een betrouwbaarheid van 99 % willen, geldt nu dat $\alpha = 0.01$ en

$$z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2, \mu = 0, \sigma = 1) \approx 2.5758.$$

Het 99 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\begin{aligned} & \left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right] \\ &= \left[20142 - 2.5758 \cdot \frac{100}{\sqrt{25}}, 20142 + 2.5758 \cdot \frac{100}{\sqrt{25}} \right] \\ &= [20090.5, 20193.5] \end{aligned}$$

Met 99 % betrouwbaarheid ligt het gemiddelde gewicht van een zak meel tussen de 20090.5 en 20193.5 gram.

- (c) Hoe groot moet men de steekproefomvang n kiezen om tot een 95 %-betrouwbaarheidsinterval voor μ te komen dat een breedte heeft van 20 eenheden (gram)?

Uitwerking

De breedte van het betrouwbaarheidsinterval

$$\left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

is gelijk aan rechtergrens – linkergrens $= 2z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = 20$. De intervalbreedte is gelijk aan twee keer de maximale afwijking a , oftewel $a = 10$. Verder geldt bij een onbetrouwbaarheidsniveau $\alpha = 0.05$ dat $z_{\alpha/2} \approx 1.9600$. Aangezien we een betrouwbaarheid van 95 % willen en een maximale afwijking $a = 10$ gram, krijgen we

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{a} \right)^2 = \left(\frac{1.9600 \cdot 100}{10} \right)^2 \approx 384.16$$

Om de garantie van een intervalbreedte van maximaal 20 gram te waarborgen, moeten we naar boven afronden, dus de steekproef moet uit minimaal $n = 385$ zakken meel bestaan.

Opdracht 8.3: Een meetapparaat in een laboratorium wordt gebruikt voor het bepalen van de hoeveelheid van een stof die aanwezig is in een oplossing. Van het apparaat is bekend

dat dit voor de gemeten hoeveelheid een standaarddeviatie heeft van 1.2 mg per bepaling. Er worden zes monsters genomen. Deze leverden voor de hoeveelheid stof de volgende resultaten (in milligram): 14.7, 13.2, 15.8, 16.1, 14.3 en 15.0. Bereken met deze gegevens een 95 %-betrouwbaarheidsinterval voor μ : de gemiddelde hoeveelheid van de stof per monster. Ga ervan uit dat de meetresultaten een normale verdeling volgen.

Uitwerking

De kansvariabele X meet de hoeveelheid stof (in mg) die aanwezig is in een oplossing. Gegeven is dat X normaal verdeeld is met onbekende verwachtingswaarde $\mu = ?$ en standaardafwijking $\sigma = 1.2$ mg. Aangezien we een 95 %-betrouwbaarheidsinterval willen berekenen, is het onbetrouwbaarheidsniveau $\alpha = 0.05$. Volgens de centrale limietstelling is het gemiddelde $\bar{X}$ van zes normaal verdeelde kansvariabelen weer normaal verdeeld met gemiddelde $\mu = ?$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{1.2}{\sqrt{6}}$. Om het specifieke betrouwbaarheidsinterval voor de geobserveerde steekproef te berekenen, bepalen we eerst het steekproefgemiddelde:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_6}{6} = \frac{14.7 + 13.2 + \dots + 15.0}{6} = 14.85.$$

Omdat $\alpha = 0.05$, werken we verder met

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - 0.025 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

Dit geeft een betrouwbaarheidsinterval van

$$\begin{aligned} & \left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right] \\ &= \left[14.85 - 1.9600 \cdot \frac{1.2}{\sqrt{6}}, 14.85 + 1.9600 \cdot \frac{1.2}{\sqrt{6}} \right] \\ &= [13.89, 15.81] \end{aligned}$$

Met 95 % betrouwbaarheid ligt de gemiddelde hoeveelheid stof in een oplossing tussen 13.89 en 15.81 mg.

Opdracht 8.4: De montagetijd van een apparaat in een fabriek is te beschouwen als een kansvariabele X die normaal is verdeeld met een verwachtingswaarde van 40 minuten en een standaarddeviatie van vier minuten. Na het invoeren van een nieuw systeem voor de montage is de chef van de afdeling benieuwd of de gemiddelde montagetijd hierdoor korter is geworden. Voor een aantal (n) montages vond hij als gemiddelde montagetijd $\bar{x} = 36$ minuten. We gaan ervan uit dat de montagetijden nog steeds normaal zijn verdeeld met $\sigma = 4$ minuten. Bereken een 95 %-betrouwbaarheidsinterval voor μ in de volgende gevallen:

- (a) als $n = 16$ waarnemingen zijn gebruikt voor het berekenen van $\bar{x} = 36$ minuten.

Uitwerking

Omdat de gewenste betrouwbaarheid 95 % is, geldt dat het onbetrouwbaarheidsniveau $\alpha = 0.05$ en

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - 0.025 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

Verder is gegeven dat het geobserveerde steekproefgemiddelde $\bar{x} = 36$. Het 95 %-betrouwbaarheidsinterval voor μ is van de vorm

$$\begin{aligned} & \left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right] \\ & = \left[36 - 1.9600 \cdot \frac{4}{\sqrt{n}}, 36 + 1.9600 \cdot \frac{4}{\sqrt{n}} \right] \end{aligned}$$

Merk op dat de grenzen van het interval nu alleen nog maar afhankelijk zijn van de steekproefgrootte n . In het geval van $n = 16$ waarnemingen krijgen we dus

$$\left[36 - 1.9600 \cdot \frac{4}{\sqrt{16}}, 36 + 1.9600 \cdot \frac{4}{\sqrt{16}} \right] = [34.04, 37.96]$$

Met 95 % betrouwbaarheid ligt de gemiddelde montagetijd tussen 34.04 en 37.96 minuten.

(b) als $n = 100$ waarnemingen gebruikt zijn.

Uitwerking

In het geval van $n = 100$ waarnemingen is de berekening op eenzelfde manier uit te voeren. Het 95 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\left[36 - 1.9600 \cdot \frac{4}{\sqrt{100}}, 36 + 1.9600 \cdot \frac{4}{\sqrt{100}} \right] = [35.22, 36.78]$$

Met 95 % betrouwbaarheid ligt de gemiddelde montagetijd tussen 35.22 en 36.78 minuten.

(c) als $n = 4$ waarnemingen gebruikt zijn.

Uitwerking

In het geval van $n = 4$ waarnemingen is de berekening weer op eenzelfde manier uit te voeren. Het 95 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\left[36 - 1.9600 \cdot \frac{4}{\sqrt{4}}, 36 + 1.9600 \cdot \frac{4}{\sqrt{4}} \right] = [32.08, 39.92]$$

Met 95 % betrouwbaarheid ligt de gemiddelde montagetijd tussen 32.08 en 39.92 minuten.

Noot: de belangrijkste boodschap van dit verhaal is het volgende: naarmate de steekproefgrootte n groter wordt, krijgen we met dezelfde betrouwbaarheid $1 - \alpha$ een steeds

smaller interval. Dit is logisch, aangezien een grotere steekproef ook meer informatie geeft over de samenstelling van de gehele populatie en daarmee ook een steeds nauwkeurigere schatting van μ kan bepalen.

Opdracht 8.5: Een bedrijf vervaardigt plastic draagtasjes die winkeliers kunnen verkopen aan klanten om hun inkopen in te doen. Deze dienen een behoorlijk groot gewicht te kunnen dragen. We willen weten hoe sterk die tasjes zijn. Bij proeven worden de tasjes steeds zwaarder belast totdat zij stukgaan. Bekend is dat de breeksterkte van een tasje, uitgedrukt in kilogram belasting, beschreven kan worden door een normale verdeling met $\mu = 11.5$ en $\sigma = 1.3$ kg.

- (a) Hoeveel procent van de tasjes breekt reeds bij een belasting van hoogstens 10 kg?

Uitwerking

De kansvariabele X meet de breeksterkte (in kg) van een willekeurig tasje. Gegeven is dat X normaal verdeeld is met verwachtingswaarde $\mu = 11.5$ en standaardafwijking $\sigma = 1.3$. De kans dat een tasje breekt bij een belasting van hoogstens 10 kg is gelijk aan

$$P(X \leq 10) = \text{normalcdf}(a = -10^{99}, b = 10, \mu = 11.5, \sigma = 1.3) \approx 0.1243.$$

Dat betekent dus dat 12.43 % van de tasjes al breekt bij een belasting van hoogstens 10 kg.

- (b) De fabrikant gaat een nieuw soort plastic gebruiken bij de productie van de tasjes. Er wordt een steekproef genomen van 25 tasjes. Deze leveren een gemiddelde breeksterkte op van 12.8 kg. Ga ervan uit dat de standaarddeviatie nog hetzelfde is. Bepaal een 95 %-betrouwbaarheidsinterval voor μ : de gemiddelde breeksterkte.

Uitwerking

We hebben nu te maken met een kansvariabele X die nog steeds normaal verdeeld is, maar met onbekende verwachtingswaarde $\mu = ?$ en nog steeds standaardafwijking $\sigma = 1.3$ kg. Een theoretische steekproef van 25 tasjes bekijkt dus 25 kansvariabelen $X_1, X_2, \dots, X_{25}$. Volgens de centrale limietstelling is het steekproefgemiddelde $\bar{X}$ van 25 tasjes bij benadering normaal verdeeld met verwachtingswaarde $\mu = ?$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{1.3}{\sqrt{25}} = 0.26$. Omdat de gewenste betrouwbaarheid gelijk is aan 95 %, hebben we te maken met $\alpha = 0.05$, dus

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - 0.025 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

Verder is gegeven dat $n = 25$ en $\bar{x} = 12.8$ kg. Het 95 %-betrouwbaarheidsinterval

is dus gelijk aan

$$\begin{aligned} & \left[\bar{x} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} \right] \\ &= \left[12.8 - 1.9600 \cdot \frac{1.3}{\sqrt{25}}, \quad 12.8 + 1.9600 \cdot \frac{1.3}{\sqrt{25}} \right] \\ &= [12.29, \quad 13.31] \end{aligned}$$

De gemiddelde breeksterkte van tasjes van het nieuw soort plastic zal met 95 % betrouwbaarheid tussen 12.29 en 13.31 kg liggen.

Merk op dat dit interval in zijn geheel voorbij het oude gemiddelde van 11.5 kg ligt. We kunnen dus met hoge betrouwbaarheid zeggen dat de gemiddelde breeksterkte μ van de tasjes groter is met het nieuwe soort plastic.

- (c) Hoeveel procent van de tasjes breekt bij een belasting van minder dan 10 kg als de nieuwe waarde van μ 12.8 is? En hoeveel procent is dit als μ gelijk is aan de linkergrens L respectievelijk de rechtergrens R van het interval dat berekend is bij vraag (b)?

Uitwerking

In het geval dat de nieuwe waarde van $\mu = 12.8$, kunnen we weer de kans berekenen met de “normalcdf” functie:

$$P(X \leq 10) = \text{normalcdf}(a = -10^{99}, b = 10, \mu = 12.8, \sigma = 1.3) \approx 0.0156.$$

Als $\mu = 12.8$ kg, dan breekt 1.56 % van de tasjes van het nieuwe soort plastic bij een belasting van minder dan 10 kg.

In het geval dat de nieuwe waarde van $\mu = L = 12.29$, kunnen we weer de kans berekenen met de “normalcdf” functie:

$$P(X \leq 10) = \text{normalcdf}(a = -10^{99}, b = 10, \mu = 12.29, \sigma = 1.3) \approx 0.0391.$$

Als $\mu = 12.29$ kg, dan breekt 3.91 % van de tasjes van het nieuwe soort plastic bij een belasting van minder dan 10 kg.

In het geval dat de nieuwe waarde van $\mu = R = 13.31$, kunnen we weer de kans berekenen met de “normalcdf” functie:

$$P(X \leq 10) = \text{normalcdf}(a = -10^{99}, b = 10, \mu = 13.31, \sigma = 1.3) \approx 0.0054.$$

Als $\mu = 13.31$ kg, dan breekt 0.54 % van de tasjes van het nieuwe soort plastic bij een belasting van minder dan 10 kg.

Opdracht 8.10: Bij een snelweg is door een verdekt opgestelde controlepost de snelheid bepaald voor een grote steekproef van de passerende auto's. Uit de aantekeningen van de onderzoeker blijkt dat de berekende standaarddeviatie van de snelheden 8.2 km/uur bedraagt.

Verder bleek dat men als 95 %-betrouwbaarheidsinterval voor de gemiddelde snelheid als resultaat opgeschreven had dat μ tussen 74.2 en 76.8 zou moeten liggen. Helaas was niet meer te vinden hoe groot de steekproefomvang is geweest.

- (a) Bereken op basis van de verstreckte gegevens de omvang van de steekproef. (Ga er hierbij van uit dat de nog onbekende steekproefomvang groot genoeg is om toepassing van de normale verdeling te rechtvaardigen.)

Uitwerking

De kansvariabele X meet de snelheid (in km/uur) van een willekeurige passerende auto. Deze kansvariabele heeft een onbekende verwachtingswaarde $\mu = ?$ en standaardafwijking $\sigma = 8.2$.

Volgens de centrale limietstelling geldt dat de gemiddelde snelheid $\bar{X}$ van n willekeurige auto's bij benadering normaal verdeeld is met verwachtingswaarde $\mu = ?$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{8.2}{\sqrt{n}}$.

Merk op dat de breedte van het interval gelijk is aan

$$\text{rechtergrens} - \text{linkergrens} = 76.8 - 74.2 = 2.6,$$

oftewel de maximale afwijking van de daadwerkelijke μ is maximaal $a = \frac{2.6}{2} = 1.3$.

Omdat de gewenste betrouwbaarheid 95 % is, geldt dat $\alpha = 0.05$ en

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - 0.025 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

Dit geeft een minimaal benodigde steekproefgrootte

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{a} \right)^2 = \left(\frac{1.9600 \cdot 8.2}{1.3} \right)^2 \approx 152.8400.$$

Afronden naar boven naar het eerstvolgende gehele getal geeft een minimale steekproefomvang van $n = 153$.

- (b) Uit het interval blijkt dat μ op z'n minst 74.2 en op z'n hoogst 76.8 zou kunnen zijn. Op het betreffende traject geldt een maximumsnelheid van 80 km/uur. Bereken op basis van beide uiterste waarden van μ het percentage auto's dat te hard rijdt. De snelheden vormen een normale verdeling. Veronderstel dat de politie alleen bekeuringen geeft indien de snelheid minstens 85.0 km/uur is. Hoeveel procent van de automobilisten krijgt dan een bekeuring? Formuleer dit als een interval.

Uitwerking

Gegeven is nu dat de kansvariabele X normaal verdeeld is met onbekende $\mu = ?$ en standaardafwijking $\sigma = 8.2$. We bekijken nu de extreme gevallen $\mu = 74.2$ en $\mu = 76.8$ en berekenen de kans dat een automobilist te hard rijdt ($P(X > 80)$) en

de kans dat een automobilist een bekeuring krijgt ($P(X > 85)$),

In het geval dat $\mu = 74.2$, geldt dat de kans dat een willekeurige passerende auto te hard rijdt gelijk is aan

$$P(X > 80) = \text{normalcdf}(a = 80, b = 10^{99}, \mu = 74.2, \sigma = 8.2) \approx 0.2397.$$

Verder geldt dat de kans dat een willekeurige passerende auto een bekeuring krijgt gelijk is aan

$$P(X > 85) = \text{normalcdf}(a = 85, b = 10^{99}, \mu = 74.2, \sigma = 8.2) \approx 0.0939.$$

Als de gemiddelde snelheid van passerende auto's $\mu = 74.2$ km/uur is, zal 23.97 % van de bestuurders te hard rijden en 9.39 % van de bestuurders een bekeuring krijgen.

In het geval dat $\mu = 76.8$, geldt dat de kans dat een willekeurige passerende auto te hard rijdt gelijk is aan

$$P(X > 80) = \text{normalcdf}(a = 80, b = 10^{99}, \mu = 76.8, \sigma = 8.2) \approx 0.3482.$$

In het geval dat $\mu = 76.8$, geldt dat de kans dat een willekeurige passerende auto een bekeuring krijgt gelijk is aan

$$P(X > 85) = \text{normalcdf}(a = 85, b = 10^{99}, \mu = 76.8, \sigma = 8.2) \approx 0.1587.$$

Als de gemiddelde snelheid van passerende auto's $\mu = 76.8$ km/uur is, zal 34.82 % van de bestuurders te hard rijden en 15.87 % van de bestuurders een bekeuring krijgen.

Het percentage automobilisten dat te hard rijdt ligt met 95 % betrouwbaarheid in het interval $[0.2397, 0.3482]$ en het percentage automobilisten dat een bekeuring krijgt ligt met 95 % betrouwbaarheid in het interval $[9.39, 15.87]$.

Opdracht 8.12: Een student doet een onderzoek naar het kijkgedrag van Nederlanders naar de uitzendingen van de samenvattingen voetbal op zondag. Zij wil weten wat het percentage vrouwen is onder de kijkers, wat de gemiddelde leeftijd is onder de kijkers en wat het percentage aanhangers van FC Utrecht is onder de kijkers. In alle drie gevallen wenst men een 95 %-betrouwbaarheidsinterval. De student wil een steekproef nemen uit de voetbalkijkers. Geef aan hoe groot de steekproefomvang moet worden gekozen als voldaan moet worden aan de volgende voorwaarden:

- (a) De gemiddelde leeftijd moet plus of min 2 jaar worden bepaald. Ga ervan uit dat de standaarddeviatie van de leeftijden 12 jaar is.

Uitwerking

De kansvariabele X meet de leeftijd (in jaren) van een willekeurige kijker. Gegeven is dat X een onbekende verwachtingswaarde $\mu = ?$ en een bekende standaardafwijking $\sigma = 12$ heeft.

Volgens de centrale limietstelling geldt dat de gemiddelde leeftijd $\bar{X}$ van n willekeurige kijkers bij benadering normaal verdeeld is met verwachtingswaarde $\mu = ?$ en standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{12}{\sqrt{n}}$. Omdat de gewenste betrouwbaarheid 95% is, geldt dat $\alpha = 0.05$ en

$$z_{\alpha/2} = z_{0.025} = \text{InvNorm}(\text{area} = 1 - 0.025 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

Verder is gegeven dat de afwijking maximaal ± 2 jaar mag zijn, oftewel $a = 2$. De steekproefomvang bij dit 95%-betrouwbaarheidsinterval berekenen we als volgt:

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{a} \right)^2 = \left(\frac{1.9600 \cdot 12}{2} \right)^2 \approx 138.2976.$$

Afronden naar boven naar het eerstvolgende gehele getal geeft een minimaal benodigde steekproefomvang van $n = 139$ kijkers.

Week 8

Schatten en betrouwbaarheid (2/2)

Hoofdstuk 8

Opdracht 8.m1: Onder de betrouwbaarheid van een intervalschatting wordt verstaan:

- (a) de afstand van het midden van het interval tot de rand ervan.
- (b) de z -waarde of t -waarde die is gebruikt om de intervalgrenzen te berekenen.
- (c) de kans dat bij een nieuw steekproefonderzoek hetzelfde interval wordt gevonden.
- (d) de kans dat de grenzen van een schattingsinterval een zodanige waarde hebben, dat de onbekende parameter zich tussen die grenzen bevindt.

Uitwerking

Het juiste antwoord is (d).

Opdracht 8.m4: Bij een schattingsprobleem moet men de t -verdeling gebruiken als voor de te onderzoeken kansvariabele geldt dat er een steekproef is genomen van:

- (a) een normale verdeling met onbekende μ en onbekende variantie.
- (b) een binomiale verdeling met onbekende succeskans π .
- (c) een normale verdeling met gegeven standaarddeviatie en onbekende verwachtingswaarde.
- (d) een gegeven normale verdeling met minder dan 30 vrijheidsgraden.

Uitwerking

De t -verdeling moet gebruikt worden in het geval dat de te onderzoeken kansvariabele normaal verdeeld is met onbekende verwachtingswaarde μ en onbekende standaarddeviatie σ . Met andere woorden, ook de variantie σ^2 is onbekend. Het juiste antwoord is dus (a).

Opdracht 8.m5: Van een normale verdeling met onbekende μ en σ worden zes waarnemingen gedaan. Deze waren: 8, 12, 7, 9, 11, 13. De puntschatting voor σ is dus ...

- (a) 5.6.
- (b) 4.67.
- (c) 2.37.
- (d) 1.87.

Uitwerking

We berekenen een puntschatting s voor een onbekende standaardafwijking σ van een normale verdeling door de steekproefvariantie s^2 te bepalen en daar de wortel uit te nemen. Allereerst berekenen we het steekproefgemiddelde

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_6}{6} = \frac{8 + 12 + 7 + 9 + 11 + 13}{6} = 10.$$

Nu kunnen we de steekproefvariantie bepalen:

$$\begin{aligned} s^2 &= \frac{(x_1 - \bar{x})^2 + \dots + (x_6 - \bar{x})^2}{6 - 1} \\ &= \frac{(8 - 10)^2 + \dots + (13 - 10)^2}{5} \\ &= 5.6. \end{aligned}$$

De puntschatting s voor de standaardafwijking σ vinden we door de wortel hiervan te nemen:

$$s = \sqrt{s^2} = \sqrt{5.6} \approx 2.3664.$$

Het juiste antwoord is dus (c).

Opdracht 8.m6: Men wil een 99%-betrouwbaarheidsinterval voor μ berekenen voor een normale verdeling met een onbekende σ . Er worden acht waarnemingen gedaan. Het interval wordt dan berekend met ...

- (a) $z = 2.58$.
- (b) $t = 3.499$.
- (c) $t = 2.998$.

(d) $t = 2.306$.

Uitwerking

We hebben te maken met een kansvariabele X die normaal verdeeld is met onbekende $\mu = ?$ en onbekende $\sigma = ?$. Omdat σ onbekend is, moeten we gebruik maken van de t -verdeling. De gewenste betrouwbaarheid is gelijk aan 99%, oftewel $\alpha = 0.01$. Tenslotte hebben we een steekproefgrootte $n = 8$, dus het aantal vrijheidsgraden is $df = n - 1 = 7$:

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 1) = \text{InvT}(\text{area} = 0.995, df = 7) \approx 3.4995.$$

Het juiste antwoord is dus (b).

Opdracht 8.2: Van een bepaalde oplossing worden tien even grote monsters genomen. Van elk monster bepaalt men het aantal milligram eiwit, om hiermee het eiwitgehalte (μ) van de gehele oplossing te kunnen schatten. De waargenomen uitkomsten zijn als volgt:

36.5	45.2	40.5	42.0	37.7	39.4	41.6	38.8	39.0	43.3
------	------	------	------	------	------	------	------	------	------

(a) Een zuivere schatter voor μ is het steekproefgemiddelde $\bar{x}$. Bereken $\bar{x}$.

Uitwerking

Het steekproefgemiddelde $\bar{x}$ berekenen we als volgt:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_{10}}{10} = \frac{36.5 + 45.2 + \dots + 43.3}{10} = 40.4.$$

Gemiddeld zit er 40.4 mg eiwit in een monster.

(b) Hier kennen we σ niet, dus voordat er een schattingsinterval kan worden berekend voor μ , moet er een schatting van de variantie gemaakt worden. Bereken deze variantie.

Uitwerking

De steekproefvariantie s^2 berekenen we als volgt:

$$\begin{aligned} s^2 &= \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_{10} - \bar{x})^2}{10 - 1} \\ &= \frac{(36.5 - 40.4)^2 + (45.2 - 40.4)^2 + \dots + (43.3 - 40.4)^2}{10 - 1} \\ &\approx 7.0533. \end{aligned}$$

(c) Bereken voor μ een betrouwbaarheidsinterval dat een betrouwbaarheid heeft van 95%.

Uitwerking

De kansvariabele X meet de hoeveelheid eiwit (in mg) in een willekeurig monster. Gegeven is dat X een onbekende verwachtingswaarde μ heeft en een onbekende

standaardafwijking σ . Volgens de centrale limietstelling geldt dat de gemiddelde hoeveelheid eiwit (in mg) $\bar{X}$ in 10 willekeurige monsters bij benadering normaal verdeeld is met verwachtingswaarde μ en een standaarddeviatie $\frac{\sigma}{\sqrt{n}} = \frac{\sigma}{\sqrt{10}}$.

We hebben een geobserveerde steekproef van 10 zakken genomen met steekproefgemiddelde $\bar{x} = 40.4$ en steekproefstandaardafwijking

$$s = \sqrt{s^2} = \sqrt{7.0533} \approx 2.6558.$$

Aangezien we een betrouwbaarheid van 95 % willen, is $\alpha = 0.05$. Verder, omdat de standaardafwijking σ onbekend is, moeten we de t -verdeling met $df = n - 1 = 9$ vrijheidsgraden gebruiken. In het bijzonder gebruiken we

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 1) = \text{InvT}(\text{area} = 0.975, df = 9) \approx 2.2622.$$

Het 95 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\begin{aligned} & \left[\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}} \right] \\ &= \left[40.4 - 2.2622 \cdot \frac{2.6558}{\sqrt{10}}, 40.4 + 2.2622 \cdot \frac{2.6558}{\sqrt{10}} \right] \\ &= [38.50, 42.30] \end{aligned}$$

Met 95 % betrouwbaarheid ligt de gemiddelde hoeveelheid eiwit μ in een monster tussen 38.50 en 42.30 mg.

Opdracht 8.6: Bij de opleiding Logistiek Management wordt de vraag onderzocht hoeveel tijd per week door studenten wordt besteed aan bijbaantjes. Een steekproef van 18 studenten leverde als gemiddelde op 346 minuten per week en een standaarddeviatie van $s = 175$ minuten.

- (a) Bereken een 95 %-betrouwbaarheidsinterval voor μ : het gemiddelde aantal werkuren van de studentenpopulatie.

Uitwerking

De kansvariabele X meet de tijd die een willekeurige student per week besteedt aan bijbaantjes. Volgens de centrale limietstelling geldt dat de gemiddelde tijd $\bar{X}$ die 18 willekeurige studenten wekelijks aan bijbaantjes besteden bij benadering normaal verdeeld is met verwachtingswaarde μ en een standaardafwijking $\frac{\sigma}{\sqrt{n}} = \frac{\sigma}{\sqrt{18}}$.

We hebben een geobserveerde steekproef van 18 studenten genomen met steekproefgemiddelde $\bar{x} = 346$ en steekproefstandaardafwijking $s = 175$. Aangezien we een betrouwbaarheid van 95 % willen, is $\alpha = 0.05$. Verder, omdat de standaardafwijking onbekend is, moeten we de t -verdeling met $df = n - 1 = 17$ vrijheidsgraden

gebruiken. In het bijzonder gebruiken we

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1) = \text{InvT}(\text{area} = 0.975, \text{df} = 17) \approx 2.1098.$$

Het 95 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\begin{aligned} & [\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}}] \\ &= [346 - 2.1098 \cdot \frac{175}{\sqrt{18}}, 346 + 2.1098 \cdot \frac{175}{\sqrt{18}}] \\ &= [258.97, 433.03] \end{aligned}$$

Met 95 % betrouwbaarheid ligt de gemiddelde tijd die studenten aan bijbaantjes besteden tussen 258 en 433 minuten per week.

- (b) Nadere inspectie van de gegevens leverde dat drie studenten helemaal geen bijbaantje hebben, dus er zijn maar 15 werkenden. Bereken voor de groep werkenden het steekproefgemiddelde en de standaarddeviatie. (*Hint: doe dit door te manipuleren met de formule van s^2 .*)

Uitwerking

De totale tijd die de 18 studenten bij elkaar aan bijbaantjes besteden is gelijk aan $18 \cdot 346 = 6228$ minuten. Aangezien slechts 15 van de 18 studenten een bijbaantje heeft, is het steekproefgemiddelde eigenlijk gelijk aan $\bar{x}_{\text{werkend}} = \frac{6228}{15} = 415.2$ minuten.

Voor de steekproefvariantie hebben we wat ingewikkeldere redeneringen nodig. In algemene zin kun je de steekproefvariantie berekenen als volgt:

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1}.$$

Deze formule is, met behulp van het inzicht $(x_i - \bar{x})^2 = x_i^2 - 2x_i\bar{x} + \bar{x}^2$ te herschrijven tot

$$s^2 = \frac{(x_1^2 + x_2^2 + \dots + x_n^2) - n\bar{x}^2}{n - 1} \Rightarrow (x_1^2 + x_2^2 + \dots + x_n^2) = (n - 1)s^2 + n\bar{x}^2.$$

We kunnen deze som van kwadraten berekenen, omdat $s^2 = 175^2$ en $\bar{x} = 346$:

$$x_1^2 + x_2^2 + \dots + x_n^2 = (18 - 1) \cdot 175^2 + 18 \cdot 346^2 = 2675513.$$

Voor de 15 werkenden geldt dat de kwadraten som nog steeds 2675513 is (aangezien de 3 niet-werkenden 0 bijdroegen aan de kwadraten som), dus:

$$\begin{aligned} s_w^2 &= \frac{\sum x_i^2 - 15 \cdot \bar{x}_w^2}{15 - 1} = \frac{2675513 - 15 \cdot 415.2^2}{14} \approx 6403.39 \\ s_w &= \sqrt{6403.39} \approx 80.02 \text{ minuten.} \end{aligned}$$

- (c) Bereken het 95 %-betrouwbaarheidsinterval voor μ van de populatie werkende studenten.

Uitwerking

De berekening kunnen we op eenzelfde manier uitvoeren als bij vraag (a). Volgens de centrale limietstelling geldt dat de gemiddelde tijd $\bar{X}$ die 15 willekeurige studenten wekelijks aan bijbaantjes besteden normaal verdeeld is met verwachtingswaarde μ en een standaarddeviatie $\frac{\sigma}{\sqrt{n}} = \frac{\sigma}{\sqrt{15}}$.

We hebben een geobserveerde steekproef van 15 studenten genomen met steekproefgemiddelde $\bar{x}_{\text{werkend}} = 415.2$ minuten en steekproefstandaardafwijking $s = 80.02$ minuten. Aangezien we weer een betrouwbaarheid van 95 % willen, is $\alpha = 0.05$. Verder, omdat de standaardafwijking onbekend is, moeten we de t -verdeling met $df = n - 1 = 14$ vrijheidsgraden gebruiken. In het bijzonder gebruiken we

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 1) = \text{InvT}(\text{area} = 0.975, df = 14) \approx 2.1448.$$

Het 95 %-betrouwbaarheidsinterval voor μ is dan gelijk aan

$$\begin{aligned} & \left[\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}} \right] \\ &= \left[415.2 - 2.1448 \cdot \frac{80.02}{\sqrt{15}}, 415.2 + 2.1448 \cdot \frac{80.02}{\sqrt{15}} \right] \\ &= [370.89, 459.51] \end{aligned}$$

Met 95 % betrouwbaarheid ligt de gemiddelde tijd die werkende studenten aan bijbaantjes besteden tussen 370.89 en 459.51 minuten per week.

Opdracht 8.7: In een aselechte steekproef van 400 kiesgerechtigde Nederlanders blijken 160 personen aanhanger van een bepaalde politieke partij te zijn. Geef een 99 %-betrouwbaarheidsinterval voor p : de fractie aanhangers in de totale populatie.

Uitwerking

Laat X het aantal kiesgerechtigde Nederlanders in een steekproef dat aanhanger is van een bepaalde politieke partij. Aangezien de steekproefomvang gelijk is aan 400 kiesgerechtigde Nederlanders, is X binomiaal verdeeld met $n = 400$ en $p = ?$ (deze willen we juist gaan schatten!).

We bepalen een 99 %-betrouwbaarheidsinterval voor p met behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 99 % is, geldt dat $\alpha = 0.01$.

De Clopper-Pearson methode werkt als volgt:

1. Bepaal de succes kans p_1 zodat de kans op minstens uitkomst $k = 160$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 160) = 1 - P(X \leq 159) = \alpha/2 = 0.005.$$

Dit kun je berekenen met behulp van “numeric solver” in de grafische rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 400, p_1 = X, k = 159)$$

$$E_2 = 0.005$$

Dit geeft een waarde van $p_1 \approx 0.3372$.

2. Bepaal de succeskans p_2 zodat de kans op hoogstens uitkomst $k = 160$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 160) = \alpha/2 = 0.005.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 400, p_1 = X, k = 160)$$

$$E_2 = 0.005$$

Dit geeft een waarde van $p_2 \approx 0.4653$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen, oftewel het 99 %-betrouwbaarheidsinterval voor de fractie aanhangers van de politieke partij is gelijk aan $[0.3372, 0.4653]$.

Met de Casio fx-CG50 is de numerieke solver aan te roepen met de functie “SolveN” (OPTN-CALC-SolveN). De syntax hierbij is als volgt:

$$\text{SolveN}(1 - \text{BinomialCD}(159, 400, x) = 0.005, x)$$

$$\text{SolveN}(\text{BinomialCD}(160, 400, x) = 0.005, x)$$

Zodra je op ENTER drukt, kan het zijn dat je een waarschuwing krijgt dat er meerdere oplossingen mogelijk zijn. Negeer deze waarschuwing en klik op EXIT. Je krijgt nu de uitkomst te zien op het scherm.

Opdracht 8.8: In een fabriek maakt men badkamertegels. Bekend is dat het productieproces 20 % ondeugdelijke tegels oplevert. Na wat wijzigingen in het productieproces, werd bijgehouden hoe groot het aantal afgekeurde tegels is in de nieuwe situatie. Men vond de volgende aantallen:

Dag	Productieomvang	Aantal afgekeurd
1	1200	120
2	1800	210
3	1000	80
4	3000	450
5	1500	120
6	1700	170
7	2000	220
8	1400	80
9	1800	200
10	1500	130

- (a) Stel dat alleen de gegevens van dag 1 bekend zouden zijn. Wat is op basis daarvan een 95 %-betrouwbaarheidsinterval voor π : de populatiefractie van afgekeurde tegels?

Uitwerking

Laat X de kansvariabele zijn die het aantal afgekeurde tegels telt op een bepaalde dag. Omdat iedere tegel onafhankelijk van elkaar ondeugdelijk is of niet, hebben we te maken met een binomiale verdeling. Op dag 1 is er een productieomvang van 1200, waarvan er 120 zijn afgekeurd. De kansvariabele X is dus binomiaal verdeeld met $n = 1200$ en een onbekende succeskans $p = ?$

We willen een 95 %-betrouwbaarheidsinterval voor p bepalen. Dit doen we met behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 95 % is, geldt dat $\alpha = 0.05$.

De Clopper-Pearson methode werkt als volgt:

- a) Bepaal de succeskans p_1 waarvoor geldt dat de kans op minstens $k = 120$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 120) = 1 - P(X \leq 119) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van de “Numeric Solver” van de grafische rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 1200, p_1 = X, k = 119)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_1 \approx 0.0836$.

- b) Bepaal de succeskans p_2 waarvoor geldt dat de kans op hoogstens $k = 120$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 120) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van de “Numeric Solver” van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 1200, p_1 = X, k = 120)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_2 \approx 0.1184$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen. Het 95 %-betrouwbaarheidsinterval voor de fractie ondeugdelijke tegels is dus gelijk aan $[0.0836, 0.1184]$.

- (b) Bereken voor iedere dag de fractie afgekeurde tegels. Bereken op basis van deze dagelijkse steekproeffracties een interval van π_D : de gemiddelde dagelijkse fractie afgekeurde tegels.

Uitwerking

Deze vraag is geen onderdeel van het huiswerk en is ook niet van toepassing voor dit vak.

- (c) Bereken de totalen over de tien dagen van productieomvang en aantal afgekeurde tegels. Bereken op basis hiervan een interval voor π . Wat is de betekenis van deze π ?

Uitwerking

De kansvariabele X telt nu het aantal afgekeurde tegels over alle tien dagen. Omdat iedere tegel onafhankelijk van elkaar ondeugdelijk is of niet, hebben we weer te maken met een binomiale verdeling. De totale productieomvang is 16900 geproduceerde tegels, dus $n = 16900$. Verder geldt dat er in totaal 1780 tegels zijn afgekeurd, dus $k = 1780$. De kansvariabele X is dus binomiaal verdeeld met $n = 16900$ en een onbekende succeskans $p = ?$

We willen een 95 %-betrouwbaarheidsinterval voor p bepalen. Dit doen we met behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 95 % is, geldt dat $\alpha = 0.05$.

De Clopper-Pearson methode werkt als volgt:

- a) Bepaal de succeskans p_1 waarvoor geldt dat de kans op minstens $k = 1780$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 1780) = 1 - P(X \leq 1779) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische

rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 16900, p_1 = X, k = 1779)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_1 \approx 0.1007$.

- b) Bepaal de succes kans p_2 waarvoor geldt dat de kans op hoogstens $k = 1780$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 1780) = 0.005$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 16900, p_1 = X, k = 1780)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_2 \approx 0.1101$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen. Het 95 %-betrouwbaarheidsinterval voor de fractie afgekeurde tegels is dus gelijk aan $[0.1007, 0.1101]$.

Merk op dat dit interval al een stuk smaller is dan het interval dat we bij (a) hebben berekend, waardoor we dus nauwkeurigere schatting kunnen maken van p . Dit komt doordat we het interval gebaseerd is op een veel grotere steekproefomvang n en dus nauwkeuriger kunnen schatten.

Opdracht 8.13: De regering besluit een referendum te houden over een kwestie aangaande de Europese Unie. Mensen kunnen alleen ja of nee stemmen. Door een bureau dat opiniepeilingen doet, wordt een representatieve steekproef getrokken uit de Nederlandse kiesgerechtigden. Van de 5000 ondervraagden stemden 3082 personen tegen en 1918 stemden voor.

- (a) Geef een 99.74 %-betrouwbaarheidsinterval voor π : de fractie voorstemmers in de populatie.

Uitwerking

De kansvariabele X telt het aantal voorstemmers bij het referendum. Omdat iedere stemmer onafhankelijk van elkaar stemt, hebben we te maken met een binomiale verdeling. Op basis van de steekproef geldt dat X binomiaal verdeeld is met $n = 5000$ en een onbekende succes kans $p = ?$. Verder is de uitkomst $k = 1918$, dit is het aantal voorstemmers in onze steekproef van $n = 5000$ proefpersonen.

We willen een 99.74 %-betrouwbaarheidsinterval voor p bepalen. Dit doen we met

behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 99.74 % is, geldt dat $\alpha = 0.0026$.

De Clopper-Pearson methode werkt als volgt:

- a) Bepaal de succeskans p_1 zodat de kans op minstens uitkomst $k = 1918$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 1918) = 1 - P(X \leq 1917) = \alpha/2 = 0.0013.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 5000, p_1 = X, k = 1917)$$

$$E_2 = 0.0013$$

Dit geeft een waarde van $p_1 \approx 0.3630$.

- b) Bepaal de succeskans p_2 zodat de kans op hoogstens uitkomst $k = 3082$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 1918) = \alpha/2 = 0.0013.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 5000, p_1 = X, k = 1918)$$

$$E_2 = 0.0013$$

Dit geeft een waarde van $p_2 \approx 0.4045$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen. Het 99.74 %-betrouwbaarheidsinterval voor de fractie voorstemmers is dus gelijk aan $[0.3630, 0.4045]$.

- (b) Vind je het houden van een referendum nog zinvol, gegeven het antwoord bij vraag (a)?

Uitwerking

Het antwoord op deze vraag is afhankelijk van het kiessysteem waarmee gewerkt wordt. Indien het gaat om een strikte meerderheid van 50 % +1 stem, dan is het vrijwel zeker dat de voorstemmers gaan verliezen, omdat het hele interval (ver) onder de 50 % ligt. Als het quorum op een andere waarde ligt of als er andere zwaarwegende politieke redenen in het spel zijn, kan het uiteraard wel van meerwaarde zijn om een referendum te houden.

Opdracht 8.14: Een handelsmaatschappij onderzoekt hoe groot de fractie orders is die binnen de afgesproken levertijd worden uitgevoerd. Van 200 orders bleken er 180 binnen de levertijd uitgevoerd te zijn.

- (a) Geef een 95 %-betrouwbaarheidsinterval voor de fractie orders die op tijd zijn uitgevoerd.

Uitwerking

De kansvariabele X telt het aantal orders die op tijd zijn uitgevoerd. Omdat iedere order onafhankelijk van elkaar wordt uitgevoerd, hebben we te maken met een binomiale verdeling. Op basis van de steekproef geldt dat X binomiaal verdeeld is met $n = 200$ en een onbekende succeskans $p = ?$.

We willen een 95 %-betrouwbaarheidsinterval voor p bepalen. Dit doen we met behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 95 % is, geldt dat $\alpha = 0.05$.

De Clopper-Pearson methode werkt als volgt:

- a) Bepaal de laagste succeskans p_1 zodat de kans op minstens $k = 180$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 180) = 1 - P(X \leq 179) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 200, p_1 = X, k = 179)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_1 \approx 0.8498$.

- b) Bepaal de succeskans p_2 zodat de kans op hoogstens $k = 180$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 180) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van het “solver”-menu van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 200, p_1 = X, k = 180)$$

$$E_2 = 0.025$$

Dit geeft een waarde van $p_2 \approx 0.9378$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen. Het 95 %-betrouwbaarheidsinterval voor de fractie orders die op tijd wordt uitgevoerd is dus gelijk aan $[0.8498, 0.9378]$.

- (b) Hoeveel orders moet worden onderzocht om een interval voor p te krijgen dat hoogstens 0.02 breed is? (We gaan ervan uit dat p ongeveer 0.9 is).

Uitwerking

Deze vraag is buiten de scope van het vak.

Opdracht 8.17: De handvatten van koffers moeten van zodanige kwaliteit zijn dat ze niet breken bij een forse belasting van de koffers. Ter controle van de kwaliteit van de handvatten werden er proeven genomen waarbij het gewicht dat aan een handvat hing net zolang werd opgevoerd tot het handvat brak. Er werden negen handvatten getest waarbij de maximale belasting werd vastgesteld. De resultaten staan in de volgende tabel:

Handvat	A	B	C	D	E	F	G	H	I
Breuk bij een gewicht (in kg) van	84	87	81	85	90	93	86	88	80

- (a) Geef een schatting van de variantie.

Uitwerking

We berekenen een schatting s^2 voor de variantie door allereerst het steekproefgemiddelde te bepalen:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{x_1 + x_2 + \dots + x_9}{9} = \frac{84 + 87 + \dots + 90}{9} = 86.$$

Nu kunnen we de steekproefvariantie bepalen:

$$\begin{aligned} s^2 &= \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} \\ &= \frac{(x_1 - \bar{x})^2 + \dots + (x_9 - \bar{x})^2}{9 - 1} \\ &= \frac{(84 - 86)^2 + \dots + (80 - 86)^2}{8} \\ &= 17.0. \end{aligned}$$

De puntschatting voor de variantie σ^2 is dus gelijk aan $s^2 = 17$.

- (b) Geef een betrouwbaarheidsinterval voor μ_x : de verwachtingswaarde van de maximumbelasting van een handvat. Kies een 99%-betrouwbaarheidsinterval.

Uitwerking

Omdat we hier te maken hebben met een onbekende standaardafwijking σ , moeten we de t -verdeling met $df = n - 1 = 8$ vrijheidsgraden gebruiken. Gegeven is een betrouwbaarheidsniveau van 99%, oftewel $\alpha = 0.01$. Verder hebben we bij vraag (a) een schatting van de variantie $s^2 = 17$ berekend, oftewel de standaardafwijking kan worden geschat met $s = \sqrt{s^2} = \sqrt{17}$. De t -waarde die hierbij hoort

is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1) = \text{InvT}(\text{area} = 0.995, \text{df} = 8) \approx 3.3554.$$

Het 99 %-betrouwbaarheidsinterval voor μ_x is in dit geval gelijk aan

$$\begin{aligned} & [\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}}] \\ &= [86 - 3.3554 \cdot \frac{\sqrt{17}}{\sqrt{9}}, 86 + 3.3554 \cdot \frac{\sqrt{17}}{\sqrt{9}}] \\ &= [81.3885, 90.6115]. \end{aligned}$$

Met 99 % betrouwbaarheid zit de gemiddelde maximumbelasting van een handvat tussen ongeveer 81.39 en 90.61 kg.

Opdracht 8.18: De Rijksdienst voor het Wegverkeer doet onderzoek naar het percentage auto's dat geregistreerd staat zonder dat er een geldige WA-verzekering is afgesloten.

- (a) Voor een steekproef van 1000 kentekens werd nauwkeurig nagetrokken of op de auto een WA-verzekering was afgesloten. Er bleken 80 auto's niet verzekerd te zijn. Geef een 95 %-betrouwbaarheidsinterval voor de fractie onverzekerde auto's in de gehele populatie.

Uitwerking

De kansvariabele X de kansvariabele telt het aantal onverzekerde auto's bij een steekproef van 1000 kentekens. Omdat iedere stemmer onafhankelijk van elkaar stemt, hebben we te maken met een binomiale verdeling met $n = 1000$ en $p = ?$. Verder hebben we een steekproefuitkomst van $k = 80$ onverzekerde auto's.

We willen een 95 %-betrouwbaarheidsinterval voor p bepalen. Dit doen we met behulp van de Clopper-Pearson methode. Omdat de gewenste betrouwbaarheid 95 % is, geldt dat $\alpha = 0.05$.

De Clopper-Pearson methode werkt als volgt:

- a) Bepaal de succeskans p_1 zodat de kans op minstens $k = 80$ gelijk is aan $\alpha/2$, oftewel

$$P(X \geq 80) = 1 - P(X \leq 79) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van de "Numeric Solver" van de grafische rekenmachine:

$$E_1 = 1 - \text{binomcdf}(n = 1000, p_1 = X, k = 79),$$

$$E_2 = 0.025.$$

Dit geeft een waarde van $p_1 \approx 0.06390.0986$.

- b) Bepaal de hoogste succeskans p_2 zodat de kans op hoogstens $k = 80$ gelijk is aan $\alpha/2$, oftewel

$$P(X \leq 80) = \alpha/2 = 0.025.$$

Dit kun je berekenen met behulp van de “Numeric Solver” van de grafische rekenmachine:

$$E_1 = \text{binomcdf}(n = 1000, p_1 = X, k = 80),$$

$$E_2 = 0.025.$$

Dit geeft een waarde van $p_2 \approx 0.0986$.

We vinden het Clopper-Pearson interval door de twee gevonden waarden als grenzen te nemen. Het 95 %-betrouwbaarheidsinterval voor de fractie onverzekerde auto's is dus gelijk aan $[0.0639, 0.0986]$.

- (b) Stel dat de Rijksdienst het percentage onverzekerde auto's wil schatten met een marge van plus of min 1 %. Hoeveel auto's moeten dan voor een steekproef worden opgenomen? Geef aan welke veronderstellingen u hanteert.

Uitwerking

Deze vraag is buiten de scope van het vak.

- (c) Voor een steekproef van 25 onverzekerde auto's werd de ouderdom bepaald. Dat leverde een gemiddelde van 8.4 jaar en een standaarddeviatie van 1.7 jaar. Geef een 95 %-betrouwbaarheidsinterval voor de gemiddelde leeftijd van alle onverzekerde auto's.

Uitwerking

Gegeven is een steekproef van $n = 25$ onverzekerde auto's, waarvoor van de leeftijd een steekproefgemiddelde $\bar{x} = 8.4$ jaar en steekproefstandaarddeviatie $s = 1.7$ jaar is bepaald. Omdat de standaardafwijking σ onbekend is, moeten we de t -verdeling met $df = n - 1 = 24$ vrijheidsgraden gebruiken. Omdat het gewenste betrouwbaarheidsniveau 95 % is, geldt dat $\alpha = 0.05$.

De bijbehorende t -waarde is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 1) = \text{InvT}(\text{area} = 0.975, df = 24) \approx 2.0639.$$

Het 95 %-betrouwbaarheidsinterval is gelijk aan

$$\begin{aligned} & [\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}}] \\ & = [8.4 - 2.0639 \cdot \frac{1.7}{\sqrt{25}}, 8.4 + 2.0639 \cdot \frac{1.7}{\sqrt{25}}] \\ & = [7.6983, 9.1017] \end{aligned}$$

Met 95 % betrouwbaarheid zit de gemiddelde leeftijd van een onverzekerde auto tussen 7.7 en 9.1 jaar.

Opdracht 8.19: Een technicus van een bedrijf dat oefenapparaten ontwikkelt voor fitness-trainingen heeft een nieuw ontwerp gemaakt van een bepaalde machine. Bedoeling is dat dit apparaat spierversterkend werkt voor personen met rugklachten. Helaas was maar één prototype van het apparaat beschikbaar om het te kunnen testen. Hierdoor konden slechts de gegevens van twaalf patiënten worden verzameld. Deze twaalf patiënten gingen oefenen met dit apparaat en het aantal dagen werd opgetekend dat nodig was om volledig het gewenste resultaat te behalen. Van de twaalf patiënten werden de volgende aantallen dagen waargenomen:

15, 18, 41, 27, 23, 16, 29, 30, 32, 22, 25, 22.

(a) Schat de standaarddeviatie.

Uitwerking

We berekenen een schatting s voor de standaardafwijking door allereerst het steekproefgemiddelde te bepalen:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{x_1 + x_2 + \dots + x_{12}}{12} = \frac{15 + 18 + \dots + 22}{12} = 25.$$

Nu kunnen we de steekproefvariantie bepalen:

$$\begin{aligned} s^2 &= \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} \\ &= \frac{(x_1 - \bar{x})^2 + \dots + (x_{12} - \bar{x})^2}{12 - 1} \\ &= \frac{(15 - 25)^2 + \dots + (22 - 25)^2}{11} \\ &= 54.7272. \end{aligned}$$

De puntschatting s voor de standaardafwijking vinden we door de wortel hiervan te nemen:

$$s = \sqrt{54.7272} \approx 7.3978.$$

- (b) Bereken een 95 %-betrouwbaarheidsinterval voor μ : de gemiddelde hersteltijd voor de populatie.

Uitwerking

Gegeven is een steekproef van $n = 12$ patiënten, waarvoor het aantal dagen tot het gewenste resultaat het steekproefgemiddelde $\bar{x} = 25$ dagen en de steekproefstandaardafwijking $s = 7.3978$ dagen is bepaald. Omdat de standaardafwijking σ onbekend is, moeten we de t -verdeling gebruiken. Omdat het gewenste betrouwbaarheidsniveau 95 % is, geldt dat $\alpha = 0.05$.

De bijbehorende t -waarde is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1) = \text{InvT}(\text{area} = 0.975, \text{df} = 11) \approx 2.2010.$$

Het 95 %-betrouwbaarheidsinterval is gelijk aan

$$\begin{aligned} & \left[\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}} \right] \\ &= \left[25 - 2.2010 \cdot \frac{7.3978}{\sqrt{12}}, 25 + 2.2010 \cdot \frac{7.3978}{\sqrt{12}} \right] \\ &= [20.2997, 29.7003]. \end{aligned}$$

Met 95 % betrouwbaarheid zit het gemiddelde aantal dagen tot het gewenste resultaat tussen ongeveer 20 en 30 dagen.

- (c) In een vervolgstudie werden 90 personen getest. Er werd een standaarddeviatie gevonden van 6.5 dagen en een gemiddelde hersteltijd van 27 dagen. Bereken opnieuw een 95 %-betrouwbaarheidsinterval voor μ .

Uitwerking

Gegeven is nu een steekproef van $n = 90$ patiënten, waarvoor het aantal dagen tot het gewenste resultaat het steekproefgemiddelde $\bar{x} = 27$ dagen en de steekproefstandaardafwijking $s = 6.5$ dagen is bepaald. Omdat de standaardafwijking σ onbekend is, moeten we de t -verdeling gebruiken met $\text{df} = n - 1 = 89$ vrijheidsgraden. Omdat het gewenste betrouwbaarheidsniveau 95 % is, geldt dat $\alpha = 0.05$.

De bijbehorende t -waarde is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, \text{df} = n - 1) = \text{InvT}(\text{area} = 0.975, \text{df} = 89) \approx 1.9870.$$

Het 95 %-betrouwbaarheidsinterval is gelijk aan

$$\begin{aligned} & \left[\bar{x} - t \cdot \frac{s}{\sqrt{n}}, \bar{x} + t \cdot \frac{s}{\sqrt{n}} \right] \\ &= \left[27 - 1.9870 \cdot \frac{6.5}{\sqrt{90}}, 27 + 1.9870 \cdot \frac{6.5}{\sqrt{90}} \right] \\ &= [25.6386, 28.3614]. \end{aligned}$$

Met 95 % betrouwbaarheid zit het gemiddelde aantal dagen tot het gewenste resultaat tussen 25 en 28 dagen. *Merk op dat dit betrouwbaarheidsinterval al een stuk smaller is, wat het effect van een grotere steekproefomvang onderschrijft!*

- (d) Men wenst het bij vraag (c) gevraagde interval zodanig te bepalen dat het resulterende interval voor μ niet breder is dan twee dagen. Hoe groot moet de steekproefomvang worden gekozen om dat te bereiken, als de standaarddeviatie van vraag (a) als vertrekpunt mag worden gekozen?

Uitwerking

Als het resulterende interval voor μ niet breder is dan twee dagen, dan is ook de foutmarge (afwijking van het gemiddelde) a niet groter dan 1 dag ($a \leq 1$). Verder mogen we aannemen dat $s = 7.3978$.

In formulevorm ziet dit er als volgt uit:

$$t \cdot \frac{s}{\sqrt{n}} \leq a = 1,$$

waarbij t ook weer afhangt van n . We bepalen de minimaal benodigde steekproefgrootte n met behulp van een tabel op de grafische rekenmachine. Vul hiertoe in het functiescherm in:

$$y_1 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, \text{df} = X - 1) \cdot \frac{7.3978}{\sqrt{X}}$$

Met de tabel optie krijgen we dan:

- Voor $n = 212 \implies \text{InvT}(\text{area} = 0.975, \text{df} = 211) \cdot \frac{7.3978}{\sqrt{212}} \approx 1.0016$ (voldoet nog niet)
- Voor $n = 213 \implies \text{InvT}(\text{area} = 0.975, \text{df} = 212) \cdot \frac{7.3978}{\sqrt{213}} \approx 0.9992$ (voldoet wel)

Er is dus minimaal een steekproefomvang van $n = 213$ personen benodigd om een interval te krijgen voor μ van maximaal 2 dagen breed.

Week 9

Hypothesetoetsen

Hoofdstuk 9

Opdracht 9.m1: Een kritiek gebied $Z \dots$

- (a) bestaat uit alle hypothesen die moeten worden verworpen.
- (b) mag geen waarneming bevatten.
- (c) geeft voor de toetsingsgrootte aan welke uitkomsten daarvan tot verwerping van de nulhypothese zullen leiden.
- (d) heeft een kans van $1 - \alpha$.

Uitwerking

Het kritieke gebied is een manier om een toetsuitslag te bepalen door te kijken naar de kansverdeling van de theoretische toetsingsgrootte en te bepalen welke uitkomsten daarvan als “extreem” kunnen worden beschouwd onder de aanname van H_0 . Het juiste antwoord is dus (c).

Opdracht 9.m2: Een fout van de eerste soort wordt gemaakt als ...

- (a) de nulhypothese wordt verworpen indien deze toch juist is.
- (b) reeds bij het nemen van de steekproef fouten worden gemaakt.
- (c) een onjuiste toetsingsprocedure wordt gevolgd.
- (d) de alternatieve hypothese wordt verworpen.

Uitwerking

Een fout van de eerste soort (een type-I fout) wordt gemaakt als de nulhypothese ten onrechte wordt verworpen. Het juiste antwoord is dus (a).

Opdracht 9.m3: Het verwerpen van een juiste alternatieve hypothese . . .

- (a) heet een fout van de eerste soort.
- (b) heet een fout van de tweede soort.
- (c) heet een steekproeffout.
- (d) kan alleen als de toetsingsgrootte een waarde in het kritieke gebied heeft laten zien.

Uitwerking

Het juiste antwoord is (b).

Opdracht 9.m4: Als bij een toetsingsprocedure wordt gewerkt met de zogeheten overschrijdingskansen μ , dan . . .

- (a) dient de nulhypothese te worden verworpen als μ groter is dan α .
- (b) dient de nulhypothese te worden verworpen als bij tweezijdige toetsing de p -waarde kleiner is dan $\frac{1}{2}\alpha$.
- (c) is $1 - p$ het onderscheidingsvermogen.
- (d) mag p niet groter zijn van 0.05.

Uitwerking

Bij tweezijdige toetsen bekijken we de toetsingsgrootte en verwerpen we de nulhypothese indien deze een waarde aanneemt die ofwel extreem klein ofwel extreem groot is. Een uitkomst is extreem klein als de kans op een kleinere uitkomst (linkeroverschrijdingskansen) kleiner dan $\alpha/2$ is. Een uitkomst is extreem groot als de kans op een grotere uitkomst (rechteroverschrijdingskansen) kleiner dan $\alpha/2$ is. De p -waarde is het minimum van de linker- en de rechteroverschrijdingskansen. Het juiste antwoord is dus (b).

Opdracht 9.m5: Een vulmachine is zodanig ingesteld dat deze verpakking vult met een vulgewicht X dat een normale verdeling volgt met $\mu = 1510$ gram en $\sigma = 20$ gram. Regelmatig wordt met een steekproef gecontroleerd of de instelling (μ) van de machine nog correct is. We nemen dan een steekproef van zestien verpakkingen en we toetsen tweezijdig met $\alpha = 0.05$. We veronderstellen dat σ niet is veranderd. De grenzen van het kritieke gebied zijn dan:

- (a) 1500.2 en 1519.8.
- (b) 1477 en 1543.

(c) 1507.55 en 1512.45.

(d) 1461 en 1559.

Uitwerking

In deze vraag wordt tweezijdig getoetst met de volgende nulhypothese en alternatieve hypothese:

$$H_0: \mu = 1510$$

$$H_1: \mu \neq 1510$$

Gegeven is dat X normaal verdeeld is met $\mu = ?$ en standaardafwijking $\sigma = 20$. We willen immers toetsen of de waarde van μ niet is veranderd, en we mogen veronderstellen dat σ niet was veranderd. Verder is het significantieniveau $\alpha = 0.05$ gegeven, evenals de steekproefgrootte $n = 16$.

Onder de aanname van H_0 is het steekproefgemiddelde $\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$ normaal verdeeld met verwachtingswaarde $\mu = 1510$ en standaardafwijking $\sigma/\sqrt{n} = 20/\sqrt{16} = 5$. Omdat we tweezijdig toetsen, wordt het kritieke gebied gegeven door $(-\infty, g_1]$ en $[g_2, \infty)$. De grenswaarden g_1 en g_2 zijn de kritieke waarden waarbij de kans op respectievelijk kleinere of grotere uitkomsten gelijk is aan $\alpha/2 = 0.025$.

$$g_1 = \text{InvNorm}(\text{area} = \alpha/2 = 0.025, \mu = 1510, \sigma = 5) \approx 1500.2$$

$$g_2 = \text{InvNorm}(\text{area} = 1 - \alpha/2 = 0.975, \mu = 1510, \sigma = 5) \approx 1519.8$$

Het grenzen van het kritieke gebied zijn dus gelijk aan 1500.2 en 1519.8. Het juiste antwoord is dus (a).

Opdracht 9.m6: Voor een normaal verdeelde variabele met onbekende μ en σ wordt een toets voor μ verricht. De volgende gegevens zijn van belang: $H_0 : \mu = 60$, $H_1 : \mu < 60$, $\alpha = 0.05$, $s^2 = 16$, $n = 25$, het steekproefgemiddelde is 62. Bij deze toets vinden we dus een berekende t^* -waarde of z^* -waarde die gelijk is aan ...

(a) 2.50.

(b) 0.625.

(c) 1.568.

(d) 1.316.

Uitwerking

In dit geval is de berekende t^* -waarde wat wij de geobserveerde toetsingsgrootte t noemen. Omdat de standaardafwijking σ onbekend is, gebruiken we de theoretische

toetsingsgrootheid $T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$ met steekproefschatting $s = \sqrt{16} = 4$ voor de onbekende standaardafwijking σ . Deze toetsingsgrootheid volgt een t -verdeling met $df = n - 1$ vrijheidsgraden. De geobserveerde toetsingsgrootheid is dus gelijk aan

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{62 - 60}{4/\sqrt{25}} = 2.5.$$

Het juiste antwoord is dus (a).

Opdracht 9.3: Een variabele X is normaal verdeeld met standaarddeviatie 10. We toetsen $H_0 : \mu = 50$ tegen $H_1 : \mu > 50$.

- (a) Bereken het kritieke gebied als er één waarneming wordt gedaan bij een kans op een fout van de eerste soort $\alpha = 0.05$ en ook bij $\alpha = 0.01$.

Uitwerking

Gegeven is dat we te maken hebben met een normaal verdeelde kansvariabele X met verwachtingswaarde $\mu = ?$ en standaardafwijking $\sigma = 10$. Aangezien de standaarddeviatie σ bekend is, kunnen we de theoretische toetsingsgrootheid $\bar{X}$ gebruiken. Deze toetsingsgrootheid is onder H_0 normaal verdeeld met verwachtingswaarde 50 en standaardafwijking $\sigma/\sqrt{n} = 10/\sqrt{1} = 10$.

- Stel eerst dat $\alpha = 0.05$.

Omdat we rechtszijdig toetsen (alternatieve hypothese van de vorm $>$), berekenen we de grenswaarde g waarvoor geldt $P(\bar{X} \geq g) = \alpha$:

$$g = \text{InvNorm}(\text{area} = 1 - \alpha = 0.95, \mu = 50, \sigma = 10) \approx 66.4485.$$

Het kritieke gebied is dus gelijk aan $[66.4485, \infty)$

- Stel nu dat $\alpha = 0.01$. Op een gelijksoortige manier kunnen we opnieuw een grenswaarde berekenen:

$$g = \text{InvNorm}(\text{area} = 1 - \alpha = 0.99, \mu = 50, \sigma = 10) \approx 73.2635.$$

Het kritieke gebied is dus gelijk aan $[73.2635, \infty)$.

- (b) We doen 100 waarnemingen van de betrokken variabele. Bereken het kritieke gebied bij $\alpha = 0.10$ en $\alpha = 0.001$.

Uitwerking

De procedure voor het berekenen van het kritieke gaat op een soortgelijke manier, alleen is de toetsingsgrootheid $\bar{X}$ in deze situatie onder aanname van de nulhypo-

these H_0 normaal verdeeld met verwachtingswaarde $\mu = 50$ en standaardafwijking $\sigma/\sqrt{n} = 10/\sqrt{100} = 1$.

- Stel eerst dat $\alpha = 0.10$. Omdat we rechtszijdig toetsen, berekenen we de grenswaarde g van het kritieke gebied, oftewel de waarde waarvoor geldt $P(\bar{X} \geq g) = \alpha$:

$$g = \text{InvNorm}(\text{area} = 1 - \alpha = 0.90, \mu = 50, \sigma = 1) \approx 51.2816.$$

Het kritieke gebied is dus gelijk aan $[51.2816, \infty)$.

- Stel nu dat $\alpha = 0.001$. Omdat we rechtszijdig toetsen, berekenen we de grenswaarde g van het kritieke gebied:

$$g = \text{InvNorm}(\text{area} = 1 - \alpha = 0.999, \mu = 50, \sigma = 1) \approx 53.0902.$$

Het kritieke gebied is dus gelijk aan $Z = [53.0902, \infty)$.

Opdracht 9.5: Een broodjeszaak langs een drukke provinciale weg heeft al een aantal jaren bijgehouden hoeveel klanten er komen tijdens de lunchperiode. Dat leverde een tamelijk stabiel patroon op met een gemiddelde van $\mu = 42$ klanten per dag en een standaarddeviatie $\sigma = 5$. Twee maanden geleden is er bij een dichtbij gelegen benzinstation een voorziening gekomen waar klanten snacks kunnen verkrijgen. De eigenaar van de broodjeszaak maakt zich zorgen en heeft gedurende 50 dagen het aantal klanten geteld dat bij hem komt tijdens de lunchperiode. Dat leverde een gemiddelde op van 37.8 klanten. Toets eenzijdig of hier sprake is van een significante daling ($\alpha = 0.05$).


Uitwerking

In deze hypothesesetoets geldt dat de nulhypothese $H_0 : \mu \geq 42$ (geen daling) getest wordt tegen de alternatieve hypothese $H_1 : \mu < 42$ (wel een daling). Omdat de standaardafwijking $\sigma = 5$ bekend is, is in dit geval de theoretische grootte gelijk aan $\bar{X}$. Onder de aanname van de nulhypothese H_0 , is deze toetsingsgrootte normaal verdeeld met verwachtingswaarde $\mu = 42$ en standaardafwijking $\sigma/\sqrt{n} = 5/\sqrt{50}$.

Omdat we linkszijdig toetsen, berekenen we de grenswaarde g van het kritieke gebied $(-\infty, g]$:

$$g = \text{InvNorm}(\text{area} = \alpha = 0.05, \mu = 42, \sigma = 5/\sqrt{50}) \approx 40.8369.$$

Het kritieke gebied is dus gelijk aan $Z = (-\infty, 40.8369]$. De geobserveerde toetsingsgrootte $\bar{x} = 37.8$ ligt wel in het kritieke gebied, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde aantal klanten per dag in de broodjeszaak significant is gedaald.



Opdracht 9.7: Capsules die zijn gevuld met een bepaald medicijn, moeten 5 mg werkzaam bestanddeel bevatten. Het is bekend dat door onnauwkeurigheden met de machine die de capsules vult de hoeveelheid werkzaam bestanddeel te beschouwen is als een normaal verdeelde kansvariabele X met verwachtingswaarde 5.0 mg en standaarddeviatie 0.15 mg. Geëist wordt dat de hoeveelheid werkzaam bestanddeel per capsule tussen 4.6 mg en 5.4 mg ligt.

- (a) Hoeveel procent van de capsules heeft een inhoud buiten de gestelde normen als de vulmachine correct is ingesteld?

Uitwerking

Gegeven is dat de hoeveelheid (in mg) werkzaam bestanddeel X normaal verdeeld is met $\mu = 5.0$ en $\sigma = 0.15$. De norm is dat deze hoeveelheid tussen de 4.6 mg en 5.4 mg ligt. De kans hierop kunnen we uitrekenen als volgt:

$$P(4.6 \leq X \leq 5.4) = \text{normalcdf}(\text{lower} = 4.6, \text{upper} = 5.4, \mu = 5.0, \sigma = 0.15) \approx 0.9923.$$

Met 99.23% kans wordt een willekeurige capsule gevuld met een hoeveelheid werkzaam bestanddeel dat binnen de norm valt, oftewel 0.77% van de capsules heeft een inhoud buiten de gestelde normen.

- (b) De instelling van de machine kan tijdens het gebruik veranderen. Daarom wordt er regelmatig een aantal capsules gecontroleerd in het laboratorium. Een steekproef van 25 capsules levert een gemiddeld gehalte van het werkzame bestanddeel van 4.70 mg. Toets of hieruit mag worden geconcludeerd dat de instelling van de machine is gewijzigd. Toets hierbij tweezijdig, kies $\alpha = 0.01$ en ga ervan uit dat de standaarddeviatie niet is veranderd.

Uitwerking


In deze hypothesetoets geldt dat de nulhypothese $H_0 : \mu = 5.0$ (geen verandering in de instelling) getest wordt tegen de alternatieve hypothese $H_1 : \mu \neq 5.0$ (wel een verandering in het gemiddelde).

De standaardafwijking $\sigma = 0.15$ is bekend, dus we gebruiken de toetsingsgrootheid $\bar{X}$. Onder aanname van de nulhypothese H_0 is deze toetsingsgrootheid normaal verdeeld met verwachtingswaarde $\mu = 5.0$ en standaardafwijking $\sigma/\sqrt{n} = 0.15/\sqrt{25} = 0.03$. Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$:

$$g_1 = \text{InvNorm}(\text{area} = \alpha/2 = 0.005, \mu = 5.0, \sigma = 0.03) \approx 4.9227$$

$$g_2 = \text{InvNorm}(\text{area} = 1 - \alpha/2 = 0.995, \mu = 5.0, \sigma = 0.03) \approx 5.0773$$

Het kritieke gebied is dus gelijk aan $(-\infty, 4.9227]$ en $[5.0773, \infty)$. De geobserveerde toetsingsgrootheid $\bar{x} = 4.70$ ligt in het kritieke gebied, dus we verwerpen H_0 . Er is voldoende reden om aan te nemen dat de instelling van de machine is gewijzigd.



- (c) Als de capsules worden gevuld met gemiddelde 4.70 mg werkzaam bestanddeel (σ is nog steeds gelijk aan 0.15 mg), hoeveel procent van de capsules voldoet dan niet meer aan de norm?

Uitwerking

Stel nu dat het werkelijke gemiddelde gelijk is aan $\mu = 4.70$ mg, en de standaarddeviatie is nog steeds $\sigma = 0.15$, oftewel X is normaal verdeeld met $\mu = 4.70$ en $\sigma = 0.15$. In dat geval is de kans dat een willekeurige capsule niet meer voldoet

aan de norm gelijk aan

$$P(4.6 \leq X \leq 5.4) = \text{normalcdf}(\text{lower} = 4.6, \text{upper} = 5.4, \mu = 4.7, \sigma = 0.15) \approx 0.7475.$$

Van alle capsules zal 74.75 % een hoeveelheid werkzaam bestanddeel bevatten dat voldoet aan de norm, oftewel 25.25 % van de capsules voldoen niet meer aan de norm.

Opdracht 9.11: Een zelfbedieningsrestaurant verkoopt hamburgers van het type Big-Smak. Het vleesgewicht van deze hamburgers bedraagt volgens het restaurant gemiddeld minstens 160 gram met een standaarddeviatie van 5 gram. Om de bewering van het restaurant te onderzoeken, kopen zes studenten een Big-Smak en bepalen het vleesgewicht. Dat leverde: 140, 148, 162, 146, 152 en 152 gram op. We gaan ervan uit dat de gewichten van hamburgers mogen worden beschouwd als trekkingen uit een normale verdeling met (nog steeds) $\sigma = 5$ gram. Toets door berekening van de p -waarde of de bewering van het restaurant staande kan worden gehouden (kies $\alpha = 0.05$).

Uitwerking

In deze hypothesetoets geldt dat de nulhypothese $H_0 : \mu \geq 160$ (gemiddeld minstens 160 gram) getest wordt tegen $H_1 : \mu < 160$ (gemiddeld minder dan 160 gram). Verder is de standaardafwijking $\sigma = 5$ bekend, en het significantieniveau $\alpha = 0.05$.

De toetsingsgrootte is in dit geval het (theoretische) steekproefgemiddelde $\bar{X}$. Onder aanname van de nulhypothese H_0 is deze toetsingsgrootte normaal verdeeld met verwachtingswaarde $\mu = 160$ en standaardafwijking $\sigma/\sqrt{n} = 5/\sqrt{6}$. De geobserveerde toetsingsgrootte $\bar{x} = \frac{x_1+x_2+\dots+x_6}{6} = \frac{140+148+162+146+152+152}{6} = 150$.

Methode 1: met behulp van het kritieke gebied

Omdat we linkszijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g]$. We berekenen deze grenswaarde g van het kritieke gebied als volgt:

$$g = \text{InvNorm}(\text{area} = \alpha = 0.05, \mu = 160, \sigma = 5/\sqrt{6}) \approx 156.6425.$$


Het kritieke gebied is dus $(-\infty, 156.6425]$. De geobserveerde toetsingsgrootte $\bar{x} = 150$ ligt in het kritieke gebied, dus we besluiten om H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde vleesgewicht van een hamburger bij Big-Smak significant lager is dan 160 gram.

Methode 2: met behulp van de p -waarde

Omdat we linkszijdig toetsen, is de p -waarde gelijk aan de linkeroverschrijdingskans

$$\begin{aligned} p &= P(\bar{X} \leq \bar{x} = 150) \\ &= \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 150, \mu = 160, \sigma = \frac{5}{\sqrt{6}}) \\ &\approx 0.000000482. \end{aligned}$$

Aangezien p -waarde extreem klein is (veel kleiner dan het significantieniveau α), besluiten we om de nulhypothese H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde vleesgewicht van een hamburger bij Big-Smak significant lager is dan 160 gram.



Opdracht 9.18: Een bedrijf voert een administratie van het aantal klachten van afnemers. In acht weken werden de volgende aantallen klachten per week geregistreerd:

Week	1	2	3	4	5	6	7	8
Aantal klachten	30	45	46	50	52	34	35	28

We gaan ervan uit dat het aantal klachten per week kan worden beschouwd als een variabele met een normale verdeling. In het verleden bleek het aantal klachten gemiddeld 51 per week te zijn. Toets of dit gemiddelde nog houdbaar is in het licht van verzamelde uitkomsten (kies $\alpha = 0.05$).

Uitwerking

In deze hypothesetoets geldt dat de nulhypothese $H_0: \mu = 51$ (gemiddeld 51 klachten per week) getest wordt tegen de alternatieve hypothese $H_1: \mu \neq 51$ (gemiddeld een ander aantal dan 51 klachten per week). In acht weken wordt het aantal klachten geteld, oftewel de steekproefgrootte is $n = 8$.

Omdat de standaardafwijking σ onbekend is, maken we gebruik van de toetsingsgrootte $T = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$, waarbij s een steekproefschatting is van σ . Onder aanname van de nulhypothese H_0 volgt deze toetsingsgrootte een t -verdeling met $df = n - 1 = 7$ vrijheidsgraden.

Om de geobserveerde toetsingsgrootte te berekenen moeten we eerst het steek-

proefgemiddelde $\bar{x}$ en de steekproefstandaardafwijking s bepalen. Het geobserveerde steekproefgemiddelde is gelijk aan

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{30 + 45 + \dots + 28}{8} = 40.$$

De schatting s^2 van de steekproefvariantie vinden we als volgt

$$\begin{aligned} s^2 &= \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} \\ &= \frac{(x_1 - \bar{x})^2 + \dots + (x_8 - \bar{x})^2}{8 - 1} \\ &= \frac{(30 - 40)^2 + \dots + (28 - 40)^2}{8 - 1} \\ &\approx 87.1429. \end{aligned}$$

Hierdoor volgt een schatting van de standaarddeviatie

$$s = \sqrt{s^2} = \sqrt{87.1429} \approx 9.3350.$$

Met behulp van deze waarden kunnen we de geobserveerde toetsingsgrootheid t berekenen:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{40 - 51}{9.3350/\sqrt{8}} \approx -3.3329.$$

Methode 1 (kritieke gebied)

Omdat we tweezijdig toetsen, berekenen we de grenswaarden g_1 en g_2 van het kritieke gebied als volgt:

$$\begin{aligned} g_1 &= \text{InvT}(\text{area} = \alpha/2 = 0.025, \text{df} = n - 1 = 7) \approx -2.3646 \\ g_2 &= \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, \text{df} = n - 1 = 7) \approx 2.3646 \end{aligned}$$

Het kritieke gebied bestaat dus uit $(-\infty, -2.3646]$ en $[2.3646, \infty)$. De geobserveerde toetsingsgrootheid $t \approx -3.3329$ ligt in het kritieke gebied, dus besluiten we de nulhypothese H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde aantal klachten per week significant afwijkt van 51.

Methode 2 (p -waarde)

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van twee kansen:


- De kans dat de toetsingsgrootheid T een waarde aanneemt kleiner dan de geobserveerde toetsingsgrootheid t :

$$P(T \leq t) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = t = -3.3329, \text{df} = n - 1 = 7) = 0.0063$$

- De kans dat de toetsingsgrootheid T een waarde aanneemt groter dan de geobserveerde toetsingsgrootheid t :

$$P(T \geq t) = \text{tcdf}(\text{lower} = t = -3.3329, \text{upper} = 10^{99}, \text{df} = n - 1 = 7) = 0.9937$$

De p -waarde is dus gelijk aan $p = 0.0063$. Deze p -waarde is veel kleiner dan $\alpha/2$ (tweezijdig!), dus besluiten we de nulhypothese H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde aantal klachten per week significant afwijkt van 51.



Opdracht 9.23: Een autofabriek heeft een nieuw model, de XGT, op de markt gebracht. In de folder staat dat het benzinegebruik laag is, namelijk gemiddeld hoogstens 7 liter voor 100 kilometer op de buitenweg. Om deze bewering te controleren, werden met zestien XGT's proefritten gemaakt van 100 kilometer. Voor deze zestien proefritten werd een gemiddeld verbruik van 7.32 liter gevonden. Wegens verschillen in rijstijl en rijomstandigheden mag worden aangenomen dat het benzineverbruik per 100 kilometer wordt beschreven door een kansvariabele X die normaal verdeeld is met $\sigma = 0.5$ liter.

- (a) Toets (volgens de gebruikelijke procedure) of de bewering van de fabrikant staande kan worden gehouden op basis van de uitkomsten van de proefritten (kies $\alpha = 0.05$).

Uitwerking


In deze hypothesetoets geldt dat de nulhypothese $H_0: \mu \leq 7$ (gemiddeld hoogstens 7 liter per 100 km) getest wordt tegen de alternatieve hypothese $H_1: \mu > 7$ (gemiddeld meer dan 7 liter per 100 km). Verder is de standaarddeviatie $\sigma = 0.5$ gegeven, evenals het significantieniveau $\alpha = 0.05$ en de steekproefgrootte $n = 16$ met steekproefgemiddelde $\bar{x} = 7.32$. Omdat de standaardafwijking σ bekend is, kunnen we in dit geval het steekproefgemiddelde $\bar{X}$ gebruiken als toetsingsgrootte. Onder aanname van de nulhypothese H_0 is deze toetsingsgrootte normaal verdeeld met verwachtingswaarde $\mu = 7$ en standaardafwijking $\sigma / \sqrt{n} = 0.5 / \sqrt{16} = 0.125$.

Omdat we rechtszijdig toetsen, is het kritieke gebied van de vorm $[g, \infty)$. Deze

grenswaarde g berekenen we als volgt:

$$g = \text{InvNorm}(\text{area} = 1 - \alpha = 0.95, \mu = 7, \sigma = 0.125) \approx 7.2056.$$

Het kritieke gebied is dus gelijk aan $[7.2056, \infty)$. De geobserveerde toetsingsgrootheid $\bar{x} = 7.32$ ligt in het kritieke gebied, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is voldoende reden om aan te nemen dat het gemiddelde verbruik strikt meer dan 7 liter per 100 km is, en dat de bewering in de folder dus niet zou kloppen met de werkelijkheid.



- (b) Bereken het onderscheidingsvermogen van de toets als in werkelijkheid zou gelden dat het gemiddelde benzineverbruik 7.30 liter per 100 kilometer is.

Uitwerking


De kans op een type II-fout wordt aangeduid met β , oftewel de kans dat de nulhypothese H_0 ten onrechte niet wordt verworpen. Het onderscheidingsvermogen van een hypothesetoets is dan gelijk aan $1 - \beta$, oftewel de kans dat de nulhypothese correct wordt verworpen als deze niet waar is.

Merk op dat de alternatieve hypothese waar is, aangezien 7.30 inderdaad groter dan 7 is. Ervan uitgaande dat $\mu = 7.3$, geldt dat het gemiddelde benzineverbruik $\bar{X}$ bij 16 willekeurige proefritten normaal verdeeld met verwachtingswaarde $\mu = 7.3$ en standaardafwijking $\sigma/\sqrt{n} = 0.5/\sqrt{16} = 0.125$. Deze kans β op een type-II fout kunnen we berekenen als de kans dat $\bar{X}$ een waarde aanneemt in het acceptatiegebied op basis van deze nieuwe kansverdeling met $\mu = 7.3$. dat we bij (a) hebben

berekend, oftewel

$$\begin{aligned}\beta &= P(\bar{X} < 7.2056 | \mu = 7.30) \\ &= \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = 7.2056, \mu = 7.30, \sigma = 0.125) \\ &\approx 0.2251.\end{aligned}$$

De kans β is het geel gearceerde gebied in de onderstaande figuur, we gaan nu immers uit van een specifieke alternatieve hypothese $\mu = 7.30$. Het onderscheidingsvermogen van deze hypothesetoets is dan gelijk aan $1 - \beta = 1 - 0.2251 = 0.7749$.



Week **10****De chikwadraatverdeling****Hoofdstuk 10**

Opdracht 10.m1: Voor een kansvariabele die een theoretische chikwadraatsverdeling met vijf vrijheidsgraden volgt, geldt dat ...

- (a) deze symmetrisch rondom 0 ligt.
- (b) deze symmetrisch rondom 5 ligt.
- (c) de kansen hiervoor kunnen worden gevonden als het kwadraat wordt genomen van een normaal verdeelde variabele met $\mu = 5$.
- (d) deze kansvariabele waarden kan aannemen die groter zijn dan 15.

Uitwerking

De uitkomstenruimte van een kansvariabele met een chikwadraatsverdeling is altijd gelijk aan alle reële getallen groter dan of gelijk aan nul, dus ook waarden die groter zijn dan 15. Het juiste antwoord is dus (d).

Opdracht 10.m2: Bij een chikwadraattoets voor onafhankelijkheid moet worden gewerkt met de chikwadraatverdeling met 6 vrijheidsgraden. Er moet worden getoetst met $\alpha = 0.05$. De kritieke tabelwaarde is daarom ...

- (a) 1.64.
- (b) 14.45.
- (c) 12.59.
- (d) 9.49.

Uitwerking

We noteren met X^2 de toetsingsgrootte die een chikwadraatverdeling met $df = 6$ vrijheidsgraden volgt. Er is verder gegeven dat het significantieniveau $\alpha = 0.05$. Aangezien chikwadraattoetsen altijd rechtszijdig zijn, moeten we de grenswaarde g van het kritieke gebied $[g, \infty)$ berekenen, oftewel de grenswaarde g waarvoor geldt dat $P(X^2 \geq g) = \alpha = 0.05$.

Deze grenswaarde g berekenen we met de “numerieke solver” door het volgende in te voeren:


$$E_1 = \chi^2 \text{cdf}(\text{lower} = X, \text{upper} = 10^{99}, df = 6)$$

$$E_2 = 0.05.$$

of met de Casio rekenmachines:

$$\text{SolveN}(\text{ChiCD}(x, 10^{99}, 6) = 0.05, x).$$

Dit geeft in beide gevallen een kritieke waarde $g \approx 12.5916$. Het juiste antwoord is dus (c).



Opdracht 10.m3: Bij een toets voor onafhankelijkheid geeft de tabel de waargenomen frequenties weer. De te verwachten of *expected* frequentie voor de cel waarin 80 waarnemingen vermeld zijn, bedraagt ...

(a) $\frac{80}{250}$.

(b) 125.

(c) 0.2.

(d) 100.

	Man	Vrouw
Links	80	120
Rechts	170	130

Uitwerking

Bekijk nu een uitgebreidere versie van de tabel van *observed* frequenties hierboven, waarbij we ook de rij- en kolomtotalen hebben toegevoegd.

	Man	Vrouw	Totaal
Links	80	120	200
Rechts	170	130	300
Totaal	250	250	500

De te verwachten of *expected* frequentie E_{ij} voor de cel in rij i en kolom j kunnen we als volgt berekenen:

$$E_{ij} = \frac{\text{rijtotaal}_i \cdot \text{kolomtotaal}_j}{\text{totaal}}$$

Voorbeeld: de *expected* frequentie voor de cel (1,1) linksboven, oftewel E_{11} , gelijk is aan

$$E_{11} = \frac{\text{rijtotaal}_1 \cdot \text{kolomtotaal}_1}{\text{totaal}} = \frac{200 \cdot 250}{500} = 100.$$

Het juiste antwoord is dus (d).

Opdracht 10.m4: Men wenst te toetsen of het aantal aanvragen bij een helpdesk van een computermaatschappij gelijk is verdeeld over de vijf werkdagen van de week. In een bepaalde week worden de volgende aantallen waarnemingen gedaan tussen maandag en vrijdag: 48, 65, 57, 72, 58. De *expected* frequentie voor het aantal aanvragen op een willekeurige maandag is dus ...

- (a) 12.
- (b) 60.
- (c) 48.
- (d) 5.

Uitwerking

In totaal zijn er in deze week $48 + 65 + 57 + 72 + 58 = 300$ waarnemingen gedaan. Indien het aantal aanvragen uniform verdeeld is over de vijf werkdagen, dan verwachten we dat 20 % van de aanvragen op maandag wordt gedaan. De *expected* frequentie van het aantal aanvragen op maandag is dus gelijk aan $0.20 \cdot 300 = 60$ aanvragen. Het juiste antwoord is dus (b).

Opdracht 10.1: Bij een onderzoek naar de rookgewoonten van Nederlanders van 18 jaar en ouder werden door loting 200 proefpersonen gekozen die vervolgens werden ingedeeld naar leeftijd en naar rookgewoonte. De resultaten waren als volgt:

	Leeftijd			Totaal
	18– < 30	30– < 45	45 en ouder	
Roker	25	35	20	80
Niet-roker	55	25	40	120
Totaal	80	60	60	200

We gaan met behulp van de chikwadraattoets onderzoeken of de indelingen naar leeftijd en rookgewoonte al dan niet afhankelijk van elkaar zijn. We toetsen met $\alpha = 0.01$. De nulhypothese luidt: H_0 : onafhankelijkheid.

(a) Bereken de *expected*-tabel.

Uitwerking

Om de *expected*-tabel te bepalen, starten we vanuit een lege tabel waarin alleen de rij- en kolomtotalen gegeven zijn:

	Leeftijd			Totaal
	18– < 30	30– < 45	45 en ouder	
Roker				80
Niet-roker				120
Totaal	80	60	60	200

Voor iedere cel in de tabel bepalen we de expected frequentie met de formule:

$$E_{ij} = \frac{\text{rijtotaal}_i \cdot \text{kolomtotaal}_j}{\text{totaal}}$$

Dit geeft de volgende *expected*-tabel:

	Leeftijd			Totaal
	18– < 30	30– < 45	45 en ouder	
Roker	$\frac{80 \cdot 80}{200} = 32$	$\frac{80 \cdot 60}{200} = 24$	$\frac{80 \cdot 60}{200} = 24$	80
Niet-roker	$\frac{120 \cdot 80}{200} = 48$	$\frac{120 \cdot 60}{200} = 36$	$\frac{120 \cdot 60}{200} = 36$	120
Totaal	80	60	60	200

(b) Bereken de toetsingsgrootte χ^2 .

Uitwerking

De theoretische toetsingsgrootte van een chikwadraattoets is X^2 en bepalen we in algemene zin aan de hand van de volgende formule:

$$X^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

waarbij $i = 1, 2$ de index van de rij is, en $j = 1, 2, 3$ de index van de kolom is. Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootte

$$\begin{aligned} \chi^2 &= \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} \\ &= \frac{(o_{11} - e_{11})^2}{e_{11}} + \frac{(o_{12} - e_{12})^2}{e_{12}} + \dots + \frac{(o_{23} - e_{23})^2}{e_{23}} \\ &= \frac{(25 - 32)^2}{32} + \frac{(35 - 24)^2}{24} + \dots + \frac{(40 - 36)^2}{36} \\ &\approx 12.0660. \end{aligned}$$

(c) Hoeveel vrijheidsgraden heeft de chikwadraatverdeling die gebruikt moet worden?

Uitwerking

Bij een χ^2 -toets voor onafhankelijkheid van twee nominale variabelen is het aantal vrijheidsgraden gelijk aan het aantal cellen waarvoor je een waarde vrij kunt kiezen. Merk op dat zodra je in een rij alle waarden op één na hebt gekozen, de laatste waarde vastligt omdat het rijtotaal al bekend is. Hetzelfde geldt voor een kolom, omdat het kolomtotaal bekend is.

Het aantal vrijheidsgraden is dus gelijk aan

$$df = (\#rijen - 1) \cdot (\#kolommen - 1) = (2 - 1) \cdot (3 - 1) = 2.$$

De toetsingsgrootte heeft voor deze chikwadraattoets dus een chikwadraatverdeling met $df = 2$ vrijheidsgraden.

(d) Geef het kritieke gebied aan van de grootte X^2 .

Uitwerking

Merk op dat onafhankelijkheid tussen de twee variabelen “leeftijd” en “rookgevoorte” waarschijnlijker is zodra de geobserveerde toetsingsgrootte χ^2 dichter bij 0 ligt. Dit volgt uit de formule van de toetsingsgrootte X^2 , omdat in dat geval de geobserveerde (“observed”) frequenties dicht in de buurt van de verwachte (“expected”) frequenties liggen.

Omdat een chikwadraattoets dus altijd een rechtszijdig toets is, is het kritieke gebied dus van de vorm $[g, \infty)$, waarbij g de grenswaarde is waarvoor geldt $P(X \geq g) = \alpha = 0.01$. Deze grenswaarde g kunnen we dus berekenen met behulp van de “numerieke solver”, door het volgende in te vullen:

$$E_1 = \chi^2 \text{cdf}(\text{lower} = X, \text{upper} = 10^{99}, \text{df} = 2)$$

$$E_2 = 0.01.$$

of op de Casio:

$$\text{SolveN}(\text{ChiCD}(x, 10^{99}, 2) = 0.01, x)$$


Dit geeft een grenswaarde $g \approx 9.2103$. Het kritieke gebied is dus gelijk aan $[9.2103, \infty)$.

(e) Wat is uw eindconclusie?

Uitwerking

De geobserveerde toetsingsgrootte $\chi^2 \approx 12.0660$ ligt binnen het kritieke gebied $[9.2103, \infty)$, dus besluiten we om H_0 te verwerpen. Er is voldoende bewijs om aan te nemen dat de twee nominale variabelen “leeftijd” en “rookgewoonte” afhankelijk zijn van elkaar. Om te bekijken hoe deze afhankelijkheid eruit ziet, moeten we de geobserveerde frequenties analyseren.

Hieruit is op te maken dat het aandeel rokers in de leeftijdsgroep $30- < 45$ een stuk hoger ligt dan in de andere leeftijdsgroepen. Hierdoor kun je dus concluderen dat rookgewoontes niet vergelijkbaar zijn over alle leeftijdscategorieën.



Opdracht 10.5: Bij een onderzoek naar het gebruik van internet werden de respondenten onderverdeeld naar leeftijd en het wel of niet werken met internet. Voor 400 respondenten leverde dit de volgende tabel:

Internetgebruik			
Leeftijd	Wel internet	Geen internet	Totaal
Tot en met 44 jaar	143	77	220
45 jaar en ouder	97	83	180
Totaal	240	160	400

- (a) De vraag is of deze indelingen onafhankelijk zijn. Bereken de *expected*-tabel en voer de chikwadraattoets uit met behulp van de tabel (kies $\alpha = 0.01$).

Uitwerking

Bij een chikwadraattoets voor onafhankelijkheid beginnen we met het definiëren van de nulhypothese H_0 en de alternatieve hypothese H_1 .

H_0 : “leeftijd” en “internetgebruik” zijn onafhankelijk van elkaar.

H_1 : “leeftijd” en “internetgebruik” zijn wel afhankelijk van elkaar.

Het significantieniveau $\alpha = 0.01$ is gegeven in de opdracht, net als de geobserveerde frequenties (data). Om de toetsingsgrootte X^2 te kunnen bepalen, moeten we eerst de *expected* frequenties berekenen. Hiervoor starten we vanuit een lege tabel waarin alleen de rij- en kolomtotalen gegeven zijn:

Internetgebruik			
Leeftijd	Wel internet	Geen internet	Totaal
Tot en met 44 jaar			220
45 jaar en ouder			180
Totaal	240	160	400

Voor iedere cel in de tabel bepalen we de expected frequentie met de formule:

$$E_{ij} = \frac{\text{rijtotaal}_i \cdot \text{kolomtotaal}_j}{\text{totaal}}$$

Dit geeft de volgende tabel met “expected” frequenties:

Internetgebruik			
Leeftijd	Wel internet	Geen internet	Totaal
Tot en met 44 jaar	$\frac{220 \cdot 240}{400} = 132$	$\frac{220 \cdot 160}{400} = 88$	220
45 jaar en ouder	$\frac{180 \cdot 240}{400} = 108$	$\frac{180 \cdot 160}{400} = 72$	180
Totaal	240	160	400

De toetsingsgrootte X^2 bepalen we aan de hand van de volgende formule:

$$X^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

waarbij $i = 1, 2$ de index van de rij is, en $j = 1, 2$ de index van de kolom is. Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootte

$$\begin{aligned} \chi^2 &= \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} \\ &= \frac{(o_{11} - e_{11})^2}{e_{11}} + \frac{(o_{12} - e_{12})^2}{E_{12}} + \frac{(o_{21} - e_{21})^2}{e_{21}} + \frac{(o_{22} - e_{22})^2}{e_{22}} \\ &= \frac{(143 - 132)^2}{132} + \frac{(77 - 88)^2}{88} + \frac{(97 - 108)^2}{108} + \frac{(83 - 72)^2}{72} \\ &\approx 4.6402. \end{aligned}$$


Onder de nulhypothese volgt de toetsingsgrootte X^2 een chikwadraatverdeling met

$$df = (\#rijen - 1) \cdot (\#kolommen - 1) = (2 - 1) \cdot (2 - 1) = 1$$

vrijheidsgraad. De p -waarde (rechteroverschrijdingskans) die hoort bij deze geobserveerde toetsingsgrootte χ^2 is gelijk aan

$$\begin{aligned} p &= P(X^2 \geq \chi^2) \\ &= \chi^2\text{cdf}(\text{lower} = \chi^2 \approx 4.6402, \text{upper} = 10^{99}, df = 1) \\ &\approx 0.0312. \end{aligned}$$

Aangezien de p -waarde groter is dan het significantieniveau $\alpha = 0.01$, wordt H_0 niet verworpen. Er is onvoldoende bewijs om de hypothese te verwerpen dat de twee nominale variabelen “leeftijd” en “internetgebruik” onafhankelijk zijn van elkaar.



Opdracht 10.7: Bij een onderzoek naar de gevolgen van roken is gemeten hoe het gesteld is met de bloeddruk van 50-jarige mannen. In het onderzoek waren 200 mannen betrokken, waarvan 40 te kwalificeren zijn als stevige roker, 30 als gelegenhedsmokers en 130 als niet-rokers. Hun bloeddruk werd een van de volgende drie kwalificaties gegeven, namelijk normaal, licht verhoogd of ernstig verhoogd. Dat leverde de volgende tabel:

Bloeddruk	Stevige roker	Matige roker	Niet-roker
Normaal	6	8	86
Licht verhoogd	10	8	22
Ernstig verhoogd	24	14	22

Toets of rookgedrag en bloeddrukniveau significant samenhangen (kies $\alpha = 0.01$).

Uitwerking

Omdat we weer te maken hebben met twee *nominale* variabelen, namelijk “rookgedrag” en “bloeddrukniveau”, kunnen we een chikwadraattoets uitvoeren om de onafhankelijkheid tussen beide variabelen te toetsen. We beginnen met het definiëren van de nulhypothese H_0 en de alternatieve hypothese H_1 .

H_0 : de categorische variabelen “rookgedrag” en “bloeddrukniveau” zijn onafhankelijk van elkaar.

H_1 : de categorische variabelen “rookgedrag” en “bloeddrukniveau” zijn wel afhankelijk van elkaar.

Het significantieniveau $\alpha = 0.01$ is gegeven in de opdracht, net als de geobserveerde data. Om de toetsingsgrootheid X^2 te kunnen bepalen, moeten we eerst de *expected*-tabel berekenen. Hiervoor starten we vanuit een lege tabel waarin alleen de totalen (van de rijen en kolommen respectievelijk) gegeven zijn:

Bloeddruk	Stevige roker	Matige roker	Niet-roker	Totaal
Normaal				100
Licht verhoogd				40
Ernstig verhoogd				60
Totaal	40	30	130	200

Voor iedere cel in de tabel bepalen we de expected frequentie met de formule:

$$E_{ij} = \frac{\text{rijtotaal}_i \cdot \text{kolomtotaal}_j}{\text{totaal}}$$

Dit geeft de volgende *expected*-tabel:

Bloeddruk	Stevige roker	Matige roker	Niet-roker	Totaal
Normaal	$\frac{40 \cdot 100}{200} = 20$	$\frac{30 \cdot 100}{200} = 15$	$\frac{130 \cdot 100}{200} = 65$	100
Licht verhoogd	$\frac{40 \cdot 40}{200} = 8$	$\frac{30 \cdot 40}{200} = 6$	$\frac{130 \cdot 40}{200} = 26$	40
Ernstig verhoogd	$\frac{40 \cdot 60}{200} = 12$	$\frac{30 \cdot 60}{200} = 9$	$\frac{130 \cdot 60}{200} = 39$	60
Totaal	40	30	130	200

De chikwadraat-toetsingsgrootheid X^2 bepalen we aan de hand van de volgende formule:

$$X^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

waarbij $i = 1, 2, 3$ de index van de rij is, en $j = 1, 2, 3$ de index van de kolom is. Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootheid

$$\begin{aligned}
 \chi^2 &= \sum_{i,j} \frac{(o_{ij} - e_{ij})^2}{e_{ij}} \\
 &= \frac{(o_{11} - e_{11})^2}{e_{11}} + \frac{(o_{12} - e_{12})^2}{e_{12}} + \dots + \frac{(o_{33} - e_{33})^2}{e_{33}} \\
 &= \frac{(6 - 20)^2}{20} + \frac{(8 - 15)^2}{15} + \dots + \frac{(22 - 39)^2}{39} \\
 &\approx 43.8214.
 \end{aligned}$$


Onder de nulhypothese volgt de toetsingsgrootheid X een chikwadraatverdeling met

$$\text{df} = (\# \text{rijen} - 1) \cdot (\# \text{kolommen} - 1) = (3 - 1) \cdot (3 - 1) = 4$$

vrijheidsgraden. De p -waarde (rechteroverschrijdingskans) die hoort bij deze geobserveerde toetsingsgrootheid χ^2 is gelijk aan

$$\begin{aligned}
 p &= P(X^2 \geq \chi^2) \\
 &= \chi^2 \text{cdf}(\text{lower} = \chi^2 \approx 43.8214, \text{upper} = 10^{99}, \text{df} = 4) \\
 &\approx 6.9879 \cdot 10^{-9}.
 \end{aligned}$$

Aangezien de p -waarde extreem klein is, betekent dit dat de geobserveerde toetsingsgrootheid χ^2 extreem hoge waarde heeft onder de aanname van onafhankelijkheid. Omdat de p -waarde veel kleiner is dan het significantieniveau $\alpha = 0.01$, wordt H_0 verworpen. Er is voldoende bewijs om aan te nemen dat de twee nominale variabelen “rookgedrag” en “bloeddrukniveau” afhankelijk zijn van elkaar.



Noot: de toetsuitslag van het verwerpen van H_0 laat niet zien hoe deze afhankelijkheid eruit ziet. Als je de ruwe data bekijkt, zie je echter dat onder de niet-rokers een groot deel gewoon een normale bloeddruk heeft, terwijl voor stevige rokers de meeste juist een ernstig verhoogde bloeddruk hebben. Een analyse van de data is dus nodig om te bekijken wat de daadwerkelijke samenhang is tussen de variabelen.

Opdracht 10.11: In een ziekenhuis worden dagelijks vijf orthopedische operaties uitgevoerd. Bekend is dat deze in 20 % van de gevallen leiden tot complicaties waardoor de patiënt enige tijd moet verblijven op de afdeling intensive care. Voor een periode van 100 dagen leidde dit tot de volgende aantallen verwijzingen naar de afdeling intensive care:

Aantal per dag (k)	Aantal dagen met k verwijzingen
0	15
1	25
2	36
3	12
4	10
5	2
Totaal	100 dagen

Toets met $\alpha = 0.05$ of de waargenomen verdeling overeenstemt met een binomiale verdeling met $p = 0.20$.

Uitwerking

We hebben steekproefdata verzameld met geobserveerde frequenties van uitkomsten van een categorische variabele (dus discreet) X . Deze kansvariabele X (aantal verwijzingen naar de IC op een willekeurige dag) heeft een bepaalde kansverdeling, maar we weten niet precies hoe deze eruit ziet.

We willen toetsen of X binomiaal verdeeld is met succeskans $n = 5$ en $p = 0.20$ (er geldt niet dat $n \neq 100$, maar wel dat we 100 trekkingen doen voor deze kansvariabele en turven hoe vaak iedere uitkomst voorkomt). Hiertoe voeren we een chikwadraat-aanpassingstoets uit (“goodness-of-fit test”). Allereerst definiëren we de nulhypothese H_0 en de alternatieve hypothese H_1 .

H_0 : de kansvariabele X is binomiaal verdeeld met parameters $n = 5$ en $p = 0.20$.

H_1 : de kansvariabele X volgt een andere kansverdeling.

Merk op dat in het geval dat H_0 verworpen wordt, dit niet betekent dat X niet binomiaal verdeeld is. Dat kan nog steeds, maar dan met een andere succeskans p . Het significantieniveau $\alpha = 0.05$ is gegeven in de opdracht, net als de geobserveerde frequenties. Om de toetsingsgrootheid X^2 te kunnen bepalen, moeten we eerst de *expected*-tabel berekenen. Hiervoor gebruiken we de nulhypothese H_0 dat X binomiaal verdeeld is met parameters $n = 5$ en $p = 0.20$. Omdat we 100 trekkingen van X bekijken, kunnen we de verwachte frequenties van uitkomst k uitrekenen als $100 \cdot P(X = k)$.

Aantal per dag (k)	Observed	Expected
0	15	$100 \cdot \text{binompdf}(n = 5, p = 0.20, k = 0) = 32.768$.
1	25	$100 \cdot \text{binompdf}(n = 5, p = 0.20, k = 1) = 40.96$.
2	36	$100 \cdot \text{binompdf}(n = 5, p = 0.20, k = 2) = 20.48$.
3	12	$100 \cdot \text{binompdf}(n = 5, p = 0.20, k = 3) = 5.12$.
4	10	$100 \cdot \text{binompdf}(n = 5, p = 0.20, k = 4) = 0.64$.
5	2	$100 - 32.768 - 40.96 - \dots - 0.64 = 0.032$.
Totaal	100 dagen	100 dagen

De toetsingsgrootheid X^2 bepalen we aan de hand van de volgende formule:

$$X^2 = \sum_{i=0}^5 \frac{(O_i - E_i)^2}{E_i},$$

waarbij $i = 0, 1, 2, 3, 4, 5$ een mogelijke uitkomst is. Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootheid

$$\begin{aligned} \chi^2 &= \frac{(o_0 - e_0)^2}{e_0} + \frac{(o_1 - e_1)^2}{e_1} + \dots + \frac{(o_5 - e_5)^2}{e_5} \\ &= \frac{(15 - 32.768)^2}{32.768} + \frac{(25 - 40.96)^2}{40.96} + \dots + \frac{(2 - 0.032)^2}{0.032} \\ &\approx 294.7815 \end{aligned}$$


Onder de nulhypothese volgt de toetsingsgrootte X een chikwadraatverdeling met

$$df = (\#rijen - 1) = 4 - 1 = 3$$

vrijheidsgraden. De p -waarde (rechteroverschrijdingskans) die hoort bij deze geobserveerde toetsingsgrootte χ^2 is gelijk aan

$$p = P(\chi^2 > 294.7815) = \chi^2\text{cdf}(\text{lower} = 294.7815, \text{upper} = 10^{99}, df = 3) \\ \approx 1.34 \cdot 10^{-63}.$$

Aangezien de p -waarde extreem klein is, betekent dit dat de geobserveerde toetsingsgrootte χ^2 een extreem hoge waarde heeft onder de aanname van een binomiale verdeling met $n = 5$ en $p = 0.20$. Omdat de p -waarde veel kleiner is dan het significantieniveau $\alpha = 0.01$, wordt H_0 verworpen. Er is voldoende bewijs om aan te nemen dat het aantal verwijzingen naar de afdeling intensive care niet binomiaal verdeeld is met parameters $n = 5$ en $p = 0.20$.



Noot: eigenlijk moet je nog doordenken over wat de toetsuitslag betekent. Merk op dat volgens de metingen het totaal aantal doorverwijzingen in 100 dagen gelijk is aan

$$0 \cdot 15 + 1 \cdot 25 + 2 \cdot 36 + 3 \cdot 12 + 4 \cdot 10 + 5 \cdot 2 = 183$$

Aangezien er elke dag 5 operaties plaatsvinden, is het totaal aantal operaties gelijk aan 500. Dit betekent dat de fractie doorverwezen patiënten gelijk is aan $\frac{183}{500} = 0.366$. Deze fractie is veel groter dan $p = 0.20$, dus misschien is het niet zo realistisch om te verwachten dat de nulhypothese gaat kloppen. Een analyse van de ruwe data is dus nodig om te bekijken wat de daadwerkelijke samenhang is tussen de variabelen.

Het kan nog steeds dat de data uit een binomiale verdeling komen, maar dan moet de waarde van de succeskans p anders zijn!

Opdracht 10.12: Soms wil men voor een getrokken steekproef beoordelen of die als representatief mag worden beschouwd met betrekking tot een bepaald kenmerk of een bepaalde variabele. Met de chikwadraattoets voor aanpassing kan worden getoetst of de waargenomen verdeling in dit opzicht voldoende gelijkenis vertoont met de populatieopbouw. Bij een opinieonderzoek over de toekomst van Europa worden 480 kiesgerechtigde Nederlanders ondervraagd. Van alle ondervraagden is het opleidingsniveau genoteerd. In de volgende tabel wordt dit opleidingsniveau vergeleken met de totale Nederlandse bevolking:

	Laag	Matig	Redelijk	Hoog	Totaal
Steekproef	134	144	129	73	480
Populatie	28 %	36 %	24 %	12 %	100 %

Toets met $\alpha = 0.05$ of de steekproef als representatief mag worden beschouwd.

Uitwerking

We willen in deze opgave toetsen of de getrokken steekproef representatief is of niet. Om die reden voeren we een chikwadraat-aanpassingstoets uit op basis van de gegeven populatieverdeling van opleidingsniveaus.

Allereerst definiëren we de hypothesen van deze toets:

H_0 : de gekozen steekproef is representatief voor de populatie, oftewel de steekproef bestaat uit personen met opleidingsniveaus naar rato van de gehele Nederlandse populatie.

H_1 : de gekozen steekproef is NIET representatief voor de populatie.

Verder is het significantieniveau $\alpha = 0.05$ en de steekproefdata (zie tabel) gegeven. Om te toetsen of de geobserveerde steekproefdata overeenkomen met de populatieverdeling, moeten we de verwachte frequenties berekenen. Dit kunnen we doen door de populatiepercentages om te rekenen naar frequenties gegeven dat de steekproef in totaal uit 480 personen bestaat:

Opleidingsniveau	Steekproeffrequenties (observed)	Verwachte frequenties (expected)
Laag	134	$28\% \cdot 480 = 134.4$
Matig	144	$36\% \cdot 480 = 172.8$
Redelijk	129	$24\% \cdot 480 = 115.2$
Hoog	73	$12\% \cdot 480 = 57.6$
Totaal	480	480

De verwachte frequenties zijn allemaal groter dan of gelijk aan 5, dus kunnen we de toetsingsgrootte direct berekenen. Merk op dat we de chikwadraatverdeling enkel

konden gebruiken zodra de verwachte frequenties allemaal minstens 5 zijn. De toetsingsgrootte χ^2 bepalen we aan de hand van de volgende formule:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i},$$

waarbij $i = 1, 2, 3, 4$ de index van de kolom is. Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootte

$$\begin{aligned} \chi^2 &= \sum_i \frac{(o_i - e_i)^2}{e_i} = \frac{(o_1 - e_1)^2}{e_1} + \frac{(o_2 - e_2)^2}{e_2} + \frac{(o_3 - e_3)^2}{e_3} + \frac{(o_4 - e_4)^2}{e_4} \\ &= \frac{(134 - 134.4)^2}{134.4} + \frac{(144 - 172.8)^2}{172.8} + \frac{(129 - 115.2)^2}{115.2} + \frac{(73 - 57.6)^2}{57.6} \\ &\approx 10.5717. \end{aligned}$$

Onder de nulhypothese volgt de toetsingsgrootte χ^2 een chikwadraatverdeling met

$$df = (\# \text{categorieën} - 1) = 4 - 1 = 3$$

vrijheidsgraden. Extreem grote waarde van de toetsingsgrootte duiden op grote verschillen tussen observed en expected frequenties, dus het kritieke gebied is van de vorm $[g, \infty)$. Deze grenswaarde g is de oplossing van de vergelijking


$$\chi^2 \text{cdf}(\text{lower} = g, \text{upper} = 10^{99}, df = 3) = \alpha = 0.05$$

Deze grenswaarde berekenen we als volgt met behulp van de “numerieke solver”:

$$E_1 = \chi^2 \text{cdf}(\text{lower} = X, \text{upper} = 10^{99}, df = 3)$$

$$E_2 = 0.05.$$


Dit geeft een oplossing $g \approx 7.8147$. Aangezien de toetsingsgrootte χ^2 groter dan deze grenswaarde is ($10.5717 > 7.8147$), geldt dat de toetsingsgrootte in het kritieke gebied ligt en dus H_0 wordt verworpen. Er is voldoende bewijs om aan te nemen dat de steekproef niet representatief is voor de populatie kiesgerechtigde Nederlanders.



Alternatief: de p -waarde (rechteroverschrijdingskans) die hoort bij deze geobserveerde toetsingsgrootte χ^2 is gelijk aan

$$\begin{aligned} p &= P(X^2 \geq \chi^2) \\ &= \chi^2 \text{cdf}(\text{lower} = \chi^2 \approx 10.5717, \text{upper} = 10^{99}, \text{df} = 3) \\ &\approx 0.0143. \end{aligned}$$

Aangezien de p -waarde kleiner is dan het significantieniveau α , betekent dit dat de geobserveerde toetsingsgrootte χ^2 een extreem hoge waarde heeft onder de aanname dat de steekproef representatief zou zijn voor de populatie. Dit betekent dat de nulhypothese H_0 wordt verworpen. Er is voldoende bewijs om aan te nemen dat de steekproef niet representatief is voor de populatie kiesgerechtigde Nederlanders.



Noot: eigenlijk moet je nog doordenken over wat de toetsuitslag betekent. Merk op dat volgens de metingen het aantal respondenten met redelijk en hoog opleidingsniveau (veel) groter is dan verwacht, terwijl dit voor mensen met een matig opleidingsniveau een stuk lager dan verwacht is. Dit kan erop duiden dat mensen met een hoger opleidingsniveau eerder geneigd zijn om deel te nemen aan een dergelijk opinieonderzoek en dat er een bias in de antwoorden van het onderzoek zit doordat de steekproef niet representatief is.

Opdracht 10.13: Het aantal brandmeldingen dat in een stad per week is geregistreerd gedurende een periode van 100 weken blijkt uit de tabel. Toets of het aantal branden per week is te beschouwen als een kansvariabele die een Poissonverdeling volgt met $\mu = 1$ (kies $\alpha = 0.05$).

Aantal branden per week	Frequentie
0	48
1	24
2	16
3	8
4 of meer	4
Totaal	100 weken

Uitwerking

Omdat we willen kijken of de gegeven data overeenkomen met een specifieke discrete kansverdeling, in dit geval de Poissonverdeling met $\mu = 1$, kunnen we een chikwaadraattoets voor aanpassing (“goodness-of-fit test”) uitvoeren. Laat X een kansvariabele zijn die het aantal branden telt in een willekeurige week. Verder is gegeven dat over een periode van 100 weken het aantal branden is geteld. Allereerst definiëren we de nulhypothese H_0 en de alternatieve hypothese H_1 .

H_0 : de kansvariabele X is Poisson verdeeld met gemiddelde $\mu = 1$.

H_1 : de kansvariabele X volgt een andere kansverdeling (Dit kan nog steeds een Poissonverdeling zijn, maar met een andere gemiddelde).

Het significantieniveau $\alpha = 0.05$ is gegeven in de opdracht, net als de geobserveerde data. Om de toetsingsgrootheid X^2 te kunnen bepalen, moeten we eerst de *expected*-tabel berekenen. Als we aannemen dat de nulhypothese H_0 waar is, dan geldt dat X Poisson verdeeld is met $\mu = 1$. Verder is gegeven dat we 100 afzonderlijke weken bekijken, dus we kunnen deze verwachte frequenties uitrekenen:

Aantal branden per week	Frequentie (observed)	Frequentie (expected)
0	48	$100 \cdot \text{poissonpdf}(\mu = 1, k = 0) = 36.7879$
1	24	$100 \cdot \text{poissonpdf}(\mu = 1, k = 1) = 36.7879$
2	16	$100 \cdot \text{poissonpdf}(\mu = 1, k = 2) = 18.3940$
3	8	$100 \cdot \text{poissonpdf}(\mu = 1, k = 3) = 6.1313$
4 of meer	4	$100 - 36.7879 - 36.7879 - \dots = 1.8988$
Totaal	100 dagen	100 dagen

De toetsingsgrootheid X^2 bepalen we aan de hand van de volgende formule:

$$X^2 = \sum_i \frac{(O_i - E_i)^2}{E_i},$$

waarbij $i = 0, 1, 2, 3, \geq 4$ een mogelijke uitkomst is.

Dit geeft in dit specifieke geval een geobserveerde toetsingsgrootheid

$$\begin{aligned} \chi^2 &= \sum_i \frac{(o_i - e_i)^2}{e_i} \\ &= \frac{(o_0 - e_0)^2}{e_0} + \frac{(o_1 - e_1)^2}{e_1} + \frac{(o_2 - e_2)^2}{e_2} + \frac{(o_3 - e_3)^2}{e_3} + \frac{(o_{\geq 4} - e_{\geq 4})^2}{e_{\geq 4}} \\ &= \frac{(48 - 36.7879)^2}{36.7879} + \frac{(24 - 36.7879)^2}{36.7879} + \frac{(16 - 18.394)^2}{18.394} + \frac{(8 - 6.1313)^2}{6.1313} + \frac{(4 - 1.8988)^2}{1.8988} \\ &\approx 11.0686 \end{aligned}$$

Onder de nulhypothese volgt de toetsingsgrootheid X een chikwadraatverdeling met

$$\text{df} = \# \text{categorien} - 1 = 4 - 1 = 3$$

vrijheidsgraden.

Merk op dat hoe groter de verschillen tussen observed en expected frequenties, hoe groter de waarde van de geobserveerde toetsingsgrootheid χ^2 . Met andere woorden, het kritieke gebied is van de vorm $[g, \infty)$. Deze grenswaarde g is de oplossing van de vergelijking


$$\chi^2 \text{cdf}(\text{lower} = g, \text{upper} = 10^{99}, \text{df} = 3) = \alpha = 0.05$$

Deze vergelijking kun je op de grafische rekenmachine invoeren in het “solver”-menu:

$$E_1 = \chi^2 \text{cdf}(\text{lower} = X, \text{upper} = 10^{99}, \text{df} = 3)$$

$$E_2 = 0.05.$$


krijgen we een waarde van $g \approx 7.8147$. Het kritieke gebied is dus $[7.8147, \infty)$. De geobserveerde toetsingsgrootheid $\chi^2 \approx 11.0686$ ligt daarmee in het kritieke gebied en dus wordt H_0 verworpen. Er is voldoende bewijs om aan te nemen dat het aantal branden per week niet een Poissonverdeling met gemiddelde $\mu = 1$ volgt.



Alternatief: de p -waarde (rechteroverschrijdingskans) die hoort bij deze geobserveerde toetsingsgrootte χ^2 is gelijk aan

$$\begin{aligned}
 p &= P(X^2 \geq \chi^2) \\
 &= \chi^2 \text{cdf}(\text{lower} = \chi^2 \approx 11.0686, \text{upper} = 10^{99}, \text{df} = 3) \\
 &\approx 0.0258
 \end{aligned}$$

Aangezien de p -waarde kleiner is dan het significantieniveau α , betekent dit dat de geobserveerde toetsingsgrootte χ^2 een extreem hoge waarde heeft onder de aanname van een Poissonverdeling met $\mu = 1$. Dit betekent dat op basis van deze steekproef de nulhypothese H_0 wordt verworpen. Er is voldoende bewijs om aan te nemen dat het aantal branden per week niet een Poissonverdeling met gemiddelde $\mu = 1$ volgt.



Week **11****Verschiltoetsen****Hoofdstuk 11**

Opdracht 11.m1: Voor een tweetal normale verdelingen is gegeven dat hun standaarddeviaties respectievelijk $\sigma_1 = 4$ en $\sigma_2 = 6$ bedragen. Men wil toetsen $H_0 : \mu_1 = \mu_2$. Een steekproef van negen waarnemingen uit de eerste verdeling leverde een gemiddelde uitkomst op van 48, en een steekproef van zestien waarnemingen uit de tweede verdeling leverde een gemiddelde op van 42. De toetsingsgrootte bij deze toets levert een z -waarde op van ...

- (a) 6.
- (b) 2.99.
- (c) 6.63.
- (d) 2.67.

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen:

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_1 = ?$ en standaardafwijking $\sigma_1 = 4$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_2 = ?$ en standaardafwijking $\sigma_2 = 6$.

Aangezien we steekproeven hebben van respectievelijke groottes $n = 9$ en $m = 16$, geldt voor de (theoretische) steekproefgemiddeldes:

- Het steekproefgemiddelde $\bar{X}$ is normaal verdeeld met verwachtingswaarde $\mu_1 = ?$ en standaardafwijking $\sigma_1/\sqrt{n} = 4/\sqrt{9} = 4/3$.

- Het steekproefgemiddelde $\bar{Y}$ is normaal verdeeld met verwachtingswaarde $\mu_2 = ?$ en standaardafwijking $\sigma_2/\sqrt{m} = 6/\sqrt{16} = 3/2$.

De verschilvariabele $V = \bar{X} - \bar{Y}$ is dan normaal verdeeld met verwachtingswaarde $\mu_V = \mu_1 - \mu_2$ en standaardafwijking $\sigma_V = \sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}$. Onder aanname van de nulhypothese H_0 nemen we aan dat $\mu_1 = \mu_2$, oftewel dat $\mu_V = \mu_1 - \mu_2 = 0$. Omdat de standaardafwijkingen σ_1 en σ_2 bekend zijn, is de toetsingsgrootte gelijk aan

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$$

De z -score (oftewel de geobserveerde toetsingsgrootte z) die hoort bij deze uitkomst is gelijk aan

$$\begin{aligned} z &= \frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}} \\ &= \frac{(48 - 42) - 0}{\sqrt{\frac{16}{9} + \frac{9}{4}}} \\ &\approx 2.99. \end{aligned}$$

Het juiste antwoord is dus (b).

Opdracht 11.m3: Voor twee populaties mag worden verondersteld dat deze allebei een normale verdeling volgen en dezelfde onbekende variantie hebben. Men wil toetsen of deze populaties hetzelfde gemiddelde hebben. Daartoe neemt men uit beide populaties een steekproef van tien waarnemingen. Bij de toets is het aantal vrijheidsgraden van de toetsingsgrootte gelijk aan ...

- (a) 9.
- (b) 18.
- (c) 19.
- (d) – (er is bij deze toetsingsgrootte geen sprake van vrijheidsgraden).

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen:

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Er wordt verondersteld dat beide kansvariabelen dezelfde onbekende variantie hebben, oftewel $\sigma = \sigma_X = \sigma_Y$. In dat geval mogen de twee steekproefschattingen s_X en s_Y voor de standaardafwijking (op basis van steekproeven van grootte $n = m = 10$ respectievelijk) worden gecombineerd tot één schatter (de zogenaamde “pooled variance”).

De kansverdeling die de bijbehorende toetsingsgrootte T volgt is de t -verdeling met $df = n + m - 2 = 10 + 10 - 2 = 18$ vrijheidsgraden. Het juiste antwoord is dus (b).

Opdracht 11.m6: Voor een tweetal normale verdelingen willen we toetsen of ze dezelfde waarde van de variantie hebben. Voor de eerste variabele werd met een steekproef van twaalf waarnemingen de waarde $s^2 = 240$ gevonden. Bij de tweede variabele leverde de steekproef van tien waarnemingen de waarde $s^2 = 160$. De toetsingsgrootte krijgt hier dan de waarde ...

- (a) 80.
- (b) 1.50.
- (c) 4.
- (d) 1.25.

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Van deze twee kansvariabelen willen we toetsen of de varianties gelijk zijn, oftewel dat geldt $\sigma^2 = \sigma_X^2 = \sigma_Y^2$. Hiervoor moeten we een F -toets voor gelijke varianties uitvoeren met de volgende hypothesen:

H_0 : De varianties zijn gelijk, oftewel $\sigma_X^2 = \sigma_Y^2$.

H_1 : De varianties zijn niet gelijk, oftewel $\sigma_X^2 \neq \sigma_Y^2$.

Verder hebben we voor beide kansvariabelen twee steekproeven van respectievelijk grootte $n = 12$ en $m = 10$ getrokken om de varianties te schatten, met als resultaat $s_X^2 = 240$ en $s_Y^2 = 160$. De toetsingsgrootte F is gelijk aan

$$F = \frac{S_X^2}{S_Y^2},$$

oftewel de geobserveerde toetsingsgrootte is in dit geval gelijk aan

$$f = \frac{s_X^2}{s_Y^2} = \frac{240}{160} = 1.50.$$

Het juiste antwoord is dus (b).

Opdracht 11.1: Een instantie die toezicht houdt op de mate van luchtverontreiniging doet regelmatig metingen op diverse plaatsen in het land. De gemeten verontreiniging wordt uitgedrukt in een bepaalde index, die op alle werkdagen wordt bepaald. In 2018 werden enkele nieuwe richtlijnen voor de industrie afgekondigd met als doel het niveau van luchtverontreiniging te verlagen. Om het effect van deze maatregelen te bestuderen, werd een onderzoek gedaan. Hierbij werden 20 waarden (x_i) die bepaald zijn in februari 2017 vergeleken met 20 waarden (y_i) die zijn gemeten in februari 2018. Voor deze waarden werd berekend:

$$\bar{x} = 164.6 \text{ en } s_X = 17.2, \text{ en } \bar{y} = 143.2 \text{ en } s_Y = 15.9$$

Met een verschiltoets gaan we bepalen of er een significante verbetering is opgetreden.

Uitwerking

Laat X en Y de kansvariabelen zijn die het niveau van luchtverontreiniging meet op een willekeurige dag in respectievelijk februari 2017 en februari 2018. De steekproefgroottes zijn beide gelijk aan $n = m = 20$. Van deze kansvariabelen zijn zowel de verwachtingswaarden als de standaardafwijkingen onbekend. Merk op dat we niet weten of de varianties gelijk zijn, dus hiervoor moeten we eerst een F -toets uitvoeren.

F -toets voor gelijke varianties:

We gaan toetsen of de varianties van X en Y gelijk zijn. Hiervoor definiëren we allereerst de nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De populatievarianties zijn gelijk, oftewel $\sigma_X^2 = \sigma_Y^2$,

H_1 : De populatievarianties zijn niet gelijk, oftewel $\sigma_X^2 \neq \sigma_Y^2$.

We gaan uit van een significantieniveau $\alpha = 0.05$ en de bovenstaande steekproefgegevens. De toetsingsgrootte van de F -toets is gelijk aan

$$F = \frac{S_X^2}{S_Y^2}$$

en volgt de F -verdeling met respectievelijk $df_1 = n - 1 = 19$ en $df_2 = m - 1 = 19$ vrijheidsgraden. In dit geval hebben we een geobserveerde toetsingsgrootte van

$$f = \frac{s_X^2}{s_Y^2} = \frac{17.2}{15.9} \approx 1.0817.$$

Methode 1 (kritiek gebied):

Een F -toets is altijd tweezijdig, dus het kritieke gebied is van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$. De grenzen g_1 en g_2 kunnen worden bepaald aan de hand van de $F(19, 19)$ -

verdeling:

$$F_{cdf}(\text{lower} = 0, \text{upper} = g_1, df_1 = 19, df_2 = 19) = \alpha/2 = 0.025 \rightarrow g_1 \approx 0.3958,$$

$$F_{cdf}(\text{lower} = g_2, \text{upper} = 10^{99}, df_1 = 19, df_2 = 19) = \alpha/2 = 0.025 \rightarrow g_2 \approx 2.5265.$$

De geobserveerde toetsingsgrootheid $f \approx 1.0817$ ligt dus niet in het kritieke gebied $(-\infty, 0.3958)$ en $(2.5265, \infty)$, dus we besluiten om de nulhypothese H_0 niet te verwerpen. Er is op basis van deze steekproeven onvoldoende reden om aan te nemen dat de varianties niet gelijk zouden zijn aan elkaar.

Methode 2 (p -waarde):

Een F -toets is altijd tweezijdig, dus om de p -waarde te bepalen behorende bij de geobserveerde toetsingsgrootheid $f \approx 1.0817$ moeten we het minimum berekenen van $P(F \leq f)$ en $P(F \geq f)$.

$$P(F \leq f \approx 1.0817) = F_{cdf}(\text{lower} = 0, \text{upper} = 1.0817, df_1 = 19, df_2 = 19) \approx 0.5671.$$

$$P(F \geq f \approx 1.0817) = F_{cdf}(\text{lower} = 1.0817, \text{upper} = 10^{99}, df_1 = 19, df_2 = 19) \approx 0.4329.$$

De p -waarde is dus gelijk aan $p \approx 0.4329$. Omdat de p -waarde veel groter dan het significantieniveau $\alpha = 0.05$ is, besluiten we om de nulhypothese H_0 niet te verwerpen. Er is op basis van deze steekproeven onvoldoende reden om aan te nemen dat de varianties niet gelijk zouden zijn aan elkaar.

Onafhankelijke t -toets (gelijke variantie)

Om te bepalen of er een significante verbetering is opgetreden, moeten we kijken of de gemiddelde luchtverontreiniging is gedaald in 2018. We voeren hiervoor een hypothesetoets uit met de volgende nulhypothese H_0 en de alternatieve hypothese H_1 :

H_0 : Er is geen verbetering opgetreden, oftewel $\mu_X \leq \mu_Y$.

H_1 : Er is wel een verbetering opgetreden, oftewel $\mu_X > \mu_Y$.

Verder wordt er uitgegaan van een significantieniveau $\alpha = 0.05$. Op basis van de toetsuitslag van de F -toets mogen we aannemen dat de varianties gelijk zijn, oftewel $\sigma^2 = \sigma_X^2 = \sigma_Y^2$. In dit geval mogen we gebruik maken van de “pooled variance”:

$$s_P^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n-1+m-1} = \frac{19 \cdot 17.2^2 + 19 \cdot 15.9^2}{38} = 274.325.$$

Onder de nulhypothese H_0 nemen we aan dat $\mu_X = \mu_Y$ (extreem geval), waardoor de bijbehorende geobserveerde toetsingsgrootte gelijk is aan

$$\begin{aligned} t &= \frac{(\bar{x} - \bar{y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}}} \\ &= \frac{(164.6 - 143.2) - 0}{\sqrt{\frac{274.325}{20} + \frac{274.325}{20}}} \\ &\approx 4.0858. \end{aligned}$$

Merk op dat de theoretische toetsingsgrootte een t -verdeling volgt met $df = n - m + 2 = 38$ vrijheidsgraden.

Methode 1 (kritiek gebied):

Omdat we rechtszijdig toetsen, is het kritieke gebied van de vorm $[g, \infty)$, waarbij de grens g als volgt bepaald kan worden:

$$g = \text{InvT}(\text{area} = 1 - \alpha, df = n + m - 2) = \text{InvT}(\text{area} = 0.95, df = 38) \approx 1.6860.$$

De geobserveerde toetsingsgrootte $t \approx 4.0858$ is groter dan deze kritieke grens g , dus t ligt in het kritieke gebied. We verwerpen dus de nulhypothese H_0 . Er is voldoende reden om op basis van deze steekproef aan te nemen dat er daadwerkelijk een significante daling is gerealiseerd in de luchtverontreiniging in 2018.

Methode 2 (p -waarde):

Aangezien we rechtszijdig toetsen, berekenen we de p -waarde als de kans dat de toetsingsgrootte T een grotere waarde aanneemt dan $t \approx 4.0858$:

$$p = P(T \geq t \approx 4.0858) = \text{tcdf}(\text{lower} = 4.0858, \text{upper} = 10^9, df = 38) \approx 1.0936 \cdot 10^{-4}.$$

De p -waarde is extreem klein (veel kleiner dan het significantieniveau $\alpha = 0.05$), dus we besluiten om de nulhypothese te verwerpen. Er is voldoende reden om op basis van deze steekproef aan te nemen dat er daadwerkelijk een significante verbetering is gerealiseerd, oftewel dat de luchtverontreiniging in 2018 significant is verlaagd.

Opdracht 11.3: De variabele X is normaal verdeeld met onbekende μ en een variantie $\text{Var}(X) = 100$. Ook de variabele Y is normaal verdeeld met onbekende verwachtingswaarde. Er geldt $\text{Var}(Y) = 30$. Van de variabele X worden tien trekkingen gedaan. Die leveren als gemiddelde $\bar{x} = 50$. Er worden vijf trekkingen gedaan van de variabele Y die als gemiddelde opleveren $\bar{y} = 55$. Toets of beide variabelen dezelfde verwachtingswaarde kunnen hebben (kies $\alpha = 0.05$).

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = \sqrt{100} = 10$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = \sqrt{30}$.

Om te toetsen of de gemiddeldes van beide kansvariabelen gelijk zijn, gebruiken we de volgende nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De verwachtingswaarden zijn gelijk, oftewel $\mu_X = \mu_Y$.

H_1 : De verwachtingswaarden zijn niet gelijk, oftewel $\mu_X \neq \mu_Y$.

Verder zijn het significantieniveau $\alpha = 0.05$ en de steekproefgemiddeldes $\bar{x} = 50$ en $\bar{y} = 55$ gegeven. Omdat de standaardafwijkingen σ_X en σ_Y bekend zijn, is de toetsingsgrootte gelijk aan

$$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}}$$

Onder de nulhypothese geldt $\mu_X = \mu_Y$, oftewel de geobserveerde toetsingsgrootte z heeft een waarde van

$$\begin{aligned} z &= \frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \\ &= \frac{(50 - 55) - 0}{\sqrt{\frac{100}{10} + \frac{30}{5}}} \\ &= -1.25. \end{aligned}$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$, waarbij de grenzen bepaald kunnen worden aan de hand van de standaardnormale verdeling (normale verdeling met $\mu = 0$ en $\sigma = 1$):

$$g_1 = \text{InvNorm}(\text{area} = \alpha/2 = 0.025, \mu = 0, \sigma = 1) \approx -1.9600,$$

$$g_2 = \text{InvNorm}(\text{area} = 1 - \alpha/2 = 0.975, \mu = 0, \sigma = 1) \approx 1.9600.$$

De geobserveerde toetsingsgrootte $z = -1.25$ ligt niet in het kritieke gebied, dus we besluiten om de nulhypothese H_0 niet te verwerpen. Er is onvoldoende bewijs tegen de aanname van gelijke verwachtingswaarden van de twee variabelen.

Methode 2 (p -waarde):

De geobserveerde toetsingsgrootte is $z = -1.25$. Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(Z \leq z)$ en $P(Z \geq z)$ behorende bij de geobserveerde toetsingsgrootte $z = -1.25$ en vergelijken deze met $\alpha/2 = 0.025$.

$$P(Z \leq z = -1.25) = \text{normalcdf}(\text{lower} = -10^{99}, \text{upper} = -1.25, \mu = 0, \sigma = 1) = 0.1056.$$

$$P(Z \geq z = -1.25) = \text{normalcdf}(\text{lower} = -1.25, \text{upper} = 10^{99}, \mu = 0, \sigma = 1) = 0.8944.$$

De p -waarde is dus gelijk aan $p \approx 0.1056$. Aangezien de p -waarde groter is dan $\alpha/2$, besluiten we om de nulhypothese H_0 niet te verwerpen. Er is onvoldoende bewijs tegen de aanname van gelijke verwachtingswaarden van de twee variabelen.

Opdracht 11.5: Van werknemers in een bepaalde bedrijfstak wordt het verband tussen jaar-salaris en het bezit van een vakdiploma onderzocht. Groep 1 is een steekproef uit de populatie van werknemers met diploma, groep 2 is een steekproef van werknemers zonder diploma. De resultaten waren (jaarinkomens in duizenden euro's):

Groep 1	40	45	48	33	42	35	32	47	38	37	43
Groep 2	25	28	30	35	38	32	22				

Veronderstel dat beide inkomensverdelingen mogen worden beschouwd als normale verdelingen met dezelfde onbekende variantie. Toets of $\mu_X = \mu_Y$ (kies $\alpha = 0.05$).

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Om te toetsen of de gemiddeldes van beide kansvariabelen gelijk zijn, gebruiken we de volgende nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De verwachtingswaarden zijn gelijk, oftewel $\mu_X = \mu_Y$,

H_1 : De verwachtingswaarden zijn niet gelijk, oftewel $\mu_X \neq \mu_Y$.

Verder is het significantieniveau $\alpha = 0.05$ gegeven. In de tabel zijn data gegeven voor beide groepen. Hieruit volgt dat de steekproefgroottes gelijk zijn aan $n = 12$ voor groep 1 en $m = 7$ voor groep 2. We berekenen allereerst de steekproefgemiddeldes:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{40 + 45 + \dots + 43}{12} = 40,$$

$$\bar{y} = \frac{y_1 + y_2 + \dots + y_m}{m} = \frac{25 + 28 + \dots + 22}{7} = 30.$$

Met behulp van de steekproefgemiddeldes kunnen we nu de steekproefvarianties bepalen.

$$s_X^2 = \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{(40 - 40)^2 + \dots + (43 - 40)^2}{11} = 30.2,$$

$$s_Y^2 = \frac{(y_1 - \bar{y})^2 + \dots + (y_m - \bar{y})^2}{m - 1} = \frac{(25 - 30)^2 + \dots + (22 - 30)^2}{6} = 31.$$

Omdat we mogen uitgaan van gelijke varianties $\sigma^2 = \sigma_X^2 = \sigma_Y^2$, kunnen we de gezamenlijke variantie σ^2 schatten met behulp van de formule voor de “pooled variance”:

$$s_P^2 = \frac{(n - 1)s_X^2 + (m - 1)s_Y^2}{n - 1 + m - 1} = \frac{11 \cdot 30.2 + 6 \cdot 31}{17} = 30.4824.$$

De toetsingsgrootheid is gelijk aan

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{m} + \frac{s_P^2}{n}}}$$

en volgt onder aanname van de nulhypothese een t -verdeling met $df = n + m - 2 = 17$ vrijheidsgraden. Onder aanname van de nulhypothese geldt $\mu_X = \mu_Y$, oftewel $\mu_X - \mu_Y = 0$. De geobserveerde toetsingsgrootheid t kunnen we dus als volgt berekenen:

$$\begin{aligned} t &= \frac{(\bar{x} - \bar{y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}}} \\ &= \frac{(40 - 30) - 0}{\sqrt{\frac{30.4824}{12} + \frac{30.4824}{7}}} \\ &\approx 3.8084. \end{aligned}$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$, waarbij de grenzen bepaald kunnen worden aan de hand van de t -verdeling met $df = 17$ vrijheidsgraden:

$$g_1 = \text{InvT}(\text{area} = \alpha/2 = 0.025, df = 17) \approx -2.1098,$$

$$g_2 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, df = 17) \approx 2.1098.$$

De geobserveerde toetsingsgrootheid $t \approx 3.8084$ ligt dus in het kritieke gebied, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het gemiddelde jaarsalaris significant verschilt tussen beide groepen werknemers.

Methode 2 (p -waarde):

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(T \leq t)$

en $P(T \geq t)$ behorende bij de geobserveerde toetsingsgrootheid $t \approx 3.8084$ en vergelijken deze met $\alpha/2 = 0.025$.

$$P(T \leq t \approx 3.8084) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = 3.8084, \text{df} = 17) \approx 0.9999. P(T \geq t \approx 3.8084) = \text{tcdf}(3.8084, 10^{99}, \text{df} = 17) \approx 0.0001$$

De p -waarde is dus $p \approx 7.0254 \cdot 10^{-4}$. Aangezien de p -waarde (veel) kleiner is dan $\alpha/2$, besluiten we om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het gemiddelde jaarsalaris significant verschilt tussen beide groepen werknemers.

Opdracht 11.7: In een studie naar luchtvervuiling leverde een aselechte steekproef van acht luchtmonsters in de omgeving van een bepaalde fabriek gemiddeld 2.26 microgram van een schadelijke stof per m^3 , met een standaardafwijking van 0.56. In een grote stad leverde een steekproef van tien monsters een resultaat van 1.54 als gemiddelde en 0.42 als standaardafwijking. Ook in dit geval ging het om de hoeveelheid van dezelfde stof per m^3 . Onderzoek met $\alpha = 0.01$ of het gevonden verschil significant is. Hierbij mag men aannemen dat de steekproeven afkomstig waren uit twee normale verdelingen met dezelfde variantie.

Uitwerking

We hebben te maken met twee normaal verdeelde kansvariabelen die het aantal microgram schadelijke stof per m^3 meet, respectievelijk in de omgeving van een bepaalde fabriek en in een grote stad.

- De eerste kansvariabele is X : deze is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- De tweede kansvariabele is Y : deze is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Tevens is gegeven dat we mogen aannemen dat beide verdelingen dezelfde onbekende variantie hebben, oftewel $\sigma^2 = \sigma_X^2 = \sigma_Y^2$. Hierdoor is een F -toets niet meer noodzakelijk. Om te toetsen of de gemiddeldes van beide kansvariabelen gelijk zijn, gebruiken we de volgende nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De verwachtingswaarden zijn gelijk, oftewel $\mu_X = \mu_Y$ (geen significant verschil in luchtvervuiling tussen grote stad en omgeving van een fabriek)

H_1 : De verwachtingswaarden zijn niet gelijk, oftewel $\mu_X \neq \mu_Y$ (wel een significant verschil in luchtvervuiling tussen grote stad en omgeving van een fabriek).

Verder is het significantieniveau $\alpha = 0.01$ gegeven, en kunnen de steekproefdata uit de vraag kunnen als volgt worden samengevat:

$$\begin{array}{lll} \bar{x} = 2.26 & s_X = 0.56 & n = 8 \\ \bar{y} = 1.54 & s_Y = 0.42 & m = 10 \end{array}$$

Omdat we mogen uitgaan van gelijke varianties, kunnen we de gezamenlijke standaardafwijking σ schatten met behulp van de formule voor de “pooled variance”:

$$s_P^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n-1+m-1} = \frac{7 \cdot 0.56^2 + 9 \cdot 0.42^2}{16} \approx 0.2364.$$

De toetsingsgrootte voor deze hypothesetoets is gelijk aan

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{m} + \frac{s_P^2}{n}}}$$

en volgt onder aanname van de nulhypothese een t -verdeling met $df = n + m - 2 = 16$ vrijheidsgraden. Onder aanname van de nulhypothese geldt $\mu_1 = \mu_2$, oftewel $\mu_1 - \mu_2 = 0$. De bijbehorende geobserveerde toetsingsgrootte t berekenen we dan als volgt:

$$\begin{aligned} t &= \frac{(\bar{x} - \bar{y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}}} \\ &= \frac{(2.26 - 1.54) - 0}{\sqrt{\frac{0.2364}{8} + \frac{0.2364}{10}}} \\ &\approx 3.1217. \end{aligned}$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$, waarbij de grenzen g_1 en g_2 bepaald kunnen worden aan de hand van de t -verdeling met $df = 16$ vrijheidsgraden.

$$g_1 = \text{InvT}(\text{area} = \alpha/2 = 0.005, df = 16) \approx -2.9208,$$

$$g_2 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, df = 16) \approx 2.9208.$$

De geobserveerde toetsingsgrootte $t \approx 3.1217$ ligt dus in het kritieke gebied, dus besluiten we om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat de gemiddelde luchtvervuiling significant hoger is in de omgeving van de fabriek.

Methode 2 (p -waarde):

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(T \leq t)$ en $P(T \geq t)$ behorende bij de geobserveerde toetsingsgrootte $t \approx 3.1217$ en vergelijken deze met $\alpha/2 = 0.005$.

$$P(T \leq t \approx 3.1217) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = 3.1217, df = 16) \approx 0.9967.$$

$$P(T \geq t \approx 3.1217) = \text{tcdf}(\text{lower} = 3.1217, \text{upper} = 10^{99}, df = 16) \approx 0.0033.$$

De p -waarde is dus gelijk aan $p \approx 0.0033$. Aangezien de p -waarde kleiner is dan $\alpha/2$, besluiten we om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat de gemiddelde luchtvervuiling significant hoger is in de omgeving van de fabriek.

Opdracht 11.12: Een grootwinkelbedrijf verkoopt in alle filialen een bepaald afwasmiddel. In een week werd in zes filialen het volgende aantal flessen van dit afwasmiddel verkocht.

Filiaal	A	B	C	D	E	F
Aantal flessen	320	260	440	400	380	300

In de week nadat voorgaande gegevens werden verzameld, is een intensieve reclamecampagne gehouden voor het desbetreffende afwasmiddel. Volgend op deze reclamecampagne worden in tien filialen in één week de volgende aantallen flessen verkocht:

Filiaal	P	Q	R	S	T	U	V	W	X	Y
Aantal flessen	400	360	410	500	540	380	490	520	420	480

Toets of het gemiddelde aantal verkochte flessen voor en na de behandeling gelijk is ($\alpha = 0.05$). (Ga ervan uit dat de waargenomen aantallen mogen worden beschouwd als trekkingen uit normale verdelingen.)

Uitwerking

Laat X en Y de kansvariabelen zijn die het aantal verkochte flessen afwasmiddel telt respectievelijk vóór en na de intensieve reclamecampagne. We mogen ervan uitgaan dat deze aantallen trekkingen zijn uit normale verdelingen, oftewel

- X is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- Y is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Merk op dat we niet weten of de varianties gelijk zijn, dus hiervoor moeten we eerst een F -toets uitvoeren.

F -toets voor gelijke varianties:

We gaan toetsen of de varianties van X en Y gelijk zijn. Hiervoor definiëren we allereerst de nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De varianties zijn gelijk, oftewel $\sigma_X^2 = \sigma_Y^2$,

H_1 : De varianties zijn niet gelijk, oftewel $\sigma_X^2 \neq \sigma_Y^2$.

We gaan opnieuw uit van een significantieniveau $\alpha = 0.05$ en de steekproefgegevens in de bovenstaande tabellen. We berekenen allereerst de steekproefgemiddeldes:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{320 + 260 + \dots + 300}{6} = 350,$$

$$\bar{y} = \frac{y_1 + y_2 + \dots + y_m}{m} = \frac{400 + 360 + \dots + 480}{10} = 450.$$

Met behulp van de steekproefgemiddeldes kunnen we nu de steekproefvarianties bepalen.

$$s_X^2 = \frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{(320 - 350)^2 + \dots + (300 - 350)^2}{5} = 4600,$$

$$s_Y^2 = \frac{(y_1 - \bar{y})^2 + \dots + (y_m - \bar{y})^2}{m - 1} = \frac{(400 - 450)^2 + \dots + (480 - 450)^2}{9} = 4000.$$

De toetsingsgrootte van de F -toets is gelijk aan

$$F = \frac{S_X^2}{S_Y^2}$$

en volgt de F -verdeling met respectievelijk $df_1 = n - 1 = 5$ en $df_2 = m - 1 = 9$ vrijheidsgraden. In dit geval hebben we een geobserveerde toetsingsgrootte van

$$f = \frac{s_X^2}{s_Y^2} = \frac{4600}{4000} = 1.15.$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1)$ en (g_2, ∞) , waarbij de grenzen g_1 en g_2 bepaald kunnen worden aan de hand van de $F(5, 9)$ -verdeling.

$$\text{Fcdf}(\text{lower} = 0, \text{upper} = g_1, df_1 = 5, df_2 = 9) = \alpha/2 = 0.025 \rightarrow g_1 \approx 0.1497,$$

$$\text{Fcdf}(\text{lower} = g_2, \text{upper} = 10^{99}, df_1 = 5, df_2 = 9) = \alpha/2 = 0.025 \rightarrow g_2 \approx 4.4844.$$

De geobserveerde toetsingsgrootte $f = 1.15$ ligt dus niet in het kritieke gebied $(0, 0.1497)$ en $(4.4844, \infty)$, dus we besluiten om de nulhypothese H_0 niet te verwerpen. Er is op basis van deze steekproeven onvoldoende reden om aan te nemen dat de varianties niet gelijk zouden zijn aan elkaar.

Methode 2 (p -waarde):

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(F \leq f)$ en $P(F \geq f)$ behorende bij de geobserveerde toetsingsgrootte $f = 1.15$, en vergelijken deze met $\alpha/2 = 0.025$:

$$P(F \geq f) = \text{Fcdf}(\text{lower} = 0, \text{upper} = 1.15, df_1 = 5, df_2 = 9) \approx 0.5980.$$

$$P(F \leq f) = \text{Fcdf}(\text{lower} = 1.15, \text{upper} = 10^{99}, df_1 = 5, df_2 = 9) \approx 0.4020.$$

De p -waarde is groter dan het significantieniveau α , dus we besluiten om de nulhypothese H_0 niet te verwerpen. Er is op basis van deze steekproeven onvoldoende reden om aan te nemen dat de varianties niet gelijk zouden zijn aan elkaar.

Onafhankelijke t -toets (gelijke variantie)

Door het toetsresultaat van de F -toets mogen we uitgaande van gelijke varianties, oftewel $\sigma^2 = \sigma_X^2 = \sigma_Y^2$. We gaan toetsen of de gemiddeldes van X en Y gelijk zijn. Hiervoor definiëren we allereerst de nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : De verwachtingswaarden zijn gelijk, oftewel $\mu_X = \mu_Y$,

H_1 : De verwachtingswaarden zijn niet gelijk, oftewel $\mu_X \neq \mu_Y$.

Gegeven is het significantieniveau $\alpha = 0.05$ en de steekproefgegevens hierboven berekend:

$$\begin{aligned}\bar{x} &= 350 & s_X^2 &= 4600 & n &= 6 \\ \bar{y} &= 450 & s_Y^2 &= 4000 & m &= 10\end{aligned}$$

Omdat we mogen uitgaan van gelijke varianties, kunnen we de gezamenlijke variantie σ^2 schatten met behulp van de formule voor de “pooled variance”:

$$s_P^2 = \frac{(n-1)s_X^2 + (m-1)s_Y^2}{n-1+m-1} = \frac{6 \cdot 4600 + 10 \cdot 4000}{14} \approx 4828.5714.$$

De toetsingsgrootheid voor deze hypothesetoets is gelijk aan

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}}}$$

en volgt onder aanname van de nulhypothese een t -verdeling met $df = n + m - 2 = 14$ vrijheidsgraden. Onder aanname van de nulhypothese geldt $\mu_1 = \mu_2$, oftewel $\mu_1 - \mu_2 = 0$. De bijbehorende geobserveerde toetsingsgrootheid t berekenen we dan als volgt:

$$\begin{aligned}t &= \frac{(\bar{x} - \bar{y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{s_P^2}{n} + \frac{s_P^2}{m}}} \\ &= \frac{(350 - 450) - 0}{\sqrt{\frac{4828.5714}{6} + \frac{4828.5714}{10}}} \\ &\approx -2.7868.\end{aligned}$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1]$ en $[g_2, \infty)$, waarbij de grenzen g_1 en g_2 bepaald kunnen worden aan de hand van de t -verdeling met $df = 14$ vrijheidsgraden.

$$g_1 = \text{InvT}(\text{area} = \alpha/2 = 0.025, df = 14) \approx -2.1448,$$

$$g_2 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, df = 14) \approx 2.1448.$$

De geobserveerde toetsingsgrootheid $t \approx -2.7868$ ligt dus wel in het kritieke gebied $(-\infty, -2.1448)$ en $(2.1448, \infty)$, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het aantal verkochte flessen afwasmiddel significant hoger is na de intensieve reclamecampagne.

Methode 2 (p -waarde):

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(T \leq$

t) en $P(T \geq t)$ behorende bij de geobserveerde toetsingsgrootheid $t \approx -2.7868$, en vergelijken deze met $\alpha/2 = 0.025$.

$$P(T \leq t \approx -2.7868) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = -2.7868, \text{df} = 14) \approx 0.0073.$$

$$P(T \geq t \approx -2.7868) = \text{tcdf}(\text{lower} = 2.7868, \text{upper} = 10^{99}, \text{df} = 14) \approx 0.9927.$$

De p -waarde is dus gelijk aan $p \approx 0.0073$. Aangezien de p -waarde kleiner is dan $\alpha/2$, besluiten we om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het aantal verkochte flessen afwasmiddel significant hoger is na de intensieve reclamecampagne.

Opdracht 11.13: In zes filialen van een supermarktketen is het aantal verkochte flessen van een wasmiddel vlak voor en vlak na een reclamecampagne geregistreerd. De resultaten waren:

Filiaal	A	B	C	D	E	F
Aantal voor	320	260	440	400	380	310
Aantal na	420	380	520	490	490	400

Toets of er een opvallend verschil is in de omzet per filiaal voor en na de campagne ($\alpha = 0.05$). Voer de toets op twee manieren uit en geef aan van welke veronderstellingen men is uitgegaan bij de toetsen (vergelijk opgave 11.12).

Uitwerking

Laat X en Y de kansvariabelen zijn die het aantal verkochte flessen wasmiddel telt respectievelijk vóór en na de reclamecampagne.

- X is normaal verdeeld met verwachtingswaarde $\mu_X = ?$ en standaardafwijking $\sigma_X = ?$.
- Y is normaal verdeeld met verwachtingswaarde $\mu_Y = ?$ en standaardafwijking $\sigma_Y = ?$.

Optie 1: gepaarde waarnemingen We kunnen ervan uit dat deze aantallen *gepaard* zijn, dus we kunnen de verschillen paarsgewijs bepalen! Hierdoor kunnen we de gepaarde uitkomsten samennemen tot een nieuwe variabele gebaseerd op het verschil:

Filiaal	A	B	C	D	E	F
Aantal voor (x)	320	260	440	400	380	310
Aantal na (y)	420	380	520	490	490	400
Verskil ($v = y - x$)	100	120	80	90	110	90

Om te toetsen of er een opvallend verschil is tussen vóór en na de campagne, gaan we een standaard t -toets uitvoeren voor het gemiddelde μ_V van de verschilvariabele. Hiervoor definiëren we allereerst de nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : Het gemiddelde verschil is gelijk aan 0, oftewel $\mu_V = 0$,

H_1 : Het gemiddelde verschil is niet gelijk aan 0, oftewel $\mu_V \neq 0$.

Gegeven is het significantieniveau $\alpha = 0.05$ en de steekproefgegevens in bovenstaande tabel. Het steekproefgemiddelde van de verschillen is gelijk aan

$$\bar{v} = \frac{v_1 + v_2 + \dots + v_6}{6} = \frac{100 + 120 + \dots + 90}{6} \approx 98.3333.$$

De steekproefvariantie s_V^2 berekenen we als volgt:

$$s_V^2 = \frac{(v_1 - \bar{v})^2 + \dots + (v_n - \bar{v})^2}{n - 1} = \frac{(100 - 98.3333)^2 + \dots + (90 - 98.3333)^2}{5} = 216.6667.$$

Neem aan dat V normaal verdeeld is $\mu_V = 0$ en met onbekende standaardafwijking σ_V . De toetsingsgrootte is gelijk aan

$$T = \frac{\bar{V} - \mu_V}{S_V / \sqrt{n}}$$

en volgt onder aanname van de nulhypothese H_0 een t -verdeling met $df = n - 1$ vrijheidsgraden. De geobserveerde toetsingsgrootte is gelijk aan

$$t = \frac{\bar{v} - \mu_V}{s_V / \sqrt{n}} = \frac{98.3333 - 0}{\sqrt{216.6667} / \sqrt{6}} \approx 16.3636.$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1)$ en (g_2, ∞) , waarbij de grenzen g_1 en g_2 bepaald kunnen worden aan de hand van de t -verdeling met $df = 5$ vrijheidsgraden:

$$g_1 = \text{InvT}(\text{area} = \alpha/2 = 0.025, df = 5) \approx -2.5706,$$

$$g_2 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, df = 5) \approx 2.5706.$$

De geobserveerde toetsingsgrootte $t \approx 16.3636$ ligt dus (ruim) in het kritieke gebied, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het aantal verkochte flessen afwasmiddel significant verschilt tussen vóór en na de reclamecampagne.

Methode 2 (p -waarde): Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(T \leq t)$ en $P(T \geq t)$ behorende bij de geobserveerde toetsingsgrootte $t \approx 16.3636$, en vergelijken deze met $\alpha/2 = 0.025$.

$$P(T \leq t \approx 16.3636) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = 6.6804, df = 5) \approx 0.999992.$$

$$P(T \geq t \approx 16.3636) = \text{tcdf}(\text{lower} = 6.6804, \text{upper} = 10^{99}, df = 5) \approx 7.7742 \cdot 10^{-6}.$$

De p -waarde is dus gelijk aan $p \approx 7.7742 \cdot 10^{-6}$. Aangezien de p -waarde (veel) kleiner is dan $\alpha/2$, dus we verwerpen de nulhypothese H_0 . Er is op basis van deze steekproeven voldoende reden om aan te nemen dat het aantal verkochte flessen afwasmiddel significant verschilt tussen vóór en na de reclamecampagne.

Opdracht 11.14: Een onderzoeker merkt naar aanleiding van de aanpak bij opgave 11.13 op dat het misschien beter is om per filiaal eerst de procentuele omzetsijging te berekenen. Voer op basis van deze uitkomsten nogmaals een t -toets uit. (Kies $\alpha = 0.05$.)

Uitwerking

Hierdoor kunnen we de gepaarde uitkomsten samennemen tot een nieuwe variabele gebaseerd op het verschil:

Filiaal	A	B	C	D	E	F
Aantal voor (x)	320	260	440	400	380	310
Aantal na (y)	420	380	520	490	490	400
Vershil ($v = y - x$)	100	120	80	90	110	90
Vershil % ($pv = \frac{v}{x} \cdot 100\%$)	31.25	46.1538	18.1818	22.5	28.9474	29.0323

We gaan toetsen of het gemiddelde van de procentuele verandering PV gelijk is aan 0, omdat dit zou duiden op $\mu_X = \mu_Y$. Hiervoor definiëren we allereerst de nulhypothese H_0 en alternatieve hypothese H_1 :

H_0 : Er is geen significante procentuele verandering, oftewel $\mu_{PV} = 0$.

H_1 : Er is wel een significante procentuele verandering, oftewel $\mu_{PV} \neq 0$.

Gegeven is het significantieniveau $\alpha = 0.05$ en de steekproefgegevens in bovenstaande tabel. Het steekproefgemiddelde van de verschillen is gelijk aan

$$\bar{pv} = \frac{pv_1 + pv_2 + \dots + pv_6}{6} = \frac{31.25 + 46.1538 + \dots + 29.0323}{6} \approx 29.3442.$$

De steekproefvariantie s_{PV}^2 berekenen we als volgt:

$$\begin{aligned} s_{PV}^2 &= \frac{(pv_1 - \bar{pv})^2 + \dots + (pv_n - \bar{pv})^2}{n - 1} \\ &= \frac{(31.25 - 29.3442)^2 + \dots + (29.0323 - 29.3442)^2}{5} \\ &\approx 91.5786. \end{aligned}$$

Neem opnieuw aan dat PV normaal verdeeld is $\mu_{PV} = 0$ en met onbekende standaardafwijking σ_{PV} . De toetsingsgrootte is gelijk aan

$$T = \frac{\bar{PV} - \mu_{PV}}{S_{PV}/\sqrt{n}}.$$

en volgt onder aanname van de nulhypothese H_0 een t -verdeling met $df = n - 1 = 5$ vrijheidsgraden. De geobserveerde toetsingsgrootte van deze toets is gelijk aan

$$t = \frac{\bar{p}_V - \mu_{pV}}{s_{pV}/\sqrt{n}} = \frac{29.3442 - 0}{\sqrt{91.5786}/\sqrt{6}} \approx 7.5111.$$

Methode 1 (kritiek gebied):

Omdat we tweezijdig toetsen, is het kritieke gebied van de vorm $(-\infty, g_1)$ en (g_2, ∞) , waarbij de grenzen g_1 en g_2 bepaald kunnen worden aan de hand van de t -verdeling met $df = 5$ vrijheidsgraden.

$$g_1 = \text{InvT}(\text{area} = \alpha/2 = 0.025, df = 5) \approx -2.5706,$$

$$g_2 = \text{InvT}(\text{area} = 1 - \alpha/2 = 0.975, df = 5) \approx 2.5706.$$

De geobserveerde toetsingsgrootte $t \approx 7.5111$ ligt dus in het kritieke gebied, dus we besluiten om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat er een significante procentuele verandering is in het aantal verkochte flessen afwasmiddel, specifiek een significante stijging.

Methode 2 (p -waarde):

Omdat we tweezijdig toetsen, berekenen we de p -waarde als het minimum van $P(T \leq t)$ en $P(T \geq t)$ behorende bij de geobserveerde toetsingsgrootte $t \approx 7.5111$ en vergelijken deze met $\alpha/2 = 0.025$.

$$P(T \geq t \approx 7.5111) = \text{tcdf}(\text{lower} = -10^{99}, \text{upper} = 7.5111, df = 5) \approx 0.9997.$$

$$P(T \leq t \approx 7.5111) = \text{tcdf}(\text{lower} = 7.5111, \text{upper} = 10^{99}, df = 5) \approx 3.3085 \cdot 10^{-4}.$$

De p -waarde is dus gelijk aan $p \approx 3.3085 \cdot 10^{-4}$. Aangezien de p -waarde veel kleiner is dan $\alpha/2$, besluiten we om de nulhypothese H_0 te verwerpen. Er is op basis van deze steekproeven voldoende reden om aan te nemen dat er een significante procentuele verandering is in het aantal verkochte flessen afwasmiddel, specifiek een significante stijging.

Week **12****Correlatie en regressie****Hoofdstuk 13**

Opdracht 13.m1: Bij regressieanalyse wordt de grootte die aangeeft hoe de variabele Y (gemiddeld) reageert op veranderingen in de variabele X aangeduid met ...

- (a) de constante term.
- (b) de storingsterm.
- (c) de richtingscoëfficiënt van de regressielijn.
- (d) de correlatiecoëfficiënt.

Uitwerking

Bij een regressieanalyse op de onafhankelijke (verklarende) variabele X en de afhankelijke (te verklaren) variabele Y proberen we een lineair verband te vinden. De formule van de regressielijn is van de vorm $Y = \alpha + \beta X$, waarbij α de constante term is en β de richtingscoëfficiënt van de regressielijn. Deze richtingscoëfficiënt geeft aan hoe de variabele Y gemiddeld reageert op een verandering van X . Het juiste antwoord is dus (c).

Opdracht 13.m2: Als bij een regressieanalyse een correlatiecoëfficiënt wordt gevonden ter grootte van -0.50 , dan ...

- (a) moet er een rekenfout zijn gemaakt.
- (b) is de variabele Y ongeschikt als verklarende variabele.
- (c) zullen bij hogere X -waarden doorgaans lagere Y -waarden worden aangetroffen.

(d) kan de storingsterm geen positieve variantie hebben.

Uitwerking

Een negatieve correlatiecoëfficiënt duidt op het feit dat naarmate de verklarende variabele X stijgt de te verklaren variabele Y doorgaans lagere waarden aanneemt (dalende trend). Het juiste antwoord is dus (c).

Opdracht 13.m3: Als bij lineaire regressie wordt vastgesteld dat $\beta = 0$, dan ...

- (a) hebben de variabele X en Y een tegengestelde relatie.
- (b) is het onderscheidingsvermogen $1 - \beta$ gelijk aan 1.
- (c) toont de variabele X geen relatie met de variabele Y .
- (d) passen de punten perfect op de lijn.

Uitwerking

Het juiste antwoord is (c).

Opdracht 13.m4: Als bij een enkelvoudige lineaire regressieanalyse blijkt dat geldt $\alpha = 0$ voor de berekende regressielijn, dan ...

- (a) geldt altijd $\alpha = 0$ voor het regressiemodel.
- (b) is de correlatie tussen X en Y gelijk aan nul.
- (c) gaat de berekende regressielijn door de oorsprong.
- (d) loopt de berekende lijn horizontaal.

Uitwerking

Een regressielijn is altijd van de vorm $Y = \alpha + \beta X$. Als dan blijkt dat $\alpha = 0$, houden we een vorm $Y = \beta X$ over. Zodra we $X = 0$ invullen, krijgen we ook $Y = \beta \cdot 0 = 0$. Dit betekent dus dat de regressielijn door de oorsprong, oftewel het punt $(0, 0)$ gaat. Het juiste antwoord is dus (c).

Opdracht 13.m6: Bij een regressieanalyse wordt het verband onderzocht tussen de omzet Y ($\times 10000$ euro) van een bedrijf en de reclame-uitgaven X ($\times 1000$ euro) in de voorafgaande periode. De leverde als regressievergelijking op:

$$Y = 220 + 32X.$$

Stel dat in een nieuwe periode 3000 euro wordt uitgegeven aan reclame, dan is de voorspelde omzet op basis van de regressievergelijking gelijk aan

- (a) 756000 euro.

- (b) 2296000 euro.
- (c) 96220 euro.
- (d) 3160000 euro.

Uitwerking

Stel dat in een nieuwe periode 3000 euro wordt uitgegeven, dat betekent dus dat $X = 3$. Invullen in de regressielijn geeft ons $Y = 220 + 32 \cdot 3 = 316$. Aangezien Y gemeten wordt in tienduizenden euro's, betekent dit dat de voorspelde omzet gelijk is aan $316 \cdot 10000 = 3160000$ euro. Het juiste antwoord is dus (d).

Opdracht 13.1: Een fabrikant van synthetische vezels onderzoekt of het krimpen van de vezels samenhangt met de temperatuur waarbij ze worden gewassen. Er wordt achtmaal een proef verricht waarbij de vezels gedurende 30 minuten aan een bepaalde temperatuur worden blootgesteld. De geconstateerde krimp werd (in procenten van de oorspronkelijke lengte) als volgt vastgesteld:

Temperatuur (°C)	60	70	80	90	100	75	85	100
Krimp (%)	1.2	1.9	2.8	3.8	4.2	2.6	3.2	4.5

Het verband tussen temperatuur en krimp willen we beschrijven door een regressielijn te berekenen op basis van de waargenomen uitkomsten.

- (a) Welke sommaties moeten we berekenen om de regressiecoëfficiënten te kunnen bepalen?

Uitwerking

Bij enkelvoudige regressie is de regressielijn van de vorm $Y = a + b \cdot X$, waarbij we de regressiecoëfficiënten a en b bepalen aan de hand van

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$

$$a = \bar{y} - b \cdot \bar{x}$$

We hebben dus de sommaties (of gemiddeldes) $\sum x_i$, $\sum y_i$, $\sum x_i \cdot y_i$ en $\sum x_i^2$

- (b) Bereken de sommaties in een rekenschema.

Uitwerking

De sommaties worden geïllustreerd in onderstaand rekenschema:

x	y	xy	x^2
60	1.2	72	3600
70	1.9	133	4900
80	2.8	224	6400
90	3.8	342	8100
100	4.2	420	10000
75	2.6	195	5625
85	3.2	272	7225
100	4.5	450	10000
$\bar{x} = 82.5$	$\bar{y} = 3.025$	$\overline{xy} = 263.5$	$\overline{x^2} = 6981.25$

(c) Bereken de coëfficiënten a en b van de lineaire vergelijking.

Uitwerking

We kunnen de gemiddeldes uit het bovenstaande rekenschema invullen om de coëfficiënten te krijgen van de regressielijn.

$$\begin{aligned}
 b &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2} \\
 &= \frac{263.5 - 82.5 \cdot 3.025}{6981.25 - (82.5)^2} \\
 &= \frac{13.938}{175} = 0.0796 \\
 a &= \bar{y} - b \cdot \bar{x} \\
 &= 3.025 - 0.0796 \cdot 82.5 \\
 &= -3.5455.
 \end{aligned}$$

De formule van de regressielijn behorende bij deze steekproef is dus gelijk aan $Y = -3.5455 + 0.0796X$.

(d) Voorspel de krimp als de temperatuur X de waarde 65°C heeft.

Uitwerking

Een voorspelling voor de krimp bij een temperatuur van 65°C vinden we simpelweg door $X = 65$ in te vullen in de regressielijn. Dit geeft een voorspelde waarde van $Y = -3.5455 + 0.0796 \cdot 65 = 1.63125$.

Dat betekent dat bij een temperatuur van 65°C de vezels naar verwachting met ongeveer 1.63 % zullen krimpen.

Opdracht 13.4: De Stichting voor Veilig Verkeer doet onderzoek naar de invloed van alcohol op het bloedalcoholgehalte (promillage). In een onderzoek onder tien mannen heeft men het

promillage gemeten, twee uur na het begin van het drinken van vijf glazen bier. Tevens heeft men van deze tien personen het lichaamsgewicht gemeten. De gegevens staan in de tabel.

Promillage	Gewicht (in kg)
1.06	61
0.77	82
0.72	86
0.95	70
0.65	96
0.83	80
0.99	67
0.73	90
0.84	75
0.96	73

Een onderzoeker heeft het idee dat het gewicht van een persoon invloed heeft op het bloedalcoholgehalte en onderzoekt dit met regressie.

- (a) Welke van de variabelen is de te verklaren variabele?

Uitwerking

De onderzoeker wil toetsen of het gewicht van een persoon invloed heeft op het promillage alcohol in het bloed van testpersonen.

Dit houdt dus in dat de verklarende variabele X het gewicht (in kg) is en de te verklaren variabele Y het promillage alcohol in het bloed.

- (b) Stel de vergelijking van de regressielijn op.

Uitwerking

Bij enkelvoudige regressie is de regressielijn van de vorm $Y = a + b \cdot X$, waarbij we de regressiecoëfficiënten a en b bepalen aan de hand van

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$

$$a = \bar{y} - b \cdot \bar{x}$$

We moeten dus een tabel construeren met de gemiddelde $\bar{x}$, $\bar{y}$, $\overline{xy}$ en $\overline{x^2}$.

x	y	xy	x^2
61	1.06	64.66	3721
82	0.77	63.14	6724
86	0.72	61.92	7396
70	0.95	66.5	4900
96	0.65	62.4	9216
80	0.83	66.4	6400
67	0.99	66.33	4489
90	0.73	65.7	8100
75	0.84	63	5625
73	0.96	70.08	5329
$\bar{x} = 78$	$\bar{y} = 0.85$	$\overline{xy} = 65.013$	$\overline{x^2} = 6190$


We hebben nu alle grootheden die benodigd zijn om de coëfficiënten van de regressielijn $Y = a + b \cdot X$ te kunnen bepalen:

$$\begin{aligned}
 b &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2} \\
 &= \frac{65.013 - 78 \cdot 0.85}{6190 - (78)^2} \\
 &= \frac{-1.287}{106} \approx -0.0121,
 \end{aligned}$$

$$\begin{aligned}
 a &= \bar{y} - b \cdot \bar{x} \\
 &= 0.85 - (-0.0121 \cdot 78) \\
 &\approx 1.7970.
 \end{aligned}$$

De formule van de regressielijn behorende bij deze steekproef is dus gelijk aan $Y = 1.7970 - 0.0121 \cdot X$.

Spreidingsdiagram: gewicht (in kg) vs. bloedalcoholgehalte (in promille)



(c) Bereken de correlatiecoëfficiënt.

Uitwerking

De correlatiecoëfficiënt $r(x, y)$ berekenen we op basis van de formule

$$r(x, y) = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\sqrt{(\overline{x^2} - \bar{x}^2) \cdot (\overline{y^2} - \bar{y}^2)}}$$

Dat betekent dat we naast de bovenstaande tabel moeten uitbreiden met een kolom voor y^2 :

x	y	xy	x^2	y^2
61	1.06	64.66	3721	1.1236
82	0.77	63.14	6724	0.5929
86	0.72	61.92	7396	0.5184
70	0.95	66.5	4900	0.9025
96	0.65	62.4	9216	0.4225
80	0.83	66.4	6400	0.6889
67	0.99	66.33	4489	0.9801
90	0.73	65.7	8100	0.5329
75	0.84	63	5625	0.7056
73	0.96	70.08	5329	0.9216
$\bar{x} = 78$	$\bar{y} = 0.85$	$\overline{xy} = 65.013$	$\overline{x^2} = 6190$	$\overline{y^2} = 0.7389$

De correlatiecoëfficiënt $r(x, y)$ is dus gelijk aan

$$\begin{aligned} r(x, y) &= \frac{\overline{x \cdot y} - \bar{x} \cdot \bar{y}}{\sqrt{(\overline{x^2} - \bar{x}^2) \cdot (\overline{y^2} - \bar{y}^2)}} \\ &= \frac{65.013 - 78 \cdot 0.85}{\sqrt{(6190 - 78^2) \cdot (0.739 - 0.85^2)}} \\ &= \frac{-1.287}{1.318} \\ &\approx -0.9761. \end{aligned}$$

Noot: de correlatiecoëfficiënt $r(x, y)$ ligt erg dicht in de buurt van -1 , wat inhoudt dat er een sterke negatieve correlatie is tussen de variabelen bloedalcoholgehalte en gewicht en dat de datapunten vrijwel op een lijn liggen. Naarmate iemand zwaarder is, zal het promillage in het bloed ook kleiner zijn bij consumptie van vijf glazen bier.

- (d) Geef het voorspelde promillage (twee uur na het begin van het drinken van vijf glazen bier) voor een man van 85 kg.

Uitwerking

Een voorspelling voor het promillage twee uur na het begin van het drinken van vijf glazen bier bij een man die 85 kg weegt vinden we simpelweg door $X = 85$ in te vullen in de regressielijn. Dit geeft een voorspelde waarde van $Y = 1.7970 - 0.0121 \cdot 85 \approx 0.7650$.

Dat betekent dat bij een gewicht van 85 kg, het bloedalcoholgehalte naar verwachting gelijk is aan 0.7650 promille.

- (e) Uit onderzoek is gebleken: het promillage ligt, twee uur na het begin van het drinken van zes glazen bier (bij mannen) 20 % hoger dan na het drinken van vijf glazen. Stel de vergelijking van de regressielijn voor dit geval op.

Uitwerking

Merk op dat we nu alle waarden voor y moeten vermenigvuldigen met 1.2 (20 % meer dan bij vijf glazen bier). Dat betekent ook dat $\bar{y}$ en $\overline{xy}$ met een factor 1.2 groter worden. De gemiddelde voor x en $\overline{x^2}$ blijven hetzelfde. Met andere woorden, we krijgen $\bar{x}_n = \bar{x}$, $\bar{y}_n = 1.2\bar{y}$, $\overline{xy}_n = 1.2\overline{xy}$, $\overline{x^2}_n = \overline{x^2}$. De formule van de (nieuwe) regressielijn $Y = a_n + b_n \cdot X$ kunnen we opstellen met behulp van:

$$\begin{aligned} b_n &= \frac{\overline{xy}_n - \bar{x}_n \cdot \bar{y}_n}{\overline{x^2}_n - (\bar{x}_n)^2} = \frac{(1.2 \cdot \overline{xy}) - \bar{x} \cdot (1.2 \cdot \bar{y})}{\overline{x^2} - (\bar{x})^2} = \frac{1.2 \cdot (\overline{xy} - \bar{x} \cdot \bar{y})}{\overline{x^2} - (\bar{x})^2} = 1.2 \cdot b, \\ a_n &= \bar{y}_n - b_n \cdot \bar{x}_n = 1.2 \cdot \bar{y} - (1.2 \cdot b) \cdot \bar{x} = 1.2 \cdot (\bar{y} - b \cdot \bar{x}) = 1.2 \cdot a. \end{aligned}$$

Dit betekent dus dat zowel het snijpunt a met de y -as als de richtingscoëfficiënt b van de regressielijn met een factor 1.2 groter worden. De nieuwe regressielijn –

uitgaande van consumptie van zes glazen bier – kan dus worden beschreven met

$$Y = 1.2 \cdot a + 1.2 \cdot b \cdot X = 2.1564 - 0.0146 \cdot X.$$

Opdracht 13.5: De weerstand van een blokje van een bepaalde metaalsoort hangt af van de temperatuur. Bij verschillende temperaturen (X) werd de weerstand (Y) gemeten. De resultaten zijn weergegeven in de volgende tabel:

Temperatuur (°C)	−100	−50	0	50	100	150	200
Weerstand (Ω)	13.2	17.5	21.3	25.4	28.9	32.8	36.8

- (a) Ga ervan uit dat het verband tussen temperatuur en weerstand lineair is. Bepaal de regressielijn met de temperatuur als verklarende variabele.

Uitwerking

De regressielijn is van de vorm $Y = a + b \cdot X$, waarbij we de regressiecoëfficiënten a en b bepalen aan de hand van

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$

$$a = \bar{y} - b \cdot \bar{x}$$

We moeten dus een tabel construeren met de gemiddelde $\bar{x}$, $\bar{y}$, $\overline{xy}$ en $\overline{x^2}$.


x	y	xy	x^2	y^2
−100	13.2	−1320	10000	174.24
−50	17.5	−875	2500	306.25
0	21.3	0	0	453.69
50	25.4	1270	2500	645.16
100	28.9	2890	10000	835.21
150	32.8	4920	22500	1075.84
200	36.8	7360	40000	1354.24
$\bar{x} = 50$	$\bar{y} = 25.13$	$\overline{xy} = 2035$	$\overline{x^2} = 12500$	$\overline{y^2} = 692.09$

We hebben nu alle grootheden die benodigd zijn om de coëfficiënten van de re-

regressielijn $Y = a + b \cdot X$ te kunnen bepalen:

$$\begin{aligned}
 b &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2} \\
 &= \frac{2035 - 50 \cdot 25.1286}{12500 - 50^2} \\
 &= \frac{778.5714}{10000} \approx 0.0779, \\
 a &= \bar{y} - b \cdot \bar{x} \\
 &= 25.1286 - 0.0779 \cdot 50 \\
 &\approx 21.2357.
 \end{aligned}$$

De formule van de regressielijn behorende bij deze steekproef is dus gelijk aan $Y = 21.2357 + 0.0779 \cdot X$.



(b) Welke weerstand kan men verwachten bij 400 °C?

Uitwerking

De weerstand Y die we verwachten bij een temperatuur X vinden we door in te vullen in de regressielijn. Hieruit volgt dat bij een temperatuur van $X = 400$ °C de verwachte weerstand gelijk is aan ongeveer $Y = 21.2357 + 0.0779 \cdot 400 \approx 52.38$ Ω.

Noot: we zijn in dit geval ver buiten de dataset aan het extrapoleren, want we hebben de regressielijn bepaald op basis van metingen voor temperaturen tussen −100 °C en 200 °C. We moeten dus voorzichtig zijn met de aanname dat deze voorspelde waarde van de weerstand bij 400 °C nauwkeurig zou zijn.

(c) Bij experimenten als het hier genoemde wordt de temperatuur vaak uitgedrukt in Kelvin (K). Hoe luidt de vergelijking van de regressielijn als de temperatuur in K wordt uitgedrukt? (Het nulpunt van de Kelvin-temperatuurschaal ligt bij −273 °C. Een stijging met 1 °C is gelijk aan een stijging met 1 K.)

Uitwerking

Zodra we de temperatuurschaal veranderen van Celsius ($^{\circ}\text{C}$) naar Kelvin (K), moet bij iedere waarde van X precies 273 worden opgeteld. Laat nu Z de temperatuur zijn in K. Dan geldt dus $Z = X + 273$, oftewel $X = Z - 273$. Invullen in de berekende regressielijn geeft:

$$\begin{aligned} Y &= 21.2357 + 0.0779 \cdot (Z - 273) \\ &= (21.2357 + 0.0779 \cdot -273) + 0.0779 \cdot Z \\ &= -0.0310 + 0.0779 \cdot Z. \end{aligned}$$

Deze lijn heeft dus exact dezelfde richtingscoëfficiënt (en is dus evenwijdig aan de regressielijn met de verklarende variabele X), maar heeft een lager gelegen snijpunt met de Y -as.

Opdracht 13.9: Een consumentenorganisatie wil onderzoeken hoe de samenhang is tussen de ouderdom van automobielen en de jaarlijkse kosten voor onderhoud. Voor auto's van het merk Inceatti zijn tien exemplaren in het onderzoek betrokken geweest. Dit leverde de volgende gegevens:

Auto nummer	Leeftijd (X) in jaren	Onderhoudskosten (Y) in de laatste 12 maanden
A	1.6	450
B	6.8	930
C	5.1	670
D	7.2	920
E	3.5	640
F	6.2	900
G	9.4	1440
H	5.5	760
I	8.0	1260
J	2.7	530
Totaal	56.0	8500

Verder zijn de volgende sommaties gegeven:

$$\sum x_i = 56, \sum y_i = 8500, \sum x_i^2 = 367.24, \sum y_i^2 = 8102000 \text{ en } \sum x_i y_i = 54132.$$

- (a) Bereken de regressielijn waardoor de onderhoudsuitgaven worden verklaard uit de leeftijd.

Uitwerking

De regressielijn is van de vorm $Y = a + b \cdot X$, waarbij we de regressiecoëfficiënten a en b bepalen aan de hand van

$$b = \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2}$$

$$a = \bar{y} - b \cdot \bar{x}$$


Veel van het rekenwerk is al gegeven in de opdracht. Het is dus niet nodig de hele rekentabel uit te werken. We hoeven alleen maar de sommaties om te zetten naar gemiddeldes door te delen door de steekproefgrootte $n = 10$. Dit geeft als gemiddeldes

$$\bar{x} = 5.6, \quad \bar{y} = 850, \quad \overline{x^2} = 36.724, \quad \overline{y^2} = 810200, \quad \overline{xy} = 5413.2.$$

We hebben nu alle grootheden die benodigd zijn om de coëfficiënten van de regressielijn $Y = a + b \cdot X$ te kunnen bepalen:

$$\begin{aligned} b &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2} \\ &= \frac{5413.2 - 5.6 \cdot 850}{36.724 - (5.6)^2} \\ &= \frac{653.2}{5.364} \approx 121.7748, \\ a &= \bar{y} - b \cdot \bar{x} \\ &= 850 - 121.7748 \cdot 5.6 \\ &\approx 168.0611. \end{aligned}$$

De formule van de regressielijn behorende bij deze steekproef is dus gelijk aan $Y = 168.0611 + 121.7748 \cdot X$.



(b) Bereken op basis van de gegevens van (a) een 95 %-voorspellingsinterval voor de onder-

houdskosten van een willekeurige auto van tien jaar oud.

Uitwerking

De eerste stap is om de puntschatting voor Y te bepalen aan de hand van de regressielijn $Y = 168.0611 + 121.7748X$ door $X = 10$ in te vullen. Dit geeft ons een puntschatting van $y_0 = 168.0611 + 121.7748 \cdot 10 \approx 1385.8091$. Daarnaast kunnen we de standaardafwijking σ van de storingsterm ε schatten:

$$\begin{aligned} s_\varepsilon &= \sqrt{\frac{n}{n-2} \cdot (\overline{y^2} - a \cdot \bar{y} - b \cdot \bar{xy})} \\ &= \sqrt{\frac{10}{8} \cdot (810200 - 168.0611 \cdot 850 - 121.7748 \cdot 5413.2)} \\ &\approx 100.9746. \end{aligned}$$

Vervolgens kunnen we een puntschatting berekenen van de standaardafwijking van Y gegeven $X = x_0$:

$$\begin{aligned} s_f &= s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{(\bar{x^2} - \bar{x}^2)}\right)} \\ &= 100.9746 \cdot \sqrt{1 + \frac{1}{10} \cdot \left(1 + \frac{(10 - 5.6)^2}{(36.724 - 5.6^2)}\right)} \\ &\approx 122.0468. \end{aligned}$$

Omdat we de standaardafwijkingen geschat hebben en de storingstermen normaal verdeeld zijn, moeten we werken met de t -verdeling met $df = n - 2 = 8$ vrijheidsgraden. De t -waarde die hoort bij een voorspellingsinterval met $\alpha = 0.05$ is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 2) = \text{InvT}(\text{area} = 0.975, df = 8) \approx 2.3060.$$

Het 95 %-voorspellingsinterval voor Y bij een gegeven $X = x_0$ kan dus worden beschreven door

$$\begin{aligned} &[y_0 - t \cdot s_f, y_0 + t \cdot s_f] \\ &= [1385.8091 - 2.3060 \cdot 122.0468, 1385.8091 + 2.3060 \cdot 122.0468] \\ &\approx [1104.3688, 1667.2494] \end{aligned}$$

Met 95 % betrouwbaarheid liggen de onderhoudskosten in de laatste 12 maanden van een willekeurige Inceatti auto van 10 jaar oud tussen ongeveer 1104 en 1667 euro.

- (c) Veronderstel eens dat de hier bedoelde regressielijn exact bekend zou zijn, bijvoorbeeld omdat een alomvattend onderzoek naar onderhoudskosten heeft plaatsgevonden waar-

bij alle 50000 Inceatti-auto's die in Nederland rondrijden, betrokken waren. Dit bleek een regressielijn op te leveren met $\alpha = 320$ en $\beta = 130$. Verder geldt voor de storings-term $\sigma_\varepsilon = 65$. Geef hiermee een 99%-voorspellingsinterval voor het bedrag aan jaarlijkse onderhoudskosten voor een willekeurige Inceatti-auto van tien jaar oud.

Uitwerking

Het daadwerkelijke verband tussen de variabelen “leeftijd (in jaren)” (X) en “onderhoudskosten in de laatste 12 maanden” (Y) is gelijk aan

$$Y = \alpha + \beta \cdot X + \varepsilon = 320 + 130 \cdot X + \varepsilon,$$

waarbij de storingsterm $\varepsilon \sim N(\mu = 0, \sigma = 65)$.

Voor een willekeurige Inceatti-auto van tien jaar oud geldt dus $X = 10$. Dat betekent dat we Y volledig kunnen beschrijven met alleen de storingsterm ε als kansvariabele:


$$Y = 320 + 130 \cdot 10 + \varepsilon = 1620 + \varepsilon.$$

We kunnen Y dus als een kansvariabele zien die normaal verdeeld is met verwachtingswaarde $\mu = 1620$ en standaardafwijking $\sigma = 65$. Omdat we een 99%-voorspellingsinterval willen bepalen (oftewel $\alpha = 0.01$), geldt dat $z_{\alpha/2} = \text{InvNorm}(\text{area} = 1 - \alpha/2) = \text{InvNorm}(\text{area} = 0.995) \approx 2.5758$.

Het 99%-voorspellingsinterval voor een volgende uitkomst van Y wordt dan gegeven door

$$\begin{aligned} & [\mu - z_{\alpha/2} \cdot \sigma, \mu + z_{\alpha/2} \cdot \sigma] \\ &= [1620 - 2.5758 \cdot 65, 1620 + 2.5758 \cdot 65] \\ &\approx [1452.5711, 1787.4289]. \end{aligned}$$

Voor een willekeurige Inceatti-auto van tien jaar oud zullen met 99% zekerheid de onderhoudskosten in de laatste 12 maanden tussen de 1452 en 1788 euro bedragen.




Opdracht 13.15: Er is een onderzoek gehouden naar het verband tussen motorinhoud en maximumsnelheid van personenauto's. Er werden tien auto's getest. De resultaten waren als volgt:

Auto nr.	Cilinderinhoud	Max. snelheid (km/uur)
I	1.2	140
II	0.8	110
III	0.8	100
IV	2.0	180
V	1.4	150
VI	1.0	100
VII	1.6	160
VIII	1.8	190
IX	1.3	140
X	1.1	130

(a) Teken de gegevens in een spreidingsdiagram.

Uitwerking

Bij het tekenen van een spreidingsdiagram is het belangrijk om van te voren te bepalen welke variabele de verklarende (onafhankelijke) variabele X is en welke variabele de te verklaren (afhankelijke) variabele Y is. In dit geval is het het meest logisch om aan de hand van de cilinderinhoud te bepalen wat de te bereiken maximum snelheid is van een auto.



(b) Bepaal het verband tussen de variabelen met behulp van lineaire regressie.

Uitwerking

Uit het spreidingsdiagram is op te merken dat het verband tussen de variabelen cilinderinhoud en maximum snelheid redelijk lineair is. Er valt dus zeker iets te zeggen voor de keuze om lineaire regressie toe te passen.

Om de bijbehorende regressielijn te bepalen, construeren we allereerst de reken-tabel met de gemiddeldes $\bar{x}$, $\bar{y}$, $\overline{xy}$, $\overline{x^2}$ en $\overline{y^2}$:


x	y	xy	x^2	y^2
1.2	140	168	1.44	19600
0.8	110	88	0.64	12100
0.8	100	80	0.64	10000
2.0	180	360	4.0	32400
1.4	150	210	1.96	22500
1.0	100	100	1.0	10000
1.6	160	256	2.56	25600
1.8	190	342	3.24	36100
1.3	140	182	1.69	19600
1.1	130	143	1.21	16900
$\bar{x} = 1.3$	$\bar{y} = 140$	$\overline{xy} = 192.9$	$\overline{x^2} = 1.838$	$\overline{y^2} = 20480$

Op basis van de bovenstaande tabel kunnen we de coëfficiënten a en b van de regressielijn bepalen:

$$\begin{aligned}
 b &= \frac{\overline{xy} - \bar{x} \cdot \bar{y}}{\overline{x^2} - (\bar{x})^2} \\
 &= \frac{192.9 - 1.3 \cdot 140}{1.838 - (1.3)^2} \\
 &= \frac{10.9}{0.148} \approx 73.6486, \\
 a &= \bar{y} - b \cdot \bar{x} \\
 &= 140 - 73.6486 \cdot 1.3 \\
 &\approx 44.2568.
 \end{aligned}$$

De formule van de regressielijn behorende bij deze steekproef is dus gelijk aan $Y = 44.2568 + 73.6486X$.

Spreidingsdiagram: cilinderinhoud (liters) vs. maximum snelheid (km/uur)



- (c) Voorspel aan de hand van de gevonden lijn de maximumsnelheid van een auto met een cilinderinhoud van 1.5 liter.


Uitwerking

Aan de hand van de regressielijn kunnen we een voorspelling doen voor de maximumsnelheid van een auto met een cilinderinhoud van 1.5 liter. Dit doen we door simpelweg $X = 1.5$ in te vullen en de bijbehorende Y -waarde te berekenen:

$$Y = a + b \cdot X = 44.2568 + 73.6486 \cdot 1.5 = 154.7297.$$

De verwachting is dus dat een willekeurige auto met een cilinderinhoud van 1.5 liter een maximumsnelheid heeft van 155 kilometer per uur.

Spreidingsdiagram: cilinderinhoud (liters) vs. maximum snelheid (km/uur)



- (d) Geef een schatting van de variantie van de storingsterm.

Uitwerking

Bij lineaire regressie nemen we aan dat de storingsterm ε normaal verdeeld is met verwachtingswaarde $\mu_\varepsilon = 0$ en (onbekende) standaardafwijking σ_ε . We kunnen een schatting van de variantie σ^2 berekenen aan de hand van de volgende formule:

$$\begin{aligned}s_\varepsilon^2 &= \frac{n}{n-2} \cdot (\overline{y^2} - a \cdot \bar{y} - b \cdot \overline{xy}) \\ &= \frac{10}{8} \cdot (20480 - 44.2568 \cdot 140 - 73.6486 \cdot 192.9) \\ &\approx 96.5372.\end{aligned}$$

- (e) Geef een 95 %-voorspellingsinterval voor de maximumsnelheid van een auto waarvan is gegeven dat deze een cilinderinhoud van 1.45 liter heeft.

Uitwerking

We willen een voorspellingsinterval bepalen voor de maximumsnelheid van een willekeurige auto met een cilinderinhoud van 1.45 liter.

De eerste stap is om de puntschatting voor Y te bepalen aan de hand van de regressielijn $Y = 44.2568 + 73.6486 \cdot X$ door $X = 1.45$ in te vullen. Dit geeft ons een puntschatting van $y_0 = 44.2568 + 73.6486 \cdot 1.45 \approx 151.0473$. Daarnaast kunnen we de standaardafwijking σ van de storingsterm ε schatten:

$$\begin{aligned}s_\varepsilon &= \sqrt{\frac{n}{n-2} \cdot (\overline{y^2} - a \cdot \bar{y} - b \cdot \overline{xy})} \\ &= \sqrt{\frac{10}{8} \cdot (20480 - 44.2568 \cdot 140 - 73.6486 \cdot 192.9)} \\ &\approx 9.8253.\end{aligned}$$

Vervolgens kunnen we een puntschatting berekenen van de standaardafwijking van Y voor gegeven $X = x_0$:

$$\begin{aligned}s_f &= s_\varepsilon \cdot \sqrt{1 + \frac{1}{n} \cdot \left(1 + \frac{(x_0 - \bar{x})^2}{\overline{x^2} - \bar{x}^2}\right)} \\ &= 9.8253 \cdot \sqrt{1 + \frac{1}{10} \cdot \left(1 + \frac{(1.45 - 1.3)^2}{1.838 - 1.3^2}\right)} \\ &\approx 10.3759.\end{aligned}$$

Omdat we de standaardafwijkingen geschat hebben en de storingstermen normaal verdeeld zijn, moeten we werken met de t -verdeling met $df = n - 2 = 8$ vrijheidsgraden. De t -waarde die hoort bij een voorspellingsinterval met $\alpha = 0.05$ is gelijk aan

$$t = \text{InvT}(\text{area} = 1 - \alpha/2, df = n - 2) = \text{InvT}(\text{area} = 0.975, df = 8) \approx 2.3060.$$

Het 95 %-voorspellingsinterval voor Y bij een gegeven $X = 1.45$ kan dus worden beschreven door

$$\begin{aligned} & [y_0 - t \cdot s_f, y_0 + t \cdot s_f] \\ & = [151.0473 - 2.3060 \cdot 10.3759, 151.0473 + 2.3060 \cdot 10.3759] \\ & \approx [127.1205, 174.9741]. \end{aligned}$$

Met 95 % betrouwbaarheid ligt de maximumsnelheid van een willekeurige auto met een cilinderinhoud van 1.45 liter tussen ongeveer 127 en 175 kilometer per uur.

