Defensie Ondersteuningscommando
Ministerie van Defensie

Statistiek: college 1a

Grondslagen van statistiek

DOSCO
Nederlandse Defensie Academie
Dr. ir. D. Blom / Dr. M. van Ee
Faculteit Militaire Wetenschappen

20 april 2026

Het Duitse tankprobleem

WO II: geallieerden hadden bij verlaten Duitse tanks ontdekt dat bepaalde onderdelen opeenvolgende serienummers bleken te hebben.

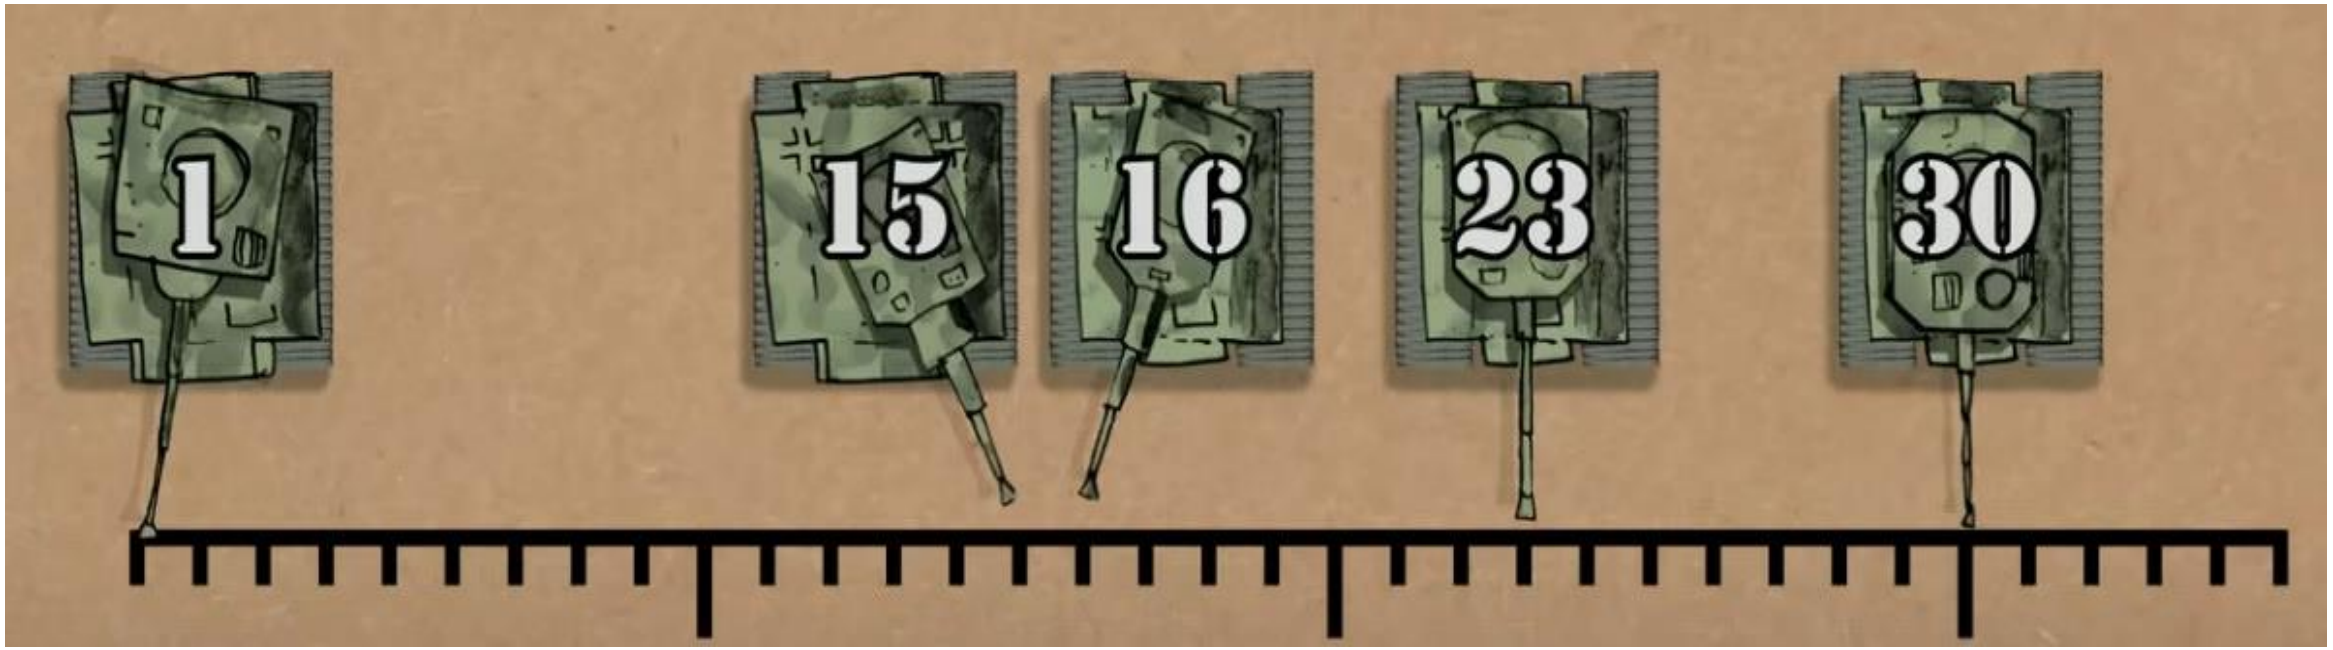

Hoeveel Duitse tanks zijn er in totaal, als we maar een paar serienummers hebben?

Wat maakt dit probleem lastig?

- We hebben niet alle gegevens tot onze beschikking.

- Waarschijnlijk hebben we maar een heel klein deel van de gegevens

- Je weet niet hoe representatief deze gegevens zijn.
  - Misschien zijn het toevallig allemaal tanks met lage serienummers

Toch willen we het liefst een betrouwbare schatting!

Dit soort problemen zien we vaker in de Defensiecontext

- Je hebt zelden volledige informatie
- Data is vaak zeer beperkt beschikbaar, variabel en onzeker
- Toch moet je als officier plannen, beslissen, voorspellen op basis van deze beperkte data.

Dit soort problemen zien we vaker in de Defensiecontext

- Duitse tankprobleem: verbeteren van *"situational awareness"*
- Hoeveel reserveonderdelen hebben we nodig op een missie?
- Wat is de invloed van windsnelheden en luchtdruk op ballistische raketten?
- Welke keuzes moeten we maken in medische triage bij *"mass casualty events"*?

Cursusdoelen

8.52 STA - Statistiek

Vaknaam: Statistiek (STA)

Studielast: 4 EC

Fasering: Ba 3

Docent(en): Dr. ir. D.A.M.P. Blom (coördinator)

Beschrijving:
De cursus bestaat uit twee delen:
Deel 1: beschrijvende statistiek en kansrekening

- Beschrijvende statistiek: meetniveaus, maten van spreiding en ligging, datavisualisaties.
- Basis kansrekening: rekenregels voor kansexperimenten.
- Discrete kansvariabelen: kansfunctie, cumulatieve verdelingsfunctie, verwachtingswaarde, variantie en standaardafwijking.
- Continue kansvariabelen: kansdichtheidsfunctie, verwachtingswaarde, variantie en standaardafwijking.
- Bekende discrete kansverdelingen: Bernoulli, binomiaal, Poisson.
- Bekende continue kansverdelingen: uniform, normaal, t, chikwadraat, exponentieel.
- Centrale limietstelling en verschil van twee kansvariabelen.
- Het gebruik van de grafische rekenmachine, Excel en/of statistische software.

Deel 2: voorspellende statistiek

- Vervolg continue kansverdelingen (Student's t, chi-kwadraat en F).
- Punt- en intervalschatters voor het gemiddelde, standaardafwijking en de binomiale succeskans.
- Hypothesetoetsen: z-toets, t-toets, chikwadraattoets, verschiltoetsen en de F-toetsen.
- (Enkelvoudig) lineair regressie en correlatie (Pearson en Spearman)
- Het gebruik van de grafische rekenmachine, Excel en/of statistische software.

Bekijk de studiegids MBW voor de complete beschrijving.

Link naar studiegids MBW is beschikbaar op de ELO:

Statistiek MBW 2025-2026 > Algemeen > Cursusinformatie

Structuur van het vak

Deel 1 (Grondslagen statistiek en kansbegrip):	12 hoor-/werkcolleges - (week 1 – 6) Tentamen (50%) – (week 7)
Deel 2 (Statistische methoden):	12 hoor-/werkcolleges - (week 8 – 13) Tentamen (50%) – (week 14)

- Naast de deeltentamen zijn er huiswerkopdrachten op de ELO (v/o)
- Beide deeltentamens $\geq$ 5,0, gemiddelde $\geq$ 5,5.
- Benodigd: grafische rekenmachine zonder Computer Algebra Systeem (CAS)
  - Collegevoorbeelden: TI-84 Plus

Materiaal

- Slides van de hoorcolleges

- Boeken
  - Arie Buijs. *Statistiek om mee te werken*. Theorieboek.
  - Arie Buijs. *Statistiek om mee te werken. Opgaven en uitwerkingen*. Opgavenboek.

- Moodle pagina met extra informatie.
  - Videos / PDFs met uitwerkingen van bepaalde opgaven, oefententamens
  - Mededelingen

<u>Maak gebruik van het Moodle forum om vragen te stellen!</u>

Leerdoelen

Aan het eind van dit college kun je:

- Het verschil *uitleggen* tussen populatie en steekproef, en dit toepassen op een Defensie-casus.
- Variabelen in een dataset *classificeren* op basis van eigenschappen als het meetniveau.
- Maten van ligging, zoals gemiddelde, mediaan en modus *berekenen* en *beargumenteren* in welke situatie welke maat gebruikt moet worden.
- Maten van spreiding, zoals variantie en standaardafwijking *berekenen* en de voor- en nadelen hiervan te *benoemen*.

Waarom statistiek in de MBW opleiding?

- Belangrijk onderdeel van de leerlijn Methoden en Technieken voor Onderzoek (MTO), als voorbereiding op de bachelor- en masterscripties
- Analyse van zowel technische als sociaal-wetenschappelijke vraagstukken van Defensie
- Voorkennis voor latere vakken
  - o.a., leerlijn Operationele Logistiek en Defensie Economie (OLDE)
- Defensie is een IGO (Informatie Gestuurde Organisatie), waarin datageletterdheid een steeds grotere rol krijgt in de profielschets van een officier bij Defensie.

Populaties en steekproeven

Populatie: gedefinieerde groep waarover je statistisch verantwoorde uitspraken wilt doen.

- alle actief dienende militairen binnen Defensie
- alle mogelijke types vijandelijke onderzeeboten

Steekproef: een (vaak veel) kleinere deel van de populatie waarover je daadwerkelijk gegevens (data) verzamelt.

- Een steekproef van 216 militairen
- Een steekproef van 4 types onderzeeboten

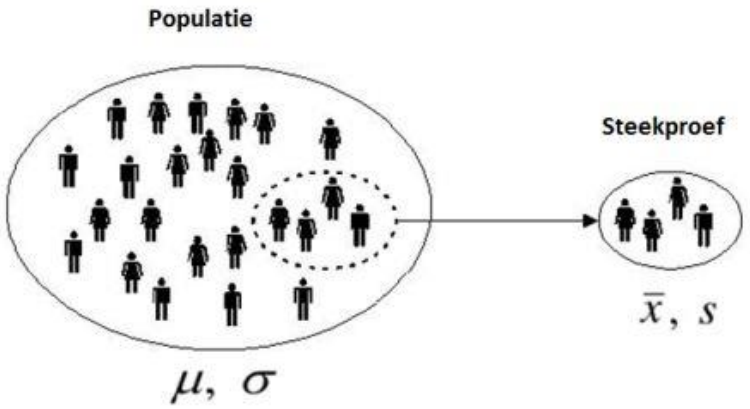

https://www.cmihva.nl/kennisbanks/populatie-of-steekproef/

Waarom gebruiken we steekproeven?

- De omvang van de populatie is te groot om alle elementen te meten
  - Politieke stemwijzers
- De gehele populatie toetsen is niet kosteneffectief
  - Toetsen van de duurzaamheid van nieuwe gevechtstenues
- Als snelheid gewenst is, waardoor niet de hele populatie kan worden onderzocht
  - COVID-19 vaccins

Representativiteit en bias

Representativiteit: elk element van de populatie heeft dezelfde kans in de steekproef te komen

Bias: maatstaf voor in hoeverre verzamelde data en statistische analyse een inaccuraat beeld van de werkelijkheid geven

https://www.geckoboard.com/blog/quick-data-lessons-survivorship-bias/

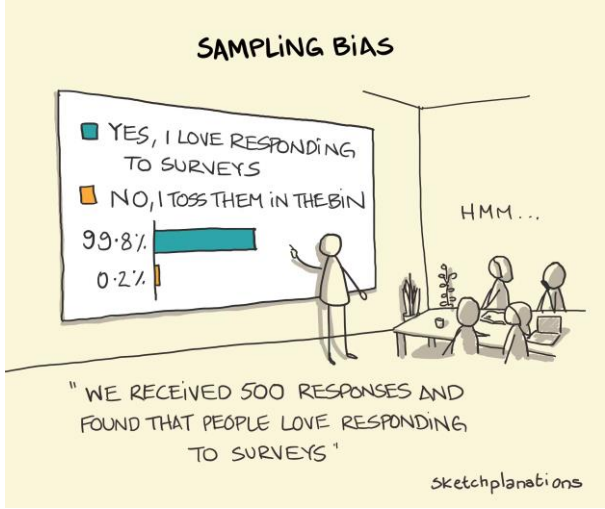

https://sketchplanations.com/sampling-bias

Datasets

Een **dataset** is een verzameling van gegevens.

We focussen nu op:

- Datasets in tabelvorm (met rijen en kolommen)
- **Rij:** element uit een steekproef.
- **Kolom:** een variabele waarvan per element een uitkomst wordt waargenomen

Dit vak: analyse van een enkele variabele of interactie tussen twee variabelen.

Dataset: jaarlijkse keuring van actieve militairen

ID	Rang	Eenheid	Oefeningstijd (min)	Schietscore (%)	Aantal missies	Geslacht
1	Sergeant	Bravo	45	85	12	Man
2	Korporaal	Alpha	60	92	8	Vrouw
3	Luitenant	Charlie	55	78	15	Man
4	Majoor	Bravo	70	88	20	Man
5	Soldaat	Alpha	30	65	5	Vrouw
6	Kapitein	Charlie	50	80	10	Vrouw
7	Sergeant	Bravo	65	90	18	Man
8	Soldaat	Alpha	40	72	6	Man
9	Soldaat	Charlie	35	70	4	Man
10	Kapitein	Bravo	75	95	25	Vrouw
11	Luitenant	Alpha	55	82	12	Man
12	Korporaal	Charlie	45	68	7	Vrouw
13	Sergeant	Bravo	60	88	14	Man
14	Majoor	Alpha	80	92	30	Vrouw
15	Soldaat	Charlie	25	60	3	Vrouw
16	Kapitein	Bravo	65	87	18	Man
17	Luitenant	Alpha	50	75	9	Man
18	Sergeant	Charlie	55	85	13	Vrouw
19	Korporaal	Bravo	45	80	10	Man
20	Soldaat	Alpha	35	62	5	Vrouw

Meetniveaus van variabelen

- **Nominaal:** waardes duiden een categorie aan (operationele eenheid).
- **Ordinaal:** waardes kunnen logisch worden gerangschikt (militaire rang).
- **Interval:** verschil tussen twee waardes heeft een eenduidige betekenis (lichaamstemperatuur tijdens inspanning)
- **Ratio:** er bestaat een waarde die een natuurlijk nulpunt aanduidt (aantal militairen in een eenheid)

Voorbeelden van meetniveaus van variabelen

Nominaal	Categorie / naam	Geboorteplaats, etniciteit, automerken Militaire voorbeelden = type wapensysteem, OPCO
Ordinaal	Categoriseren en rangschikken	Top tien bestsellers, taalvaardigheid (zoals laag, gemiddeld, hoog), Likertschaal-vragen (zeer oneens, oneens, neutraal, eens, zeer eens) Militaire voorbeelden = rang, alert state
Interval	Categoriseren en rangschikken en verschillen tussen waardes hebben een eenduidige betekenis	Temperatuur, IQ, Big Five persoonlijkheidstest Militaire voorbeelden = temperatuur van militaire apparatuur, tijdzone in een conflictgebied
Ratio	Categoriseren en rangschikken en verschillen tussen waardes hebben een eenduidige betekenis en een natuurlijk nulpunt	Lengte, tijd, gewicht Militaire voorbeelden = snelheid van een F-35 (km/h), vrijgekomen energie van een explosief (TNT-equivalent)

Wat zijn de meetniveaus van deze variabelen?

ID	Rang	Eenheid	Oefeningstijd (min)	Schietscore (%)	Aantal missies	Geslacht
1	Sergeant	Bravo	45	85	12	Man
2	Korporaal	Alpha	60	92	8	Vrouw
3	Luitenant	Charlie	55	78	15	Man
4	Majoor	Bravo	70	88	20	Man
5	Soldaat	Alpha	30	65	5	Vrouw
6	Kapitein	Charlie	50	80	10	Vrouw
7	Sergeant	Bravo	65	90	18	Man
8	Soldaat	Alpha	40	72	6	Man
9	Soldaat	Charlie	35	70	4	Man
10	Kapitein	Bravo	75	95	25	Vrouw
11	Luitenant	Alpha	55	82	12	Man
12	Korporaal	Charlie	45	68	7	Vrouw
13	Sergeant	Bravo	60	88	14	Man
14	Majoor	Alpha	80	92	30	Vrouw
15	Soldaat	Charlie	25	60	3	Vrouw
16	Kapitein	Bravo	65	87	18	Man
17	Luitenant	Alpha	50	75	9	Man
18	Sergeant	Charlie	55	85	13	Vrouw
19	Korporaal	Bravo	45	80	10	Man
20	Soldaat	Alpha	35	62	5	Vrouw
	Ordinaal	Nominaal	Ratio	Ratio	Ratio	Nominaal

Kwalitatieve en kwantitatieve variabelen

Kwalitatief:

- variabelen die een categorie beschrijven of een tekstuele waarde kunnen hebben

Kwantitatief:

- variabelen die een meetbare hoeveelheid / aantal (getal) als waarde kunnen hebben.

Zijn deze variabelen kwalitatief of kwantitatief?

ID	Rang	Eenheid	Oefeningstijd (min)	Schietscore (%)	Aantal missies	Geslacht
1	Sergeant	Bravo	45	85	12	Man
2	Korporaal	Alpha	60	92	8	Vrouw
3	Luitenant	Charlie	55	78	15	Man
4	Majoor	Bravo	70	88	20	Man
5	Soldaat	Alpha	30	65	5	Vrouw
6	Kapitein	Charlie	50	80	10	Vrouw
7	Sergeant	Bravo	65	90	18	Man
8	Soldaat	Alpha	40	72	6	Man
9	Soldaat	Charlie	35	70	4	Man
10	Kapitein	Bravo	75	95	25	Vrouw
11	Luitenant	Alpha	55	82	12	Man
12	Korporaal	Charlie	45	68	7	Vrouw
13	Sergeant	Bravo	60	88	14	Man
14	Majoor	Alpha	80	92	30	Vrouw
15	Soldaat	Charlie	25	60	3	Vrouw
16	Kapitein	Bravo	65	87	18	Man
17	Luitenant	Alpha	50	75	9	Man
18	Sergeant	Charlie	55	85	13	Vrouw
19	Korporaal	Bravo	45	80	10	Man
20	Soldaat	Alpha	35	62	5	Vrouw
	Kwalitatief	Kwalitatief	Kwantitatief	Kwantitatief	Kwantitatief	Kwalitatief

Maten van ligging (centrale tendens)

Als we een variabele in een dataset willen bestuderen, dan kunnen we kijken naar een “centrale waarde” voor die variabele.

- Gemiddelde
- Mediaan
- Modus

We bekijken hiervoor de schietscores van 20 militairen als voorbeeld.

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

Gemiddelde: schietscores

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

Tel de waarden $x_1, x_2, x_3, \ldots, x_{20}$ bij elkaar op en deel door het aantal waarden ($n = 20$):

Gemiddelde schietscore (%) = $\frac{\text{som}}{\text{aantal}} = \frac{x_1+x_2+\cdots+x_n}{n} = \frac{85+92+78+\cdots+62}{20} \approx 75{,}45$

Algemene formule: $\overline{x} = \frac{x_1+x_2+\cdots x_n}{n}$

Mediaan van schietscores

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

De mediaan is de **middelste waarde** in een rij van n uitkomsten

1. n is even ⇒ neem de **middelste waarde**
2. n is oneven ⇒ neem het gemiddelde van de **twee middelste waarden**.

Mediaan:

1. *Sorteer de waarden van laag naar hoog:*

Schietscore (%)	60	62	65	68	70	72	75	78	80	80	82	85	85	87	88	88	90	92	92	95

2. Het aantal waarden n *is even* ($n = 20$), *dus neem de twee middelste waarden 80 en 82.*

De mediaan is het gemiddelde van 80 en 82, oftewel 81.

Modus van schietscores

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

De modus is de **meest voorkomende waarde** (er kunnen meerdere modi zijn).

We kunnen dit beter zien als we de schietscores sorteren:

Schietscore (%)	60	62	65	68	70	72	75	78	80	80	82	85	85	87	88	88	90	92	92	95

Meerdere modi: $80, 85, 88, 92$ (komen elk 2x voor in de dataset)

Connectie met meetniveaus

Maten van ligging	Vereist meetniveau?
Gemiddelde	
Mediaan	
Modus	

Invloed van outliers op het gemiddelde

<u>Outliers</u>: extreme scores in vergelijking met de andere gegevens

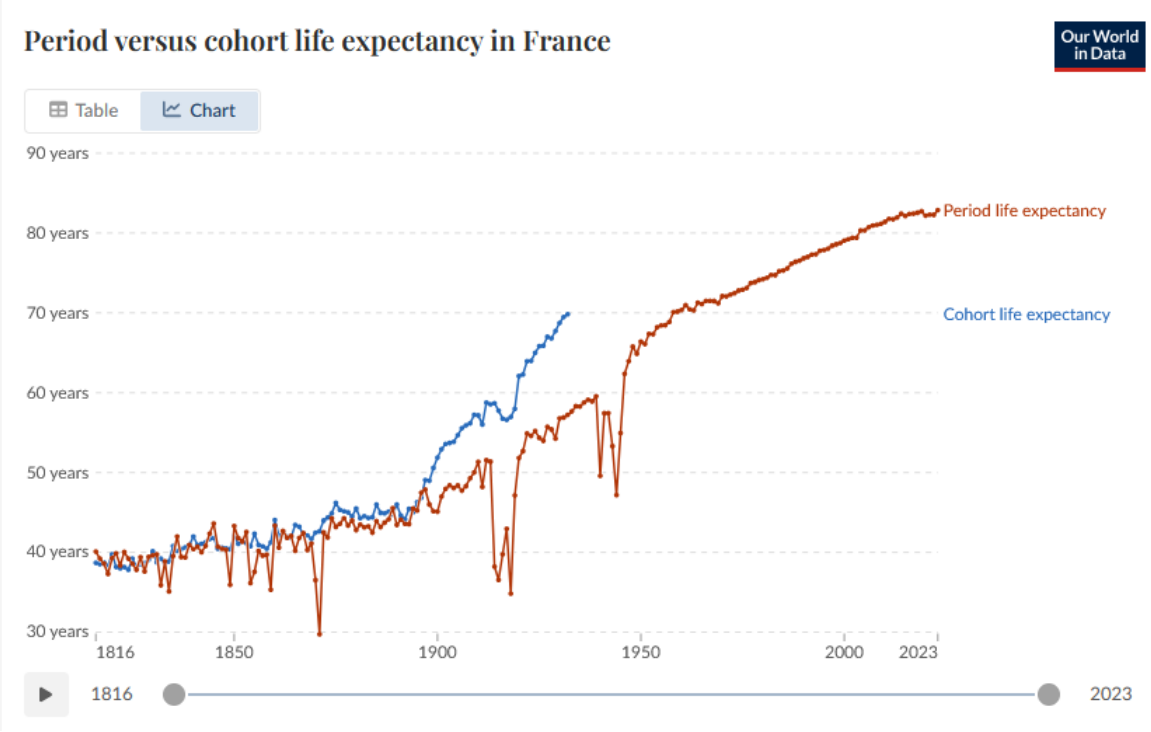

Wat zegt een outlier ons? Is het een meetfout, of een zeldzaam verschijnsel?

Verdelingen van data

Je kunt ook een frequentiediagram maken om de data te groeperen en te zien hoe vaak je deze waarneemt.
Hiermee kun je de vorm van de **verdeling** van deze data visualiseren.
De vorm van de verdeling zegt iets over hoe gemiddelde, modus en mediaan ten opzichte van elkaar liggen.

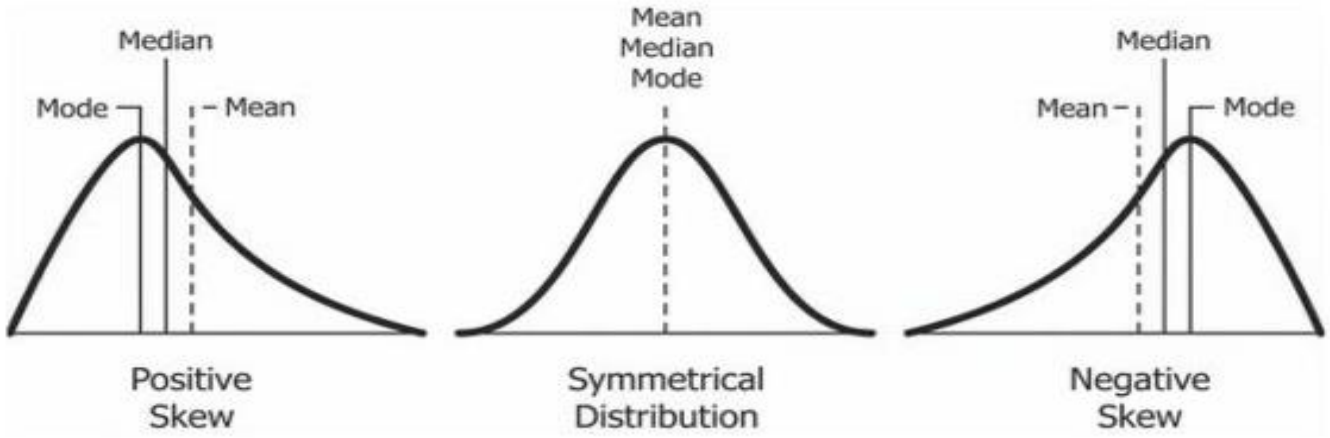

https://www.analyticsvidhya.com/blog/2020/07/what-is-skewness-statistics/

Samenvatting: centrale tendens

Gemiddelde	Mediaan	Modus

Buijs: opgave 2.4

Een docent heeft gedurende 20 weken geteld hoeveel studenten zijn lessen hebben bijgewoond. Dit leverde als aantallen:

30	36	32	28	38	25	27	37	34	31
20	33	24	35	22	19	29	35	30	25

a) Bereken voor deze gegevens het gemiddelde.
b) Bepaal de mediaan.
c) Bepaal de modus.

Buijs: opgave 2.4

30	36	32	28	38	25	27	37	34	31
20	33	24	35	22	19	29	35	30	25

a) **Gemiddelde**: $\overline{x} = \frac{\text{som}}{\text{aantal}} = \frac{\sum_{i=1}^{20} x_i}{20} = \frac{30+36+32+\cdots+30+25}{20} = \frac{590}{20} = 29.5.$

b) **Mediaan:**

- Sorteer van laag naar hoog:

  19-20-22-24-25-25-27-28-29-30-30-31-32-33-34-35-35-36-37-38

- Even aantal ($n = 20$): neem het gemiddelde van de twee middelste getallen:

$$\text{Mediaan} = \frac{30+30}{2} = 30$$

c) **Modus:** Er zijn drie getallen die het vaakst (2 keer) voorkomen, namelijk 25, 30 en 35.

Spreidingsmaten

We hebben net gezien hoe we “centrale waarden” kunnen bepalen, maar dit zegt niet zozeer iets over hoe dicht deze waarden bij elkaar liggen.

Hiervoor kijken we naar **spreidingsmaten**.

Lage mate van spreiding:
- consistente waardes
- hoge betrouwbaarheid van voorspellingen

Hoge mate van spreiding:
- inconsistente waardes
- lage betrouwbaarheid van voorspellingen

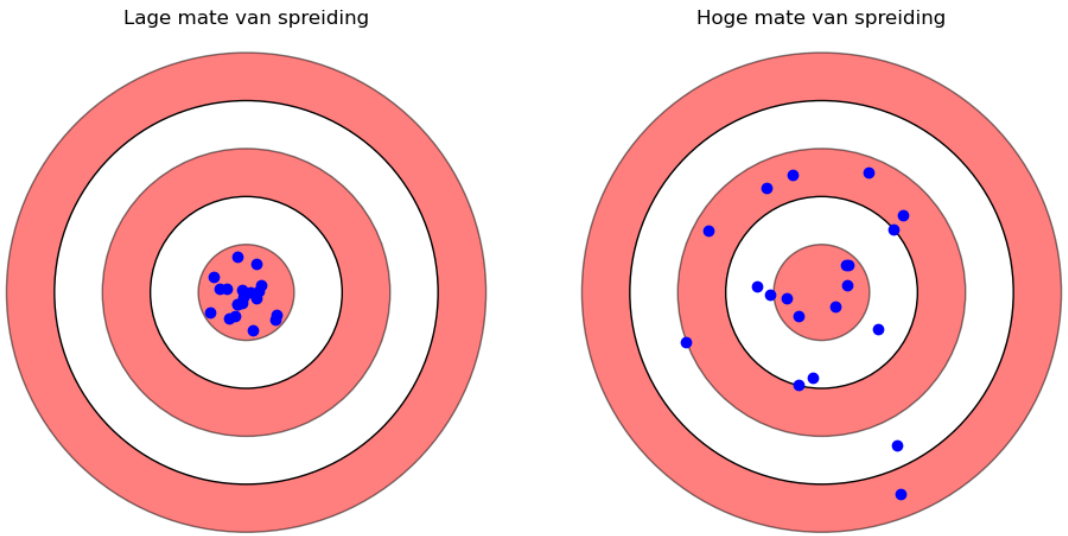

Bereik

De simpelste spreidingsmaat is het **bereik:**

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

$$\text{Bereik} = \text{hoogste waarde} - \text{laagste waarde} = 95 - 60 = 35$$

Wat zijn de voor- en nadelen van het bereik?

Interkwartiele afstand (interquartile range, IQR)

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

Bij de interkwartiele afstand (IQR) berekenen we het bereik van **de middelste helft van de data**:

1. Bereken de mediaan (middelste waarde).
2. Bereken de mediaan van de laagste 50% waarden (Q_1).
3. Bereken de mediaan van de hoogste 50% waarden (Q_3).
4. De interkwartielafstand is gelijk aan $\mathrm{IQR} = Q_3 - Q_1$.

Interkwartiele afstand (interquartile range, IQR)

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

1. Mediaan = 81 (eerder berekend)

2. Q_1: mediaan van de laagste 50% warden
   Laagste 50% (10) waardes: 60, 62, 65, 68, 70, 72, 75, 78, 80, 80 $\Rightarrow \mathrm{Q}_1 = \frac{70+72}{2} = 71.$

3. Q_3: mediaan van de hoogste 50% waarden
   Hoogste 50% (10) waardes: 82, 85, 85, 87, 88, 88, 90, 92, 92, 95 $\Rightarrow \mathrm{Q}_3 = \frac{88+88}{2} = 88.$

4. $\mathrm{IQR} = \mathrm{Q}_3 - \mathrm{Q}_1 = 88 - 71 = 17$

Interkwartiele afstand

Voordelen	Nadelen
• Betrouwbare spreidingsmaat, ook bij scheve verdelingen	• Negeert de informatie uit de laagste en hoogste 25% van de data
• Minder gevoelig voor outliers (kan zelfs worden gebruikt om outliers te detecteren)	• Geeft geen informatie over de spreiding in de “staarten” van de verdeling

Standaardafwijking

De **standaardafwijking** is een mate van spreiding die alle datapunten uit een dataset gebruikt.

- Gebaseerd op de afstand tussen een datapunt en het gemiddelde
- Specifiek: het *kwadraat* van de afstand

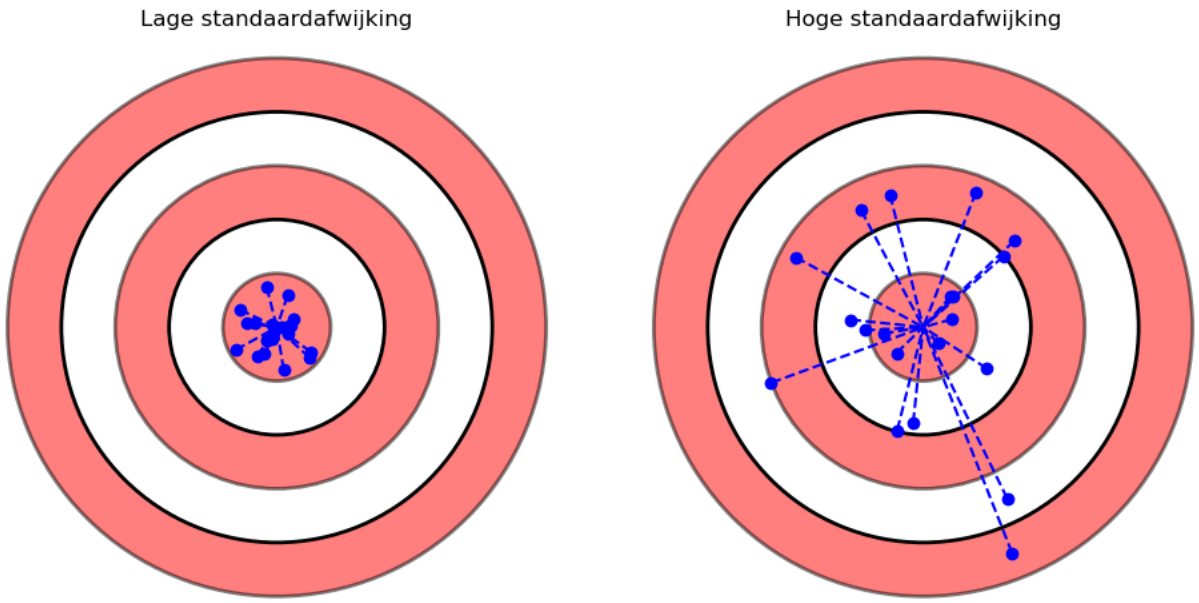

Tussenstap: variantie

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

Stap 1: bereken het gemiddelde: $\overline{x} = \frac{x_1+x_2+\cdots+x_{20}}{20} = \frac{60+62+65+\cdots+92+95}{20} = 79.7.$

Stap 2: bereken de kwadraten $(x_i - \overline{x})^2$ van de afstanden tot het gemiddelde:

x_i	Kwadratische afstand tot gemiddelde $(x_i - \overline{x})^2$
85	$(85 - 79.7)^2 = 28.09$
62	$(92 - 79.7)^2 = 151.29$
…	…

Stap 3: de variantie is een gemiddelde van deze kwadratische afstanden:

$$\text{variantie} = \frac{\sum_{i=1}^{20}(x_i - \overline{x})^2}{20} = \frac{28.09 + 151.29 + \cdots}{20} \approx 106.41.$$

Variantie

Voordelen	Nadelen
• Precieze mate van spreiding	• Kwadraten: outliers hebben uitvergroot effect
• Gebruikt alle datapunten	• Heeft een andere eenheid dan de data zelf, en is daardoor niet altijd makkelijk te interpreteren
• Handige theoretische eigenschappen	• Kost meer moeite om uit te rekenen (zeker voor grote datasets)

Notatie: voor een dataset met getallen $x_1, x_2, \dots, x_n$ berekenen we de variantie als

$$\sum_{i=1}^{n} \frac{(x_i - \overline{x})^2}{n}$$

Standaardafwijking

De **standaardafwijking** is sterk gerelateerd aan de variantie, namelijk de wortel van de variantie:

$$\text{standaardafwijking} = \sqrt{\text{variantie}}$$

***Voorbeeld*:** schietscores

ID	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
Schietscore (%)	85	92	78	88	65	80	90	72	70	95	82	68	88	92	60	87	75	85	80	62

$$\text{variantie} \approx 106.41.$$

$$\text{standaardafwijking} = \sqrt{\text{variantie}} = \sqrt{106.41} \approx 10.3155.$$

Standaardafwijking

Voordelen	Nadelen
• Heel informatief omdat de gehele dataset wordt gebruikt.	• Blijft nog steeds gevoelig voor outliers
• Eén waarde die makkelijk te begrijpen is (hoe kleiner de standaardafwijking, hoe dichter geclusterd de waarden zitten)	• Moeilijker om uit te rekenen vergeleken met het bereik en IQR
• Breed inzetbaar voor statistische analyses (samen met gemiddelde)	• Geeft een vertekend beeld met asymmetrische verdelingen (zoals niet-normale verdelingen)

Variantie en standaardafwijking: populatie versus steekproef

De standaardafwijking kan in twee gevallen bepaald worden, en daarbij is een subtiel verschil:

Standaardafwijking binnen een steekproef zelf

$$\sqrt{\frac{\sum_i (x_i - \overline{x})^2}{n}}$$

(n is de populatiegrootte)

Schatting voor de populatiestandaardafwijking op basis van de steekproef

$$\sqrt{\frac{\sum_i (x_i - \overline{x})^2}{n-1}}$$

(n is de steekproefgrootte)

Meestal hebben we te maken met het rechtergeval: binnen de statistiek gebruiken we een steekproef om iets over een populatiekenmerk te kunnen zeggen ⇒ delen door $n - 1$.

Wat is de standaardafwijking in de oefeningstijd (min) voor deze 10 militairen?

ID	Rang	Eenheid	Oefeningstijd (min)	Schietscore (%)	Aantal missies	Geslacht
1	Sergeant	Bravo	45	85	12	Man
2	Korporaal	Alpha	60	92	8	Vrouw
3	Luitenant	Charlie	55	78	15	Man
4	Majoor	Bravo	70	88	20	Man
5	Soldaat	Alpha	30	65	5	Vrouw
6	Kapitein	Charlie	50	80	10	Vrouw
7	Sergeant	Bravo	65	90	18	Man
8	Soldaat	Alpha	40	72	6	Man
9	Soldaat	Charlie	35	70	4	Man
10	Kapitein	Bravo	75	95	25	Vrouw

Wrapup

Hoe zou je de kennis die we vandaag hebben opgedaan kunnen toepassen op het voorbeeld van het Duitse tankprobleem?

- Populatie versus steekproef?
- Meetniveau van de variabele?
- Maten van ligging en spreiding?

Het Duitse tankprobleem

Het geschatte aantal tanks is

$$\widehat{N} = m + \frac{m}{k} - 1$$

waarbij

- m = hoogste waargenomen serienummer,
- k = het aantal waargenomen tanks

Maand	Schatting intelligence	Schatting intelligence + statistiek	Duitse rapporten
Jun 1940	1000	169	122
Jun 1941	1550	244	271
Aug 1942	1550	327	342

Ruggles, R.; Brodie, H. (1947).
"An Empirical Approach to Economic Intelligence in World War II".
Journal of the American Statistical Association.
42 (237): 72. doi:10.1080/01621459.1947.10501915. JSTOR 2280189.

Volgend college

- Datavisualisatie

Huiswerk:

- Lezen van A. Buijs: hoofdstuk 1.1 (blz. 13-20), 2.1 (blz. 65-70), 2.3 (blz. 74-76)
- Opdrachten uit *"Statistiek om mee te werken: opgaven en uitwerkingen"*:
  - H1: m1, m2, 3, 4
  - H2: m1, m2, m3, m4, m5, m6, 9, 10, 20