Defensie Ondersteuningscommando
Ministerie van Defensie

Statistiek: college 1b

Datavisualisatie

DOSCO
Nederlandse Defensie Academie
Dr. ir. D. Blom / Dr. M. van Ee
Faculteit Militaire Wetenschappen

college 1b: datavisualisatie

Florence Nightingale: the data-driven nurse

https://nl.wikipedia.org/wiki/Florence_Nightingale#/media/Bestand:Florence_Nightingale_(H_Hering_NPG_x82368).jpg

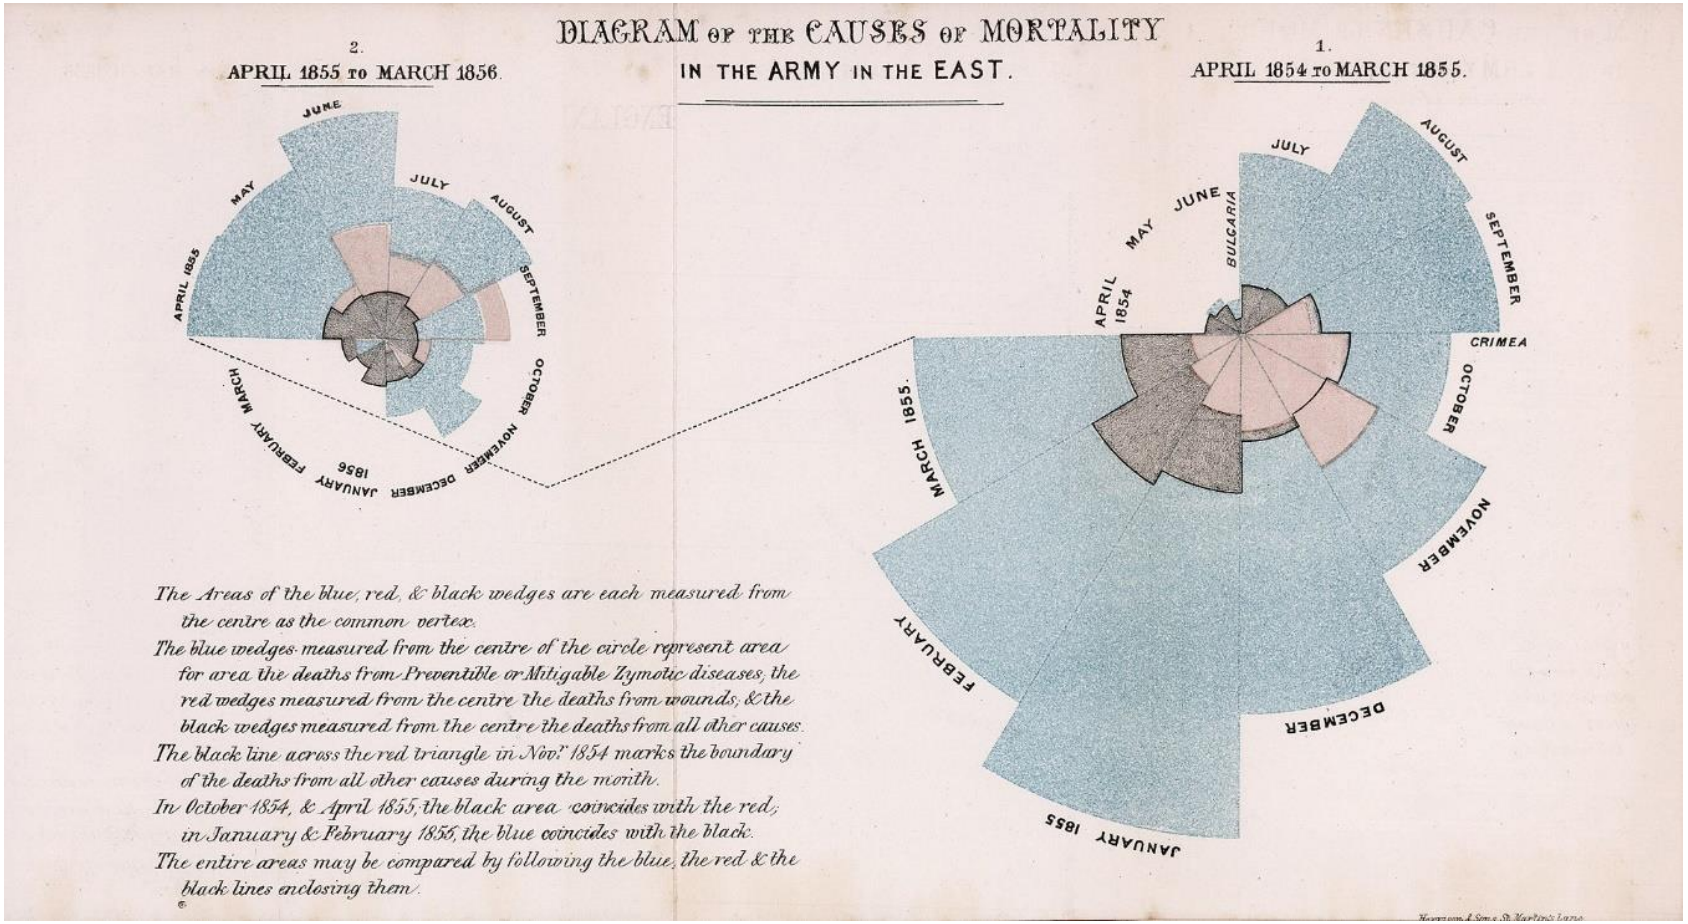

https://nl.wikipedia.org/wiki/Florence_Nightingale#/media/Bestand:Nightingale-mortality.jpg

Florence Nightingale: the data-driven nurse

Maand	Overleden door infectieziektes	Overleden aan verwondingen	Overleden door andere oorzaken
Apr 1854	1	0	5
Mei 1854	12	0	9
Jun 1854	11	0	6
Jul 1854	359	0	23
Aug 1854	828	1	30
Sep 1854	788	81	70
Okt 1854	503	132	128
Nov 1854	844	287	106
Dec 1854	1725	114	131
...	...	...	...
Dec 1855	91	18	28
Jan 1856	42	2	48
Feb 1856	24	0	19
Maa 1856	15	0	35

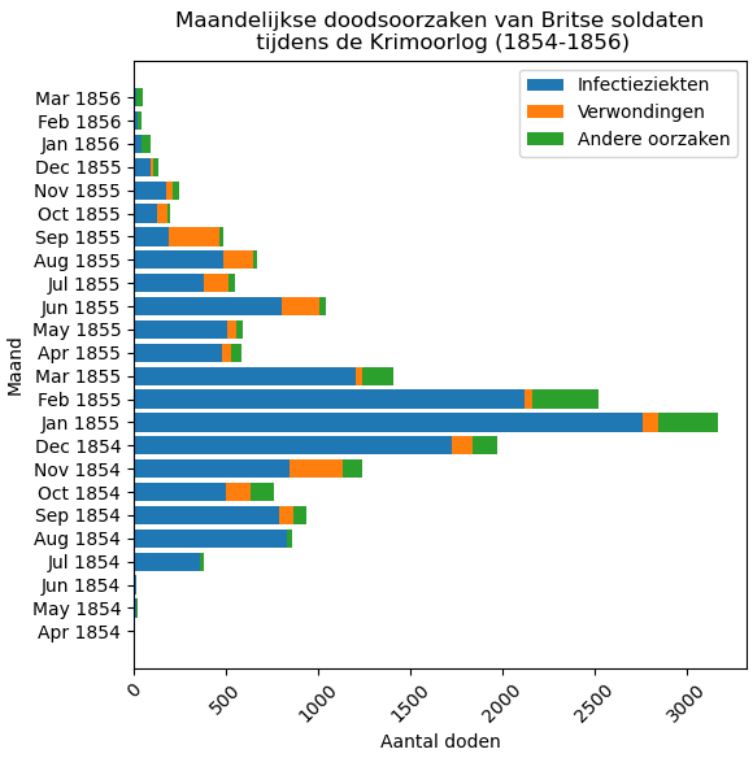

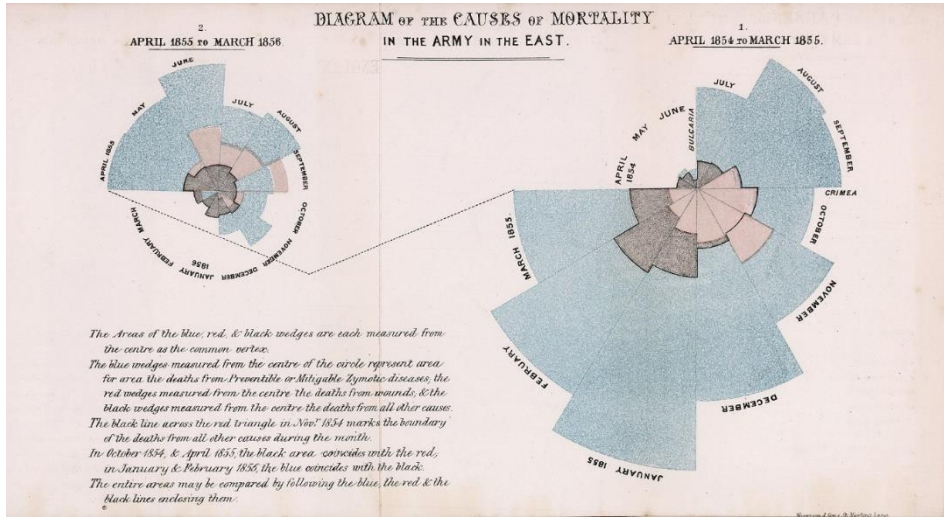

Vorige week

- Belang van statistiek
- Meetniveaus
- Types variabelen
- Maten van ligging en spreiding

Leerdoelen

Aan het eind van dit college kun je:

- De meest voorkomende typen datavisualisatie (staafdiagram, histogram, cirkeldiagram, boxplot en spreidingsdiagram) *koppelen* aan het bijbehorende meetniveau en visualisatiedoel.
- Op basis van concrete kenmerken van de data (zoals het meetniveau van variabelen) en het visualisatiedoel een passend type visualisatie *kiezen* en deze keuze *toelichten*.
- Specifieke kenmerken van misleidende visualisaties *benoemen* zoals gemanipuleerde assen, ongeschikte diagramkeuze of bewust weglaten van data en *uitleggen* welk effect deze hebben op de interpretatie.

Vandaag: datavisualisatie

Datavisualisatie is het “gebruiken van een visueel format (grafiek, diagram, kaart, …) om complexe datasets op een gemakkelijker te begrijpen manier te presenteren.”

één beeld zegt meer dan duizend woorden.

Nightingale’s visualisaties vormen de basis van **data storytelling**:

- Blootleggen van een probleem (te veel sterfgevallen onder Britse soldaten)
- Ontdekken van de oorzaak (vermijdbare ziektes door gebrekkige ziekenzorg)
- Overtuigen van beleidsmakers (“audience-driven design”)

Datavisualisatie binnen Defensie

Datavisualisatie is het “gebruiken van een visueel format (grafiek, diagram, kaart, …) om complexe datasets op een gemakkelijker te begrijpen manier te presenteren”.

- Helpt bij besluitvorming en het verkrijgen van *situational awareness* in complexe situaties
- Ontdekken van patronen en trends in bv. inlichtingen, logistiek en operationele gereedheid.
- Communiceren van complexe informatie (bv. aan commandanten of eenheden).

Verschillende vormen van datavisualisaties

- **Tabellen:** frequentietabellen, kruistabellen, …
- **Diagrammen:** boxplots, staafdiagram, cirkeldiagram
- **Grafieken:** lijngrafiek, spreidingsdiagram
- **Kaarten:** geografische kaarten, heatmaps, …

(Synthetische) dataset: gereedheid voor Hoofdtaak 1

Type eenheid	Personeel inzetbaar (%)	Opleiding voltooid (%)	Materiële beschikbaarheid (%)	Onderhouds-status	Ondersteunings-niveau	Inzetstatus	Gereedheids-score
Infanterie	92	88	85	Goed	Hoog	Stand-by	86
Artillerie	85	82	80	Goed	Medium	Stand-by	80
Genie	78	75	70	Matig	Medium	Inzet	70
Luchtmobiel	90	90	88	Goed	Hoog	Stand-by	85
Logistiek	95	92	93	Uitstekend	Hoog	Reserve	92
Infanterie	92	88	85	Goed	Hoog	Stand-by	86
Artillerie	85	82	80	Goed	Medium	Stand-by	80
…	…	…	…	…	…	…	…

Wanneer gebruik je welke visualisatie?

Belangrijke factoren bij het kiezen van een visualisatie:

Op welk meetniveau zijn de variabelen in je dataset?

- nominaal, ordinaal, interval of ratio

Welk doel wil je bereiken met de visualisatie?

- Vergelijking tussen populaties
- Trend over de tijd
- Verdeling van de data bepalen
- Relatie tussen variabelen
- Samenstelling van de data

Frequentietabellen

Meetniveau: nominaal

Doel: patroon beschrijven van een reeks waarden door per waarde (categorie) te tellen hoe vaak deze waarden (relatief) voorkomen in de data.

Onderhouds-status
Matig
Goed
Matig
Goed
Uitstekend
Goed
Onvoldoende
…

→

Categorie	Absolute frequenties ($n = 125$)	Relatieve frequenties ($n = 125$)
Uitstekend	39	$\frac{31}{125} * 100\% = 24{,}8\%$
Goed	43	$\frac{43}{125} * 100\% = 34{,}4\%$
Matig	27	$\frac{27}{125} * 100\% = 21{,}6\%$
Onvoldoende	16	$\frac{16}{125} * 100\% = 12{,}8\%$

Kruistabellen

Meetniveau: twee nominale variabelen

Doel: frequentieverdeling beschrijven van combinaties van waarden voor twee variabelen.

Type eenheid	Onderhouds-status
Infanterie	Goed
Artillerie	Goed
Genie	Matig
Luchtmobiel	Goed
Logistiek	Uitstekend
Infanterie	Goed
Artillerie	Goed
…	…

→

		Onderhoudsstatus				
		Uitstekend	Goed	Matig	Onvoldoende	Totaal
Type eenheid	Artillerie	0	9	10	3	**22**
	Geneeskundige keten	20	0	0	0	**20**
	Genie	0	7	10	3	**20**
	Infanterie	0	12	7	4	**23**
	Logistiek	19	0	0	1	**20**
	Luchtmobiel	0	15	0	5	**20**
	Totaal	**39**	**43**	**27**	**16**	**125**

Staafdiagrammen

Meetniveau: nominaal of ordinaal

Doel: vergelijken van (relatieve) frequenties tussen waarden van een nominale variabele.

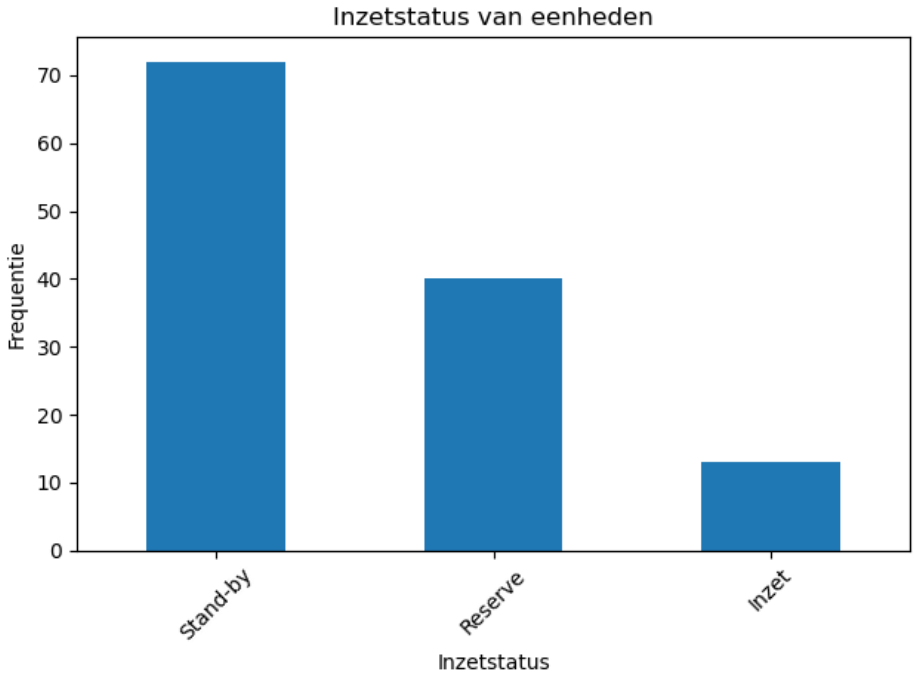

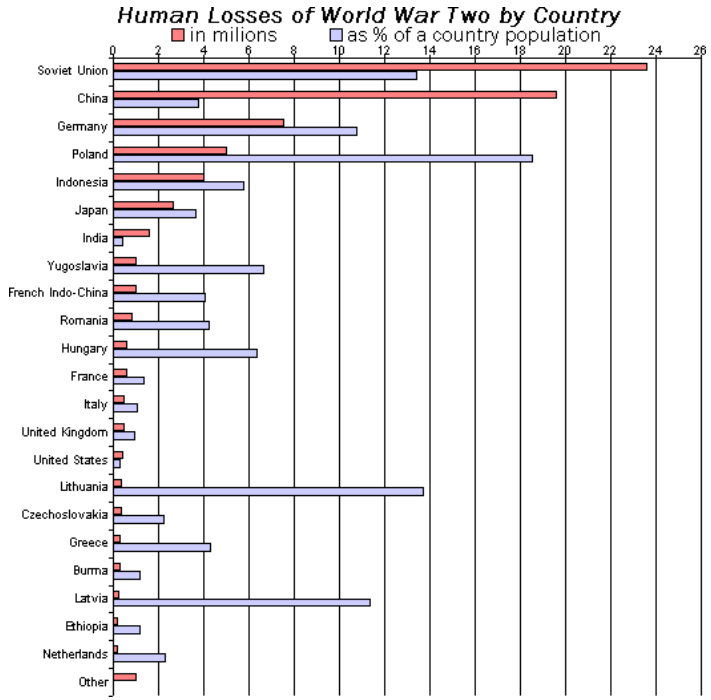

Gestapelde staafdiagrammen

Meetniveau: twee nominale variabelen.

Doel: visualiseren van data van een nominale variabele, gegroepeerd op een tweede nominale variabele.

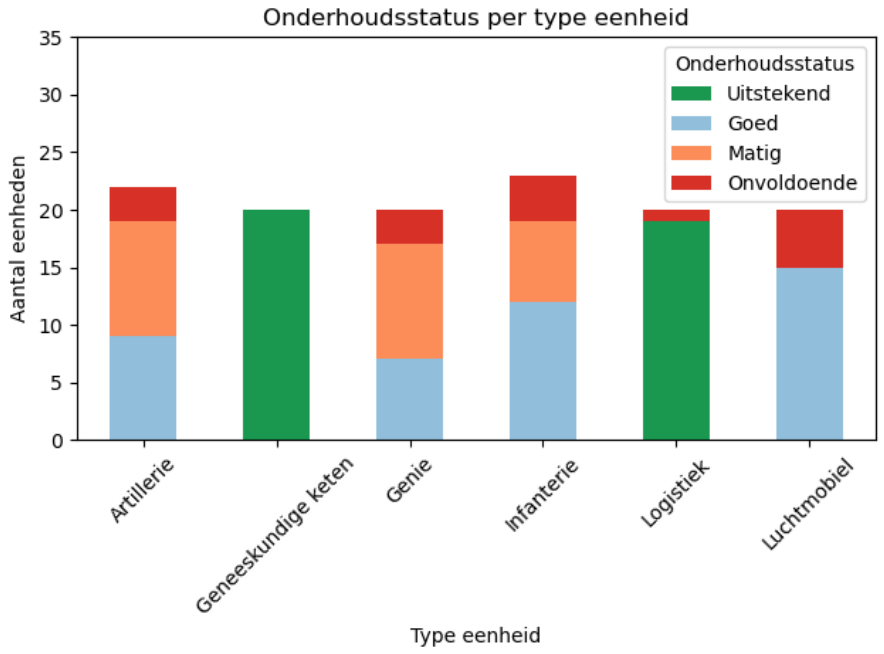

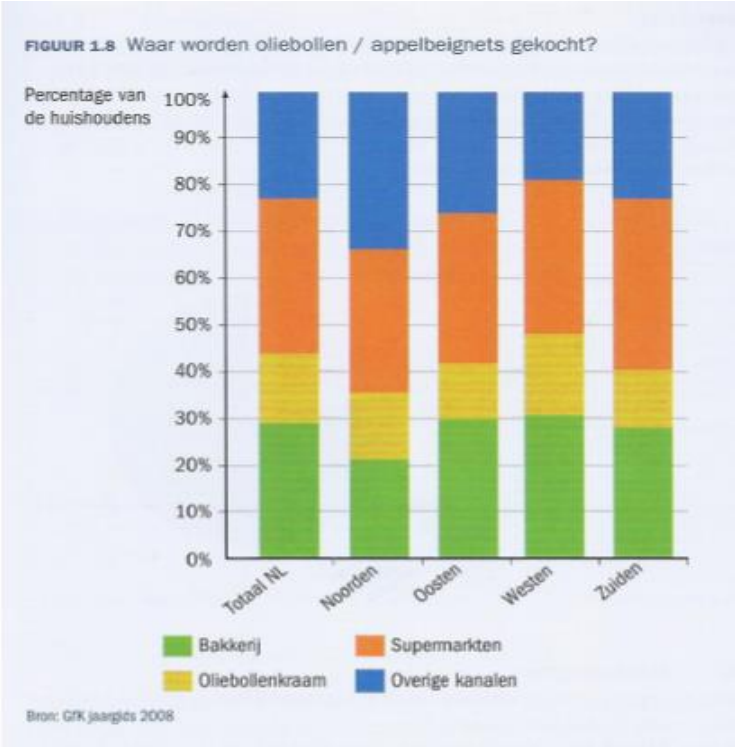

Cirkeldiagram

Meetniveau: nominaal

Doel: in beeld brengen van de relatieve frequenties van een nominale variabele.

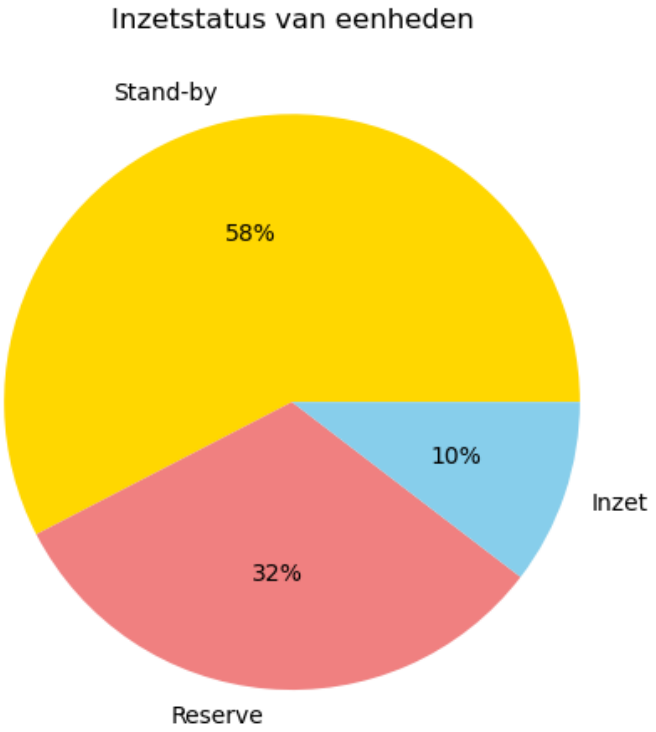

Histogrammen

Meetniveau: interval

Doel: weergeven van de verdeling in klassen gegroepeerde data op intervalniveau.

Gereedheids-score
86
80
70
85
92
86
80
...

Opdelen in klassen →

Gereedheids-score	Absolute frequenties	Relatieve frequenties
< 65	1	0,8%
65 -< 70	7	5,6%
55 -< 75	29	23,2%
60 -< 80	25	20%
65 -< 85	18	14,4%
70 -< 90	13	10,4%
75 -< 95	23	18,4%
≥ 95	9	7,2%

Histogram →

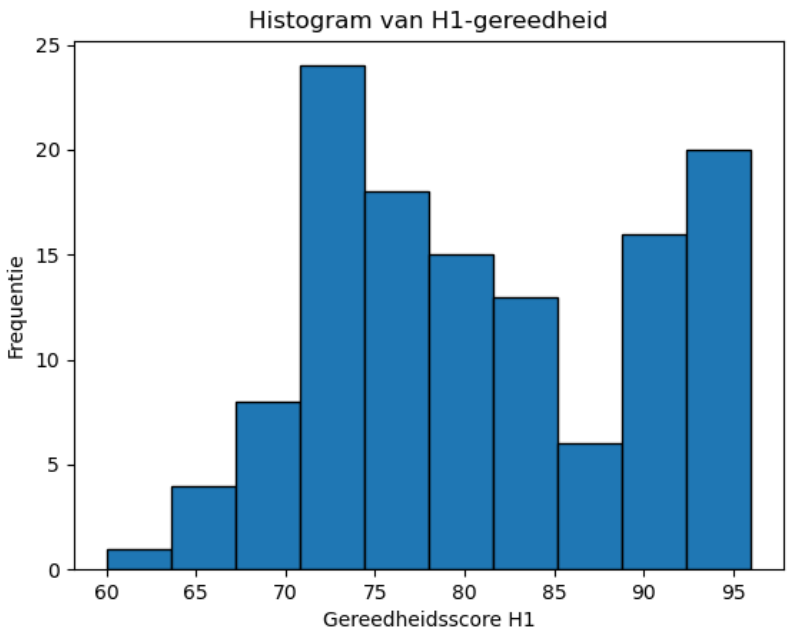

Histogrammen

Vuistregel: n waarnemingen → histogram met $\approx \sqrt{n}$ klassen

Te weinig bins

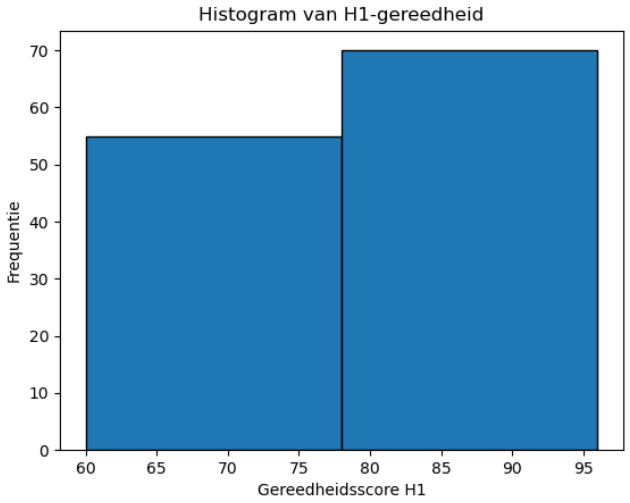

Te veel bins

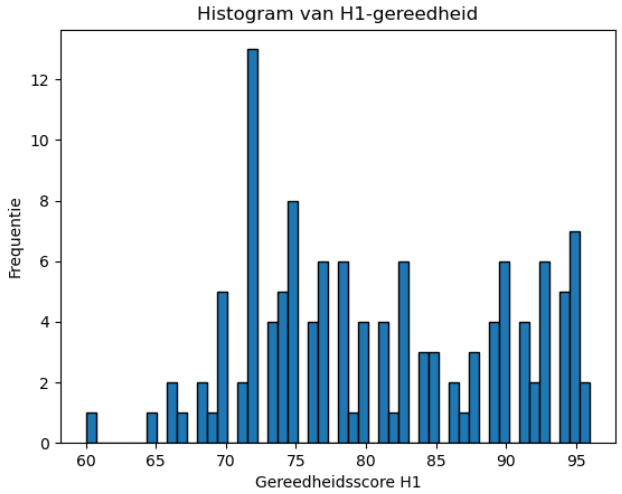

Goed

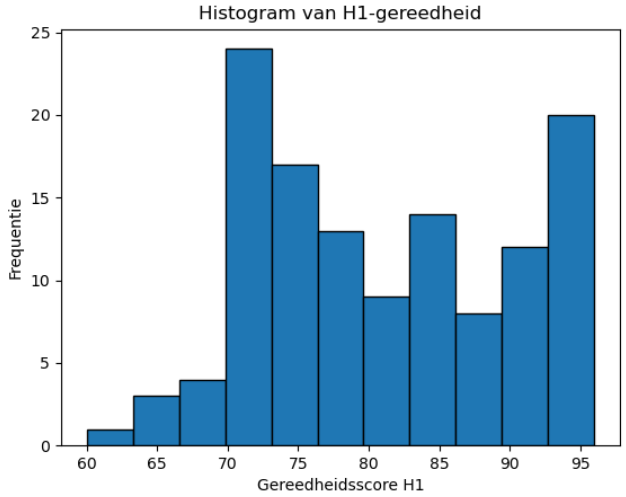

Verschil tussen staafdiagram en histogram

Staafdiagram

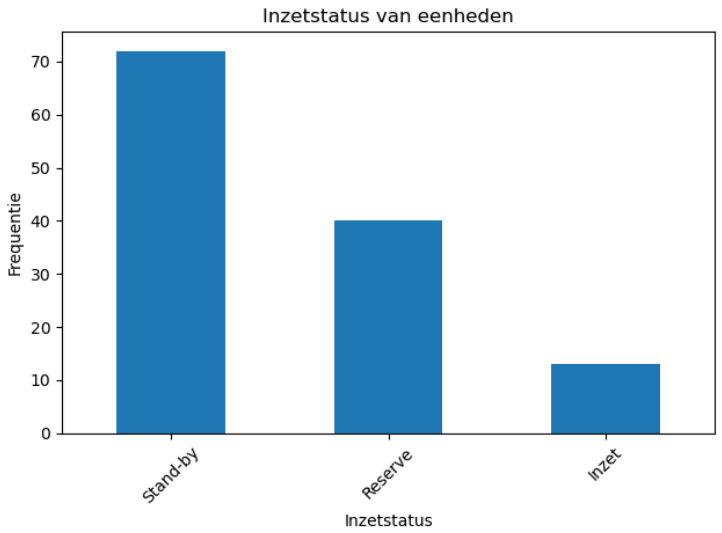

Gebaseerd op **discrete** data (nominaal / ordinaal)

Staven staan los van elkaar (categorieën)

Categorieën kunnen worden herschikt in volgorde

Histogram

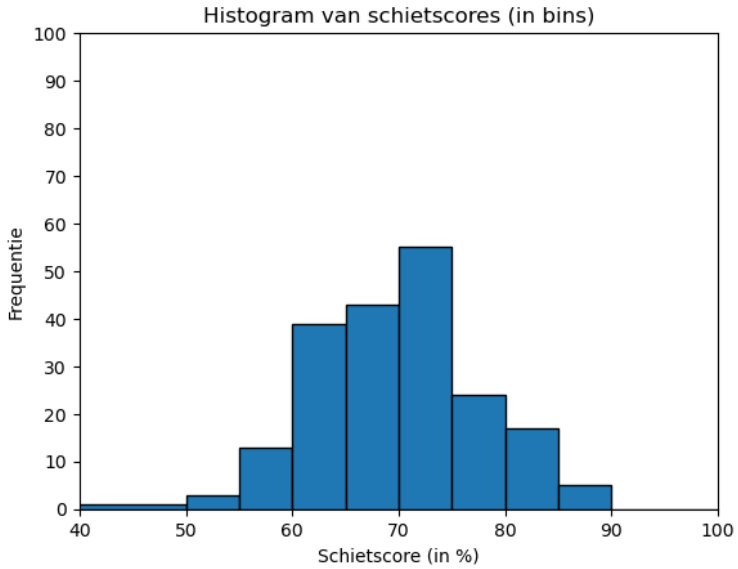

Gebaseerd op **continue** data (interval / ratio)

Staven staan tegen elkaar aan (gegroepeerde dataklassen)

Categorieën kunnen niet worden herschikt (vaste numerieke volgorde)

Scatter plot (spreidingsdiagram)

Meetniveau: twee ratiovariabelen

Doel: weergeven van patronen en relaties tussen twee variabelen met een 2D-puntenwolk

Opleiding voltooid (%)	H1-gereedheids-score (0-100)
88	86
82	80
75	70
90	85
92	92
...	...
76	73
86	85
90	90
94	93
74	72

→

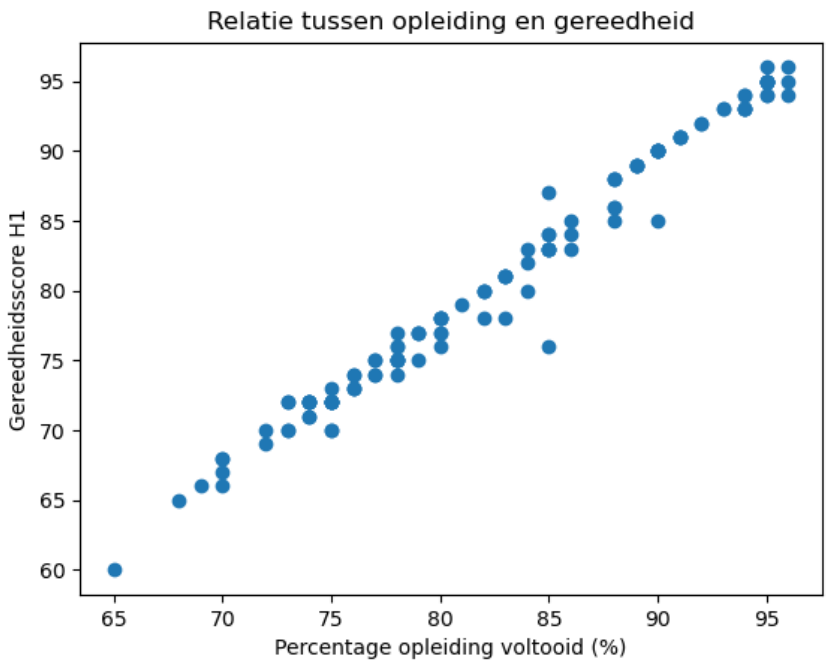

Correlatie en regressie

Vooral handig voor het effect tussen twee variabelen te duiden.

Stijgende lijn: er is een **positieve correlatie** tussen het “percentage personeel in een eenheid dat de benodigde opleiding heeft voltooid” en “gereedheidsscore voor Hoofdtaak 1”.

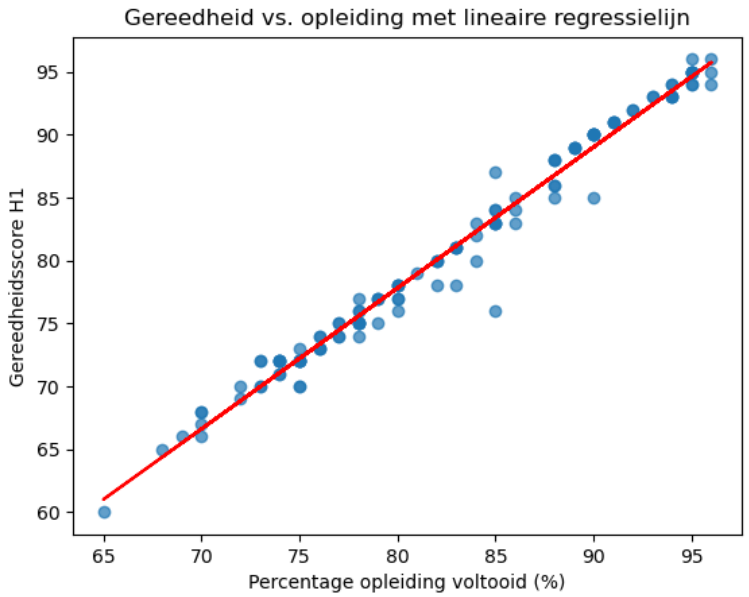

Boxplot

Meetniveau: minimaal interval
Doel: verdeling van data visualiseren aan de hand van vijf beschrijvende statistieken:

- Minimum
- Q1: mediaan van laagste 50% waarden
- Q2: mediaan
- Q3: mediaan van hoogste 50% waarden
- Maximum
- Soms: uitbijters

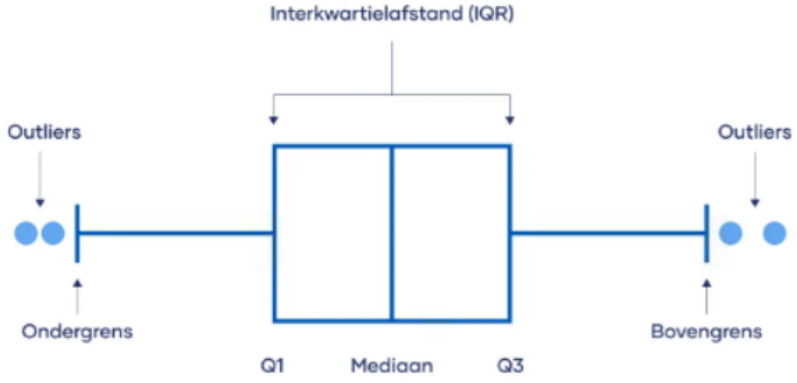

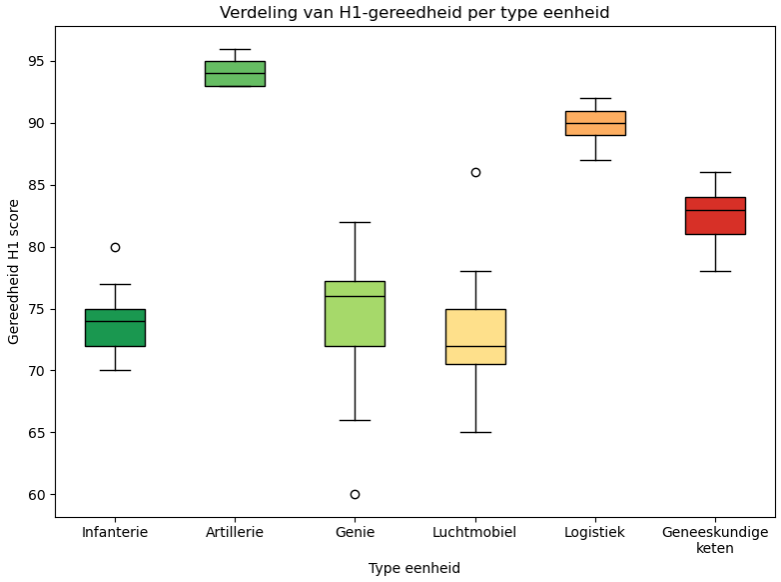

Onbetrouwbare / misleidende visualisaties

Blijf altijd kritisch kijken naar data en visualisaties:

- Wat vertellen ze je echt? Wordt de boodschap ook daadwerkelijk effectief gecommuniceerd?

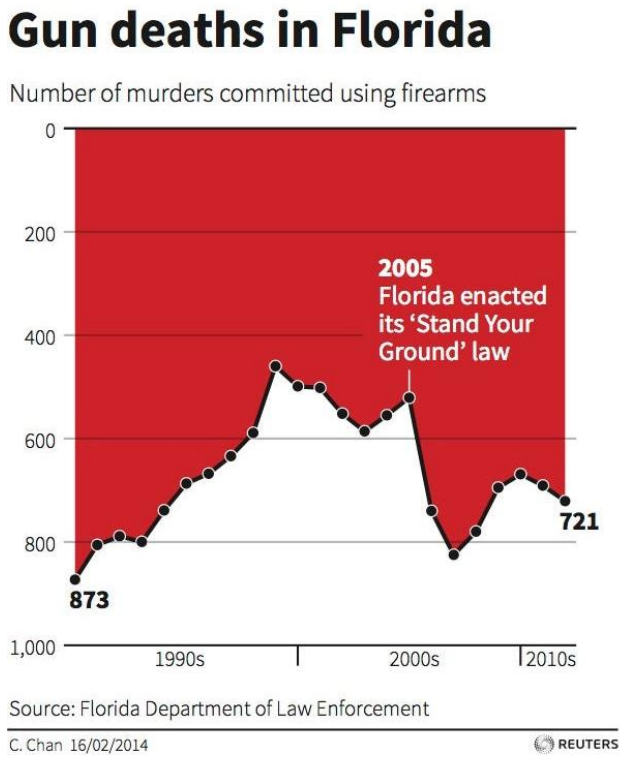

https://www.plecto.com/blog/dashboard-design/6-examples-bad-data-visualizations/

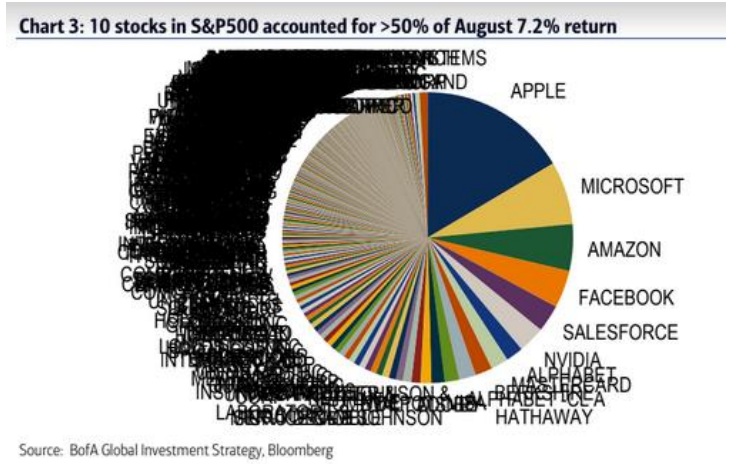

https://www.reddit.com/r/dataisugly/comments/ir3lum/now_every_time_i_make_a_case_against_pie_charts/#lightbox

Onbetrouwbare visualisaties

Blijf altijd kritisch kijken naar visualisaties: wat vertellen ze je echt?

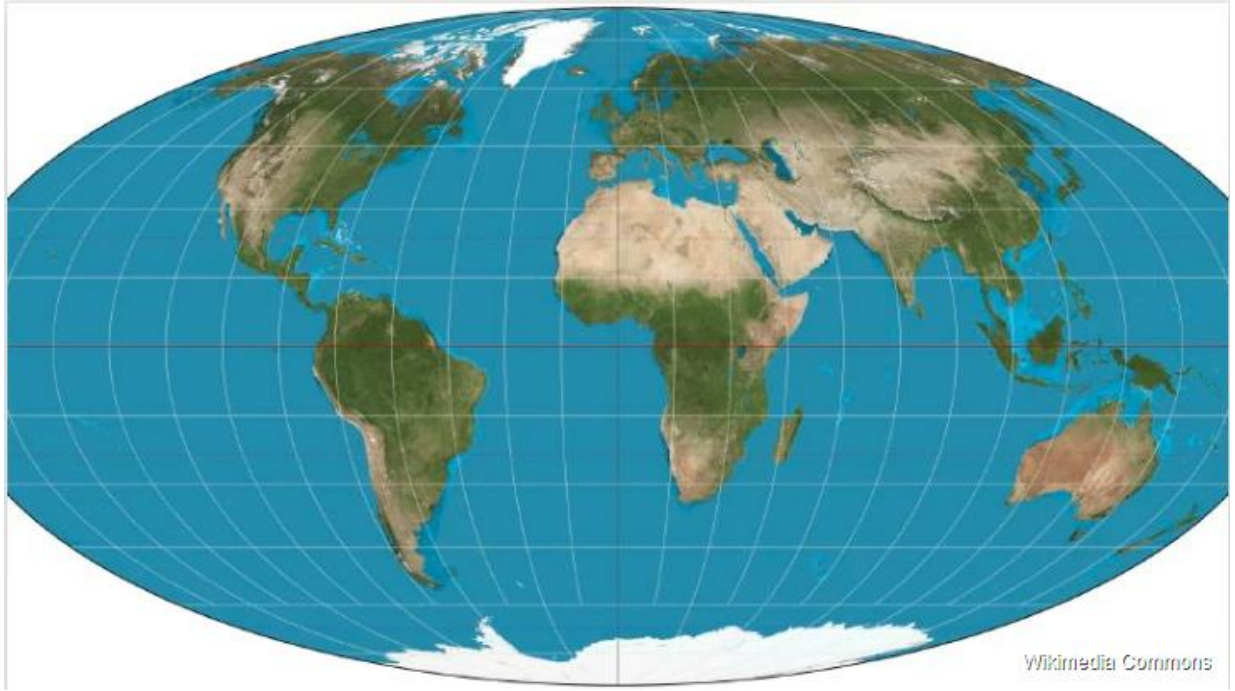

https://www.grunge.com/276947/why-greenland-is-way-smaller-than-it-appears-on-most-maps/

Onbetrouwbare visualisaties

Disclaimer: fictieve cijfers, puur ter illustratie van het principe

Veelgemaakte fout / truc (?): assen starten niet op hun nulpunt

Dramatische daling?

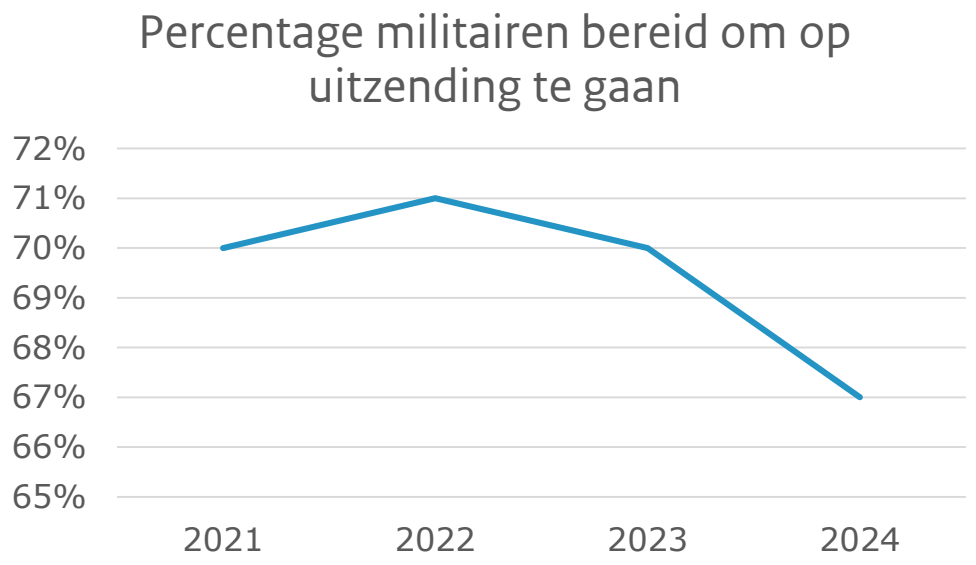

Of valt het mee?

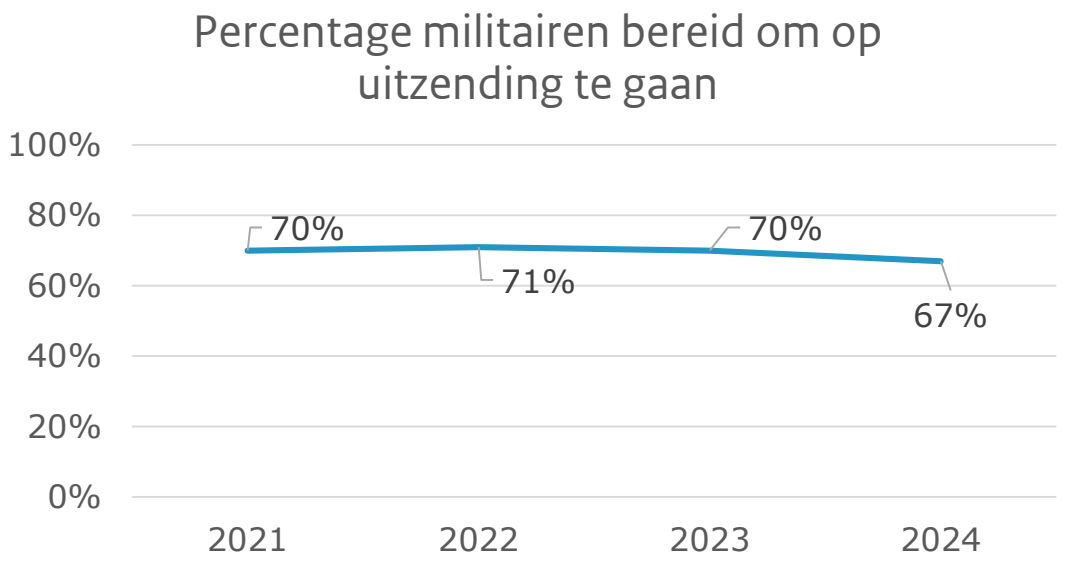

!

Onbetrouwbare visualisaties

1. Wie is de maker van de visualisatie? Heeft hij/zij een belang bij het achterwege laten van data om een onbetrouwbaar verhaal te vertellen?

2. Wat is het beoogde doel van een visualisatie?

3. Wat is de verdeling / bereik van de assen? Lineair, logaritmisch, nulpunt?

4. Is de gekozen vorm van visualisatie het meest geschikt?

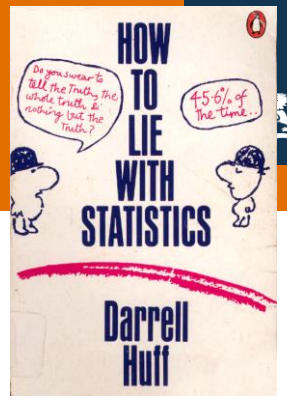

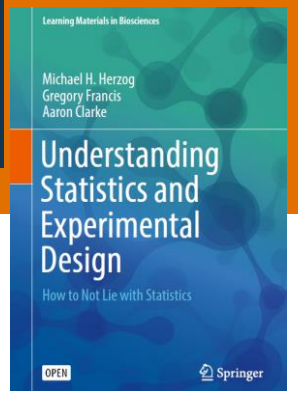

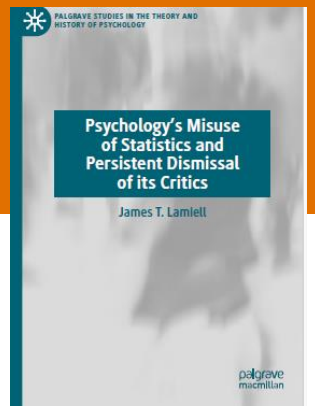

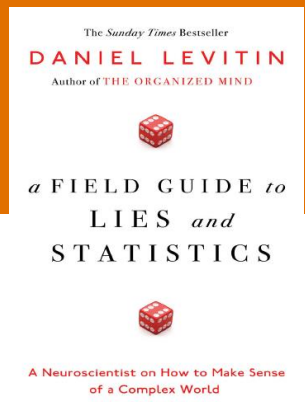

Samenvatting

We kunnen nu de volgende vragen beantwoorden:

- Welk type datavisualisatie hoort bij welke soort data?
- Hoe onderbouw je de keuze van je visualisatie?
- Hoe herken je misleidende visualisaties?

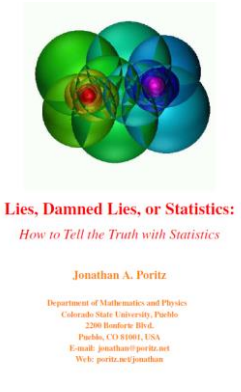

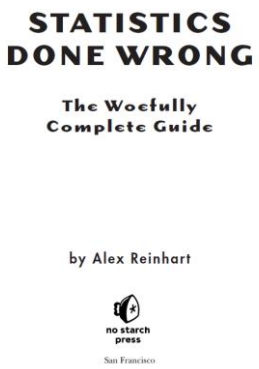

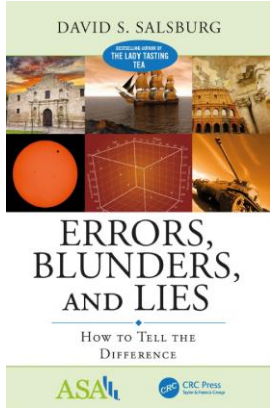

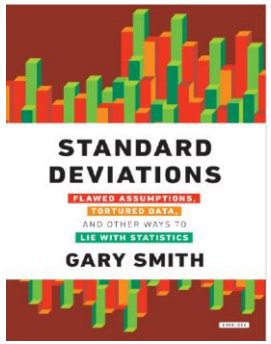

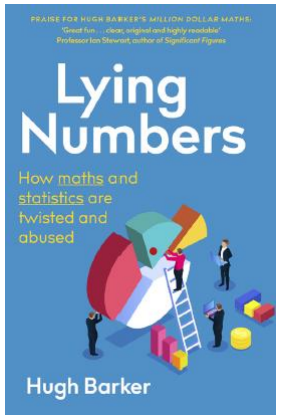

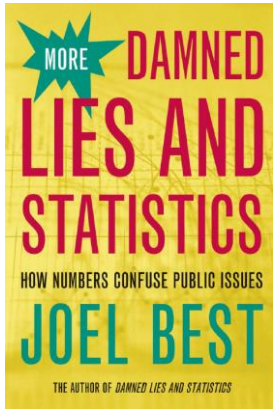

Volgend college

- Introductie kansrekening
- Discrete kansvariabelen

Huiswerk:

- Lezen van A. Buijs: 1.2 (blz. 20-25), 1.3 (blz. 30-35), 1.4 (blz. 35-40), 1.5 (blz. 40-47)
- Opdrachten uit *"Statistiek om mee te werken: opgaven en uitwerkingen"*:
  - H1: 7, 15
  - H2: 20