Defensie Ondersteuningscommando
Ministerie van Defensie

Statistiek: college 5b

De centrale limietstelling

DOSCO
Nederlandse Defensie Academie
Dr. ir. D. Blom / Dr. M. van Ee
Faculteit Militaire Wetenschappen

21 mei 2026

Recap

- Discrete kansvariabelen ("tellen")
  - Uitkomstenruimte bevat een *eindig / aftelbaar oneindig* aantal mogelijke uitkomsten
  - Kansfunctie $p(k) = P(X = k)$
  - Kansen op een specifieke uitkomst / intervallen

- Continue kansvariabelen ("meten")
  - Uitkomstenruimte bevat een *overaftelbaar oneindig* aantal mogelijke uitkomsten
  - Kansdichtheidsfunctie (PDF) $f(x) \neq P(X = x)$
  - Kansen zijn alleen zinnig op intervallen

- Specifieke kansverdelingen:
  - Discreet: Bernoulli- en binomiale verdeling
  - Continu: normale verdeling

Leerdoelen

Aan het eind van dit college kan de student:

- De belangrijkste eigenschappen van sommen en gemiddelden van kansvariabelen benoemen
- Kansen uitrekenen in situaties waarin de centrale limietstelling kan worden gebruikt.
- De betekenis en consequenties van de centrale limietstelling in eigen woorden uitleggen.

Voorbeeld

Een militaire commandant moet inschatten hoeveelbrandstof nodig is voor een konvooi van 100 pantservoertuigen tijdens een missie van 500 km.

- Het brandstofverbruik van een enkel voertuig is willekeurig en afhankelijk van externe factoren zoals terrein, snelheid en belasting.
- Een beschrijving van de kansverdeling van het verbruik per voertuig hoeft niet bekend te zijn, behalve gemiddelde en standaardafwijking
- Het brandstofverbruik van een voertuig is onafhankelijk van andere voertuigen.

Kun je iets zeggen over de kansverdeling van het totale brandstofverbruik?

Voorbeeld

Stel dat X_i de kansvariabele is die het brandstofverbruik meet van voertuig $i = 1, 2, \ldots, 100$

- **Wat is de kansverdeling van het gemiddelde** $\overline{\boldsymbol{X}} = \frac{\boldsymbol{X_1 + X_2 + \cdots + X_{100}}}{\mathbf{100}}$

- **Wat is de kansverdeling van de som** $\sum \boldsymbol{X} = \boldsymbol{X_1} + \boldsymbol{X_2} + \cdots + \boldsymbol{X_{100}}$?

Centrale limietstelling

Als de kansvariabelen $X_1, X_2, \dots, X_n$ dezelfde kansverdeling hebben met gemiddelde μ en standaardafwijking σ, dan geldt (bij benadering) dat:

- het gemiddelde $\overline{X}$ normaal verdeeld is met gemiddelde μ en standaardafwijking $\frac{\sigma}{\sqrt{n}}$

$$\overline{X} = \frac{X_1 + X_2 + \cdots + X_n}{n} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

- de som $\sum_{i=1}^{n} X_i$ normaal verdeeld is met gemiddelde $n \cdot \mu$ en standaardafwijking $\sqrt{n} \cdot \sigma$

$$\sum_{i=1}^{n} X_i = X_1 + X_2 + \cdots + X_n \sim N(n \cdot \mu, \sqrt{n} \cdot \sigma)$$

Merk op: we gebruiken alleen μ en σ!

Voorbeeld

Stel dat X_i de kansvariabele is die het brandstofverbruik meet van voertuig $i = 1, 2, \dots, 100$

- Wat is de kansverdeling van het gemiddelde brandstofverbruik $\overline{X} = \frac{X_1 + X_2 + \cdots + X_{100}}{100}$
  - **Centrale limietstelling:** $\overline{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right) = N\left(\mu, \frac{\sigma}{10}\right)$

- Wat is de kansverdeling van het totale brandstofverbruik $\sum_{i=1}^{n} X_i = X_1 + X_2 + \cdots + X_{100}$?
  - **Centrale limietstelling:** $\sum_{i=1}^{n} X_i \sim N(n \cdot \mu, \sigma \cdot \sqrt{n}) = N(100 \cdot \mu, 10 \cdot \sigma)$

Interactieve simulatie van de centrale limietstelling

https://interactive-cls.streamlit.app

Consequenties

- Vaak heel complex om de kansverdeling van $\sum_{i=1}^{n} X_i$ te bepalen (n –voudige integralen)
  - **Centrale limietstelling:** kansverdeling is goed te benaderen met een normale verdeling

- Maakt analyse van complexe kansexperimenten veel gemakkelijker

- **Later dit vak:** betrouwbaarheidsintervallen en hypothesetoetsen m.b.v. normale verdeling

Buijs: opgave 5.12

De tijd die een vertegenwoordiger nodig heeft voor het bezoeken van een klant wordt weergegeven door de kansvariabele X. Op grond van ervaring is bekend dat X normaal verdeeld is met $\mu = 45$ minuten en $\sigma = 10$ minuten (in de tijdsduur x is ook de reistijd opgenomen). De tijdsduren van bezoeken zijn onderling onafhankelijk.

a) Hoe groot is de kans dat een willekeurig bezoek meer dan 60 minuten vergt?

Buijs: opgave 5.12

a) Hoe groot is de kans dat een willekeurig bezoek meer dan 60 minuten vergt?

Gegeven is dat $X \sim N(\mu = 45,\ \sigma = 10)$. De kans dat een willekeurig bezoek meer dan 60 minuten vergt is dus $P(X > 60)$.

De z-score van $x = 60$ gegeven $X \sim N(\mu = 45, \sigma = 10)$ is gelijk aan

$$z = \frac{x - \mu}{\sigma} = \frac{60 - 45}{10} = 1.5.$$

Hierdoor geldt dus

$$P(X > 60) = P(Z > 1.5) = \text{normalcdf}(a = 1.5, b = 10^{99}, \mu = 0, \sigma = 1) \approx 0.0668.$$

Met 6.68% kans vergt een willekeurig bezoek meer dan 60 minuten.

Buijs: opgave 5.12

De tijd die een vertegenwoordiger nodig heeft voor het bezoeken van een klant wordt weergegeven door de kansvariabele X. Op grond van ervaring is bekend dat X normaal verdeeld is met $\mu = 45$ minuten en $\sigma = 10$ minuten (in de tijdsduur x is ook de reistijd opgenomen). De tijdsduren van bezoeken zijn onderling onafhankelijk.

b) Hoe groot is de kans dat acht bezoeken meer dan $6\frac{1}{2}$ uur vergen?

b) Hoe groot is de kans dat acht bezoeken meer dan $6\frac{1}{2}$ uur vergen?

De kansvariabele X_i meet de bezoektijd aan klant i, waarbij $i = 1, 2, \ldots, 8$.

Centrale limietstelling: de som $\sum_{i=1}^{8} X_i = X_1 + X_2 + \cdots + X_8$ is normaal verdeeld is met:

- Gemiddelde $n \cdot \mu = 8 \cdot 45 = 360$.
- Standaardafwijking $\sqrt{n} \cdot \sigma = \sqrt{8} \cdot 10 \approx 28.2843$.

De z-score behorende bij $x = 390$ ($6\frac{1}{2}$ uur = 390 minuten) met deze normale verdeling is gelijk aan

$$z = \frac{x - n \cdot \mu}{\sqrt{n} \cdot \sigma} = \frac{390 - 360}{28.2843} \approx 1.06.$$

De kans dat acht bezoeken meer dan $6\frac{1}{2}$ uur vergen is dan gelijk aan

$$P\left(\sum_{i=1}^{8} X_i > 390\right) = P(Z \geq 1.06 \ldots) = \text{normalcdf}(a = 1.06 \ldots, b = 10^{99}, \mu = 0, \sigma = 1) \approx 0.1444.$$

Buijs: opgave 5.12

De tijd die een vertegenwoordiger nodig heft voor het bezoeken van een klant wordt weergegeven door de kansvariabele X. Op grond van ervaring is bekend dat X normaal verdeeld is met $\mu = 45$ minuten en $\sigma = 10$ minuten (in de tijdsduur X is ook de reistijd opgenomen). De tijdsduren van bezoeken zijn onderling onafhankelijk.

c) De vertegenwoordiger moet op zekere dag tien klanten bezoeken. Hoeveel tijd T moet hij reserveren om met 95% kans de tien bezoeken binnen de tijdsduur T te kunnen afhandelen.

Binnen hoeveel tijd T zijn met 95% kans de tien bezoeken afgehandeld?

De kansvariabele X_i meet de bezoektijd aan klant i, waarbij $i = 1, 2, \ldots, 10$.

Centrale limietstelling: de som $\sum_{i=1}^{10} X_i = X_1 + X_2 + \cdots + X_{10}$ is normaal verdeeld is met:

- Gemiddelde $n \cdot \mu = 10 \cdot 45 = 450$.
- Standaardafwijking $\sqrt{n} \cdot \sigma = \sqrt{10} \cdot 10 \approx 31.6228$.

We willen nu de grens T berekenen waarvoor geldt $P\left(\sum_{i=1}^{10} X_i \leq T\right) = 0.95$.
De bijbehorende z-score waarvoor geldt $P(Z \leq z) = 0.95$ vinden we als volgt:

$$z = \mathrm{InvNorm}(\mathrm{area} = 0.95, \mu = 0, \sigma = 1) \approx 1.6449.$$

De tijdsduur T vinden we door om te rekenen naar de originele verdeling $N(450, 31.6228)$ van $\sum_{i=1}^{10} X_i$:

$$T = \mu + z \cdot \sigma = 450 + 1.6449 \cdot 31.2668 \approx 502.0148.$$

De vertegenwoordiger moet meer dan 8 uur en 22 minuten reserveren om de tien bezoeken met 95% kans binnen de tijd af te kunnen handelen.

Verschil tussen twee kansvariabelen

Een militaire eenheid wil evalueren of een nieuw noodprotocol leidt tot een snellere respons in crisissituaties, zoals natuurrampen of terroristische dreigingen.

X_A: reactietijd van crisis response teams volgens het bestaande protocol (in minuten)

X_B: reactietijd van crisis response teams volgens het nieuwe protocol (in minuten)

Stel nu dat we weten dat $X_A \sim N(\mu_A = 50, \sigma_A = 5)$ en $X_B \sim N(\mu_B = 47, \sigma_B = 2)$

Welke uitspraken kunnen we doen over welk protocol het meest efficient is?

Verschil tussen twee kansvariabelen

Er geldt dat $X_A \sim N(\mu_A = 50, \sigma_A = 5)$ en $X_B \sim N(\mu_B = 47, \sigma_B = 2)$

We bekijken de **verschilvariabele** $V = X_A - X_B$, waarvoor geldt:

- Kansverdeling: V is ook normaal verdeeld
- Gemiddelde: $\mu_V = \mu_A - \mu_B = 50 - 47 = 3$
- Standaardafwijking: $\sigma_V = \sqrt{\sigma_A^2 + \sigma_B^2} = \sqrt{5^2 + 2^2} = \sqrt{29}$

Wat kunnen we met de uitkomst van de variabele V?

- $V < 0$: het oude protocol is efficiënter dan het nieuwe protocol
- $V > 0$: het nieuwe protocol is efficiënter dan het oude protocol
- $V = 0$: beide protocollen zijn even efficiënt

Verschil tussen twee kansvariabelen

De verschilvariabele $V = X_A - X_B$ is normaal verdeeld met $\mu_V = 3$ en $\sigma_V = \sqrt{29}$.

Wat is de kans dat het nieuwe protocol efficiënter is dan het oude protocol?

We willen dus de kans $P(V > 0)$ bepalen. De bijbehorende z-waarde van $x = 0$ gelijk aan

$$z = \frac{x - \mu_V}{\sigma_V} = \frac{0 - 3}{\sqrt{29}} \approx -0.5571.$$

En de kans $P(V > 0)$ is gelijk aan:

$$P(V > 0) = P(Z > -0.5571) = \text{normalcdf}(a = -0.5571, b = 10^{99}, \mu = 0, \sigma = 1) \approx 0{,}7113$$

Met 71.13% kans is het nieuwe protocol efficiënter dan het oude protocol.

Verschil tussen twee kansvariabelen

Door verbeterde communicatietraining kan de gemiddelde reactietijd voor het nieuwe protocol nog verder worden verminderd. Hoe groot moet de gemiddelde reactietijd maximaal zijn zodat het nieuwe protocol met 95% kans efficiënter is dan het oude protocol?

In dit geval is de verschilvariabele $V = X_A - X_B$ normaal verdeeld met:

- Gemiddelde $\mu_V = \mu_A - \mu_B = 50 - \mu_B$
- Standaardafwijking $\sigma_V = \sqrt{\sigma_A^2 + \sigma_B^2} = \sqrt{5^2 + 2^2} = \sqrt{29}$.

We willen de waarde voor μ_B bepalen dusdanig dat $P(V > 0) = 0.95$. De z-waarde waarvoor geldt dat $P(Z > z) = 0.95$ is gelijk aan $z = \mathrm{InvNorm}(1 - p = 0.05, \mu = 0, \sigma = 1) \approx -1.6449$.

Terugrekenen naar de normale verdeling van de verschilvariabele V geeft:

$$0 = \mu_V + z \cdot \sigma_V \rightarrow 0 = (50 - \mu_B) - 1.6449 \cdot \sqrt{29} \rightarrow \mu_B \approx 41.1422$$

De gemiddelde reactietijd van het nieuwe protocol mag maximaal iets meer dan 41 minuten zijn.

Samenvatting

Waarom is de centrale limietstelling (CLS) zo krachtig?

- Kansverdeling van sommen/gemiddelden bepalen is zeer complex
  - Vereist het doorrekenen van n-voudige integralen …
  - De centrale limietstelling biedt in veel gevallen een goede benadering
- De centrale limietstelling brengt orde in de chaos
  - Chaos: verschillende kansvariabelen volgen allerlei verschillende kansverdelingen
  - Orde: **gemiddeld** volgen alle kansvariabelen hetzelfde voorspelbare patroon (normale verdeling)
- De meeste statistische methoden leunen op de schouders van de CLS
  - Betrouwbaarheidsintervallen, hypothesetoetsen, voorspellingen op basis van data (Statistiek 2)

Volgende week

- De Poissonverdeling

Huiswerk:

- Lezen van A. Buijs: hoofdstuk 5.3 (blz. 180-183), 5.4.3 (blz. 188-189), 5.5 (blz. 190-193)
- Opdrachten uit "*Statistiek om mee te werken: opgaven en uitwerkingen*":
  - H5: 5.10, 5.12